

iPAS AI 應用規劃師 中級應考教科書

第一冊 | 科目一 人工智慧技術應用與規劃

依 iPAS 官方考綱條目順序整理・L211／L212／L213

114-2+115-1 官方公告試題（全套 300 題）逐題解析・考點表格化



L211 AI 相關技術應用

L212 AI 導入評估規劃

L213 AI 技術應用與系統部署

網站【唐門企鵝】:DonmenKir.com

v3・2026

Email:donmenkir@gmail.com

iPAS AI 應用規劃師中級・應考教科書

全三冊・第一冊 | 科目一 人工智慧技術應用與規劃 (L211/L212/L213)

版次：第三版 (v3)・2026 年
作者：唐門企鵝 (DonmenKir)
網站：DonmenKir.com

來源與著作權標示

本套教材為個人應考整理，內容混合多種來源，各段落著作權狀態分類如下：(一) **iPAS 官方公告試題**（散見全書【中級真題與解析】區塊，題號格式如 [114-2-1-Q01]）節錄自經濟部產業發展署 iPAS 官網公告之歷屆試題，僅作考點解析引用；本教材主張其依著作權法第 9 條第 1 項第 5 款、依法令舉行之各類考試試題不得為著作權之標的，縱認 iPAS 能力鑑定（法源為產業創新條例第 18 條）非屬該款之考試而試題仍受保護，該等試題亦由主辦機關於官網免費公開，另依第 52、65 條主張合理使用；附圖題所嵌官方原卷圖同屬第 9 條排除項；(二) **政府文件原文摘要**（含台灣人工智慧基本法、行政院使用生成式 AI 參考指引、各產業 AI 導入／運用指引等），依著作權法第 9 條第 1 項第 1 款及第 2 項，法律、命令、公文不得為著作權之標的；(三) **個人歸納框架與分類整理**（跨章元規則、判別表、比較表、逐題選項解析、口訣與延伸補充等），為個人應考整理或 AI 輔助生成內容；(四) **第三方素材改寫**，基底參考多份公開 iPAS 中級備考素材與公開課程／文章，均經個人重新組織、改寫、整合，並經開源相似度查核與接觸來源比對複查。

※ 本書免費公開、無廣告、不單獨販售，非以營利為目的，依著作權法第 52 條（合理使用引用）及第 65 條（合理使用判斷基準）整理。如涉及侵權，請來信 donmenkir@gmail.com 告知，將立即修正或下架。

授權條款

本書由作者編寫之內容（歸納框架、判別表、比較表、逐題選項解析、口訣與延伸補充等）採用 **創用 CC 姓名標示-非商業性-相同方式分享 4.0 國際 (CC BY-NC-SA 4.0)** 授權。您可以自由分享與改作（重製、散布、修改、再混搭本著作），惟須遵守下列條件：**姓名標示**（須標明作者唐門企鵝與來源）、**非商業性**（不得將本著作用於商業目的）、**相同方式分享**（若修改或改作本著作，須以相同授權條款釋出）。iPAS 官方公告試題與政府文件依著作權法第 9 條不得為著作權之標的，不在本授權範圍內。完整授權條款見 creativecommons.org/licenses/by-nc-sa/4.0。

※ 機構、課程或任何營利性（含補習班收費課程）使用，請來信 donmenkir@gmail.com 取得授權。

免責聲明

本書為依 iPAS「AI 應用規劃師」中級官方考綱自編整理之應考參考教材，內容力求正確，惟若與 iPAS 官方最新公告之考綱、簡章、學習指引或政府文件有出入，**一律以官方版本為準**。官方公告答案有技術爭議之題目，本書照官方答案標示並另附「官方答案與技術爭議註記」。本書為輔助學習之用，如發現任何錯誤或疏漏，歡迎來信指正，作者將持續修訂改進。

編製說明

本套教材完全依 iPAS 官方中級考綱結構（科目 → 評鑑主題 → 評鑑內容）組織，全套三冊：第一冊科目一 L21 人工智慧技術應用與規劃 (L211~L213)、第二冊科目二 L22 大數據處理分析與應用 (L221~L224)、第三冊科目三 L23 機器學習技術與應用 (L231~L234)，共 11 個評鑑主題、34 項評鑑內容；第三冊末並收錄跨科目附錄（交叉引用表、易混淆對比集、名詞索引、考前總複習）。歷屆官方公告試題含 114 年第二梯次與 115 年第一次共 300 題，以【中級真題與解析】區塊散見各節，均附 4 選項詳細解析；附圖題嵌用官方原卷圖。本冊為第一冊（科目一 人工智慧技術應用與規劃）。

Contents

iPAS AI 應用規劃師（中級）第一冊 科目一 人工智慧技術應用與規劃	1
前言與考試概覽	2
1. 考試結構	2
2. 與初級的銜接	2
3. 應試策略	2
4. 本檔使用方式	2
5. 核心縮寫快查表（首見三件套統一索引）	2
6. 科目編碼（L-code）對照速查表	3
科目一 L21 人工智慧技術應用與規劃	7
L211 AI 相關技術應用	7
L21101 自然語言處理技術與應用	7
L21102 電腦視覺技術與應用	26
L21103 生成式 AI 技術與應用	37
L21104 多模態人工智慧應用	53
L212 AI 導入評估規劃	69
L21201 AI 導入評估	69
L21202 AI 導入規劃	78
L21203 AI 風險管理	87
L213 AI 技術應用與系統部署	100
L21301 數據準備與模型選擇	100
L21302 AI 技術系統集成與部署	121
考綱編碼索引	142

iPAS AI 應用規劃師（中級）第一冊 | 科目一 人工智慧技術應用與規劃

編寫基準：依官方三科考綱編排（中級 L21 + L22 + L23，共 3 科目 / 11 評鑑主題 / 34 項評鑑內容）。

- 科目一：人工智慧技術應用與規劃
- 科目二：大數據處理分析與應用
- 科目三：機器學習技術與應用

官方試題：書中引用之公告試題題幹屬 iPAS 主辦單位（經濟部產業發展署）公告內容，本教材主張依著作權法第 9 條第 1 項第 5 款不受著作權保護；縱認 iPAS 能力鑑定（法源為產業創新條例第 18 條）非屬該款所指之考試，該等試題亦屬官方官網免費公開，本教材僅為考點解析之用並附原創解析，另依第 52、65 條合理使用。含 **114 年第二梯次**（三科各 50 題）與 **115 年第一次**（三科各 50 題）共 **300 題**，均附 4 選項詳細解析；附圖題嵌用官方原卷圖（真題附圖/，同屬第 9 條排除項）。

編製日期：2026-07-16（v7）。版本沿革：

- **v7**（2026-07-14 起）：接觸來源比對修訂 13 項（詳見《20260714_v6 至 v7 修訂差異》）；2026-07-16 補正式版權聲明區塊、114-2 真題 17 題嵌入官方附圖並校正 3 題答案錯位、**併入 115 年第一次真題 150 題**（真題 150→300 題）、全書 QA 修正（含 114-2-3-Q34 依官方答案更正並加爭議註記）。
- 前版 v6（2026-07-14）：全書開源相似度查核修訂——12 項敘事案例改以公開可查證來源替換／7 項事實與標註修正（詳見《20260714_v5 附圖版權與開源相似度查核報告》與《20260714_v5 至 v6 修訂差異》）；v5（2026-07-02）為三軌複查修訂版。

編排方式：依評鑑代碼（L-code）章節重整／考點表格化／跨科交叉引用／易混淆對比集／名詞索引三件套／延伸補充

延伸閱讀：《iPAS AI 應用規劃師初級考綱教科書（含政府指引版）》（DonmenKir.com）

前言與考試概覽

1. 考試結構

中級考試含三科目（L21 / L22 / L23），合計：

- 3 科目、11 評鑑主題、34 項評鑑內容
- 較初級多出 18 項評鑑內容（初級 16 項 → 中級 34 項，量級 +112%）
- 主要新增領域：機率統計、線性代數、數值優化、深度學習數學、模型部署、ML 治理（偏見與公平性）

科目	名稱	評鑑主題	評鑑內容	重點知識領域
L21	人工智慧技術應用與規劃	3 個	9 項	NLP/CV/生成式 AI/多模態/導入評估/風險管理/系統部署
L22	大數據處理分析與應用	4 個	13 項	機率統計/資料儲存/ETL/SQL/NoSQL/視覺化/大數據與 AI
L23	機器學習技術與應用	4 個	12 項	ML 數學/ML/DL 演算法/建模/訓練評估/ML 治理

2. 與初級的銜接

主題層	初級對應	中級延伸方向
AI 基礎	L111 概念	L21 進階技術應用（NLP/CV/生成式/多模態深度技術）
資料	L112 基本概念	L22 統計推論/大數據工程/視覺化/隱私技術
機器學習	L113 概念	L23 數學基礎/演算法深度/訓練評估/治理
生成式 AI	L114 鑑別/生成 + L12 應用規劃	分散至 L21103/L22403（中級不再為獨立科目）
應用規劃	L12 No-Code/工具/導入	L212/L213 進階導入與部署

3. 應試策略

- L21（應用題佔比高）：聚焦各技術領域情境判斷與選型決策（不只名詞）
- L22（公式與計算題佔比高）：機率統計部分熟悉公式 + 計算範例；資料工程部分熟悉技術選型表
- L23（最廣最深）：演算法分類 + 評估指標公式 + 訓練流程 + 治理（偏見與隱私）

4. 本檔使用方式

- 按 L 代碼章節依序學習，每章末有【考點】／【陷阱】／【口訣】／【判別表】標記輔助複習
- 跨章節主題用 → 見 L[xxxxx] 標記，可至 附錄一 | 跨科目交叉引用表（見第三冊）看完整對照
- 名詞首次出現含「縮寫（全名，中譯）」三件套，可至 附錄三 | 名詞索引（三件套）（見第三冊）查名詞索引

5. 核心縮寫快查表（首見三件套統一索引）

主檔內 Top 38 最常見縮寫的「縮寫（英文全名，中文翻譯）」完整對照。本表作為前言索引；個別章節的詳細展開仍見 附錄三 | 名詞索引（三件套）（見第三冊）（358 條目完整版）。

縮寫	英文全名	中文翻譯	領域
AI	Artificial Intelligence	人工智慧	總稱
AGI	Artificial General Intelligence	通用人工智慧	總稱
ML	Machine Learning	機器學習	總稱
DL	Deep Learning	深度學習	總稱
NLP	Natural Language Processing	自然語言處理	L21101 自然語言處理技術與應用
NLU	Natural Language Understanding	自然語言理解	L21101 自然語言處理技術與應用
NLG	Natural Language Generation	自然語言生成	L21101 自然語言處理技術與應用
CV	Computer Vision	電腦視覺	L21102 電腦視覺技術與應用
CNN	Convolutional Neural Network	卷積神經網路	L21102 電腦視覺技術與應用
RNN	Recurrent Neural Network	遞迴神經網路	L23203 深度學習原理與框架

縮寫	英文全名	中文翻譯	領域
LSTM	Long Short-Term Memory	長短期記憶網路	L23203 深度學習原理與框架
GRU	Gated Recurrent Unit	閘控循環單元	L23203 深度學習原理與框架
Transformer	Transformer (Attention is All You Need)	變換器架構	L21101 自然語言處理技術與應用
BERT	Bidirectional Encoder Representations from Transformers	雙向編碼器表徵	L21101 自然語言處理技術與應用
GPT	Generative Pre-trained Transformer	生成式預訓練 Transformer	L21101 自然語言處理技術與應用
GAN	Generative Adversarial Network	生成對抗網路	L21103 生成式 AI 技術與應用
VAE	Variational Autoencoder	變分自編碼器	L21103 生成式 AI 技術與應用
RAG	Retrieval-Augmented Generation	檢索增強生成	L21101 自然語言處理技術與應用
LoRA	Low-Rank Adaptation	低秩自適應	L23304 模型調整與優化
CLIP	Contrastive Language-Image Pre-training	對比式語言—影像預訓練	L21104 多模態人工智慧應用
ETL	Extract-Transform-Load	擷取-轉換-載入	L22202 數據儲存與管理
ELT	Extract-Load-Transform	擷取-載入-轉換	L22202 數據儲存與管理
SQL	Structured Query Language	結構化查詢語言	L22202 數據儲存與管理
NoSQL	Not Only SQL	非關聯式資料庫	L22202 數據儲存與管理
ACID	Atomicity, Consistency, Isolation, Durability	原子性、一致性、隔離性、持久性	L22202 數據儲存與管理
CAP	Consistency, Availability, Partition tolerance	一致性、可用性、分區容錯	L22202 數據儲存與管理
SMOTE	Synthetic Minority Over-sampling Technique	合成少數類過採樣	L23301 數據準備與特徵工程
PCA	Principal Component Analysis	主成分分析	L23202 常見機器學習演算法
LDA	Linear Discriminant Analysis	線性判別分析	L23202 常見機器學習演算法
F1	F1 Score	F1 分數	L23303 模型訓練、評估與驗證
AUC	Area Under Curve	曲線下面積	L23303 模型訓練、評估與驗證
ROC	Receiver Operating Characteristic	接收者操作特徵曲線	L23303 模型訓練、評估與驗證
Adam	Adaptive Moment Estimation	適應性動量估計	L23103 數值優化技術與方法
GDPR	General Data Protection Regulation	歐盟通用資料保護規則	L21203 AI 風險管理
PDPA	Personal Data Protection Act	個人資料保護法（台灣）	L21203 AI 風險管理
HITL	Human-in-the-Loop	人在迴圈中	L21203 AI 風險管理
XAI	Explainable AI	可解釋 AI	L21203 AI 風險管理
MLOps	Machine Learning Operations	機器學習維運	L21302 AI 技術系統集成與部署

使用提示：表格內縮寫在主檔個別 L 章節首次出現時，仍會展開完整三件套；本表作為「跨章節速查」用途，避免讀者中途遇到縮寫需翻附錄三全表。

6. 科目編碼（L-code）對照速查表

全書依官方評鑑代碼（L-code）編排。代碼分三層：2 碼＝科目、3 碼＝評鑑主題、5 碼＝評鑑內容。讀者於內文遇到代碼時，可回查本表對照名稱（代碼只是定位用的編號，名稱才是重點）。

科目（2 碼）

代碼	名稱
L21	人工智慧技術應用與規劃
L22	大數據處理分析與應用
L23	機器學習技術與應用

科目一 L21（評鑑主題 3 碼／評鑑內容 5 碼）

代碼	名稱
L211	AI 相關技術應用
L21101	自然語言處理技術與應用
L21102	電腦視覺技術與應用
L21103	生成式 AI 技術與應用
L21104	多模態人工智慧應用
L212	AI 導入評估規劃
L21201	AI 導入評估
L21202	AI 導入規劃
L21203	AI 風險管理
L213	AI 技術應用與系統部署
L21301	數據準備與模型選擇
L21302	AI 技術系統集成與部署

科目二 L22

代碼	名稱
L221	機率統計基礎
L22101	敘述性統計與資料摘要技術
L22102	機率分佈與資料分佈模型
L22103	假設檢定與統計推論
L222	大數據處理技術
L22201	數據收集與清理
L22202	數據儲存與管理
L22203	數據處理技術與工具
L223	大數據分析方法與工具
L22301	統計學在大數據中的應用
L22302	常見的大數據分析方法
L22303	數據可視化工具
L224	大數據在人工智慧之應用
L22401	大數據與機器學習
L22402	大數據在鑑別式 AI 中的應用
L22403	大數據在生成式 AI 中的應用
L22404	大數據隱私保護、安全與合規

科目三 L23

代碼	名稱
L231	機器學習基礎數學
L23101	機率／統計之機器學習基礎應用
L23102	線性代數之機器學習基礎應用
L23103	數值優化技術與方法
L232	機器學習與深度學習
L23201	機器學習原理與技術

代碼	名稱
L23202	常見機器學習演算法
L23203	深度學習原理與框架
L233	機器學習建模與參數調校
L23301	數據準備與特徵工程
L23302	模型選擇與架構設計
L23303	模型訓練、評估與驗證
L23304	模型調整與優化
L234	機器學習治理
L23401	數據隱私、安全與合規
L23402	演算法偏見與公平性

科目一（第一冊）

人工智慧技術應用與規劃

•	L211 AI 相關技術應用	7
	L21101 自然語言處理技術與應用	7
	L21102 電腦視覺技術與應用	26
	L21103 生成式 AI 技術與應用	37
	L21104 多模態人工智慧應用	53
•	L212 AI 導入評估規劃	69
	L21201 AI 導入評估	69
	L21202 AI 導入規劃	78
	L21203 AI 風險管理	87
•	L213 AI 技術應用與系統部署	100
	L21301 數據準備與模型選擇	100
	L21302 AI 技術系統集成與部署	121

科目一 | L21 人工智慧技術應用與規劃

L211 AI 相關技術應用

本評鑑主題涵蓋人工智慧 (AI) 四大子領域的核心技術與實務應用：自然語言處理 (NLP)、電腦視覺 (CV)、生成式 AI (GenAI)，以及多模態 AI (Multimodal AI)。學習重點為理解各技術之原理脈絡、典型模型、評估指標、應用情境與風險治理。

L21101 自然語言處理技術與應用

※ 考綱重點 (L21101 自然語言處理技術與應用)：自然語言處理技術原理 (理解／處理／生成三層任務)、典型模型 (RNN／LSTM／Transformer／BERT／GPT 等)、評估指標、實際應用場域 (情緒分析、翻譯、問答、摘要等)

NLP 概念與三層任務架構

NLP (Natural Language Processing, 自然語言處理) 是讓電腦能「理解、處理並產生」人類語言的 AI 核心技術，是人機溝通、自動化知識擷取與語言智慧創作的關鍵基礎。

NLP 三層任務架構：

任務層次	英文	工作內容	例子
理解	Understand	解析語法、辨識意圖、判讀情緒	「我想退貨」→ 退貨意圖
處理	Process	將語言轉為機器可運算的結構 (特徵向量、語法樹、標注格式)	句子 → 向量
生成	Generate	根據情境產出自然、流暢且具邏輯的文字或語音	自動回覆、摘要撰寫

NLP / NLU / NLG 三者關係：

概念	角色定位	範疇	常見任務
NLP (Natural Language Processing, 自然語言處理)	總稱	整合所有讓機器能理解、處理、產生語言的技術	對話系統、機器翻譯、語音助理
NLU (Natural Language Understanding, 自然語言理解)	「理解」階段	分析輸入語言之語意與結構，判讀使用者意圖	意圖辨識、NER (Named Entity Recognition, 命名實體辨識)、情感分析
NLG (Natural Language Generation, 自然語言生成)	「生成」階段	將資料或語意轉換為自然語言文字進行表達	自動摘要、回應生成、報告撰寫

【判別表】 客服「我想退貨」流程：

階段	子任務	屬於
解析意圖	從句子推斷退貨意圖	NLU
觸發後端	系統執行退貨流程	業務邏輯
自動回覆	「請提供您的訂單編號」	NLG
整段流程	對話系統	NLP

【陷阱】 NLU、NLG 為 NLP 的兩個子任務，不可說「NLU = NLP」或「NLG 不屬 NLP」。

NLP 技術演進四世代

世代	時期	技術階段	核心特徵	代表技術/模型
第一代	1980s-1990s	規則式方法 (Rule-based)	手動設計語法規則與詞彙辭典	ELIZA (ELIZA 為 1966 年作品、屬規則式早期代表)、專家系統
第二代	1990s-2010	統計語言模型 (Statistical LM)	用大量語料訓練機率模型	N-gram、HMM (Hidden Markov Model, 隱馬可夫模型)、CRF (Conditional Random Field, 條件隨機場)
第三代	2010-2018	深度學習模型 (Deep Learning)	用神經網路處理語言序列	RNN、LSTM、GRU

世代	時期	技術階段	核心特徵	代表技術/模型
第四代	2018-至今	預訓練語言模型（Pre-trained LM）	大規模語料預訓練＋下游微調	BERT、GPT、RoBERTa、T5

【口訣】「規則→統計→序列→預訓練」（四代演進依序記）。

四世代核心差異對比：

維度	規則式	統計式	深度學習	預訓練 LM
是否需手工特徵	是	部分	否	否
可解釋性	高	中	低	低
長距離依賴	差	差	中（LSTM 改善）	強（Self-Attention）
訓練資料需求	少	大	大	極大
算力需求	低	中	高	極高
泛化能力	差	中	良	優

【考點】2017 年 Google 提出 Transformer 架構，引入自注意力機制（Self-Attention），徹底改變 NLP 發展路徑，使模型可平行運算並建模全局語境，是預訓練語言模型崛起的關鍵。

→ 模型訓練與評估方法 見 L23303 模型訓練、評估與驗證（見第三冊）；深度學習基礎架構 見 L23203 深度學習原理與框架（見第三冊）

NLP 前處理技術

自然語言資料具非結構化性、語意模糊與語境多變特性，前處理品質直接決定模型成效。

處理步驟	英文	說明	常見工具/技巧
分詞	Tokenization	將文字拆解為單字、詞組或子詞	基於空白、斷詞字典、BPE（Byte Pair Encoding）
詞性標注	POS Tagging	標記每個詞的語法角色（名詞/動詞/形容詞等）	常用於語法分析、NER
詞形還原	Lemmatization	將單詞還原為字典形式（running → run）	保留語意一致性
詞幹提取	Stemming	去除詞尾變化取得詞幹（connections → connect）	處理速度快，準確性低於 Lemmatization
停用詞移除	Stopword Removal	去除 is/the/at 等語意貢獻低的高頻詞	降低資料維度、提升關鍵詞比重

【易混淆對比】Lemmatization vs Stemming：

維度	詞形還原（Lemmatization）	詞幹提取（Stemming）
依據	語法規則＋字典	字首字尾裁剪規則
範例	running → run；better → good	running → run；happiness → happi
結果有效性	一定為有效單字	不一定為有效單字
語意正確性	保留	可能損失
速度	較慢	快

【陷阱】中文、日文等無空白語言的分詞需斷詞字典或模型輔助。錯誤分詞（「自然語言處理」誤切為「自然」「語言」「處理」）會嚴重影響下游任務。

【陷阱】停用詞移除並非萬用：在分類/檢索任務可降維提升效能；但在對話生成、語法分析等任務中，去掉「我」「在」可能破壞語意完整性。

文字表示與詞嵌入

詞彙向量化（Word Vectorization）／文字表示學習（Representation Learning）將語言轉為數字，使機器可運算。

表示類型	技術代表	分布特性	語境特性	優點	限制
純離散表示	One-hot、BoW	非分布式	非語境型	簡單、易實作	向量稀疏、無語意、維度高

表示類型	技術代表	分布特性	語境特性	優點	限制
統計型表示	TF-IDF	非分布式	非語境型	能反映詞彙重要性	忽略上下文與語序
統計共現表示	N-grams	有限分布性	上下文敏感（短範圍）	可表示語序與詞組共現	長句效果差、資料稀疏
靜態詞嵌入	Word2Vec、GloVe、FastText	分布式	非語境型	可表示語意、向量可運算	每詞固定向量、忽略上下文
語境型詞嵌入	ELMo、BERT、GPT	分布式	動態語境型	語意精準、處理多義詞佳	模型大、算力需求高

【判別表】三個核心概念：

概念	定義	範例對比
語境型 vs 非語境型	詞向量是否隨上下文變化	BERT「bank」依語境變；Word2Vec「bank」固定
分布式 vs 非分布式	詞義是否由鄰近詞共現學得	Word2Vec 為分布式（dog、cat 接近）；One-hot 為非分布式
詞嵌入（Word Embedding）	將詞彙轉為含語意的數值向量	語意相近詞於向量空間中接近

核心技術逐項：

技術	全名	機制	優點	限制
One-hot Encoding	—	高維稀疏向量、唯一位置為 1	簡單	維度高、無語意
BoW	Bag of Words	忽略詞序、計算詞頻	簡單	丟失順序與語意
TF-IDF	Term Frequency-Inverse Document Frequency	詞頻 × 逆文件頻率	反映詞彙重要性	忽略上下文
N-grams	—	保留連續 N 個詞	短期語序保留	N 大時維度膨脹
Word2Vec	—	CBOW/Skip-gram 神經網路	語意推理（king-man+woman≈queen）	每詞固定向量
GloVe	Global Vectors for Word Representation	全局共現矩陣分解（Stanford 2014）	全局統計資訊	靜態
FastText	—	n-gram 子詞集合（FAIR 2016）	可處理 OOV、形態豐富語言佳	仍為靜態
ELMo	Embeddings from Language Models	雙向 LSTM（AllenNLP 2018）	語境敏感	序列式較慢
BERT	Bidirectional Encoder Representations from Transformers	雙向 Transformer Encoder（Google 2018，MLM + NSP）	理解類任務佳	不擅生成
GPT	Generative Pre-trained Transformer	自迴歸單向 Transformer Decoder（OpenAI）	生成類任務佳	僅看前文

【公式】TF-IDF：

- 詞頻： $TF(t, d) = \frac{\text{詞 } t \text{ 在文檔 } d \text{ 中的出現次數}}{\text{文檔 } d \text{ 的總詞數}}$
- 逆文件頻率： $IDF(t, D) = \log\left(\frac{|D|}{|\{d \in D: t \in d\}|}\right)$
- 綜合分數： $tf-idf(t, d, D) = TF(t, d) \times IDF(t, D)$

【考點】TF-IDF 計算範例（語料庫 1000 篇、詞「AI」出現於 10 篇、某文件總詞數 100、「AI」出現 3 次）：

步驟	計算	結果
TF	3 / 100	0.03
IDF	$\log(1000 / 10) = \log(100)$	2
tf-idf	0.03×2	0.06

【陷阱】 $\log(100) = 2$ （以 10 為底），不是約等於 2。考題若給「 ≈ 2 」屬不嚴謹寫法。

Word2Vec 兩種架構：

架構	全名	預測目標	適用情境
CBOW	Continuous Bag of Words	用上下文預測中心詞	訓練速度快、適合小型語料
Skip-gram	—	用中心詞預測上下文	對低頻詞更有效、語意捕捉佳

【口訣】 Word2Vec 經典類比 king - man + woman $\approx$ queen，展示語意推理能力。

【易混淆對比】 BERT vs GPT：

維度	BERT	GPT
架構	雙向 Transformer Encoder	單向 Transformer Decoder
預訓練任務	MLM (Masked Language Model，遮蔽語言模型) + NSP (Next Sentence Prediction)	自迴歸語言建模
擅長任務	理解類 (分類、問答、NER)	生成類 (對話、摘要、創作)
上下文	同時看前後文	僅看前文

Transformer 與自注意力機制

2017 年 Google 提出 Transformer 架構，是 NLP 進入預訓練時代的關鍵分水嶺。

核心三大創新：

創新	英文	機制	解決問題
自注意力機制	Self-Attention	處理每個詞時自動學習其與所有詞的關聯權重	RNN 難捕捉的長距離依賴 (Long-Range Dependencies)
Encoder-Decoder 架構	—	Encoder 編碼語意、Decoder 逐步輸出	適用 Seq2Seq (機器翻譯、摘要)
全平行架構	Fully Parallel Architecture	一次計算整段序列注意力分數	摒棄 RNN 逐步處理，適合 GPU/TPU

範例：The cat that was chased by the dog ran away. Self-Attention 能正確關聯 cat 與 ran，即使中間隔多詞。

【考點】 Transformer 解決了 RNN/LSTM 的兩大瓶頸：(1) 長距離依賴；(2) 無法平行運算。這是預訓練大型語言模型可行的技術基礎。

→ 深度學習與 Transformer 原理 見 L23203 深度學習原理與框架 (見第三冊)

預訓練 + 微調與提示工程

「預訓練再微調 (Pre-train and Fine-tune)」是當前 NLP 主流策略。

Prompt-based Learning 三大模式：

模式	中文	訓練樣本需求	範例
Zero-shot Learning	零樣本學習	0 個示例	直接問「請將這封信分類為：1.會議 2.支援 3.履歷 4.推銷 5.其他」
Few-shot Learning	少樣本學習	少量 (如 3-5 個) 示例	提供 5 條已標註情感的評論作為示例
Fine-tuning	微調	大量標註資料	在領域資料集上完整再訓練

【判別表】 何時用哪種方法：

情境	推薦方法	理由
完全沒標註資料	Zero-shot + Prompt	利用通用模型語言理解能力
少量資料、需快速上線	Few-shot 或 LoRA	高效低成本
大量標註資料、追求穩定	Fine-tuning	效能最佳但成本最高
知識密集型問答	RAG (Retrieval-Augmented Generation)	結合外部知識庫提升準確性

進階強化技術對照：

技術	全名	機制	適用
RAG	Retrieval-Augmented Generation 檢索增強生成	先檢索外部知識再生成	時效性、領域知識、可追溯來源
LoRA	Low-Rank Adaptation，低秩自適應	加入輕量化低秩參數進行微調	資源有限、邊緣部署

【易混淆對比】 Fine-tuning vs RAG vs Prompt Engineering：

維度	Fine-tuning	RAG	Prompt Engineering
是否更改模型權重	是	否	否
是否需訓練資料	大量	不需	不需
知識更新速度	慢（需重訓）	快（替換檢索庫即可）	中（改 prompt）
適用	領域客製化	知識問答	任務切換

NLP 應用情境與實務案例

應用任務	英文	範例情境	關鍵挑戰
文字分類	Text Classification	垃圾郵件偵測、商品評論分類、客服請求分派	多語言與語境複雜性
情感分析	Sentiment Analysis	社群輿情監控、顧客滿意度調查	反諷、方言、俚語誤判
對話系統	Chatbot	任務導向（訂票/訂位）、開放式（ChatGPT）	長期對話一致性
文字生成與總結	Text Generation & Summarization	新聞摘要、廣告標題生成、報表自動化	事實性、語意一致性
機器翻譯	Machine Translation	商業文件翻譯、跨國客服支援	專業術語、語法差異
命名實體辨識	NER (Named Entity Recognition)	法律/醫療文書標註	領域實體歧義
關係抽取	Relation Extraction	知識圖譜建構	多步推理

用詞中性化對照表：

標準用詞	不再使用
使用者	客戶
回饋	反饋
回應	響應
合約	合同
營運	運營
個人化推薦	個性化推薦
併發	並發

NLP 技術挑戰與風險

資料層風險：

風險	說明	處理機制
資料隱私	客服對話、郵件、社群留言含個資	匿名化（Anonymization）/ 去識別化（De-identification）；符合 PDPA、GDPR
標註與品質	標註不一致、樣本偏斜、資料偏見（Data Bias）	多重標註、樣本平衡、資料增強
資料授權與版權	爬蟲、未授權訓練資料、生成內容侵權	確認資料授權、生成內容版權檢查

【判別表】 去識別化（De-identification）vs 匿名化（Anonymization）：

維度	去識別化	匿名化
可否反查還原	可（透過對應代碼）	不可（徹底切斷）
應用情境	研究、系統測試	開放資料、法規要求無可辨識性
常見方法	代碼替換（Pseudonymization）、資料抽象化、資料遮罩（Masking）	徹底刪除、隨機化（Randomization）、聚合處理（Aggregation）

【陷阱】 去識別化 ≠ 匿名化。考題常用「將姓名替換為代碼 ID」這類情境，屬「去識別化」（可反查），不可答匿名化。

模型層風險：

風險	範例	處理機制
模型偏見 (Model Bias)	履歷分類偏好男性管理階層	WEAT (Word Embedding Association Test) 檢測詞向量偏見、平衡訓練資料
公平性評估不足	對少數語言 (泰文、原住民族語) 表現差	多維度資料審查、人工覆核機制

應用層風險：

風險	範例	處理機制
語意理解限制	反諷「服務真讚」誤判正評；方言「很雷」誤解	結合語境型詞向量 (BERT、GPT) + 常識推理模組
部署與維運	Chatbot 推論慢、高併發無法即時回應	回饋機制、再訓練、版本控制、容錯與資源優化
生成內容風險	模型幻覺 (Model Hallucination)：流暢但事實錯誤；冒犯/不當語言	事實檢查機制、人工審核 (高風險領域)、使用前風險聲明

【考點】 模型幻覺 (Model Hallucination)：生成模型產生語法正確但事實虛假/虛構的內容，例如「法國的首都在柏林」。屬生成式 NLP 系統的關鍵風險，特別在醫療、法律、金融等高風險領域更需審核。

→ 資料隱私法規與合規 見 L23401 數據隱私、安全與合規（見第三冊）；演算法偏見與公平性 見 L23402 演算法偏見與公平性（見第三冊）

延伸補充：NLP 重點整理

以下為本章節考點的延伸整理，補充原理脈絡、易混淆對比與記憶訣竅。

考點

- **NLP (Natural Language Processing, 自然語言處理) 三層分工** (可用「一條訊息的旅程」記)：
 - NLP = 整條處理線的總包商
 - NLU (Natural Language Understanding, 自然語言理解) = 入口的判讀員 (負責輸入理解、意圖辨識)
 - NLG (Natural Language Generation, 自然語言生成) = 出口的撰稿員 (負責輸出生成)
- **四層定位法** (拿到任何 NLP 考題，先問「這題在哪一層」)：
 1. 語言任務層 (先確定目標是什麼)
 2. 前處理層 (把輸入清乾淨)
 3. 表示與模型層 (向量化 + 架構)
 4. 應用與評估層
- **NLP 四大子任務關鍵字：**
 - 意圖辨識 (Intent Recognition)：使用者「想做什麼」
 - NER (Named Entity Recognition, 命名實體辨識)：抽出「人名／地名／組織」
 - POS (Part-of-Speech tagging, 詞性標注)：判斷「名詞／動詞／形容詞」
 - 句法分析 (Syntactic Parsing)：分析句子結構與依存關係
- **文字前處理對比：**
 - Stemming (詞幹提取)：機械式裁切詞尾，速度快但結果不一定是合法單字 → 適合追求速度、容錯度高的大規模網頁索引
 - Lemmatization (詞型還原)：依詞性與字典規則還原成標準字根，結果一定合法 → 適合追求精準、不容誤解的正式文本分析
 - Stop Words (停用詞)：濾掉資訊量低的高頻詞 (the、的) → 適合分類、情感分析
 - N-grams (N 元語法)：把連續 N 個詞綁成一組 → 用來保留「機器學習」這類固定片語
- **詞向量演進史** (最常考的「靜態 vs 動態」分水嶺)：
 - One-hot：1/0 開關，看不出詞間關聯
 - BoW (Bag of Words, 詞袋模型)：丟袋子統計頻率

- ▶ TF-IDF (Term Frequency-Inverse Document Frequency, 詞頻—逆文件頻率)：降低常見詞權重，凸顯關鍵詞
- ▶ Word2Vec：用向量映射語意距離（局部窗口）；**靜態**
- ▶ GloVe (Global Vectors)：全局共現統計；**靜態**
- ▶ FastText：加入 subword (n-gram 子詞)，擅長拼錯詞/罕見詞；**靜態**
- ▶ ELMo (Embeddings from Language Models)：引入上下文，**動態**詞向量
- 模型架構演進：
 - ▶ RNN/LSTM：循序架構，逐一時間步處理，有梯度消失問題
 - ▶ Transformer：自注意力 (Self-Attention) 一次掃全句，可平行運算
 - ▶ BERT (Bidirectional Encoder Representations from Transformers)：雙向編碼架構，長於語意理解 (NLU)
 - ▶ GPT (Generative Pre-trained Transformer)：單向自回歸架構，長於文本生成 (NLG)
- 預訓練 (Pre-train) + 微調 (Fine-tune) + 遷移學習 (Transfer Learning) 三件套：通用大腦 + 客製化補習 + 舊知識遷移
- 語音任務：
 - ▶ ASR (Automatic Speech Recognition, 自動語音辨識)：音訊 → 文字
 - ▶ TTS (Text-to-Speech, 文字轉語音)：文字 → 音訊
 - ▶ WER (Word Error Rate, 字詞錯誤率)：評估 ASR，**越低越好**
 - ▶ MOS (Mean Opinion Score, 平均意見分數)：人類主觀評分，**越高越好**

陷阱

- 陷阱：問題問「不更動模型、成本最低、快速驗證」→ 選 Prompt Engineering (Zero/Few-shot)，不是 Fine-tune
- 陷阱：問題問「資料每天都在變動」(即時匯率、庫存) → Prompt 力不從心，要選 RAG
- 陷阱：BLEU vs ROUGE 一定要分清「翻譯 (BLEU 偏精確率)」vs「摘要 (ROUGE 偏召回率)」
- 陷阱：MOS 是「人類主觀」評分，不是電腦算出來的；WER 才是電腦算的客觀指標
- 陷阱：Word2Vec/GloVe 是**靜態**詞向量（同字不同句也一樣），ELMo 才是**動態**

補充比較表

Word2Vec vs GloVe vs FastText vs ELMo

維度	Word2Vec	GloVe	FastText	ELMo
學習方式	局部窗口、淺層神經網路	全局共現統計	子詞 n-gram	雙向 LSTM 語境化
動/靜態	靜態	靜態	靜態	動態
強項	語意相似度	全局統計	拼錯詞/罕見詞	上下文敏感

BERT vs GPT

維度	BERT	GPT
方向性	雙向 (看左右上下文)	單向 (從左到右)
核心能力	理解 (NLU)	生成 (NLG)
訓練目標	掩碼語言模型 (MLM)	自回歸 (Autoregressive)
記憶要訣	同時參照左右文 → 重「讀懂」	只看已寫出的前文 → 重「續寫」
適用	分類、NER、QA 抽取	文章生成、對話、摘要生成

生成參數 (Temperature / Top-P / Penalty)

參數	功能
Temperature	隨機性/創意程度 (高→發散)
Top-P	動態確定候選詞範圍
Frequency Penalty	抑制同一詞句反覆出現的重複輸出
Presence Penalty	鼓勵討論新主題

文字生成評估指標

指標	焦點	任務	偏向
BLEU (Bilingual Evaluation Understudy)	精確率	機器翻譯	字面重疊 N-gram
ROUGE (Recall-Oriented Understudy for Gisting Evaluation)	召回率	文本摘要	重點覆蓋率
METEOR	語義彈性 (含同義詞)	翻譯+摘要	兼顧語意
Human Eval	最終品質	所有生成任務	主觀真值

語音任務指標

任務	指標	性質	方向
ASR	WER	客觀	越低越好
TTS	MOS	人類主觀	越高越好 (1-5 分)

補充精華

- **NLP 五大核心應用場景：**
 1. 情緒分析 (Sentiment Analysis)：極性 (正/負/中性) + 主觀性 (事實 vs 意見)
 2. 機器翻譯 (Machine Translation)
 3. 問答系統 (QA)：提取式 vs 生成式
 4. 文本摘要 (Text Summarization)：提取式 vs 摘要式
 5. 資訊檢索 (Information Retrieval)：從大量文件中找出相關段落
- **電商客服 NLP 流程串接：**先用情緒分析篩出帶有「慢、卡頓」的負評 → 再讓 QA 機器人接手常見問題 → 接著用摘要把冗長抱怨濃縮 → 最後從知識庫檢索出對應解法。
- **分布假說 (Distributional Hypothesis)：**一個詞的意義，是由它「常常和哪些詞一起出現」決定的。換句話說，語境相近的詞，語意也相近——這正是所有詞嵌入技術的出發點。
- **機器翻譯架構演進的體感：**早期 RNN 翻長句容易前後文脫節；LSTM 雖改善品質卻處理得慢；到了 Transformer，因為可平行運算又能掌握全句關聯，速度與準確度才同步提升。
- **長文本中段被忽略的問題：**純靠向量相似度的 RAG，遇到很長的文件時容易漏掉夾在中間的重點 → 改用 GraphRAG／知識圖譜，替資訊建立結構性連結，就不會只憑相似度撈資料。
- **智慧客服兩段式管線：**意圖分類器 (微調後的 encoder 模型) 先判別客戶需求類型，再路由給生成模型產出回覆；分類器只需少量標註資料微調即可上線，是低成本落地的常見架構。
- **評論量化的直覺：**把每則評論轉成向量後攤在語意空間裡，正面詞 (超棒、令人驚艷、CP 值高) 會自然聚成一群，負面詞 (失望、糟糕、爛透了) 則落在很遠的另一區。

延伸補充：NLP 演進與架構速覽

考點

- NLP (Natural Language Processing, 自然語言處理) 的終極目標：從佔比極高的非結構化文字資料中挖掘可用價值。
- NLP 演進四階段：1980s 符號／規則 (規則式方法可上溯 1950s–60s, 如 1966 年的 ELIZA) → 1990s 統計 (N-grams) → 2010s 前後神經網路 (Word Embedding) → 2018 起預訓練生成時代 (Transformer / GPT / BERT)。
- Word Embedding (詞嵌入) 經典範例：King - Man + Woman $\approx$ Queen (向量算術可捕捉語意關係)。
- Transformer 的核心武器 = **Attention (注意力機制)**：在一整句裡，自動把注意力集中到真正相關的字上，不被無關字干擾。
- **RAG (Retrieval-Augmented Generation, 檢索增強生成)** 三步驟：檢索 → 增強 → 生成。可理解為「先查資料再作答」，對比傳統 LLM 「只憑記憶硬答」。
- AI 規劃師的定位：站在技術團隊與業務需求之間，把雙方語言對接起來的橋樑角色。

陷阱 / 風險

- **幻覺 (Hallucination)：**AI 把錯誤資訊講得很有自信，企業仍要負法律責任 (如後述航空公司客服案)。
- **演算法偏見：**訓練資料本身帶偏見，模型就會把刻板印象學進去並放大。
- **提示詞注入 (Prompt Injection)：**攻擊者用精心設計的輸入，誘導 AI 繞過安全限制。

- **資料隱私**：員工把公司機密貼進公開的對話式 AI → 等同把營業祕密外送。

補充比較表 — BERT vs GPT vs T5

維度	BERT（編碼器）	GPT（解碼器）	T5（編碼器-解碼器）
記憶定位	先把整段讀通的理解者	一路往下接話的續寫者	先讀懂再轉述的轉換者
閱讀方式	雙向（同時參照左右）	單向（看前文猜下字）	先編碼理解再解碼輸出
擅長任務	閱讀理解 / 抓重點 / 克漏字	寫作 / 對話 / 文字接龍	翻譯 / 摘要

補充精華 — 真實案例

- **航空業客服責任案例**：某航空業者的 AI 客服給出與實際規定不符的退費資訊，最終企業仍須對該錯誤承擔賠償責任（提醒：AI 的幻覺輸出一樣構成企業的法律責任，不能以「是機器講的」卸責）。
- **金融客服分流案例**：某客服 AI 上線後大幅分攤了原本由真人處理的對話量，在維持服務品質的前提下節省了可觀人力成本（提醒：自動化客服的價值在於分流而非完全取代，仍需保留真人接手異常情境的機制）。
- **台灣金融／銀行業 AI 導入比例偏高**：常見落地在智慧客服、文件審核與詐騙偵測。
- **零售業 AI 商品推薦助理**：顧客以自然語言描述使用情境與偏好，系統解析語意後比對商品屬性，回傳合適的候選商品清單。

延伸補充：文字分類演算法選型

考點

- NLP 任務的兩大型態：**分類**（判斷類別，如垃圾郵件／詐騙）+ **回歸**（預測連續數值，如氣溫／二手車價格）
- 文字分類常見首選 NB（Naive Bayes，**樸素貝氏**）：速度快、能應付高維稀疏特徵，與文字場景很合拍
- SVM（Support Vector Machine，**支援向量機**）的瓶頸不在特徵維度，而是樣本數過多時訓練會明顯變慢

補充比較表

演算法	文字分類適用性	主因
NB (Naive Bayes)	★★★★★ 經典首選	速度快、擅長高維資料
SVM	★★★ 偏慢	樣本數一多就吃力
k-NN	★ 不建議	高維度下計算量爆增
複迴歸	×	本質是「預測數值」而非分類

補充精華

白話拆解：

- **NB 的「條件獨立假設」**：以症狀推斷疾病為例，NB 把各項症狀（如「發燒」「咳嗽」）視為互不影響的獨立特徵來計算機率。雖然這些特徵在現實中常有關聯、使該假設在理論上並不嚴謹，但它在許多分類任務上仍有可觀準確度——關鍵在於這個簡化大幅降低運算量，讓模型能快速比較各類別的相對機率。
- **NB 為什麼夠用**：它不必算出精準的機率數值，只要能判斷「哪個類別的相對機率最高」就行；能把第一名挑對，分類任務就成功了。

【中級真題與解析（114 年第二梯次）】

本節對應 **10 題**官方真題（114 年第二梯次中級 AI 應用規劃師），每題含 4 選項詳細解析、核心考點、易混淆對比。

第 1 題（114-2-1-Q01）

題幹：某電商企業希望利用自然語言處理（NLP）技術，分析顧客在社群平台與商品評論中的文字內容，以即時掌握顧客對產品的滿意度變化。若採用情感分析（Sentiment Analysis）模型，其主要目的為何？

選項：

- (A) 預測顧客使用的語言風格與語氣
- (B) 判斷文本中所表達的情感傾向
- (C) 將顧客留言自動翻譯成企業內部指定語言
- (D) 產生顧客評論的自動化摘要內容

正確答案：B

詳細解析：

- ✓ (B) 正確：情感分析 (Sentiment Analysis，又稱意見挖掘 Opinion Mining) 核心任務是判斷文本所表達的情感傾向 (正面 / 中性 / 負面，或更細的多級情緒標籤)。常見於品牌口碑監控、客服情緒識別、社群輿情分析。技術實作可使用 lexicon-based (情感字典) 或 ML/DL 模型 (如 BERT fine-tune)。
- × (A) 錯誤：預測語言風格與語氣屬於風格分析 (Style Analysis) / 語體分析 (Stylometry)，常用於作者識別、文體分類，與情感極性判斷不同任務。
- × (C) 錯誤：自動翻譯屬於機器翻譯 (Machine Translation, MT)，使用 Seq2Seq、Transformer、NMT 模型實作，與情感分析是不同 NLP 子領域。
- × (D) 錯誤：產生摘要屬於自動摘要 (Text Summarization)，分抽取式 (Extractive) 與生成式 (Abstractive) 摘要兩類，與情感分析目標不同。

核心考點：情感分析的定義與 NLP 任務分類辨識。

易混淆對比：情感分析 (極性判斷) vs 風格分析 (語體) vs 機器翻譯 (語言轉換) vs 文本摘要 (內容壓縮) — 皆為 NLP 應用但目標完全不同。

對應章節：L21101 自然語言處理技術與應用

第 2 題 (114-2-1-Q02)

題幹：某跨國金融科技公司導入 Transformer 架構開發多語客服系統，以提升長篇金融文件的自動翻譯品質。下列何者為該模型能顯著改善翻譯準確度的主要原因？

選項：

- (A) 透過自注意力機制 (Self-Attention Mechanism) 捕捉長距離語境依賴關係
- (B) 透過卷積運算 (Convolution Operation) 加速訓練過程
- (C) 透過強化學習 (Reinforcement Learning) 自動調整語句生成策略
- (D) 透過資料增強 (Data Augmentation) 平衡多語語料比例

正確答案：A

詳細解析：

- ✓ (A) 正確：Transformer (Vaswani et al., 2017) 的核心創新是自注意力機制 (Self-Attention Mechanism)，可一次性計算序列中所有 token 對之間的相依關係 ($O(n^2)$ pairwise attention)，不像 RNN 受梯度消失限制，能有效捕捉長距離依賴 (Long-range Dependency)，這是長篇文件翻譯品質提升的根本原因。
- × (B) 錯誤：Transformer 不使用卷積運算 (Convolution)，CNN 是 ConvS2S、TCN 等架構的特色。Transformer 完全以 attention + FFN 為主，跟 CNN 是不同架構派系。
- × (C) 錯誤：強化學習 (Reinforcement Learning, RL) 非 Transformer 預設訓練機制。RL 用於 RLHF (Reinforcement Learning from Human Feedback，人類回饋強化學習；如 ChatGPT 對齊) 等微調階段，不是翻譯準確度提升的「主要原因」。
- × (D) 錯誤：資料增強 (Data Augmentation) 是訓練資料策略，與 Transformer 架構本身無關。Transformer 改善翻譯品質的關鍵在「架構設計」而非「資料量」。

核心考點：Transformer 自注意力機制處理長距離依賴的核心優勢。

易混淆對比：Self-Attention (Transformer) vs RNN/LSTM (順序依賴，長序列梯度消失) vs CNN (局部感受野，需多層堆疊才能擴展)。

對應章節：L21101 自然語言處理技術與應用

第 3 題 (114-2-1-Q03)

題幹：某企業計畫應用 BERT (Bidirectional Encoder Representations from Transformers) 模型分析大量顧客意見，以強化客服自動回覆系統。在 BERT 的預訓練過程中，「遮罩語言模型 (Masked Language Model, MLM)」的主要訓練策略為何？

選項：

- (A) 依序遮罩句尾詞語，讓模型從左到右逐步生成完整句子
- (B) 隨機遮罩部分詞語，並讓模型根據雙向上下文 (Bidirectional Context) 預測被遮罩的詞
- (C) 透過對抗訓練 (Adversarial Training) 生成語意相似的擾動樣本以提升泛化性
- (D) 以未遮罩的詞為條件，使用解碼器 (Decoder) 結構重建整句內容

正確答案：B

詳細解析：

- ✓ (B) 正確：BERT 的 MLM 預訓練策略是隨機選取 15% 的 token 遮罩 (其中 80% 換成 [MASK]、10% 換成隨機詞、10% 保持原詞)，然後讓 Encoder 利用「左+右雙向上下文」預測被遮罩的詞。這是 BERT 與單向自回歸模型 (如 GPT) 的根本差異。
- × (A) 錯誤：「依序遮罩句尾詞語、從左到右逐步生成」是自回歸語言模型 (Autoregressive LM)，如 GPT 系列、傳統 N-gram LM 的訓練方式，不是 BERT MLM 的策略。
- × (C) 錯誤：對抗訓練 (Adversarial Training) 是另一種正則化技術 (如 FGSM、PGD)，用於提升模型對擾動的魯棒性，非 BERT 預訓練核心策略。
- × (D) 錯誤：BERT 是 Encoder-only 架構，沒有 Decoder。使用 Encoder-Decoder 重建整句是 BART、T5 等 seq2seq 預訓練模型的策略。

核心考點：BERT MLM 預訓練策略的雙向上下文預測機制。

易混淆對比：MLM (BERT, 雙向) vs 自回歸 LM (GPT, 單向左到右) vs Denoising AE (BART/T5, Encoder-Decoder 重建)。

對應章節：L21101 自然語言處理技術與應用

第 4 題 (114-2-1-Q04)

題幹：在詞向量 (Word Embedding) 訓練方法中，GloVe (Global Vectors for Word Representation) 與 Word2Vec 的主要差異為何？

選項：

- (A) Word2Vec 以詞頻權重訓練詞向量，而 GloVe 以隨機初始化向量進行學習
- (B) Word2Vec 以全局統計矩陣為基礎，而 GloVe 採用神經網路進行上下文預測
- (C) Word2Vec 為基於預測的模型，而 GloVe 為基於共現統計的模型
- (D) Word2Vec 僅能用於靜態文本語料，而 GloVe 可應用於即時語料更新

正確答案：C

詳細解析：

- ✓ (C) 正確：Word2Vec (Mikolov, 2013) 是基於預測 (Prediction-based) 的模型，透過 Skip-gram / CBOW 用中心詞預測周圍詞 (或反之)；GloVe (Pennington, 2014) 是基於共現統計 (Count-based) 的模型，先構建全局詞-詞共現矩陣 (Global Co-occurrence Matrix)，再透過矩陣分解學習詞向量。這是兩者本質區別。
- × (A) 錯誤：方向相反。Word2Vec 不是「以詞頻權重訓練」，而是預測式；GloVe 不是隨機初始化 (雖向量初始化會隨機，但其損失函數明確使用共現次數權重)。
- × (B) 錯誤：完全顛倒。Word2Vec 才是神經網路預測模型；GloVe 才是基於全局統計矩陣。
- × (D) 錯誤：兩者都是靜態詞向量 (Static Embedding)，訓練後詞向量固定，皆無法處理「即時語料更新」或「上下文動態變化」(這需要 ELMo / BERT 等動態 embedding)。

核心考點：Word2Vec (預測式) 與 GloVe (統計式) 的核心方法論差異。

易混淆對比：Word2Vec (局部窗口預測) vs GloVe (全局共現統計) vs FastText (subword n-gram) vs ELMo / BERT (上下文動態 embedding)。

對應章節：L21101 自然語言處理技術與應用

第 5 題 (114-2-1-Q05)

題幹：某企業以詞頻-逆文件頻率 (Term Frequency-Inverse Document Frequency, TF-IDF) 方法分析顧客意見內容，但發現模型在處理篇幅較長的回饋文本時，無法準確反映關鍵詞的重要性。下列何者為造成此現象的主要原因？

選項：

- (A) 長文本中的詞頻偏高，導致常見詞權重被過度放大
- (B) 長文本中缺乏明確句子邊界，造成 TF-IDF 無法計算詞頻
- (C) TF-IDF 無法同時處理多份文件
- (D) 長文本會改變 IDF (Inverse Document Frequency) 的計算，使所有詞權重趨於相近

正確答案：A

詳細解析：

- √ (A) 正確：TF-IDF 的 TF 項 $TF(t, d) = \frac{\text{count}(t, d)}{|d|}$ (或不正規化版本)，長文本中所有詞的詞頻自然偏高，特別是「常見詞」(如 the、的、是) 累計次數會被過度放大，導致關鍵字權重被淹沒。改善方法：使用 sublinear TF ($1 + \log(tf)$)、文本長度正規化。
- × (B) 錯誤：TF-IDF 計算是「文件 vs 語料庫」層級，不需要句子邊界，只看詞在文件內出現次數。長文本沒有句子邊界仍可計算。
- × (C) 錯誤：TF-IDF 本來就是「跨文件」計算 IDF ($IDF(t) = \log \frac{N}{df_t}$)，其設計就是為了處理多份文件，此說法完全錯誤。
- × (D) 錯誤：IDF 是「全局統計量」，由整個語料庫的 document frequency 計算，不受單一長文本影響。IDF 不會因為某文件變長就改變。

核心考點：TF-IDF 在長文本中的 TF 失衡問題。

易混淆對比：TF (局部，文件內) vs IDF (全局，語料庫)；長度正規化與 sublinear TF 是常見緩解手段。

對應章節：L21101 自然語言處理技術與應用

第 6 題 (114-2-1-Q06)

題幹：某企業嘗試以 N-gram 語言模型 (N-gram Language Model) 建立客服自動回覆系統，但發現模型生成的句子雖在片段上合理，卻缺乏整體語意連貫性。此問題最可能源自 N-gram 模型的哪一項限制？

選項：

- (A) N-gram 模型在訓練過程中需要龐大計算量，導致長句無法收斂
- (B) N-gram 模型僅根據固定長度的前序詞建立機率估計，難以捕捉長距離依賴關係 (Long-range Dependencies)
- (C) N-gram 模型缺乏語意嵌入 (Semantic Embedding) 層，因此無法表徵詞語間的語意相似度
- (D) N-gram 模型假設詞與詞之間相互獨立，導致無法建構上下文語意關聯

正確答案：B

詳細解析：

- √ (B) 正確：N-gram 模型只看前 N-1 個詞估計下一詞機率 $P(w_t | w_{t-N+1}, \dots, w_{t-1})$ ，這個「固定窗口」就是限制。當 N=3 (trigram) 時，模型無法回顧 5、10 個詞之前的語境，所以「片段合理但整體不連貫」正是長距離依賴問題的典型表現。
- × (A) 錯誤：N-gram 計算量小 (只是查表 / 簡單統計)，不是「龐大計算量」問題；長句收斂與否與其無關。
- × (C) 錯誤：N-gram 確實沒有語意嵌入層 (這也是缺陷之一)，但「無法表徵詞間語意相似度」不是造成「片段 OK 但整體不連貫」的直接原因。題幹強調「整體連貫性」→ 對應「長距離依賴」更準確。
- × (D) 錯誤：詞獨立假設是 Unigram (N=1) 的特性；N-gram (N≥2) 並非假設詞完全獨立，而是基於馬可夫假設 (受前 N-1 詞影響)。

核心考點：N-gram 模型固定窗口導致長距離依賴限制。

易混淆對比：N-gram (固定窗口) vs RNN/LSTM (理論上無限但梯度消失) vs Transformer (全局 attention)。

對應章節：L21101 自然語言處理技術與應用

第 17 題 (114-2-1-Q17)

題幹：在自然語言處理中，檢索增強生成（Retrieval-Augmented Generation, RAG）是一種結合語言模型與向量搜尋的技術，可有效減少模型知識過時與產生幻覺的問題。若要建立一套高效能的 RAG 系統，下列何者為在「檢索階段」最關鍵的挑戰？

選項：

- (A) 確保檢索到的文件能被完整納入語言模型的上下文視窗（Context Window）中進行生成
- (B) 選擇使用 Faiss 或 ScaNN 等近似最近鄰搜尋函式庫
- (C) 降低嵌入模型（Embedding Model）在高維空間中的計算成本與記憶體占用
- (D) 避免向量檢索結果僅具語意相似但與查詢意圖無實質關聯的情況

正確答案：D

詳細解析：

- ✓ (D) **正確：**RAG 檢索階段最關鍵的挑戰是「語意相似 ≠ 真正相關」。向量搜尋只回傳「embedding 接近」的文件，但 embedding 空間的相似可能跟「查詢意圖」無實質關聯（如“Apple 公司財報”可能召回“Apple 水果食譜”）。解法：Re-ranking（用 cross-encoder 重排）、Hybrid Search（BM25 + Vector）、Query Expansion、HyDE 等。
- × (A) **錯誤：**上下文視窗限制是「生成階段」議題，不是「檢索階段」核心挑戰；且現代 LLM 上下文視窗已大幅擴展（128K+）。
- × (B) **錯誤：**Faiss / ScaNN 選擇是「技術實作選型」，屬於工程議題不是技術挑戰，任何成熟向量庫都可用。
- × (C) **錯誤：**Embedding 計算成本是「效能議題」，不是「檢索品質的關鍵挑戰」。

核心考點：RAG 檢索階段的「語意相似 vs 查詢相關」挑戰。

易混淆對比：語意相似（embedding 距離近）vs 查詢相關（真正回答問題）；解法包含 Re-ranker（cross-encoder）、Hybrid Search、HyDE。

【考點：Hybrid Search 與 RRF 融合】（115-1 第三科 Q22 對應）

RAG 檢索階段為兼顧「語意」與「精確關鍵字」，常用 **混合檢索（Hybrid Search）**：同時跑語意向量檢索（Dense / Vector，擅長同義改寫、語意相近）與 **BM25（Best Matching 25，最佳匹配 25）** 關鍵字檢索（Sparse，擅長專有名詞、代號、精確字面）。但兩條管線各自輸出一份排名，分數尺度不同（向量是相似度、BM25 是字頻權重），無法直接相加——此時用 **RRF（Reciprocal Rank Fusion，倒數排名融合）** 來合併。

RRF 機制：不看原始分數、只看「名次（rank）」，對每份結果清單取倒數加總：

$$\text{score}(d) = \sum 1 / (k + \text{rank}_i(d))$$

其中 $\text{rank}_i(d)$ 是文件 d 在第 i 條檢索清單中的名次， k 為平滑常數（常設 60，避免前段名次差距過度放大）。一份文件「在多條清單都排前面」→ 各項倒數都大 → 融合分數高 → 排到最終結果前列。**優點：**免去跨系統分數正規化（Score Normalization）的麻煩，只靠排名就能穩健融合。

【易混淆對比】 Hybrid Search（RRF）vs 純向量檢索 vs 純 BM25：

維度	純語意向量（Dense）	純 BM25（Sparse 關鍵字）	Hybrid Search + RRF
擅長	同義詞、語意改寫、概念相近	專有名詞、代號、精確字面、罕見詞	兩者兼得
弱點	漏精確關鍵字（如型號“A-1234”）、語意相似但不相關	不懂同義／語意（“汽車”找不到“轎車”）	需融合機制（RRF）整合
分數性質	向量相似度	字頻權重（TF-IDF 家族）	只用名次倒數，免正規化
對「語意相似 ≠ 相關」	△ 易中招	△ 易漏召回	✓ 互補緩解

【口訣】「向量懂意思、BM25 抓字面、RRF 比名次（ $1/(k+\text{rank})$ ）把兩榜合一」。正解即「採 Hybrid Search 結合語意向量 + BM25，並以 RRF 融合排序」；直接把向量分數與 BM25 分數相加是陷阱（兩者尺度不同、未正規化，相加無意義，RRF 改用名次倒數正是為了繞開此問題）。

對應章節：L21101 自然語言處理技術與應用

第 18 題 (114-2-1-Q18)

題幹：當 Transformer 模型發生「注意力分布過於平均 (Attention Collapse)」的情形時，導致模型無法有效聚焦於關鍵資訊，下列哪一項策略可有效改善此問題？

選項：

- (A) 提高 Query-Key 點積 (Dot Product) 的縮放常數
- (B) 在 Softmax 前加入高斯雜訊 (Gaussian Noise)
- (C) 使用 ReLU 函數取代 Softmax
- (D) 對注意力權重施加稀疏化約束 (Sparsity Constraint)

正確答案：D

詳細解析：

- ✓ (D) 正確：注意力坍縮 (Attention Collapse / Over-smoothing) 指 attention 分佈太平均，所有 token 權重接近 $1/n$ ，失去聚焦能力。稀疏化約束 (Sparsity Constraint) 強迫 attention 集中在少數重要 token，如 Sparse Attention (Sparse Transformer, Longformer, BigBird)、Top-k Attention、Entmax (替代 Softmax 的稀疏版本)。是公認解法。
- × (A) 錯誤：標準 Transformer 縮放常數是 $\sqrt{d_k}$ ，提高常數會讓點積更小、Softmax 更平均，反而加劇注意力坍縮。
- × (B) 錯誤：加雜訊會讓 attention 分佈更隨機，惡化聚焦問題，不解決坍縮。
- × (C) 錯誤：ReLU 取代 Softmax 雖然能產生稀疏輸出，但 ReLU 不歸一化 (總和不為 1)，破壞 attention 機率分佈本質，有研究但非主流解法。

核心考點：注意力坍縮的稀疏化約束解法。

易混淆對比：Softmax (dense) vs Sparsemax/Entmax (sparse) vs ReLU (無歸一化) vs Sparse Transformer 系列 (架構級稀疏)。

對應章節：L21101 自然語言處理技術與應用

第 19 題 (114-2-1-Q19)

題幹：某研究團隊正在訓練一個針對低資源語言 (如少數民族語言) 的語言模型，但該語言僅有約 1 萬筆語料可用。在訓練過程中出現明顯的過擬合現象，若希望在不新增真實語料的前提下提升模型的泛化能力，採用下列哪一種方法最為適合？

選項：

- (A) 將 Transformer 的隱藏層維度擴增至 1024，以提升表徵能力
- (B) 採用反向翻譯 (Back-Translation) 技術，以生成額外目標語句的偽平行語料 (Pseudo-Parallel Corpus)
- (C) 對詞嵌入矩陣 (Embedding Matrix) 施加 L1 正則化以壓縮模型參數
- (D) 將多語言 BERT (mBERT) 中所有 Transformer 層全部凍結以保留預訓練知識

正確答案：B

詳細解析：

- ✓ (B) 正確：反向翻譯 (Back-Translation, BT) 是低資源 NMT 的經典技術 (Sennrich 2016)：用反向 MT 模型 (target→source) 將大量目標語單語語料翻成源語，得到偽平行語料 (Pseudo-Parallel Corpus)，大幅擴充訓練資料。不需要真實平行語料，完全符合「不新增真實語料」條件。
- × (A) 錯誤：低資源情境下擴增模型容量會加劇過擬合 (參數更多、資料不足)，與目標相反。
- × (C) 錯誤：L1 正則化只是稍微緩解過擬合，對「低資源語料嚴重不足」的根本問題效果有限，不如資料增強類方法。
- × (D) 錯誤：凍結所有 Transformer 層會讓 mBERT 無法適應新語言的特定模式，新層只能微調最後分類器，效果差。應該凍結部分層 + 微調部分層 (partial freezing)。

核心考點：低資源語言的反向翻譯資料增強。

易混淆對比：Back-Translation (生成偽平行語料) vs Data Augmentation (替換 / 增強原語料) vs Transfer Learning (mBERT 微調) vs Self-training。

對應章節：L21101 自然語言處理技術與應用

第 33 題 (114-2-1-Q33)

題幹：企業團隊在使用 Word2Vec 模型訓練客服文本語料時,若訓練資料量龐大且希望模型能更有效捕捉罕見詞的語意關聯,下列哪一種訓練策略最為適合?

選項：

- (A) 採用 Skip-gram 模型,但以隨機初始化權重加快高頻詞的訓練收斂
- (B) 採用 CBOW 模型 (Continuous Bag of Words Model) 並結合 TF-IDF 權重以強化低頻詞表示
- (C) 採用 Skip-gram 模型,利用中心詞預測周圍詞語,能更有效學習低頻詞關係
- (D) 採用 CBOW 模型 (Continuous Bag of Words Model),利用周圍詞預測中心詞,能提升罕見詞的語意穩定度

正確答案：C

詳細解析：

- ✓ (C) 正確：**Skip-gram 模型「用中心詞預測周圍詞」**,罕見詞作為中心詞時也能得到充分訓練 (每次出現都更新自己的向量)。Mikolov 2013 原論文明確指出：**Skip-gram 對罕見詞更友好**,CBOW 對高頻詞更快收斂。客服文本中罕見詞 (如專有名詞、術語) 品質是關鍵 → 用 Skip-gram。
- × (A) 錯誤：「隨機初始化加快高頻詞收斂」與題目目標 (罕見詞) 相反。
- × (B) 錯誤：CBOW 對低頻詞效果不如 **Skip-gram**,且 TF-IDF 是統計詞頻方法,直接結合到 Word2Vec 不是標準做法。
- × (D) 錯誤：CBOW (用周圍詞預測中心詞) 會平均周圍詞 **embedding**,容易抹平低頻詞的獨特性,反而不利於罕見詞語意保留。完全與題目目標相反。

核心考點：Skip-gram vs CBOW 在罕見詞學習上的差異。

易混淆對比：Skip-gram (中心→周圍,罕見詞友好,訓練慢) vs CBOW (周圍→中心,高頻詞快,罕見詞弱);可搭配 Negative Sampling / Hierarchical Softmax 加速。

對應章節：L21101 自然語言處理技術與應用

延伸補充：NLP / CV / 生成式整合速記

以下為跨 NLP、CV 與生成式 AI 的整合速記，方便考前一次掃過共通考點。

考點

- 【考點】NLP 演進四階段時序：1980s 規則式系統 → 1990s 統計語言模型 → 2010s 深度學習 (RNN/LSTM) → 2018 預訓練語言模型時代 (BERT/GPT)。
- 【考點】NLP 資料前處理四步驟標準流程：斷詞 (Tokenization) → 詞性標註 (POS Tagging) → 詞型還原 / 詞幹提取 → 移除停用詞 (Stop Words)。
- 【考點】NLP 第一步「把文字切成一個一個詞彙單元」= 斷詞 (Tokenization)。
- 【考點】RNN 長期依賴問題 (Long-term Dependency Problem)：RNN 逐字往下讀，讀到句尾時前面的資訊已逐漸淡去 → 這正是 Transformer 誕生的動機。
- 【考點】Transformer 在 2017 年提出 (論文「Attention Is All You Need」)，徹底拋棄逐字處理模式，核心 = 自注意力機制 (Self-Attention)。
- 【考點】Self-Attention 機制：處理含代詞的句子時，模型讀到代詞 (如「牠」「它」) 會對句中真正指代的名詞給予較高關注權重，藉此判斷指代對象、捕捉長距離依賴關係。
- 【考點】CV (Computer Vision，電腦視覺) 四大核心任務：影像分類 → 物件偵測 → 語意分割 → 影像生成 (難度遞增)。

- 【考點】CNN（Convolutional Neural Network，卷積神經網路）三層結構：卷積層（提取邊緣/角落/紋理）→ 池化層（縮小特徵圖、減少計算量）→ 全連接層（決策中樞做分類）。
- 【考點】YOLO（高效率物件偵測演算法）= 以 CNN 為基礎的即時偵測代表。

陷阱

- 【陷阱】Lemmatization（詞型還原）vs Stemming（詞幹提取）：兩者目標都是把單字標準化，但路徑不同。
 - Lemmatization = 依詞性與字典規則還原成真實存在的字 → 用於需精準語意的分析（如情感分析）
 - Stemming = 直接裁掉字首字尾，速度快但結果未必是合法單字 → 用於搜尋引擎的初步索引
- 【陷阱】Word2Vec vs GloVe：Word2Vec 以滑動視窗做局部預測任務學習向量；GloVe 對全域共現矩陣做加權分解。一個「局部預測」、一個「全域統計」，是選擇題常設的對比點。
- 【陷阱】判別式 AI vs 生成式 AI：考試很愛考兩者的根本目標差異。
 - 判別式 = 學「類別之間的分界線」、回答「這是貓還是狗」
 - 生成式 = 學「資料本身的分佈與長相」、回答「請畫一隻貓」
- 【陷阱】RAG（Retrieval-Augmented Generation，檢索增強生成）= 結合檢索 + 生成模型的技術，務必理解其「先查再答」精神。

補充比較表

模型家族	架構類型	核心機制	記憶定位	擅長任務
BERT	雙向編碼器（Encoder）	Bidirectional	同時參照左右文的理解者	理解型：文本分類、問答
GPT	單向解碼器（Decoder）	Autoregressive	依前文一路接話的續寫者	生成型：聊天、寫文章、摘要

口訣：Encoder 讀懂（BERT）、Decoder 接話（GPT）。

生成式模型架構	核心原理	代表應用
GAN（Generative Adversarial Network，生成對抗網路）	生成器與判別器互相對抗（一方造假、一方挑錯）	影像生成
VAE（Variational Autoencoder，變分自動編碼器）	編碼-解碼學潛在分佈	影像生成
Diffusion Models（擴散模型）	從純雜訊圖一步步還原清晰影像	主流文生圖工具後端

補充精華

- **Word2Vec 的語意座標觀念**：每個詞都對應到高維空間的一個座標點。常出現在類似語境的詞（如國王、皇后）座標彼此靠近；因此可做語意運算： $\text{國王} - \text{男人} + \text{女人} \approx \text{皇后}$ 。
- **GAN 對抗訓練的動態**：生成器負責造出愈來愈逼真的假樣本，判別器則努力把真假分辨開來；兩者你來我往互相施壓，造假與鑑別能力同步進化，最終生成器能產出極度逼真的成果。
- **CLIP（Contrastive Language-Image Pre-training，對比式語言影像預訓練）**：多模態 AI 的關鍵基礎。以海量「圖片+文字描述」配對訓練，將圖文映射到同一嵌入空間、以對比學習對齊語意，使文字可直接檢索或分類影像。
- **CNN 的層級特徵學習**：淺層卷積擷取邊緣、角落、紋理等低階特徵，經池化逐步縮小特徵圖；較深層再組合出局部形狀與物件部件等高階特徵，最後由全連接層整合各層線索輸出類別機率。此即「由低階到高階逐層抽象」的特性。
- **5 題快速自我檢測**：
 1. 以注意力機制取代循環結構、支撐現代 NLP 的架構？= Transformer
 2. 訓練時先對影像逐步加噪、推論時再逐步去噪生成的模型家族？= Diffusion Models
 3. 文字進模型前先切成最小處理單位的步驟？= Tokenization
 4. 兩個網路以對抗方式互相訓練（一方合成樣本、一方鑑別真偽）？= GAN
 5. 把圖像與文字對齊到同一嵌入空間、支援零樣本檢索的代表模型？= CLIP

延伸補充：NLP 演進對應表

考點

- **NLP 演進四階段**（高頻必考順序對應題）：
 1. 1980s：語法規則與辭典 → 代表系統 **ELIZA**（ELIZA 為 1966 年作品、屬規則式早期代表）

2. 1990s：機率統計模型 → 代表技術 N-gram
3. 2010s：神經網路時代 → 代表架構 RNN (Recurrent Neural Network，遞迴神經網路) / LSTM (Long Short-Term Memory，長短期記憶)
4. 2018+：預訓練與微調 → 代表模型 BERT (Bidirectional Encoder Representations from Transformers，雙向 Transformer 編碼器表示) / GPT (Generative Pre-trained Transformer，生成式預訓練 Transformer)

- 2018 是分水嶺：Transformer 架構於該年帶起預訓練語言模型大爆發。
- RNN/LSTM 出現動機：為了補上統計模型「掌握不了長距離依賴」的缺口。

補充比較表

階段	年代	核心方法	代表技術
規則式	1980s	專家手寫規則	ELIZA
統計式	1990s	大資料算機率	N-gram
深度學習	2010s	深度學習方法成為主流	RNN、LSTM
預訓練	2018+	Transformer + 大模型	BERT、GPT

補充精華

- 資料前處理術語對照：
 - Tokenization (斷詞)：把一句話切成一個一個的詞。
 - POS Tagging (Part-of-Speech Tagging，詞性標註)：替每個詞標上「名詞／動詞」等語法角色。
 - NLU (Natural Language Understanding，自然語言理解)：從文字中抽取意圖與語意結構。
 - NLG (Natural Language Generation，自然語言生成)：將結構化資訊組織為通順文字。
- NLP 實務案例：大量客服對話的意圖分類；挑戰常不在模型本身，而在標註規範一致性，以及口語與方言變異的涵蓋度。

延伸補充：考試改版方向

考點

- iPAS 中級認證 115 年起改版核心：從「知道 AI 是什麼」進化到「規劃 AI」；考試對象由「基礎應用者」轉為「開發實務者」
- 改版幅度：大量內容對齊業界真實工作與日常使用的工具；考題從教科書理論轉向真實企業導入情境
- 思維轉換：從「Developer」→「Architect」；從「會調參數」→「懂得邊界與取捨」

補充精華

- 考題範例：直接給出商業情境（工廠瑕疵品過多、金融交易風險偵測），要求你提出一整套 AI 解決方案

【中級真題與解析（115 年第一次）】

本節對應 4 題官方真題（115 年第一次中級 AI 應用規劃師），每題含 4 選項詳細解析、核心考點、易混淆對比。

第 1 題 (115-1-1-Q01)

題幹：某工程師正在建置一套法律文件解析系統，在進行資訊擷取 (Information Extraction) 前，需要對文本進行詞性標註 (Part-of-Speech Tagging, POS Tagging)。請問此步驟的主要目的為何？

選項：

- (A) 將文本翻譯為其他語言以利跨語言分析
- (B) 將文本切分為基本詞彙單位，以便後續處理
- (C) 判斷文本中各詞彙的情感傾向
- (D) 為每個詞彙標記其語法類別，如名詞、動詞與形容詞

正確答案：D

詳細解析：

- √ (D) 正確：POS Tagging (Part-of-Speech Tagging，詞性標註) 的定義就是為序列中每個詞彙指派語法類別（名詞、動詞、形容詞、副詞等）。在資訊擷取 (IE, Information Extraction，資訊擷取) 管線中，詞

性是下游任務的重要語法線索——例如命名實體多為名詞片語、關係觸發詞多為動詞，先標註詞性能讓實體辨識與關係抽取更精準。

- × (B) 錯誤：「將文本切分為基本詞彙單位」是斷詞／分詞 (Tokenization 符記化) 的工作，屬於 POS Tagging 的「前置」步驟——必須先切出詞彙單位，才能對每個單位標詞性。本選項是典型的「前一步驟」陷阱。
- × (C) 錯誤：判斷情感傾向是情感分析 (Sentiment Analysis，情感分析) 的任務，關注的是語意層面的極性 (正面／負面／中立)，而非語法類別。
- × (A) 錯誤：翻譯是機器翻譯 (MT，Machine Translation 機器翻譯) 的任務，與詞性標註無關，POS Tagging 是單語言內的語法層處理。

核心考點：NLP 前處理管線中各步驟的定義切分——Tokenization (切詞) → POS Tagging (標語法類別) → NER / IE (擷取實體與關係)；看到「標記名詞、動詞」即指向 POS。

易混淆對比：Tokenization (切成詞彙單位，回答「哪裡是一個詞」) vs POS Tagging (標記語法類別，回答「這個詞是什麼詞類」) vs NER (Named Entity Recognition，命名實體辨識：標記人名、地名、組織等語意類別，而非語法類別)。

對應章節：L21101 自然語言處理技術與應用

第 3 題 (115-1-1-Q03)

題幹：某工程師在建構搜尋引擎的詞向量模型時，語料庫規模達數十億 token，且包含大量長尾詞彙 (Long-tail Terms)。他在 Word2Vec 的 CBOW 與 Skip-gram 兩種訓練策略之間進行選擇，需考量訓練效率與低頻詞表示品質之差異。下列何者最能準確地反映兩者在此情境下的取舍？

選項：

- (A) CBOW 對長尾詞表現更好，因為它透過多個上下文詞的平均來強化稀疏詞的訓練訊號
- (B) CBOW 訓練速度較快、整體語意平滑，但對低頻詞的向量品質較差；Skip-gram 以中心詞預測周圍詞，對長尾詞累積更多訓練樣本，向量品質較優
- (C) Skip-gram 訓練速度更快，因為每次只需預測單一目標詞，計算量低於 CBOW
- (D) 兩者對低頻詞的表現完全相同，差異僅在於訓練時的 Batch 組織方式

正確答案：B

詳細解析：

- ✓ (B) 正確：CBOW (Continuous Bag-of-Words，連續詞袋模型) 用「上下文預測中心詞」，一個視窗只產生一次預測且上下文向量被平均，訓練快、語意平滑，但低頻詞出現次數少、又被平均稀釋，向量品質差。Skip-gram (跳躍式模型) 用「中心詞預測每一個周圍詞」，同一個低頻詞每出現一次就產生視窗大小×2 筆訓練樣本，梯度更新次數多，因此對長尾詞的表示品質明顯較好——這正是 Mikolov 原始論文的結論：CBOW 快、Skip-gram 對稀有詞好。
- × (A) 錯誤：方向完全相反。「多個上下文詞取平均」恰恰是 CBOW 對低頻詞不利的原因——低頻詞作為上下文時訊號被平均稀釋，作為中心詞時又只獲得一次預測機會。
- × (C) 錯誤：Skip-gram 每個中心詞要對「每個」上下文位置各做一次預測 (一個視窗多次前向／反向傳播)，計算量大於 CBOW 的「一個視窗一次預測」，所以 Skip-gram 是較慢的一方。
- × (D) 錯誤：兩者的差異是「預測方向」(誰預測誰) 造成的訓練訊號分配差異，直接影響低頻詞品質，絕非只有 batch 組織方式不同。

核心考點：CBOW vs Skip-gram 的經典取舍——速度 vs 低頻詞品質；情境線索「大量長尾詞彙」就是在暗示 Skip-gram 的優勢面。

易混淆對比：CBOW (context→center、快、平滑、低頻詞差) vs Skip-gram (center→context、慢、低頻詞好)；口訣可記「skip 慢工出細活 (稀有詞)」。

對應章節：L21101 自然語言處理技術與應用

第 4 題 (115-1-1-Q04)

題幹：某金融科技公司的工程師正在準備內部客服對話與交易紀錄文本，進行 BERT 模型的預訓練，以提升模型對金融語境的理解能力，並採用遮蔽語言建模（Masked Language Model, MLM）作為訓練任務。請問 MLM 的核心訓練目標為何？

選項：

- (A) 讓模型自左至右逐 token 生成句子，學習自迴歸語言模型（Autoregressive LM）能力
- (B) 透過對抗訓練（Adversarial Training）縮小真實句與生成句之間的語意差異
- (C) 隨機遮蔽輸入序列中部分 token，訓練模型根據雙向上下文預測被遮蔽的原始內容
- (D) 透過遮蔽低頻詞來減少詞彙表大小，降低 Embedding 的記憶體使用

正確答案：C

詳細解析：

- ✓ (C) **正確：**MLM（Masked Language Model，遮蔽語言模型）是 BERT（Bidirectional Encoder Representations from Transformers，基於 Transformer 的雙向編碼器表示）的核心預訓練任務：隨機遮蔽約 15% 的輸入 token（以 [MASK] 取代、隨機替換或保留原詞），要求模型利用「左右雙向」上下文還原被遮蔽的原始 token。這種完形填空式目標讓 BERT 能同時看見前後文，學到深層雙向語意表示——這也是 BERT 名稱中「Bidirectional」的由來。
- × (A) **錯誤：**「自左至右逐 token 生成」是自迴歸語言模型（Autoregressive LM，自迴歸語言模型）的目標，即 GPT（Generative Pre-trained Transformer，生成式預訓練 Transformer）系列的訓練方式；它只能看見左側上下文，與 MLM 的雙向設計正好是兩大預訓練典範的分野。
- × (B) **錯誤：**對抗訓練描述的是 GAN（Generative Adversarial Network，生成對抗網路）式的生成器—判別器框架；BERT 的 MLM 不涉及對抗機制（ELECTRA 的替換偵測才較接近，但那也非本題所問）。
- × (D) **錯誤：**MLM 的遮蔽是「隨機」的訓練訊號設計，不是針對低頻詞、更不是為了縮小詞彙表；詞彙表大小由斷詞器（如 WordPiece）決定，與 MLM 無關。

核心考點：BERT=Encoder+MLM（雙向完形填空）；GPT=Decoder+自迴歸（單向生成）——兩大預訓練目標的對比是高頻考點。

易混淆對比：MLM（雙向、克漏字、適理解類任務）vs Autoregressive LM（單向、續寫、適合生成類任務）；另 BERT 預訓練還有 NSP（Next Sentence Prediction，下一句預測）輔助任務，別與 MLM 混淆。

對應章節：L21101 自然語言處理技術與應用

第 5 題 (115-1-1-Q05)

題幹：某電商平台的工程師在開發商品評論情感分析系統時，發現使用 One-Hot 編碼無法表達詞語之間的語意關係，且隨著詞彙表擴大，向量維度與記憶體需求快速增加。工程師因此改用 Word2Vec 進行詞語表示。請問 Word2Vec 從根本上解決了上述問題的哪項限制？

選項：

- (A) 建立詞語之間的序列依賴關係，以捕捉長距離上下文語意
- (B) 根據詞語在語料中的出現頻率調整其重要性，使模型更重視高頻詞
- (C) 降低詞彙表示的維度，同時保留語意結構，避免高維稀疏表示所帶來的限制
- (D) 透過監督式學習利用標註語料，提升詞語分類的準確性

正確答案：C

詳細解析：

- ✓ (C) **正確：**One-Hot 編碼有兩大限制：①維度等於詞彙表大小（數十萬維）且極度稀疏；②任兩個詞向量正交（內積為 0），完全無法表達語意相似性。Word2Vec 將詞映射到低維（常見 100~300 維）稠密向量空間，且分佈假說（Distributional Hypothesis，分佈假說：上下文相似的詞語意相近）使語意相近的詞在空間中距離相近——同時解決「高維稀疏」與「無語意結構」兩個根本問題，正對應題幹的兩個痛點。
- × (A) **錯誤：**Word2Vec 產生的是「靜態」詞向量，訓練時僅用固定視窗的共現資訊，不建模序列依賴；捕捉長距離上下文依賴是 RNN/LSTM（Long Short-Term Memory，長短期記憶網路）或 Transformer 的能力。

- × (B) 錯誤：「依出現頻率調整重要性」描述的是 TF-IDF (Term Frequency-Inverse Document Frequency, 詞頻—逆文件頻率) 的加權邏輯 (且 TF-IDF 是降低高頻常見詞權重, 本選項連方向都不對)。
- × (D) 錯誤：Word2Vec 是自監督學習 (Self-Supervised Learning, 自監督學習) ——訓練標籤 (上下文詞) 直接來自未標註語料本身, 不需要人工標註, 與監督式分類無關。

核心考點：One-Hot (高維、稀疏、正交無語意) → Word2Vec (低維、稠密、語意距離有意義) 的表示法演進；判別關鍵是「稀疏 vs 稠密」「有無語意結構」。

易混淆對比：One-Hot (詞彙表維度、無語意) vs TF-IDF (加權詞頻統計、仍稀疏) vs Word2Vec (低維稠密嵌入、靜態) vs BERT 嵌入 (上下文相關的動態嵌入, 同詞不同句向量不同)。

對應章節：L21101 自然語言處理技術與應用

L21102 電腦視覺技術與應用

※ 考綱重點 (L21102 電腦視覺技術與應用)：電腦視覺技術原理 (影像分類／物件偵測／影像分割／姿態估測)、典型模型 (CNN／YOLO／R-CNN／U-Net／ViT 等)、評估指標、實際應用場域 (醫療影像、自駕、工業檢測等)

CV 概念與任務分類

CV (Computer Vision, 電腦視覺) 使機器具備「看懂世界」的能力, 從靜態影像或動態影片中擷取、辨識並解釋語意資訊。CV 是跨領域整合, 涵蓋影像處理 (Image Processing)、模式辨識 (Pattern Recognition)、機器學習 (Machine Learning) 與深度學習 (Deep Learning)。

【考點】 2012 年 AlexNet 在 ImageNet 競賽以卷積神經網路 (CNN, Convolutional Neural Network) 大幅提升圖像分類準確度, 是 CV 進入深度學習時代的里程碑。

CV 核心任務類型：

任務類型	英文	說明	常見應用
影像分類	Image Classification	判斷整張影像屬哪一類別	商品辨識、醫療影像分類
物件偵測	Object Detection	辨識影像中物件並標示位置 (邊界框)	自動駕駛、安防監控、人流偵測
語意分割	Semantic Segmentation	將每個像素標為語意類別 (不區分同類個體)	城市街景、農作物分類
實例分割	Instance Segmentation	在語意分割上再分辨同類別不同實體	自駕車多目標、AR 虛實分離
影像生成與合成	Image Generation & Synthesis	從文字描述或既有影像生成新影像	設計輔助、遊戲開發、風格轉換

【易混淆對比】 語意分割 vs 實例分割：

維度	語意分割 (Semantic Segmentation)	實例分割 (Instance Segmentation)
同類別不同個體	不區分 (所有車輛像素都標為「車輛」)	區分 (車 1、車 2 有獨立 ID)
組成	像素分類	語意分割 + 物件偵測
應用	街景、農作物	自駕多目標、AR 虛實分離

【陷阱】 「人臉偵測 (Face Detection)」≠ 「人臉辨識 (Face Recognition)」：

任務	中文	回答的問題
Face Detection	人臉偵測	影像中有哪些人臉、位置在哪
Face Recognition	人臉辨識	該人臉是誰 (比對資料庫身分)

用詞標準對照表：

標準用詞	不再使用
人臉偵測	人臉檢測

標準用詞	不再使用
特徵擷取	特徵提取
鏡頭	攝像頭

CV 技術演進三階段

階段	時期	技術特徵	代表方法
特徵工程主導	1980s-2010	手工設計特徵 + 傳統 ML 分類器	邊緣偵測 (Canny)、SIFT、SURF、ORB、SVM、KNN、隨機森林
深度學習興起	2012-2020	CNN 自動學習特徵	AlexNet、VGGNet、GoogLeNet、ResNet、DenseNet、YOLO、Faster R-CNN、U-Net
多模態與生成式	2020-至今	跨模態理解 + 創造性生成	CLIP、Vision Transformer (ViT)、DALL·E、Stable Diffusion、Midjourney、SAM

現代代表模型一覽：

模型	全名	開發者	核心能力
CLIP	Contrastive Language-Image Pre-Training	OpenAI	文圖嵌入到同一語意空間，跨模態理解
ViT	Vision Transformer	Google	將 Transformer 套用至影像處理
DALL·E	—	OpenAI	文字到圖像生成
Stable Diffusion	—	Stability AI	開源高效圖像生成，支援編輯與風格變換
Midjourney	—	Midjourney Inc.	高美學風格藝術生成（Discord 平台）
SAM	Segment Anything Model	Meta	通用化影像分割，可處理未知任務

影像標註與資料前處理

影像標註（Image Annotation）是為訓練資料建立 Ground Truth（標準答案）的關鍵步驟。

標註方式對應表：

任務類型	標註方式	工具範例
影像分類	類別標籤 (Label)	LabelImg、Label Studio
物件偵測	邊界框 (Bounding Box)	CVAT、Roboflow
語意分割	每像素分割標籤	LabelMe、SuperAnnotate
實例分割	像素遮罩 + 實例 ID	VGG Image Annotator
關鍵點標注	身體節點或特定座標	COCO Annotator
文字辨識 (OCR)	區塊框選 + 文字內容	Tesseract Trainer

進階標註技術：

技術	機制	適用
自動化標註 (Auto-labeling)	用模型預標註，人工僅校對	大量資料、低成本
半監督式學習	少量標註 + 大量未標註資料	標註資源有限
主動學習 (Active Learning)	模型自選最具挑戰性的樣本給人工	標註預算優化
雙重標註	兩位標註者對同一影像分別標註	高風險領域（醫療影像）

影像資料前處理常見步驟：

處理類別	技術	應用情境
圖像尺寸處理	Resize / Padding / Cropping	統一輸入尺寸
正規化處理	Pixel Normalization (0-255 → 0-1 或 Z-score)	加速收斂
像素增強	直方圖均衡化、Gamma 校正	低光源、品質差影像
噪聲去除	高斯濾波、雙邊濾波	感測器雜訊
色彩空間轉換	RGB ↔ Grayscale、HSV	簡化輸入

處理類別	技術	應用情境
資料擴增 (Data Augmentation)	翻轉、旋轉、裁剪、模糊、色彩偏移	對抗過擬合、增強泛化
序列統一	影格取樣	影片或時間序列任務

CV 關鍵技術與模型

1. 影像分類 — CNN 基本組件：

層級	英文	功能
卷積層	Convolutional Layer	用卷積核提取局部特徵，生成特徵圖 (Feature Map)
池化層	Pooling Layer	降維 (如 Max Pooling)，減少計算、增強泛化
激活層	Activation Layer	引入非線性 (如 ReLU)
全連接層	Fully Connected Layer	整合特徵為一維向量做最終分類
輸出層	Output Layer	Softmax 轉為類別機率

知名 CNN 架構對比：

模型	提出者/年代	特色	適用
LeNet	Yann LeCun	5 層簡單結構	手寫數字辨識
AlexNet	2012 ImageNet 冠軍	8 層、ReLU、Dropout	大規模影像分類
VGG	2014	深度 + 小卷積核 (3×3)，可達 19 層	高準確度分類
ResNet	2015	殘差結構 (Residual Connection)，可達 152 層	解決深層網路梯度消失

影像分類評估指標：

指標	中文	說明
Accuracy	準確率	預測正確樣本 / 總樣本
Top-5 Error	Top-5 錯誤率	真實類別若在預測前 5 名內即視為正確 (適用 ImageNet 大量類別)
Confusion Matrix	混淆矩陣	展示各類別預測分佈，分析誤分類

2. 物件偵測模型：

模型	全名	特點	速度 vs 準確度
YOLO	You Only Look Once	基於迴歸，同時預測邊界框與類別	速度快、適合即時
Faster R-CNN	—	兩階段：RPN (Region Proposal Network) + 分類	準確度高、速度慢
SSD	Single Shot Multibox Detector	多尺度特徵	速度與準確度平衡

3. 影像分割模型：

模型	全名	特點	應用
FCN	Fully Convolutional Network	上採樣還原解析度，端到端訓練	通用語意分割
U-Net	—	對稱 Encoder-Decoder + 跳躍連接 (Skip Connections)	醫療影像 (資料量少、不平衡)
Mask R-CNN	—	Faster R-CNN + 遮罩預測分支	實例分割

4. 評估指標 IoU

【公式】
$$\text{IoU} = \frac{\text{Area}_{\text{Intersection}}}{\text{Area}_{\text{Union}}}$$

IoU (Intersection over Union) 衡量預測區域與真實區域的重疊度，值介於 0-1。物件偵測通常 $\text{IoU} > 0.5$ 或 0.7 才算成功預測。

【考點】 IoU 計算範例 (真實框面積 = 100、預測框面積 = 80、重疊區域 = 40)：

步驟	計算	結果
交集	重疊	40
聯集	$100 + 80 - 40$	140

步驟	計算	結果
IoU	40 / 140	≈ 0.286

CV 應用情境

領域	應用	技術核心
監控與安全	人臉辨識系統	人臉偵測 → 特徵擷取 → 比對與辨識
監控與安全	車牌辨識系統 (ANPR, Automatic Number Plate Recognition)	車牌區域偵測 → 字符辨識
醫療影像診斷	CT/MRI 分類為診斷結果	CNN 影像分類
醫療影像診斷	腫瘤、病灶定位	U-Net 影像分割
醫療影像診斷	合規限制	HIPAA (Health Insurance Portability and Accountability Act, 美國健康保險可攜與責任法) 隱私法規、專業醫師標註
智慧製造	工業瑕疵偵測 (Industrial Defect Detection)	邊緣運算 + 即時回饋
零售	商品行為分析、熱點圖 (Heatmap)	顧客動線、停留時間分析
AR/VR	實體追蹤、虛擬疊加	沉浸體驗
自動駕駛	車道線偵測、物件偵測	多模態融合 (鏡頭、雷達、光達 LiDAR)

CV 技術挑戰與風險

風險面向	核心議題	因應策略
資料隱私與合規	人臉、車牌、敏感影像屬 PII (Personally Identifiable Information, 個人識別資料)	匿名化、模糊化遮罩、合法授權、資料最小化
偏見與模型可靠度	訓練資料族群 (膚色、性別、年齡) 不平衡、標註偏誤、拍攝條件偏差	偏見診斷測試 (Bias Audit)、資料平衡與重加權、多維度指標 (AUC、Precision、Recall)
部署與維運	GPU/TPU 資源限制、批次處理延遲、版本管理、資料漂移 (Data Drift)	輕量化模型 (MobileNet、YOLOv5-Nano)、MLOps、影像品質監測、容錯與回退機制

【易混淆對比】誤檢 (False Positive) vs 漏檢 (False Negative)：

類型	定義	醫療範例	工業範例
誤檢 (FP)	把陰性誤判為陽性	健康人誤判為病人 → 不必要檢查	良品誤判為瑕疵 → 良率假性下降
漏檢 (FN)	把陽性誤判為陰性	漏掉真正病人 → 延誤治療	缺陷產品流入市場

→ 模型部署架構 (MLOps) 見 L21302 AI 技術系統集成與部署；演算法偏見治理 見 L23402 演算法偏見與公平性 (見第三冊)

延伸補充：電腦視覺重點整理

以下為電腦視覺章節的延伸整理，聚焦 CNN 結構、四大任務與評估指標。

考點

- **CNN (Convolutional Neural Network, 卷積神經網路) 三層核心：**
 - 卷積層 (Convolutional Layer) = 特徵抽取的主力，用 kernels 滑動掃描提取邊緣/角落/紋理特徵
 - 池化層 (Pooling Layer) = 下採樣壓縮，max pooling (保留最強) vs average pooling (取平均)
 - 全連接層 (Fully Connected Layer) = 最後做整合判斷的分類層
- **權重共享 (Weight Sharing)：**同一個 kernel 用同樣標準掃整張圖 → 無論特徵在哪個位置都認得，大幅減少參數
- **CNN 模型演進史：**
 - 1998 LeNet-5：開山鼻祖，辨識手寫數字
 - 2012 AlexNet：引入 ReLU、用 GPU 加速，引爆深度學習革命
 - 2014 VGGNet/InceptionNet：證明「越深越好」

- 2015 ResNet：用殘差（Residual）解決梯度消失問題
- **學習機制**：前向預測 → 損失函數（Loss）算誤差 → 反向傳播（Backpropagation）→ 梯度下降（Gradient Descent）調整權重
- **視覺三任務升級**：
 - 影像分類（Classification）：「這是什麼」（你在水果區）
 - 物件偵測（Object Detection）：「在哪裡＋是什麼」（蘋果在那裡，用 bounding box）
 - 影像分割（Image Segmentation）：「精確輪廓」（描出蘋果外形）
- **物件偵測兩大流派**：
 - 兩階段（Two-Stage）：R-CNN 系列；精度高、速度慢
 - 單階段（One-Stage）：YOLO、SSD；速度快、精度略低
- **影像分割兩種**：
 - 語意分割（Semantic Segmentation）：把所有「貓」塗藍色，不分個體
 - 實例分割（Instance Segmentation）：區分「貓 1、貓 2、貓 3」；代表模型 Mask R-CNN
- **黃金評估指標**：
 - IoU（Intersection over Union，交集與聯集比例）：0–1，衡量框重疊度
 - mAP（mean Average Precision，平均精確率）：物件偵測綜合指標，兼顧 Precision+Recall
 - Dice Coefficient：影像分割專用，類似 IoU

陷阱

- **陷阱**：瑕疵率極低（1/100）時，**Accuracy 99% 沒有參考價值**，要看 Recall（不能漏抓瑕疵品）
- **陷阱**：問題提到「即時／速度／串流」→ 選 YOLO/SSD（單階段）；提到「精度／離線分析」→ 選 R-CNN 系列
- **陷阱**：問題問「區分個體」→ 實例分割（Instance）；只要「同類塗同色」→ 語意分割（Semantic）

補充比較表

Two-Stage vs One-Stage 偵測器

維度	Two-Stage (R-CNN 家族)	One-Stage (YOLO/SSD)
工作方式	先提案區域，再分類	一次性掃完直接預測
精度	高	略低
速度	慢	快（適合即時）
應用	醫療影像、離線分析	自駕車、監控

混淆矩陣與關鍵指標

指標	公式概念	適用場景
Accuracy	$(TP+TN)/\text{總數}$	類別平衡時
Precision（精確率）	$TP/(TP+FP)$	在預測為正的內容中，多少是真的（怕誤報）
Recall（召回率）	$TP/(TP+FN)$	在所有真實正例中，抓到多少（怕漏報）
F1 Score	Precision 與 Recall 調和平均	兩者平衡
IoU	交集面積/聯集面積	物件偵測位置精準度
mAP	多類別平均 Precision	物件偵測綜合

補充精華

- **類別不平衡下的指標選擇**：當正例（如瑕疵品）極少時，僅看 Accuracy 會失真——模型全數預測為多數類別即可獲得高準確率卻完全漏掉少數類別。應改以 Recall 控制漏判（False Negative），並以 Precision 與 Recall 的調和平均 F1 取得平衡。
- **物件偵測模型與指標對應**：
 - 即時、速度優先的偵測情境多採單階段（One-Stage）模型（如 YOLO 系列）；精度優先則採兩階段（Two-Stage）模型（如 Faster R-CNN）。
 - 需要像素級輪廓時採實例分割（Instance Segmentation，如 Mask R-CNN）。

- **IoU (Intersection over Union, 交並比)** 衡量預測框與真實框的重疊程度，提高 IoU 門檻代表對定位精準度的要求更嚴格；**mAP (mean Average Precision, 平均精確率)** 則綜合不同類別與門檻下的精確率與召回率，作為整體偵測能力的指標。

延伸補充：影像表示與 CNN 演進

考點

- 彩色照片在電腦裡的本質 = 張量 (Tensor)，維度 = 高 × 寬 × 3 (RGB 三通道)。
- **正規化 (Normalization)** 做法：像素值 ÷ 255 → 壓縮到 [0, 1]，可加速並穩定訓練。
- **CNN (Convolutional Neural Network, 卷積神經網路)** 兩大主角：卷積層 (負責抽特徵) + 池化層 (負責壓縮資訊)。
- 池化層好處：①減少運算量 ②保留主要特徵、忽略微小位移 (位置不變性 translation invariance)。

補充比較表 — CNN 演進史

模型	年份	突破
LeNet	1998	CNN 鼻祖，辨識手寫數字
AlexNet	2012	引爆深度學習革命，確立 GPU 訓練霸主
GoogLeNet (Inception)	2014	多尺度卷積核並行 (加寬網路)
ResNet	2015	殘差結構解決梯度消失，網路可深至千層
ViT	2020+	Transformer 入侵 CV，全域關係勝局部

補充比較表 — 四大視覺任務

任務	輸出	區分個體？	應用
影像分類	整張圖一個標籤	否	「這是一隻貓」
物件偵測	標籤 + 邊界框	否	圈出每隻貓
語意分割	每像素分類	否 (不分個體)	所有車塗藍色
實例分割	每像素分類 + 個體編號	是	第 1 台車藍 / 第 2 台紅

補充比較表 — CNN vs ViT

維度	CNN	ViT (Vision Transformer)
觀察方式	一塊一塊掃描局部	一次看整張圖、建立區塊間關係
關注	局部細節	全域語意
資料量	中等即可訓練	需超大量資料

補充精華 — 真實應用場景

- 半導體 AOI (Automated Optical Inspection, 自動光學檢測)：晶圓瑕疵檢測。
- 智慧回收設備、交通違規影像辨識、車牌辨識。
- 作物病害早期偵測 (智慧農業)。
- 對抗式貼紙 (Adversarial Patch)：在交通標誌上貼特製圖案 → AI 可能誤判，屬自駕車安全課題。
- 擴散模型 (Diffusion) 原理：學會把雜訊一步步「除噪」還原 → 反過來就能從純雜訊生成全新影像。

延伸補充：為什麼用 CNN 而非 MLP

考點

- 傳統 MLP (Multi-Layer Perceptron, 多層感知器) 採全連接結構處理影像時，需先將二維像素展開為一維向量，導致相鄰像素的空間關係喪失，且輸入維度一旦放大，第一層所需的權重數量便隨之爆增，難以擴展到較大的影像。
- **CNN (Convolutional Neural Network, 卷積神經網路)** 的三項核心特性：
 1. **局部連結 (Local Connectivity)**：每個神經元只連結輸入的一個小範圍 (感受野, Receptive Field)，對應影像中「特徵多為局部」的先驗。
 2. **權重共享 (Weight Sharing)**：同一個卷積核 (Kernel / Filter) 在整張影像上滑動並重複使用相同參數，使參數量與輸入尺寸脫鉤、大幅下降。
 3. **平移不變性 (Translation Invariance)**：同一特徵不論出現在影像何處皆能被同一卷積核偵測到。

- **池化層 (Pooling Layer)**：對特徵圖做降取樣 (Downsampling)，常見為最大池化 (Max Pooling) 或平均池化 (Average Pooling)。
- 池化層好處：
 1. 降低特徵圖空間維度與後續計算量、抑制過擬合。
 2. 對輸入的微小位移與形變更具強健性。

補充比較表

面向	MLP (傳統)	CNN
連結方式	全連接、輸入需展平	局部連結 + 卷積核滑動
空間關係	展平後喪失	透過卷積結構保留
參數規模	隨輸入尺寸快速增長	權重共享使參數量大幅縮減
設計取向	通用，不利大尺寸影像	針對網格狀資料設計

補充精華

白話拆解：

- **池化層的作用**：它要的是「整體輪廓」而非每個細節。就像看一幅畫時退後幾步，雖然看不清每根線條，卻能更清楚掌握整體構圖；池化把細節模糊化、保留主結構，也讓模型對位移更不敏感。
- **卷積濾鏡的作用**：每個濾鏡像一個「專責偵測員」，在整張圖上滑動，只負責找出某一種特定模式（例如橫線、圓角）。
- **CNN 完整流程**：特徵由淺到深層層抽象
 1. 淺層卷積 + 池化 → 擷取低階特徵（邊緣、紋理、色塊）
 2. 中層 → 將低階特徵組合成局部結構（角點、輪廓片段）
 3. 深層 → 形成高階語義特徵，最後經全連接層整合並輸出分類結果

核心觀念：只要資料具有「網格狀空間結構」，CNN 都值得一試——不只一般圖片，聲波頻譜圖（智慧音箱）、醫療斷層掃描、自動駕駛影像 也都能用 CNN 處理。

【中級真題與解析（114 年第二梯次）】

本節對應 **3 題** 官方真題（114 年第二梯次中級 AI 應用規劃師），每題含 4 選項詳細解析、核心考點、易混淆對比。

第 7 題 (114-2-1-Q07)

題幹：在企業導入的智慧監控系統中，模型以物件偵測 (Object Detection) 方式自動辨識影像中的人物與車輛。若評估指標採用平均精確率 (Mean Average Precision, mAP)，其中 IoU (Intersection over Union) 閾值設定較高時，代表下列哪一項意義？

選項：

- (A) 預測邊界框與真實邊界框的重疊程度越高，模型偵測結果越精準
- (B) 預測邊界框與真實邊界框的誤差越大，導致 mAP 數值上升
- (C) 模型整體精確率 (Precision) 降低，但召回率 (Recall) 上升
- (D) 預測邊界框的評估結果不受真實框大小影響

正確答案：A

詳細解析：

- **✓ (A) 正確**：IoU (Intersection over Union) = $\frac{\text{預測框} \cap \text{真實框}}{\text{預測框} \cup \text{真實框}}$ ，取值 0~1。IoU 閾值設高（如 0.75 或 0.9）= 要求預測框與 GT 框重疊比例極高才算 TP。所以高 IoU 閾值代表「模型偵測位置必須非常精準」才算正確。COCO mAP@0.5:0.95 就是用 10 個閾值平均，越高越嚴格。
- **× (B) 錯誤**：方向完全相反。IoU 閾值高 → 容錯空間小 → mAP 通常下降（更嚴格的評估），不會上升。
- **× (C) 錯誤**：IoU 閾值提高會讓 Precision 與 Recall **同步下降**（更多預測被歸為 FP），不會出現「Precision 降但 Recall 升」的情況。

- × (D) 錯誤：IoU 是比例計算，理論上對框大小較不敏感，但 mAP 評估在 COCO 等基準上會分大/中/小物件分別評估 (AP_S, AP_M, AP_L)，實務上小物件偵測準確度通常較差。

核心考點：IoU 閾值在 mAP 評估中的物理意義。

易混淆對比：IoU@0.5 (寬鬆) vs IoU@0.75/0.95 (嚴格)；COCO mAP (多閾值平均) vs PASCAL VOC mAP (單一閾值 0.5)。

對應章節：L21102 電腦視覺技術與應用

第 8 題 (114-2-1-Q08)

題幹：關於 Softmax 與 Max-Pooling，下列敘述何者正確？

選項：

- (A) Softmax 與 Max-Pooling 都會將特徵張量壓縮為單一最大值
- (B) Max-Pooling 會對輸入進行機率分佈的轉換
- (C) Softmax 會保留所有輸入資訊，但以比例表示；Max-Pooling 只保留區域最大值
- (D) Softmax 主要用於特徵降維，而 Max-Pooling 用於分類輸出

正確答案：C

詳細解析：

- ✓ (C) 正確：Softmax $\sigma(z_i) = \frac{e^{z_i}}{\sum_j e^{z_j}}$ ，將輸入向量映射為**機率分佈**（所有元素總和 = 1），**保留所有輸入資訊**（每個 logit 都對應一個比例）；Max-Pooling 則是**取局部窗口內的最大值**（丟棄其他值），實現降採樣與位置不變性。
- × (A) 錯誤：Softmax 不會壓縮為單一最大值，而是輸出整個機率分佈向量；Max-Pooling 才是取最大值（但仍是逐個 pooling window 取）。
- × (B) 錯誤：機率分佈轉換是 **Softmax** 的功能，不是 Max-Pooling。Max-Pooling 只取數值最大值，輸出不是機率。
- × (D) 錯誤：兩者用途顛倒。Softmax 用於**分類輸出層**（多類別機率）；Max-Pooling 用於 **CNN 中的特徵降維 / 降採樣**。

核心考點：Softmax（機率分佈）與 Max-Pooling（空間降採樣）的功能差異。

易混淆對比：Softmax（輸出機率分佈，保留資訊）vs Argmax（直接取最大類別，硬決策）vs Max-Pooling（空間取最大，降維）。

對應章節：L21102 電腦視覺技術與應用

第 34 題 (114-2-1-Q34)

題幹：在自駕車影像辨識系統中，開發團隊希望模型能同時辨識每個像素所屬的物件類別（例如道路、建築、行人），又能區分出同類物件的不同個體（例如多位行人）。此時最適合採用下列哪一項電腦視覺技術？

選項：

- (A) 語義分割 (Semantic Segmentation)
- (B) 物件偵測 (Object Detection)
- (C) 實例分割 (Instance Segmentation)
- (D) 全景分割 (Panoptic Segmentation)

正確答案：D

詳細解析：

- ✓ (D) 正確：**全景分割 (Panoptic Segmentation)** 結合語意分割（每個像素分類）與實例分割（區分同類個體），對 stuff（背景：道路、天空）做語意分割，對 things（前景：行人、車輛）做實例分割，**同時滿足「每像素分類」+「區分個體」**。Kirillov et al. (2019) 提出，正是為自駕車場景設計。
- × (A) 錯誤：語意分割只給每像素分類標籤，**無法區分同類別的不同個體**（兩個行人會被當成同一類），不滿足「區分多位行人」需求。

- × (B) 錯誤：物件偵測輸出邊界框 (Bounding Box) + 類別，**不做像素級分類**，不滿足「每個像素所屬類別」需求。
- × (C) 錯誤：實例分割 (如 Mask R-CNN) 可區分個體，但**通常只標註可數物件 (things)**，背景區域 (stuff：道路、建築) 不會被像素級分類，不滿足「同時辨識所有像素」需求。

核心考點：全景分割整合語義 + 實例分割的雙重能力。

易混淆對比：語意分割 (像素分類，不分個體) vs 實例分割 (個體 mask，不分背景) vs 全景分割 (兩者整合) vs 物件偵測 (bbox，無像素級)。

對應章節：L21102 電腦視覺技術與應用

延伸補充：CV 任務與工具整合

以下為電腦視覺任務、CNN 直覺與業界 AI 工具的整合速記。

考點

- 【考點】影像分類：為整個影像分配一個標籤 (這是貓的照片)。
- 【考點】物件偵測 (Object Detection)：用邊界框 (Bounding Box) 識別並定位物件 (貓在哪裡)，自駕車應用必備。
- 【考點】語意分割 (Semantic Segmentation)：對影像中每個像素分類 (哪些像素是天空/建築/樹木)。
- 【考點】全景分割 (Panoptic Segmentation) = 實例分割 + 語意分割：不只區分同類別中的不同實例 (每輛車各自獨立標識)，還要對背景 (道路、天空等 stuff) 做像素級語意分類。
- 【考點】CNN 能自動從圖片學特徵，是其最大優勢。
- 【考點】CV 評估指標：mAP (mean Average Precision，平均精度均值)、IoU (Intersection over Union，交並比)。

補充比較表

CV 任務	輸出粒度	範例
影像分類	整張圖一個標籤	貓/狗
物件偵測	物件 + 邊界框位置	找出畫面中所有車
語意分割	每個像素一個類別	像素級分類天空/建築
全景分割	像素級 + 物件實例	A 車與 B 車區分

補充精華

- CNN 卷積層的直覺：許多小濾鏡 (filter) 分別掃過整張圖，各自負責偵測邊緣／角落／紋理等基礎特徵。
- 池化層作用：把特徵圖縮小、只留下重要資訊，順帶降低後續計算量。

延伸補充：CNN 與醫療影像考點

考點

- CNN (Convolutional Neural Network，卷積神經網路) 配對題訣竅：題目情境提到「圖片、影像、空間區域性特徵」→ 直接對應 CNN。
- 醫療影像常見做法：用 CNN 家族中的 ResNet (Residual Network，殘差網路) 處理 X 光等影像。

陷阱

- 醫療影像考題的重點**常在資料合規而非模型**：訓練前需完成去識別化，並確認取得合法授權依據 (病患同意或 IRB 審查) —— 選項若只談模型效能、忽略資料合規，多為誘答。

補充精華

- CNN 的特性：極度擅長聚焦在區域性細節上，是影像辨識的主力架構。
- 製造業案例：產線檢測交由 CNN，能揪出產品表面肉眼難辨的微小瑕疵。
- 遷移學習省標註成本：只需少量瑕疵照片，拿預訓練模型微調，準確率仍可維持。

延伸補充：AI 工具類型與選用原則

考點

- 中級考題會直接點名業界主流 AI 工具，但重點不在工具名稱，而在**依任務型態選對工具類型**。
- 選用原則：長文撰寫與邏輯推理 → 長上下文對話式助理；跨檔程式開發與除錯 → IDE 整合型程式輔助工具；需自主上網、多步驟操作的事務 → 通用型 AI 代理（Agent）。

補充比較表：AI 工具類型對照

類型	核心強項	典型情境
對話式 AI 助理	長上下文理解、文本生成與摘要	合約審查、長文總結、文案撰寫
程式輔助工具	跨檔程式理解與自動除錯	軟體開發、Bug 修復
通用型 AI 代理	自主規劃、多步驟工作流程、工具呼叫	跨系統自動化、資料蒐集與報表生成

補充精華 — AI Agent 的組成與可靠性（通用概念）

- **模型本體 vs 外圍環境**：一個 AI 代理可分為「模型本體」（負責語言理解與決策推理）與「外圍工具鏈與執行環境」（負責工具呼叫的編排、狀態管理、錯誤偵測與恢復）。模型再強，缺少外圍環境把它與真實系統、工具串接起來，也無法自主完成整個工作流程。
- **職責分離以防自評過樂觀**：複雜任務中讓不同代理分別承擔「產出」與「審查」職責，由狀態獨立的代理把關，避免同一模型對自己的輸出評分過寬。
- **檢索增強上下文**：程式輔助工具常先掃描專案、挑出最相關的少量程式片段餵給模型，避免一次塞入過多內容而超出上下文視窗（屬 RAG 概念的應用）。
- **對齊設計**：以明文原則約束模型行為並讓其自我檢查，常見以「有用、誠實、無害（Helpful, Honest, Harmless）」為設計目標（業界公開的對齊概念）。

【中級真題與解析（115 年第一次）】

本節對應 4 題官方真題（115 年第一次中級 AI 應用規劃師），每題含 4 選項詳細解析、核心考點、易混淆對比。

第 6 題（115-1-1-Q06）

題幹：某自駕車感知系統需要在同一張影像中同時完成道路、建築、行人的逐像素分類，並且能夠區分畫面中兩名相鄰行人（標記為「行人 #1」和「行人 #2」）。工程師在選擇語義分割（Semantic Segmentation）與實例分割（Instance Segmentation）時，請問兩者的根本差異為何？

選項：

- (A) 實例分割對每個像素進行分類但不產生 Bounding Box；語義分割產生 Bounding Box 但不進行像素級標記
- (B) 實例分割僅用於影像層級的類別分類，語義分割才進行逐像素標記
- (C) 語義分割將每個像素分配至預定義類別，但同一類別內的不同個體無法區分；實例分割能對同一類別的不同物件（如兩名行人）分別建立獨立遮罩（Mask）
- (D) 語義分割與實例分割皆為逐像素分類任務，但兩者在是否需要區分不同物件個體上並無差異

正確答案：C

詳細解析：

- ✓ (C) **正確**：語義分割（Semantic Segmentation，語義分割）回答「每個像素屬於哪個類別」——所有行人像素都標成同一個「行人」類，兩名相鄰行人會黏成一片，無法分辨個體。實例分割（Instance Segmentation，實例分割）在像素級分類之上再加「個體識別」，對同類別的每個物件各自產生獨立遮罩（行人 #1、行人 #2 各一個 Mask）。題幹「需區分兩名相鄰行人」就是決定性線索——只有實例分割做得到。
- × (A) **錯誤**：兩個描述都顛倒了。語義分割是純像素級標記、不產生 Bounding Box（邊界框）；實例分割（如 Mask R-CNN）通常反而先產生候選框再在框內生成遮罩。
- × (B) **錯誤**：「影像層級的類別分類」是影像分類（Image Classification）的定義；實例分割是像素級任務，且語義分割與實例分割「都」進行逐像素標記。
- × (D) **錯誤**：「是否區分物件個體」正是兩者的根本差異所在，說「並無差異」直接否定了題目要考的核心概念。

核心考點：CV 任務粒度階梯——分類（整張圖）＜偵測（框＋類別）＜語義分割（像素＋類別）＜實例分割（像素＋類別＋個體）；「能否分開同類別的兩個個體」是語義 vs 實例的判別關鍵。

易混淆對比：語義分割（同類別合併為一片）vs 實例分割（同類別逐個體分開）vs 全景分割（Panoptic Segmentation，全景分割：背景類用語義、前景物件用實例，兩者合一）。

對應章節：L21102 電腦視覺技術與應用

第 7 題 (115-1-1-Q07)

題幹：某大型超市的防損系統需要即時偵測多名顧客各自手持的購物籃、手機與商品，並需對每個物件進行精確區域標記（Pixel-level Mask），同時能區分畫面中不同個體（即使不同顧客拿著相同商品，也需分別標記）。請問下列哪一項技術最適合此場景的需求？

選項：

- (A) 影像分類 (Image Classification)
- (B) 目標檢測 (Object Detection)
- (C) 實例分割 (Instance Segmentation)
- (D) 語義分割 (Semantic Segmentation)

正確答案：C

詳細解析：

- ✓ (C) **正確：**題幹給出兩個需求線索：①「Pixel-level Mask（像素級遮罩）」→ 需要分割而非只畫框；②「區分不同個體（相同商品也要分別標記）」→ 需要實例級識別。兩個條件同時滿足的只有實例分割（Instance Segmentation，實例分割），典型模型如 Mask R-CNN。
- × (B) **錯誤：**目標檢測（Object Detection，目標檢測）能定位並區分多個物件，但輸出是矩形邊界框（Bounding Box），無法提供題目要求的像素級精確區域標記——它滿足條件②但不滿足條件①。
- × (D) **錯誤：**語義分割提供像素級標記，但同類別物件會合併成一片（兩個相同商品分不開）——它滿足條件①但不滿足條件②。
- × (A) **錯誤：**影像分類只對整張影像輸出一個類別標籤，既無定位、無遮罩、也無個體區分，是四個選項中資訊粒度最粗的。

核心考點：情境題的雙條件交集判斷——「像素級遮罩」剔除分類與偵測，「區分個體」剔除語義分割，交集即實例分割。

易混淆對比：Object Detection（框、可分個體、無像素遮罩）vs Semantic Segmentation（像素遮罩、不分個體）vs Instance Segmentation（像素遮罩＋分個體，前兩者能力的聯集）。

對應章節：L21102 電腦視覺技術與應用

第 10 題 (115-1-1-Q10)

題幹：某工廠導入即時影像瑕疵偵測系統，需在高頻影像流中進行快速推論。工程師在 YOLO 與 Faster R-CNN 兩種物件偵測架構之間進行評估，請問下列哪一個針對兩者在偵測流程設計上的差異最為正確？

選項：

- (A) YOLO 採用單階段偵測，直接從整張影像預測物件位置與類別；Faster R-CNN 則先產生候選區域再進行分類
- (B) YOLO 與 Faster R-CNN 皆採用兩階段流程，但在特徵擷取方式上有所不同
- (C) YOLO 採用單階段架構，主要透過增加候選區域數量來提升偵測準確率
- (D) Faster R-CNN 採用單階段偵測方式，將物件定位與分類整合於同一模型中

正確答案：A

詳細解析：

- ✓ (A) **正確：**YOLO (You Only Look Once，你只看一次) 是單階段 (One-Stage) 偵測器，將影像劃分為網格，一次前向傳播同時回歸所有物件的位置與類別，速度快、適合即時場景。Faster R-CNN 是兩階段 (Two-Stage) 偵測器：第一階段由 RPN (Region Proposal Network，區域候選網路) 產生候選區域 (Region Proposals)，

第二階段對每個候選區域做分類與框回歸，精度通常較高但速度較慢。題幹「高頻影像流、快速推論」的情境也暗示了單階段 YOLO 的適用性。

- × (B) 錯誤：YOLO 是單階段，並非兩階段；「皆採用兩階段」前提就錯。
- × (C) 錯誤：「候選區域 (Region Proposal)」機制屬於兩階段架構；YOLO 的設計初衷正是「取消」候選區域步驟以換取速度，此選項把兩派的機制張冠李戴。
- × (D) 錯誤：與事實相反——Faster R-CNN 是兩階段的代表架構；「將定位與分類整合於單一網路一次完成」描述的反而是 YOLO。

核心考點：單階段 (YOLO/SSD：快、端到端、適即時) vs 兩階段 (R-CNN 系列：先提候選區再分類，精度高但慢)；判別關鍵字 = 「候選區域 (Region Proposal)」只出現在兩階段。

易混淆對比：YOLO (一次前向傳播、無 proposal、速度優先) vs Faster R-CNN (RPN 產生 proposal → 逐區分類、精度優先)；延伸：Mask R-CNN = Faster R-CNN + 遮罩分支 (實例分割)。

對應章節：L21102 電腦視覺技術與應用

第 32 題 (115-1-1-Q32)

題幹：某工程師正在實作一個 CNN 影像分類模型，在 PyTorch 中定義模型架構時，需要在卷積擷取特徵後接上全連結層 (Fully Connected Layer) 進行分類。在模型程式碼中，需要在卷積輸出與全連結層之間插入什麼操作？

選項：

- (A) 使用全域平均池化 (Global Average Pooling) 將特徵圖壓縮後再接全連結層
- (B) 使用 Flatten 將特徵圖展平成一維向量
- (C) 直接將卷積輸出接到全連結層，系統會自動轉換維度
- (D) 先對特徵圖做 Softmax，再輸入全連結層

正確答案：B

詳細解析：

- ✓ (B) 正確：卷積層輸出是形狀為 (批次, 通道 C, 高 H, 寬 W) 的 4D 張量 (就單一樣本而言是 $C \times H \times W$ 的 3D 特徵圖, Feature Map)，而全連結層 (nn.Linear) 只接受一維特徵向量輸入。標準做法是插入 Flatten 操作 (PyTorch 的 nn.Flatten() 或 x.view(x.size(0), -1))，把 $C \times H \times W$ 展平成長度 $C \cdot H \cdot W$ 的一維向量，維度才能對上 nn.Linear($C \cdot H \cdot W$, num_classes)。這是經典 CNN (LeNet、VGG) 卷積段接分類頭的標準銜接方式。
- × (A) 錯誤 (本題情境下非答案)：GAP (Global Average Pooling, 全域平均池化) 是另一種可行的現代做法 (每張特徵圖取平均、輸出 C 維向量，參數更少、抗過擬合，ResNet/GoogLeNet 採用)，但題幹問的是「展平特徵圖接 FC」這一標準操作的名稱；GAP 之後其實輸出已是 (C,1,1)，嚴格說仍常需一次 flatten/squeeze。在 iPAS 命題脈絡下，「卷積輸出→全連結層之間插入的操作」標準答案是 Flatten。
- × (C) 錯誤：PyTorch 不會自動轉換維度——3D 特徵圖直接餵 nn.Linear 會拋出形狀不匹配錯誤 (或被廣播成非預期的逐位置線性變換)；「框架自動處理」是對深度學習框架運作的常見誤解。
- × (D) 錯誤：Softmax 是輸出層把 logits 轉成機率分佈的最後一步 (且 PyTorch 慣例中通常併入 CrossEntropyLoss 內)，放在中間層會壓縮特徵資訊、破壞梯度流，完全不是維度銜接操作。

核心考點：CNN 架構銜接：卷積特徵圖 ($C \times H \times W$ 三維) → Flatten (展平成一維) → 全連結層 (分類)。記口訣「卷積出圖、展平進線性」。

易混淆對比：Flatten (保留全部空間資訊、參數量大 = $C \cdot H \cdot W \times$ 輸出維) vs GAP (每通道取一個平均值、輸出僅 C 維、參數少抗過擬合、對輸入尺寸更寬容) ——兩者都是「圖→向量」橋樑，傳統 CNN 用 Flatten、現代架構偏好 GAP；Softmax (機率正規化，放最後) vs ReLU (中間層啟動函數)。

對應章節：L21102 電腦視覺技術與應用

L21103 生成式 AI 技術與應用

※ 考綱重點 (L21103 生成式 AI 技術與應用)：生成式 AI 技術原理 (GAN/VAE/Diffusion/Transformer-LLM)、提示工程、RAG、Fine-tuning、AI 代理、應用場域 (文本/圖像/影音/程式碼/多模態生成)

生成式 AI 概念與四階段 AI 演進

NVIDIA CEO 黃仁勳 2025 CES 提出 AI 四階段演進：

階段	英文	能力
感知 AI	Perception AI	理解影像、語音、文字（如圖像辨識、語音轉文字）
生成式 AI	Generative AI	主動產生文本、圖像、影片、語音等多模態內容
代理式 AI	Agentic AI	具備推理與計畫能力，自動完成複雜任務
物理 AI	Physical AI	在真實世界移動、操控、互動（如 AI 機器人、自駕車）

【口訣】「感知 → 生成 → 代理 → 物理」（AI 從理解資料 → 創造內容 → 自主決策 → 操作實體）。

【易混淆對比】生成式 AI vs 鑑別式 AI：

維度	生成式 AI (Generative AI)	鑑別式 AI (Discriminative AI)
目標	生成新資料樣本（文本、圖像、音訊）	分類、辨識、預測
工作方式	學習資料分佈並生成新樣本	學習資料特徵進行判別
主要應用	內容創作（ChatGPT、DALL·E）	圖像分類、語音辨識、疾病預測
模型例子	GPT、VAE、GAN、Diffusion Models	SVM、決策樹、隨機森林、Logistic 迴歸
輸出	新資料點或內容	類別標籤或數值預測

【陷阱】ChatGPT、DALL·E 為生成式 AI；ResNet（影像分類）、SVM、邏輯迴歸為鑑別式。HMM 雖用於語音辨識任務，但在分類學上屬生成式模型（建模聯合機率 $P(X,Y)$ ，與鑑別式的 CRF 相對）——這正是考題常設的陷阱。考題若問「以下何者為生成式 AI 模型」，要選 GAN、VAE、Diffusion、GPT 系列。

生成式 AI 技術演進五階段

階段	時期	核心技術	代表模型	特徵與限制
初期階段	2013–2015	VAE、RNN	VAE、Encoder-Decoder	生成模糊、訓練困難
GAN 時代	2014–2020	對抗訓練	DCGAN、StyleGAN、CycleGAN	高寫實性、訓練不穩定（Mode Collapse）
Transformer 崛起	2017 起	自注意力機制	BERT、GPT、T5	高效語境建模、NLP 主導
擴散與多模態	2020 起	擴散模型、跨模態對齊	Stable Diffusion、DALL·E、Flamingo、Gemini	高品質、多模態整合
巨型模型與 Agent 化	2023 起	巨型參數、工具整合	GPT-4、Claude 2、Gemini 1.5	自主性、任務導向、工具鏈整合

核心生成模型逐項：

模型	全名	機制	優點	限制
VAE	Variational Autoencoder，變分自編碼器	變分推斷學習資料潛在分佈（Latent Distribution）	訓練穩定、潛在空間結構好	生成樣本較模糊
GAN	Generative Adversarial Network，生成對抗網路	生成器（Generator）+ 判別器（Discriminator）對抗訓練（Ian Goodfellow 2014）	高寫實性	訓練不穩定（Mode Collapse 模式崩潰）、對超參數敏感
Diffusion Models	擴散模型	逐步加噪 + 反向去噪（Denoising），代表 DDPM、Stable Diffusion	生成品質高、穩定	生成速度慢、運算成本高

【考點】GAN 的核心兩組件：生成器（Generator）+ 判別器（Discriminator），不是「編碼器/解碼器」（後者屬 VAE/Transformer），也不是「強化器/回饋器」。

生成式 AI 三大應用領域

1. 文本生成 (Text Generation)

工具/平台	開發者	特色
GPT 系列	OpenAI	對話、摘要、翻譯、程式碼生成
ChatGPT	OpenAI	多情境對話、最廣為人知
Claude	Anthropic	安全性、長上下文
Gemini	Google DeepMind	多模態、工具調用
LLaMA / Mistral / Command-R	Meta / Mistral / Cohere	開源模型

文本生成評估指標：

指標	全名	核心目標	偏重	適用情境
BLEU	Bilingual Evaluation Understudy	詞彙相似度 (N-gram 重疊)	Precision	機器翻譯
ROUGE	Recall-Oriented Understudy for Gisting Evaluation	摘要資訊召回	Recall	自動摘要、問答
人工評估	Human Evaluation	流暢性與準確性	語意、語用	對話、創意寫作

【判別表】 BLEU vs ROUGE：

指標	偏重	核心問題	首選任務
BLEU	Precision	生成內容中有多少與參考重疊	機器翻譯
ROUGE	Recall	參考內容中有多少被覆蓋	摘要

ROUGE 變體：

變體	內容
ROUGE-N	n-gram 重疊
ROUGE-L	最長公共子序列 (LCS, Longest Common Subsequence)
ROUGE-S	跳躍詞對

2. 圖像生成 (Image Generation)

工具	部署型態	特色
Midjourney	雲端 (Discord/官網)	高美學風格
Stable Diffusion WebUI	開源本地部署	支援 LoRA 微調、ControlNet
Adobe Firefly	整合 Photoshop/Illustrator	設計師專業工具
Canva AI	整合 Canva 平台	非專業使用者友善
DALL·E 2 / Imagen	雲端 API	文字到圖像

核心生成模型對比：

模型類型	代表	機制	控制能力
Diffusion Models	Stable Diffusion、DALL·E 2、Imagen	逐步降噪	高自由度
GAN	StyleGAN、BigGAN	對抗訓練	風格化生成
ControlNet / InstructPix2Pix	(插件式)	控制姿態、邊緣、遮罩	局部編輯

3. 語音合成 (Voice Synthesis / TTS, Text-to-Speech)

模型/工具	開發者	特色
Tacotron 2 + WaveNet	Google	經典自迴歸架構
FastSpeech 2	Microsoft	非自迴歸、生成快速
VITS (Variational Inference TTS)	學術	VAE + GAN 端到端
ElevenLabs	ElevenLabs	多語言、高情感表達
Azure TTS / Google Cloud TTS / Amazon Polly	三大雲端	企業級 API

△ 常見誘答：Whisper (OpenAI) 是 STT (語音轉文字) 模型，不是 TTS——見下方陷阱。

TTS 關鍵指標：

指標	全名	說明
MOS	Mean Opinion Score，平均意見分數	人工評分 (1–5)，衡量自然度
WER	Word Error Rate，字錯率	內容準確性
生成延遲	Latency	即時應用關鍵

【陷阱】 Whisper 是 **STT (Speech-to-Text，語音辨識)** 模型，不是 TTS。考題易混。

生成式 AI 風險與未來趨勢

潛在風險：

風險	範例
內容真偽與資訊可信度	偽造新聞、合成語音詐騙
智慧財產權與授權爭議	訓練資料含受著作權保護的內容
偏見放大與倫理風險	訓練資料中的性別/種族偏見被擴大
深偽 (Deepfake) 技術濫用	換臉影片用於詐騙、假訊息
可控性與輸出不確定性	Prompt 引導不準 → 模型生成不相關/不適當內容

【考點】 模型幻覺 (Hallucination) 與 Deepfake 是生成式 AI 兩大代表性風險：

風險	特徵	高風險領域
Hallucination	模型「自信地」產出虛假內容 (語法對、事實錯)	醫療、法律、金融
Deepfake	圖像/語音偽造他人身分	政治、詐騙、媒體

技術發展趨勢：

趨勢	內涵
多模態生成	整合文字、語音、圖像、影片、3D 場景
可控生成與提示工程深化	Prompt Engineering (提示工程) 成關鍵技能
小型化與邊緣部署	模型在手機、PC、IoT 設備上本地執行
模型對齊與安全防護	RLHF (Reinforcement Learning from Human Feedback，人類回饋強化學習)、紅隊測試 (Red Teaming)
法規制定	歐盟 AI 法案 (EU AI Act)、美國 AI 政策框架、國際技術標準

→ 深度學習與 Transformer 架構 見 L23203 深度學習原理與框架 (見第三冊)；資料隱私 見 L23401 數據隱私、安全與合規 (見第三冊)

延伸補充：生成式 AI 重點整理

以下為生成式 AI 章節的延伸整理，含模型家族、控制手段與風險案例。

考點

- **生成式 AI 演進十年史**：VAE (Variational Autoencoder) → GAN (Generative Adversarial Network，生成對抗網路) → Transformer → AI Agent (代理式 AI)
- **生成式 AI 家族**：
 - ▶ GAN：生成器 (Generator) 與判別器 (Discriminator) 相互對抗，一方造假、一方辨真
 - ▶ VAE：先壓縮學出資料的潛在特徵，再從特徵還原／創造新樣本
 - ▶ Diffusion Models (擴散模型)：先對清晰圖逐步加雜訊，再學會反向「除噪還原」
 - ▶ LLMs (Large Language Models)：以 GPT 系列為代表的大型語言模型
- **AI 幻覺 (Hallucination) 的本質**：LLM 本質是「預測下一個詞」，它追求的是「機率上看起來合理」而非「事實上正確」

- **控制 AI 的三種手段：**
 1. Prompt Engineering（提示工程）：Zero-shot / Few-shot；不動模型、成本最低、快速驗證
 2. RAG (Retrieval-Augmented Generation，檢索增強生成)：先查外部資料再作答；解決「資訊每天變動」「需要事實精準」
 3. LoRA (Low-Rank Adaptation)：以輕量外掛微調，用來調整「說話風格」或補上「專業技能」
- **GAN 的致命傷：模式崩潰 (Mode Collapse)：**生成器走捷徑，只反覆產出某一種樣本就能騙過判別器，導致多樣性喪失
- **DeepFake 防禦三層：**
 - 技術層：活體檢測（要求做特定動作）
 - 法規層：合規聲明、資料用途與保存期限明確
 - 營運層：持續監控模型漂移 (Model Drift)
- **AI 生成內容評估：**
 - 文字：BLEU（翻譯）、ROUGE（摘要）
 - 語音：MOS（主觀自然度）、WER（客觀錯誤率）
 - 數位浮水印 (Digital Watermark)：確保可追溯性
- **語音 TTS 演進：**
 - Tacotron 2：兩階段（文字→頻譜→波形），有電音感
 - VITS：端到端模型，即時、情感豐富、能模擬呼吸聲

陷阱

- **陷阱：**「銀行利率／法律條文／公司規章」這類需要「事實精準、隨時更新」→ 必選 RAG，**不是 LoRA**
- **陷阱：**「希望 AI 說話像某個品牌風格／特定 Python 程式碼格式」→ 選 LoRA（學風格），**不是 RAG**
- **陷阱：**即時視訊變臉、直播濾鏡 → 選 GAN（速度快）；廣告海報、創意視覺 → 選 Diffusion（品質高但慢）
- **陷阱：**AI 把錯誤講得很有自信 = 幻覺（並非惡意），成因是「靠機率拼湊」+「缺乏外部事實驗證」

補充比較表

RAG vs LoRA 決策

維度	RAG	LoRA
目的	講事實、查資料	學風格、低算力
一句話	先查外部資料再答	凍結主模型，訓練輕量外掛
適用	法律、銀行、即時資訊	客製化語氣、品牌風格
解決	幻覺、資訊過時	缺乏領域口吻
成本	中等（要建向量庫）	低（只訓練小矩陣）

GAN vs Diffusion Model

維度	GAN	Diffusion Model
原理	對抗博弈生成	加雜訊後再學去噪還原
速度	極快	慢（吃算力）
品質	中等、易模式崩潰	極高、細節豐富
適用	即時變臉、直播	廣告海報、藝術創作

控制 AI 三種手段

工具	一句話	適用情境
Prompt Engineering	不動模型，給範例	快速驗證、變動小
RAG	動態檢索外部資料	事實要對、資訊變動快
LoRA	凍結主模型，訓練小外掛	改風格、改口吻

補充精華

- **企業視訊會議 Deepfake 詐騙案**：詐騙集團以 AI 偽造出一整場視訊會議，畫面中「同事」全是合成影像，財務人員因看見一群熟面孔而放下戒心，分多筆匯出鉅款。教訓：跨人匯款流程不能只憑視訊「看到本人」，須加入額外身分核驗。
- **以 RAG 抑制幻覺**：當 LLM 對外提供資訊時可能「言之鑿鑿」地生成不存在的事實（幻覺，Hallucination）。對策的關鍵不在持續微調模型本身，而是導入 RAG（Retrieval-Augmented Generation，檢索增強生成），讓模型回答前先從可信的內部正式資料來源檢索，再依檢索結果作答，使輸出可溯源、可查核。
- **生成式技術的綜合應用**：一個能對話、有視覺形象、又能發聲的虛擬代理人，通常需要整合多種生成式技術——文字互動用 LLM（可搭 RAG 提升事實正確性、用 LoRA 微調語氣風格）、視覺內容用影像生成模型（如 Diffusion）、語音用文字轉語音（TTS, Text-to-Speech）。核心考點是「依模態挑選合適技術並整合」，而非追求單一萬能模型。
- **長文本處理**：
 - 一般 RAG 容易漏掉「夾在中間」的資訊（純靠向量相似度，中段往往相似度偏低）
 - GraphRAG / 知識圖譜：建立實體之間的關聯網絡，補上「結構性連結」
- **速記口訣**：RAG 講事實（先查再答） / LoRA 學風格（輕量外掛） / GAN 速度快但不穩 / Diffusion 細節強但較慢 / 端到端語音合成自然度高

延伸補充 — LLM 推論成本優化（輸入主導成本必背）

核心觀念：LLM API 計費 = 輸入 token 數 × 輸入單價 + 輸出 token 數 × 輸出單價。**RAG／長對話系統的成本結構通常由「輸入」主導**——因為每次請求都要塞入大量檢索區塊（Retrieved Chunks）、固定 System Prompt、與不斷累積的對話歷史（Conversation History）。因此**降成本的關鍵是「砍輸入」而非「砍輸出」**。

為什麼（成本拆解）：以一個典型 RAG 法律問答系統為例，單次請求的輸入 token 可能由「10 區塊 × 600 ≈ 6,000（檢索）+ 500（System Prompt）+ 8,000（對話歷史）≈ 14,500 輸入 token」對上「約 300 輸出 token」，輸入是輸出的 ~48 倍。此時就算把輸出 max_tokens 從 1,000 壓到 200，省下的是「輸出端的零頭」，對總成本幾乎無感——這正是干擾選項設計的陷阱。

四大降輸入成本手段：

手段	機制	砍哪一端	對「輸入主導」場景效果
Prompt Caching（提示快取／靜態前綴重用）	將「每次都相同的靜態前綴」（System Prompt、固定背景說明）標記為可快取，後續請求命中快取時該段輸入以 大幅折扣計價 （部分供應商快取讀取約為原價 1/10）	砍輸入（重複前綴）	✓ 顯著
對話歷史摘要壓縮（History Summarization）	不保留逐字完整歷史，改用 LLM 把舊輪對話 摘要成精簡語意 ，保留意義、丟棄冗詞	砍輸入（歷史）	✓ 顯著
壓縮輸出 max_tokens	限制模型回答長度上限	砍輸出（零頭）	× 輸入主導時幾乎無感
Batch API（批次非同步）	把請求改為離線批次送出 換取 單價折扣 （常約 5 折）	折扣套在輸入+輸出，但 不減 token 量 ；且 犧牲即時性	△ 有省但違反「即時問答」需求、且非「降 token」

【易混淆對比】四種「降成本」策略誰真正打中「輸入主導」：

策略	是否減少輸入 token	是否維持品質	是否即時	適用判斷
Prompt Caching + 歷史摘要壓縮	✓ 兩者都砍輸入	✓ 摘要保語意、快取不改內容	✓	輸入主導場景首選
壓縮輸出 max_tokens	× 只動輸出	△ 可能砍掉必要內容	✓	輸出佔比高時才有效
Prompt 內要求「回答簡短」	× 只是「引導」輸出變短，不保證、且 新增指令本身反而加輸入	△ 引導不穩定	✓	效果最弱、最不可靠
Batch API	× token 量不變，只拿單價折扣	✓	× 非同步、犧牲即時	離線大量任務（非即時問答）

【口訣】「輸入主導砍輸入：快取靜態前綴 + 摘要對話歷史」；砍輸出、喊簡短、轉批次都是搔不到癢處。

【115-1 科一 Q21 真題對應】正解 (B)：將 System Prompt 改為 **Prompt Caching**／靜態前綴重用，並對對話歷史實作摘要壓縮——兩招都直接砍「輸入主導」的成本來源，且摘要保語意不傷品質。各干擾選項為何錯：

- × (A) 壓縮輸出 max_tokens：題目已言明「成本主要集中於輸入 tokens」，砍輸出對輸入主導場景幾乎無效——典型陷阱選項。
- × (C) 改用 Batch API：只是拿「單價折扣」且不減 token 量，更嚴重的是批次非同步會犧牲即時問答體驗，不符問答系統需求。
- × (D) 在 Prompt 要求「盡量簡短」：只是「軟性引導輸出」，不保證生效、不動輸入，且新增的指令本身還反向增加輸入 token。

延伸補充：鑑別式／生成式與 Transformer

考點

- 鑑別式 vs 生成式 AI：
 - 鑑別式：學的是決策邊界，任務是分類／判別。
 - 生成式：學的是資料分佈，任務是創造新樣本。
- Attention is all you need (2017 Google 論文) → 開啟 Transformer 時代。
- Self-Attention (自我注意力)：句中每個字都掃描前後文，判斷自己跟哪些字關係最密切。
- 圖像生成三代演進：VAE (早期，輸出較朦朧) → GAN (清晰但訓練不穩、易模式崩潰 Mode Collapse) → Diffusion (集大成，穩定且多樣)。
- Diffusion 兩步驟：前向 (一路加雜訊到接近純亂訊) → 反向 (學會除噪 → 從雜訊重建影像)。

延伸補充 — ReAct 框架與 Agent 防幻覺 (Agent 必考)

ReAct (Reasoning + Acting, 推理 + 行動) 是 AI Agent (智慧代理) 的核心推理框架，讓 LLM 在「思考」與「呼叫工具行動」之間交錯迴圈，邊推理邊取得外部真實資訊，藉此降低幻覺 (Hallucination)。

ReAct 三步迴圈 (Thought → Action → Observation Loop)：

步驟	英文	內涵
思考	Thought	Agent 推理「現在該做什麼、為何這樣做」
行動	Action	呼叫一個工具 (如 web_search、calculator)
觀察	Observation	接收工具回傳結果，作為下一輪 Thought 的依據

→ 三步循環直到 Agent 判斷已有足夠資訊，才輸出 **Final Answer**。

【關鍵考點：System Prompt 防幻覺】ReAct Agent 最常見的設計缺陷是——System Prompt 沒有「強制即時性／事實性問題必須先呼叫工具驗證」。若放任 Agent「自認為知道答案就直接回答」，它會依賴過時的內部知識 (參數記憶) 直接編造，產生幻覺 (如自信報出錯誤的公司名與數字)。正確做法：在 System Prompt 明確規定「涉及即時、時效、可查證的問題，必須先執行 web_search 等工具，禁止直接憑既有知識作答」。

【易混淆對比】CoT vs ReAct vs Reflexion：

維度	CoT (Chain-of-Thought, 思維鏈)	ReAct (Reasoning + Acting)	Reflexion (自我反思)
核心	只「想」：拆解步驟、逐步推理	「想 + 做」：推理 + 呼叫工具取外部資訊	「做完再檢討」：對失敗結果自我反省後重試
是否用外部工具	× 純內部推理	√ 邊推理邊呼叫工具	√ (建立在 ReAct 之上) + 反思記憶
對幻覺	△ 推理更有條理，但仍憑內部知識、無法驗證事實	√ 工具取真實資料、可大幅減幻覺	√√ 多一層自我糾錯
迴圈	單向一次推理	Thought → Action → Observation 多輪	ReAct 迴圈 + 失敗後 Reflect → 重試
適用	數學／邏輯純推理題	需查即時資訊、操作工具的任務	多次嘗試、需從錯誤學習的複雜任務

【口訣】「CoT 只動腦、ReAct 動手查、Reflexion 還會反省重來」。

【115-1 科一 Q16 真題對應】正解 (A)：System Prompt 未要求 Agent 在回答前用工具驗證，導致它直接依賴既有知識產生幻覺；應明確規定「即時性問題需先執行 web_search」。各干擾選項為何錯：

- × (B) 嫌 calculator/get_current_date 多餘：這些是合理備用工具，「工具多」不是本題核心病灶，真正問題是「根本沒用工具就作答」。
- × (C) 主張移除 Thought 欄位以省 token：Thought 正是 ReAct 的靈魂，移除等於閹割推理過程，反而更易亂跳行動、降低可靠性——典型「為效率犧牲正確性」陷阱選項。
- × (D) 要 Agent 第一輪就呼叫所有工具再彙整：違反 ReAct「逐步觀察再決策」精神，盲目全呼叫反而引入雜訊、增加延遲與成本。

延伸補充 — CO-STAR 提示工程框架（必背口訣）

字母	全名	意義	範例
C	Context	背景	「你是企業內部教育訓練講師」
O	Objective	目標	「撰寫一份資料備份重要性的宣導」
S	Style	風格	「條理清晰、重點分明」
T	Tone	語氣	「專業而不生硬」
A	Audience	受眾	「非技術部門的一般同仁」
R	Response	格式	「一段導言＋三項具體做法」

陷阱

- 生成式 AI 三大關鍵風險：
 1. 幻覺（生成看似合理但錯誤的資訊）
 2. 供應鏈攻擊（下載的開源模型內嵌惡意程式碼）
 3. 資料隱私（用機密資料訓練 → 模型可能反向洩漏內容）

補充精華 — 差分隱私（Differential Privacy）

- 作法直覺：在每筆真實數值上加入一個小幅隨機擾動（noise），使得整體統計（如平均）仍然準確，但任何人都無法從結果反推出某個個人的真實值。
- 核心精神：「保護到個人，仍看得見整體趨勢」。

延伸補充：生成式 AI 主軸提示

本章節以 GAN / Transformer / LLM 為主軸；此處僅作概念提示，深度學習如何擅長處理影像、聲音與語言可參見對應深度學習章節。

【中級真題與解析（114 年第二梯次）】

本節對應 6 題官方真題（114 年第二梯次中級 AI 應用規劃師），每題含 4 選項詳細解析、核心考點、易混淆對比。

第 9 題（114-2-1-Q09）

題幹：某企業在訓練生成式 AI 模型時，導入資料增強（Data Augmentation）技術以擴充訓練資料，但觀察到模型效能反而下降。下列哪一項最可能的原因與對應改善策略最為正確？

選項：

- (A) 增強樣本未經隨機初始化，導致模型梯度更新不穩定，應重新設計訓練啟動流程
- (B) 增強後資料的特徵分佈與原始資料不一致，影響模型的泛化能力，應檢查並調整增強策略以維持語意一致性
- (C) 增強樣本的比例過高，造成模型對特定資料產生偏好，應適度提高增強比例並調整學習率
- (D) 增強後資料的標註可信度下降，導致訓練訊號偏差，應以半監督學習方式重新校正資料

正確答案：B

詳細解析：

- ✓ (B) 正確：資料增強若未維持語意一致性（如過度旋轉影像導致文字倒置、過度 paraphrase 改變原意），會使增強資料分佈偏離原始分佈，導致模型學到錯誤模式、泛化能力下降。正確做法是檢查增強強度、確保語意保持（如 RandAugment 控制 magnitude）。
- × (A) 錯誤：增強樣本與「隨機初始化」無關（這是模型權重初始化的概念，不是資料增強）。混淆兩個獨立概念。
- × (C) 錯誤：增強比例過高的改善策略應該是「降低增強比例」而非「提高」；選項自相矛盾。
- × (D) 錯誤：資料增強通常保持標籤不變（如旋轉影像，標籤仍是貓），不會造成標註可信度下降；半監督學習用於「無標籤資料」場景，與此題不對應。

核心考點：資料增強的分佈一致性與語意保持原則。

易混淆對比：資料增強（保留語意，擴充樣本）vs 對抗樣本（惡意擾動）vs 標籤雜訊（標註錯誤）vs 半監督學習（利用無標籤資料）。

對應章節：L21103 生成式 AI 技術與應用

第 20 題 (114-2-1-Q20)

題幹：在使用生成對抗網路（GAN）進行人臉影像生成時，若出現「模式崩潰」（Mode Collapse）現象，下列哪一種方法最常被用來有效解決此問題？

選項：

- (A) 在鑑別器中加入梯度懲罰（Gradient Penalty）以穩定訓練過程
- (B) 採用 Wasserstein 距離（WGAN 損失）替代原始的 GAN 損失函數
- (C) 對生成器輸入的潛在向量加入隨機擾動
- (D) 使用多尺度鑑別器架構以提高對多樣性的判別能力

正確答案：B

詳細解析：

- ✓ (B) 正確：模式崩潰（Mode Collapse）指 GAN 生成器只生成極少數樣本以欺騙鑑別器，喪失多樣性。WGAN（Wasserstein GAN, Arjovsky 2017）用 Wasserstein 距離（Earth Mover's Distance）替代 JS 散度，梯度更穩定、能有效緩解 Mode Collapse，是最經典的解決方案。
- × (A) 錯誤：梯度懲罰（WGAN-GP）主要解決「訓練不穩定 / 梯度爆炸」問題，是 WGAN 的後續改進，但直接解決 Mode Collapse 的根源仍是 Wasserstein 損失本身。題幹問「最常用」→ 答案落在 WGAN (B)。
- × (C) 錯誤：對潛在向量加擾動可微幅增加多樣性，但無法根治 Mode Collapse（崩潰是判別損失幾何問題，非輸入問題）。
- × (D) 錯誤：多尺度鑑別器（如 PatchGAN、MSG-GAN）用於提升細節品質，對 Mode Collapse 的直接緩解效果有限。

核心考點：WGAN 解決 Mode Collapse 的核心方法。

易混淆對比：GAN（JS 散度，易崩潰）vs WGAN（Wasserstein 距離，穩定）vs WGAN-GP（加梯度懲罰，更穩）vs LSGAN/SAGAN（其他改進）。

對應章節：L21103 生成式 AI 技術與應用

第 25 題 (114-2-1-Q25)

題幹：某企業部署生成式 AI 系統協助行銷與內容產出，但近期遭質疑部分生成內容可能涉及著作權侵權。為降低企業在法律層面的潛在責任與風險，下列哪一項策略最能有效預防侵權問題產生？

選項：

- (A) 對生成內容進行語意相似度比對，自動標註可能涉及既有著作的輸出結果，以降低侵權風險
- (B) 建立訓練資料篩選與授權驗證機制，排除未授權或高風險資料來源
- (C) 在訓練與微調過程中採用差分隱私技術，避免模型記憶特定受著作權保護的樣本
- (D) 在模型輸出端嵌入浮水印（Watermarking）或數位指紋（Digital Fingerprint）技術，以確保生成內容可追溯

正確答案：B

詳細解析：

- ✓ (B) 正確：預防侵權的根本在「源頭管控」——從訓練資料就排除未授權內容。建立資料授權驗證機制 (Data Licensing Verification) + 資料來源篩選，可確保模型輸出不會「再現」未授權著作，是最徹底的預防策略。
- × (A) 錯誤：「事後比對 + 標註」屬於事後檢測，當內容已生成才偵測，無法「預防」侵權產生，只能補救。
- × (C) 錯誤：差分隱私 (Differential Privacy) 主要用於個資保護 (避免模型記憶個人資料)，對「著作權侵權」防範的針對性較低，且會犧牲模型品質。
- × (D) 錯誤：浮水印 / 數位指紋是追溯機制 (事後識別內容來源)，可幫助歸責但不能預防侵權。

核心考點：生成式 AI 著作權侵權「源頭預防 vs 事後補救」的差異。

易混淆對比：訓練資料授權 (預防) vs 內容比對 (檢測) vs 浮水印 (追溯) vs 差分隱私 (個資)。

對應章節：L21103 生成式 AI 技術與應用

第 38 題 (114-2-1-Q38)

題幹：某影像設計團隊在使用 Stable Diffusion 生成 4K 級產品圖時，發現影像邊緣與細節存在顆粒化與模糊現象。若僅能在生成階段進行調整，希望提升畫面清晰度與紋理層次，同時避免過度平滑，下列哪一項作法最適合？

選項：

- (A) 降低取樣步數，以縮短生成時間
- (B) 增加取樣步數並選擇高品質取樣器，以強化細節還原度
- (C) 提高 CFG (Classifier-Free Guidance) 值，使生成結果更具創意與多樣性
- (D) 改用低解析度輸入以降低計算成本

正確答案：B

詳細解析：

- ✓ (B) 正確：Stable Diffusion 的取樣步數 (Sampling Steps) 越多，去噪過程越精細，細節還原越好。搭配高品質取樣器 (如 DPM++ 2M Karras、UniPC、Euler a 等) 可在更少步數內達到優質結果，提升清晰度與紋理層次。
- × (A) 錯誤：降低取樣步數會讓去噪不完整，細節更模糊，與題意相反。
- × (C) 錯誤：CFG 值控制「對 prompt 遵循度」，提高 CFG 增加 prompt 對齊但會降低多樣性 (與選項描述「更具創意與多樣性」自相矛盾)，且過高 CFG 反而會產生過飽和、雜訊 (artifacts)。
- × (D) 錯誤：低解析度輸入直接降低細節，與「提升清晰度」目標相反。

核心考點：Diffusion 模型取樣步數與取樣器對生成品質的影響。

易混淆對比：取樣步數 (去噪精細度) vs CFG (prompt 對齊強度) vs Sampler (去噪演算法，如 DDIM/Euler/DPM++) vs 解析度 (細節容量)。

對應章節：L21103 生成式 AI 技術與應用

第 40 題 (114-2-1-Q40)

題幹：下列哪一項最正確地描述了 VAE (Variational Autoencoder)、GAN (Generative Adversarial Network) 與擴散模型 (Diffusion Model) 在多模態潛在空間對齊 (Latent Alignment) 與生成策略上的根本差異？

選項：

- (A) VAE 透過顯式潛在變數建模實現跨模態對齊，適合捕捉整體語意結構但生成解析度有限；GAN 透過對抗損失 (Adversarial Loss) 在不同模態間學習分佈映射，生成品質高但穩定性差；擴散模型則以條件化噪聲反推 (Conditional Denoising) 方式實現高保真跨模態生成，兼具穩定性與多樣性
- (B) VAE 與 Diffusion Model 均屬隱式生成架構，主要依賴對抗式訓練實現跨模態對齊；GAN 則以顯式後驗估計方式提升樣本一致性
- (C) VAE 與 GAN 均使用馬爾可夫鏈 (Markov Chain) 進行跨模態轉換；Diffusion Model 則透過 KL 散度最小化學習語意對應
- (D) 三者或多模態應用中皆依賴同一潛在表徵空間 (Shared Latent Space)，僅在解碼器結構不同而已

正確答案：A

詳細解析：

- ✓ (A) 正確：VAE 使用顯式潛在變數（latent code 服從先驗分佈，如高斯），ELBO 損失優化重建+KL，生成偏模糊但語意結構完整；GAN 用對抗式訓練（Generator vs Discriminator），生成銳利但訓練不穩、易模式崩潰；Diffusion 透過正向加噪 + 反向去噪過程，搭配條件 guidance 實現高保真生成，是當前 SOTA。完全描述三者根本差異。
- × (B) 錯誤：完全顛倒。VAE 是顯式（explicit）生成模型（有 ELBO 後驗分佈）；Diffusion 不是隱式（也有顯式去噪過程）；只有 GAN 才是隱式（implicit）（不顯式建模 likelihood）。
- × (C) 錯誤：Diffusion 才是馬爾可夫鏈過程（forward / reverse Markov chain）；VAE/GAN 不用馬爾可夫鏈；且 KL 散度也是 VAE 損失組成。整段描述完全錯誤。
- × (D) 錯誤：三者潛在空間結構完全不同：VAE（高斯潛在空間）、GAN（任意先驗）、Diffusion（漸進噪聲空間）；解碼器也不只是「結構不同」。

核心考點：VAE / GAN / Diffusion 三大生成模型的本質差異。

易混淆對比：VAE（顯式變分推論，模糊但結構好）vs GAN（隱式對抗，銳利但不穩）vs Diffusion（馬可夫鏈去噪，高保真）。

對應章節：L21103 生成式 AI 技術與應用

第 44 題 (114-2-1-Q44)

題幹：某電信公司希望建立一個模型來預測顧客是否即將流失，並進一步模擬不同促銷或服務策略下顧客的行為變化，以生成多樣化的虛擬樣本資料進行 A/B 測試與行銷策略評估。若要同時兼顧預測與資料生成的需求，最適合採用下列哪一種方法？

選項：

- (A) 使用傳統隨機森林（Random Forest）
- (B) 使用邏輯迴歸（Logistic Regression）模型
- (C) 使用變分自編碼器（Variational Autoencoder, VAE）或生成對抗網路（Generative Adversarial Network, GAN）
- (D) 使用強化學習代理（Reinforcement Learning Agent）

正確答案：C

詳細解析：

- ✓ (C) 正確：VAE / GAN 既是生成模型，又可結合下游分類器，能同時滿足「生成虛擬樣本」+「預測流失」。Tabular GAN（如 CTGAN）、Tabular VAE 是模擬顧客行為的標準工具，可生成 A/B 測試虛擬資料。
- × (A) 錯誤：隨機森林是鑑別式分類模型，只能預測類別，無法生成多樣化虛擬樣本。
- × (B) 錯誤：邏輯迴歸是線性鑑別式模型，只做分類預測，無生成能力。
- × (D) 錯誤：強化學習代理可模擬決策序列，但主要用於最佳決策策略學習，非「生成多樣化虛擬樣本」的標準工具；且 RL 訓練成本高、不適合此情境。

核心考點：生成模型（VAE/GAN）同時具備生成與分類能力。

易混淆對比：生成模型（VAE/GAN/Diffusion）vs 鑑別模型（RF/LR/SVM）vs 強化學習（決策序列）。

對應章節：L21103 生成式 AI 技術與應用

延伸補充：生成式 AI 與治理整合速記

以下為生成式 AI 概念辨識與治理框架的整合速記。

考點

- 【考點】生成式 AI 核心 = 創造新內容；判別式 AI 核心 = 分類現有內容。
- 【考點】主流生成式模型架構三大類：GAN、VAE、Diffusion Models（最先進）。

- 【考點】Diffusion Models 透過「從純雜訊一步步還原清晰影像」生成，是當前主流文生圖工具的核心。
- 【考點】GAN 由生成器（Generator）+ 判別器（Discriminator）兩者對抗構成。

補充精華

- GAN 對抗螺旋：生成器造假愈來愈逼真 → 判別器辨真能力同步變強 → 在這種互相施壓下，生成器最終能產出極度逼真的作品。

延伸補充：鑑別式 vs 生成式判讀

考點

- 鑑別式 vs. 生成式 AI 是情境題的關鍵判斷起點：
 - ▶ 看到「分類」「預測」「找出邊界」→ 鑑別式
 - ▶ 看到「創造」「生成全新內容」「GAN（Generative Adversarial Network，生成對抗網路）」→ 生成式
- 題目一出現 GAN，幾乎可直接歸到生成式 AI。

補充比較表

維度	鑑別式 AI (Discriminative AI)	生成式 AI (Generative AI)
學習目標	找決策邊界	學分佈特徵
任務	分類、預測	創造全新內容
一句話	判斷「這屬於哪一類」	產出「一個全新的樣本」
應用	垃圾信過濾、瑕疵偵測	文案生成、圖像生成

補充精華

- 生成式 AI 的核心取舍：創造力 vs. 對生成內容的精確控制——放手讓它發揮會更有創意，但也更難保證輸出符合特定要求，兩者需取得平衡。
- 應用熱門場景：程式碼輔助生成、行銷素材產製、客服知識庫問答。

延伸補充：AI 治理框架

考點

- 可信任 AI 四大原則（必考）：透明性、可解釋性、公平性、問責制
- 歐盟 AI 法案風險分級（必考）；台灣 AI 基本法 2025-12-23（民國 114/12/23）三讀通過（國科會為主政機關（統籌），數位部訂定風險分級框架，各部會就主管領域執行 / 七大原則 / 2 年過渡期）

補充比較表：全球 AI 治理三方

維度	歐盟	美國	台灣
法源性質	硬法（嚴格罰金）	軟法（自律）	基本法（框架）
產業戰略	保護人民	當老大	軟硬整合
主管機關	集中	分散	國科會為主政機關（統籌），數位部訂定風險分級框架，各部會就主管領域執行
算力門檻	10 ²⁵ FLOPs（系統性風險）	10 ²⁶ FLOPs	—

補充比較表：歐盟 AI 法案風險金字塔

風險等級	範例	監管措施
不可接受	政府社會評分系統	完全禁止
高風險	醫療器材 AI、銀行信用評估	嚴格監管（仍可做）
有限風險	聊天機器人	要求透明度
最小風險	一般應用	無額外義務

補充精華 — 台灣 AI 基本法四大開發者關鍵

1. 風險評估提早做 — 設計時就要評估
2. 生成內容標示 — 基本法明定生成內容標示原則，具體強制義務由後續子法與主管機關指引落實（打擊 Deepfake）
3. 資料治理 — 來源合法 + 用多少拿多少

4. 人機協作 (Human-in-the-Loop, HITL) — 重要決策不能讓 AI 自己決定

- 高風險領域：醫療、銀行、生物辨識
- 未成年資料：除家長同意外，**不能拿去商業營利**
- 中小企業解方：鼓勵用聯邦學習

【中級真題與解析 (115 年第一次)】

本節對應 6 題官方真題 (115 年第一次中級 AI 應用規劃師)，每題含 4 選項詳細解析、核心考點、易混淆對比。

第 2 題 (115-1-1-Q02)

題幹：一家新創公司希望對 Llama3 70B 模型進行領域微調 (Domain Fine-Tuning) 以建立企業專用助理，但 GPU 記憶體有限，無法支撐完整模型的反向傳播梯度計算。工程師希望凍結 (freeze) 原模型權重、僅訓練少量額外參數的前提下，評估採用 LoRA (Low-Rank Adaptation) 方案。請問 LoRA 在此場景下的主要優勢為何？

選項：

- (A) 透過知識蒸餾 (Knowledge Distillation) 將 70B 模型壓縮為較小的學生模型
- (B) 對原始模型各層權重進行剪枝 (Pruning)，移除低重要性參數後再進行微調
- (C) 凍結原始預訓練權重，僅在各層加入低秩分解的可訓練矩陣，大幅降低可訓練參數量與 GPU 記憶體需求
- (D) 將模型中的注意力機制改為稀疏注意力 (Sparse Attention)，以降低長序列計算成本

正確答案：C

詳細解析：

- ✓ (C) 正確：LoRA (Low-Rank Adaptation，低秩適應) 的核心設計是：凍結原始權重矩陣 W ，在其旁邊並聯一組低秩分解矩陣 $\Delta W = BA$ (B 為 $d \times r$ 、 A 為 $r \times k$ ，秩 $r \ll d, k$)，只訓練 A 、 B 兩個小矩陣。因為梯度與優化器狀態 (如 Adam 的動量、變異數) 只需為這些低秩矩陣保存，可訓練參數量常降到原模型的 0.1%~1%，GPU 記憶體需求大幅下降——正對應題幹「記憶體有限、凍結原權重、只訓練少量額外參數」三個線索。
- × (A) 錯誤：知識蒸餾 (Knowledge Distillation，知識蒸餾) 是「訓練一個小的學生模型模仿大的教師模型輸出」，屬於模型壓縮，會產生另一個模型；LoRA 不改變也不壓縮原模型本體。
- × (B) 錯誤：剪枝 (Pruning，剪枝) 是移除權重中不重要的連接或神經元來縮小模型，會「修改」原模型結構；LoRA 恰好相反——完全不動原權重，只外掛新參數。
- × (D) 錯誤：稀疏注意力 (Sparse Attention，稀疏注意力) 是改變注意力計算模式以降低長序列的 $O(n^2)$ 計算成本，屬於架構層優化，跟「參數高效微調」是不同維度的問題。

核心考點：PEFT (Parameter-Efficient Fine-Tuning，參數高效微調) 家族中 LoRA 的機制——「凍結原權重 + 低秩旁路矩陣」是判別關鍵字。

易混淆對比：LoRA (外掛低秩矩陣、原模型不動、解決「微調成本」) vs 蒸餾 (造新的小模型、解決「部署成本」) vs 剪枝/量化 (修改或壓縮原模型、解決「推論成本」) ——三者常被同題並列當干擾項，抓住「處理的是訓練階段還是推論階段、動不動原權重」即可判別。

對應章節：L21103 生成式 AI 技術與應用

第 11 題 (115-1-1-Q11)

題幹：某工程師在分析 Transformer 架構時，發現自注意力機制 (Self-Attention) 能夠有效提升模型對序列中長距離依賴關係的建模能力。請問 Self-Attention 的核心功能為何？

選項：

- (A) 透過隱藏狀態的遞迴傳遞，逐步累積序列中的上下文資訊
- (B) 讓序列中每個 token 能與其他所有 token 建立關聯，並根據重要性分配權重
- (C) 對輸入序列進行局部運算，以捕捉相鄰詞之間的關係
- (D) 將整個序列壓縮為固定長度表示，以提供後續任務使用

正確答案：B

詳細解析：

- ✓ (B) 正確：自注意力（Self-Attention，自注意力）機制中，每個 token 產生 Query、Key、Value 三組向量，以 Q·K 相似度計算該 token 對序列中「所有」token（含自己）的注意力權重，再對 Value 加權求和。任意兩個位置之間的路徑長度為 $O(1)$ ——不論相距多遠都直接建立關聯，這正是它擅長長距離依賴的原因，也是題幹的呼應點。
- × (A) 錯誤：「隱藏狀態遞迴傳遞、逐步累積」是 RNN（Recurrent Neural Network，循環神經網路）的運作方式；遞迴使遠距資訊須經多步傳遞，梯度易消失，長距依賴弱——Transformer 就是為取代這個瓶頸而生。
- × (C) 錯誤：「局部運算、捕捉相鄰關係」是 CNN（Convolutional Neural Network，卷積神經網路）卷積核的特性（局部感受野）；Self-Attention 恰是全域運算。
- × (D) 錯誤：「壓縮為固定長度表示」描述的是傳統 Seq2Seq（Sequence-to-Sequence，序列到序列）編碼器的固定上下文向量瓶頸——注意力機制的提出正是為了「避免」把整個序列壓縮成單一向量。

核心考點：Self-Attention = 「每個 token 對所有 token 的加權關聯」，全域、平行、 $O(1)$ 路徑長度；三個錯誤選項分別對應 RNN、CNN、傳統 Seq2Seq 的特徵，是經典的架構對照陷阱。

易混淆對比：RNN（序列遞迴、難平行、長距弱）vs CNN（局部視窗、需疊層擴大感受野）vs Self-Attention（全域直連、可平行、計算量 $O(n^2)$ ）；另 Self-Attention（同一序列內部互相關注）vs Cross-Attention（交叉注意力：一序列關注另一序列，如解碼器看編碼器輸出）。

對應章節：L21103 生成式 AI 技術與應用

第 13 題 (115-1-1-Q13)

題幹：某公司評估兩種方案，將大型語言模型客製化為內部客服助理：方案 A 為提示微調（Prompt Tuning），在輸入端加入可學習的軟提示（Soft Prompt）；方案 B 為傳統微調（Fine-Tuning），以標註問答資料調整模型。兩方案最本質的技術差異為何？

選項：

- (A) 提示微調主要用於降低推論延遲，而傳統微調則用於提升模型容量
- (B) 兩者技術本質相同，差別僅在於學習率（Learning Rate）設定不同
- (C) 傳統微調通常需要更新模型參數，而提示微調主要透過調整輸入表示來影響模型行為
- (D) 提示微調與傳統微調的差異僅在於是否使用預訓練模型

正確答案：C

詳細解析：

- ✓ (C) 正確：兩者的本質分野在「動什麼參數」。傳統微調（Fine-Tuning，微調）更新模型本體權重（全部或大部分層）；提示微調（Prompt Tuning，提示微調）則凍結整個模型，只在輸入嵌入序列前面拼接一段「可學習的連續向量」（Soft Prompt，軟提示），訓練時僅更新這段軟提示向量——透過改變「輸入表示」引導凍結模型產生期望行為。可訓練參數量從數十億降到數萬～數十萬等級。
- × (A) 錯誤：Prompt Tuning 反而會「增加」輸入序列長度、略增推論計算，主要目的是省訓練成本，不是降低推論延遲；「提升模型容量」也不是傳統微調的目的（微調不改變模型大小）。
- × (B) 錯誤：差異在「更新對象」（模型權重 vs 輸入端軟提示）這個結構層面，不是學習率之類的超參數設定。
- × (D) 錯誤：兩者「都」建立在預訓練模型之上，此選項的區分維度不成立。

核心考點：PEFT 判別軸——「模型權重動不動」：Fine-Tuning 動權重；Prompt Tuning 凍結權重、只學輸入端軟提示。

易混淆對比：Prompt Engineering（提示工程：人工撰寫離散文字提示、完全不訓練）vs Prompt Tuning（機器學習連續軟提示向量、需訓練但不動模型）vs LoRA（在模型「內部各層」加低秩矩陣）vs Full Fine-Tuning（全參數更新）——由外到內、成本遞增。

對應章節：L21103 生成式 AI 技術與應用

第 14 題 (115-1-1-Q14)

題幹：某工程師計劃將通用 LLM 在醫療問答語料上進行監督微調 (Supervised Fine-Tuning, SFT)，但發生了災難性遺忘 (Catastrophic Forgetting) 問題。在計算資源有限的情況下，工程師希望透過調整微調策略來緩解此問題。下列哪一種訓練設計最能有效率地學習新任務的同時保留原有能力？

選項：

- (A) 凍結大部分預訓練參數，僅對少量新增模組（如 LoRA 層）進行微調，並控制更新範圍以減少對原有知識的干擾
- (B) 提高學習率 (Learning Rate) 並縮短訓練步數，使模型快速收斂至新任務，避免長時間訓練造成遺忘
- (C) 僅使用醫療語料進行多輪訓練，強化模型對新任務的專注程度
- (D) 增加批次大小 (Batch Size) 以穩定梯度更新，使模型同時保留舊知識與學習新知識

正確答案：A

詳細解析：

- ✓ (A) **正確：**災難性遺忘 (Catastrophic Forgetting，災難性遺忘) 的成因是新任務的梯度更新覆寫了承載原有知識的權重。凍結大部分預訓練參數、只訓練 LoRA 等少量外掛模組，等於把「可被覆寫的範圍」限制在旁路小矩陣內——原權重原封不動，通用能力自然保留；同時可訓練參數少，也符合題幹「計算資源有限」的條件，一石二鳥。
- × (B) **錯誤：**提高學習率會讓每步更新幅度更大，對原有權重的破壞「更劇烈」，是加重遺忘的反向操作；縮短步數也不能抵銷大步長造成的覆寫。
- × (C) **錯誤：**只用新領域語料反覆多輪訓練，正是引發災難性遺忘的典型情境（分佈完全偏向新任務）；緩解方向反而是混入部分原始／通用資料重放 (Replay／Rehearsal，重放)。
- × (D) **錯誤：**加大批次只讓梯度估計更穩定（變異數更小），更新方向仍完全由新任務資料決定，不會保護舊知識——「穩定」不等於「不覆寫」。

核心考點：緩解災難性遺忘的思路＝限制對原權重的更新（凍結＋PEFT）、或讓舊資料持續參與（重放）、或懲罰重要權重的變動（如 EWC，Elastic Weight Consolidation，彈性權重固化）；本題情境「資源有限」指向 PEFT 路線。

易混淆對比：災難性遺忘（訓練階段舊能力被覆寫）vs 過擬合（模型記住訓練集細節、泛化差）——前者是「新舊任務間」的干擾，後者是「訓練與測試分佈間」的落差；解法族也不同（凍結／重放 vs 正則化／資料擴增）。

對應章節：L21103 生成式 AI 技術與應用

第 15 題 (115-1-1-Q15)

題幹：某企業建置一套多代理人 (Multi-Agent) 系統，由一個 Orchestrator Agent 負責任務分配，多個 Worker Agent 分別執行網路搜尋、程式撰寫與結果彙整。若 Orchestrator 發現某 Worker Agent 回傳結果品質不符合預期，從系統容錯與任務可靠性角度，下列哪一項機制最能確保整體任務仍能正確完成？

選項：

- (A) 直接採用該 Worker Agent 的輸出，避免重試機制造成延遲
- (B) Orchestrator 具備結果評估能力，對不合格結果觸發重試 (Retry) 或重新分配給不同 Worker，並記錄失敗原因供後續改善
- (C) 強制所有 Worker Agent 統一使用相同的 LLM 模型，以減少輸出差異
- (D) 當任何一個 Worker 失敗時，整個 Multi-Agent 任務直接中止並通知使用者重新啟動

正確答案：B

詳細解析：

- ✓ (B) **正確：**Orchestrator—Worker（協調者—工作者）架構中，協調者的職責不只是「派工」，還包括「驗收」。具備結果評估（品質檢核）能力後，對不合格輸出觸發重試 (Retry) 或改派其他 Worker，形成閉環容錯；記錄失敗原因則支撐可觀測性 (Observability，可觀測性) 與持續改善。這是分散式系統容錯設計（重試、故障轉移 Failover、日誌）在 Multi-Agent 系統上的直接映射，完整回應題幹「容錯與任務可靠性」的要求。

- × (A) 錯誤：明知品質不合格仍直接採用，等於放棄品質保證——錯誤輸出會向下游傳播（例如彙整 Agent 拿到錯誤搜尋結果），低延遲換來錯誤結果，違背「任務正確完成」的目標。
- × (C) 錯誤：統一模型只是減少 Worker 間的「風格差異」，與單次輸出品質不佳的容錯無關；而且不同任務（搜尋、寫程式）本就可能適合不同模型，強制統一反而喪失專業化優勢。
- × (D) 錯誤：單點失敗就整體中止（Fail-Stop）是最脆弱的設計，浪費其他 Worker 已完成的工作；容錯設計的精神正是「局部失敗、局部恢復」。

核心考點：Multi-Agent 系統的可靠性設計——Orchestrator 需具備「評估→重試／重派→記錄」的閉環機制；情境線索是「容錯與任務可靠性角度」。

易混淆對比：重試（Retry，同一或不同 Worker 再做一次，處理暫時性失敗）vs 斷路器（Circuit Breaker，對「持續」失敗的依賴暫停呼叫，防連鎖故障）——前者處理偶發錯誤、後者處理系統性故障，層次不同。

對應章節：L21103 生成式 AI 技術與應用

第 16 題 (115-1-1-Q16)

題幹：一位工程師正在實作一個 ReAct 框架的 AI Agent，該 Agent 需要回答「台灣目前最大的電動車充電站營運商是哪間公司，以及其充電樁總數」。

Agent 的工具清單如下：

- web_search(query)：回傳搜尋結果摘要
- get_webpage(url)：回傳網頁內文
- calculator(expression)：回傳計算結果
- get_current_date()：回傳今日日期

工程師設計了以下的 System Prompt 與 ReAct Loop，請問此 Agent 設計存在哪些問題？應如何改善？

[System Prompt]

你是一個資料查詢助理。
每次只能使用一個工具。
當你知道答案時，直接輸出最終答案。

[第一輪 Agent 輸出]

Thought: 我已經知道台灣電動車市場的概況，不需要搜尋，可以直接回答。
Action: 無
Answer: 台灣最大充電站營運商是 XX 公司，共有 500 個充電樁。

選項：

- (A) System Prompt 未要求 Agent 在回答前使用工具驗證，導致直接依賴既有知識產生幻覺（Hallucination）；應明確規定即時性問題需先執行 web_search
- (B) 工具清單提供了 calculator 與 get_current_date，屬於多餘工具，可能增加 Agent 的選擇複雜度
- (C) ReAct 框架的核心問題在於 Thought 步驟佔用過多 token，應移除 Thought 欄位，直接讓 Agent 輸出 Action，以提升推理效率
- (D) Agent 應在第一輪就呼叫所有可用工具並彙整結果，避免多輪 Loop 造成的延遲

正確答案：A

詳細解析：

- ✓ (A) 正確：題目問的是「目前最大」——時效性問題，答案會隨時間變動，超出 LLM 訓練資料截止日的知識範圍。範例輸出顯示 Agent 在 Thought 就宣稱「已經知道、不需搜尋」，跳過工具直接作答，這正是幻覺（Hallucination，幻覺：模型自信地產生無事實根據的內容）的高風險行為。System Prompt 的缺陷在於允許「當你知道答案時直接輸出」，卻沒有規定「即時性／事實性問題必須先以 web_search 等工具查證」。ReAct（Reasoning + Acting，推理加行動）框架的價值正是讓模型把推理與工具取證交錯進行——設計 Prompt 時必須明確約束何時「必須」行動。
- × (B) 錯誤：calculator 與 get_current_date 對本任務其實有潛在用途（加總充電樁數量、確認「目前」的時間基準）；即使暫時用不到，多備工具不是此 Agent 失敗的原因——失敗原因是「該用工具時沒用」。
- × (C) 錯誤：Thought（思考）步驟是 ReAct 的核心貢獻——顯式推理讓 Agent 規劃下一步行動並提升可解釋性；移除 Thought 等於退化成無推理的工具呼叫，本末倒置。

- × (D) 錯誤：一次呼叫所有工具違反 ReAct 的迭代精神：後續行動應根據前一步觀察（Observation）動態決定（例如先 search 拿到 URL 再 get_webpage），盲目全呼叫既浪費資源也無從決定參數。

核心考點：ReAct Agent 的 Prompt 設計——對時效性／事實性問題必須強制「先取證後作答」；情境中的決定性線索是題目含「目前」二字+Agent 第一輪就「Action: 無」直接輸出答案。

易混淆對比：ReAct (Thought→Action→Observation 循環 邊推理邊用工具取證) vs CoT (Chain-of-Thought，思維鏈：只有推理步驟、不與外部工具互動) ——CoT 解決「推理深度」，ReAct 額外解決「知識時效與事實接地 (Grounding)」。

對應章節：L21103 生成式 AI 技術與應用

L21104 多模態人工智慧應用

※ 考綱重點 (L21104 多模態人工智慧應用)：多模態整合（文字、圖像、聲音等）、跨模態對齊與融合（CLIP / Flamingo / GPT-4o / Gemini）、應用場域與評估方法

2024-2025 熱門新興主題：多模態 AI (Multimodal AI) 是繼 LLM 之後最受矚目的 AI 範式，GPT-4o、Gemini 2.0、Claude Sonnet 4、Sora 等指標性模型皆為原生多模態。本章為 iPAS AI 應用規劃師中級的「新興技術」高頻考點。

章前跨章節導引：

- L21101 自然語言處理技術與應用 — NLP 基礎（文字模態處理）
- L21102 電腦視覺技術與應用 — CV 基礎（影像模態處理）
- L21103 生成式 AI 技術與應用 — GenAI 與多模態生成模型
- L23203 深度學習原理與框架（見第三冊） — Transformer 架構多模態擴展基礎
- L23402 演算法偏見與公平性（見第三冊） — 跨模態偏見議題
- L23401 數據隱私、安全與合規（見第三冊） — 多模態資料隱私
- L21302 AI 技術系統集成與部署 — 多模態系統部署

一、多模態 AI 核心概念與範疇

1.1 模態 (Modality) 的完整定義

模態 (Modality)：資訊以某種感官或形式呈現的型態。AI 系統中「模態」對應到一種特定資料表達方式。

模態類別	英文	結構特性	典型範例	代表技術
文字	Text	離散符號、語意性強、序列性	自然語言、描述、問句、程式碼	NLP / Transformer
影像	Image	空間二維、顏色紋理、像素密集	照片、繪畫、X-ray、衛星圖	CNN / ViT
影片	Video	時空四維 (H×W×T×C)、運動資訊	監視器影像、電影、社群短片	3D-CNN / Video Transformer
音訊／語音	Audio / Speech	時間序列、頻譜、情緒線索	語音內容、音樂、背景聲	Wav2Vec / Whisper
結構化資料	Structured Data	表格、欄位、關聯	EMR 電子病歷、POS 交易、IoT 紀錄	Tabular Transformer
感測器資料	Sensor Data	連續、多通道、時間戳	Lidar 點雲、加速度計、GPS、溫度	Sensor Fusion Network
3D 點雲／模型	3D / Point Cloud	三維座標 + 屬性、無序點集合	自駕車 Lidar、AR/VR 模型	PointNet / PointNet++
醫學影像	Medical Imaging	高解析度、灰階、體積資料	CT、MRI、超音波、病理切片	3D-UNet / MedSAM
生理訊號	Biosignal	一維時間序列、低訊雜比	ECG、EEG、EMG、PPG	1D-CNN / Bio-Transformer

1.2 單模態 vs 多模態 vs 跨模態（核心區別）

概念	英文	定義	輸入 / 輸出	範例
單模態	Unimodal	僅處理單一種模態	同模態進、同模態出	BERT（純文字）、ResNet（純影像）
多模態	Multimodal	同時接收 2 種以上模態作為輸入	多模態進、單／多模態出	GPT-4V（圖+文→文）、Whisper（音→文）
跨模態	Cross-modal	從 A 模態轉換到 B 模態（強調轉換）	單模態進、不同模態出	DALL·E（文→圖）、TTS（文→音）

【陷阱 1】：「多模態（Multimodal）」≠「多任務（Multi-task）」。前者強調多種輸入模態（如圖+文），後者強調多種任務輸出（如同模型做分類+偵測+分割）。考題常混淆。

【陷阱 2】：「跨模態（Cross-modal）」與「多模態（Multimodal）」常互用，但嚴格定義：跨模態強調「模態間轉換」（A→B），多模態強調「模態並用」（A+B→C）。實務上 GPT-4o 兩者兼具。

1.3 多模態 AI 核心三大挑戰（Baltrusaitis et al. 2018 經典分類）

【考點】這是多模態 AI 的經典理論框架，論文「Multimodal Machine Learning: A Survey and Taxonomy」提出五大挑戰，其中前三大為基礎技術核心：

挑戰	英文	核心問題	對應技術
表徵	Representation	如何把不同模態編碼成可比較或可結合的向量？	Joint / Coordinated Embedding
對齊	Alignment	不同模態的元素如何對應到一起？	Cross-Attention / DTW
融合	Fusion	多模態資訊如何整合做決策？	Early / Late / Hybrid Fusion
翻譯	Translation	如何從 A 模態生成 B 模態？	Text-to-Image / Image-to-Text
共學習	Co-learning	模態間如何互相提升學習？	Knowledge Distillation across Modalities

二、三大核心技術深度解析

2.1 表徵（Representation）

將不同模態資料映射至共同向量空間，使模型能跨模態比較與運算。

表徵類型	英文	機制	範例模型	適用任務
聯合表徵	Joint Representation	所有模態映射到同一個共享空間	CLIP、ImageBind	跨模態檢索、零樣本分類
協調表徵	Coordinated Representation	各模態有獨立空間，但透過約束保持對應關係	DeViSE、Word2Visual Vec	跨模態相似度、模態互補

【判別表 1】聯合 vs 協調表徵：

條件	推薦
需要直接做向量相似度比對（內積/餘弦）	聯合表徵（Joint）
模態異質性高、各自有獨立用途	協調表徵（Coordinated）
零樣本跨模態檢索	聯合表徵（CLIP 典範）

2.2 對齊（Alignment）

找出不同模態中對應的元素（例：影像區域 ↔ 文字單詞）。

對齊類型	英文	機制	範例
硬對齊	Hard Alignment	一對一明確對應（離散）	字幕逐字對齊音訊（DTW）
軟對齊	Soft Alignment	透過注意力機制權重對應（連續）	Cross-Attention（影像 token ↔ 文字 token）

Cross-Attention 機制（多模態核心）：

Query：來自模態 A（例：文字 token）
Key / Value：來自模態 B（例：影像 patch）
Output = softmax(QK^T / √d) · V

【考點】 Cross-Attention 是現代 VLM（Vision-Language Model）的核心，BLIP-2、Flamingo、LLaVA 皆使用此機制讓 LLM「看懂」影像。

2.3 融合（Fusion）—— 多模態最高頻考點

融合策略五大類型對照表：

融合策略	英文	融合層級	訊息保留	維度／計算	優點	缺點	典型應用
早期融合	Early Fusion	原始資料／低階特徵層	最完整	維度爆炸高	模態間互動最強、訊息損失最少	維度高、需大量資料、對齊敏感	多攝像頭、感測器資料
晚期融合	Late Fusion	決策／輸出層	較少	計算分散低	模組化、各模態可獨立訓練	模態互動弱、無法挖深層關聯	異質模態（音+影）
混合融合	Hybrid Fusion	混合多層級	中等	中等	兼顧互動與穩定	設計複雜	醫療多模態診斷
中間融合	Intermediate Fusion	中層特徵	中等	中等	Transformer 時代主流	需細調融合點	BLIP、LLaVA
跨注意力融合	Cross-Modal Attention Fusion	注意力層	強動態	高（O(n·m)）	動態對齊、可解釋性高	計算成本高	GPT-4V、Gemini

【判別表 2】 Early / Late / Hybrid 融合何時用：

條件	推薦融合方式	理由
模態同質性高、訊號相似（多攝像頭、多麥克風）	Early Fusion	訊息保留最完整
模態異質性高（音 + 影 + 文）、各自需特化	Late Fusion	各模態可用最適合的子網路
想兼顧深層互動與穩定性	Hybrid Fusion	多醫療應用採此
需要動態對齊（不同樣本對應關係不同）	Cross-Modal Attention	Transformer 時代首選
訓練資料不足、模態獨立性高	Late Fusion	早融合需大量配對資料

【陷阱 3】：「Early Fusion 一定比 Late Fusion 好」是錯的。Early Fusion 在訊息保留上勝出，但對標註對齊極度敏感、維度容易爆炸、需更多訓練資料。實務上 Late / Hybrid 反而更穩。

三、多模態翻譯（Translation）任務分類

【考點】 多模態翻譯 = 從 A 模態生成 B 模態，這是 GenAI 時代爆紅的應用方向。

任務類別	英文	輸入 → 輸出	代表模型	開發者 / 年份
文生圖	Text-to-Image (T2I)	文字 → 影像	DALL· E 3、Stable Diffusion、Midjourney v6、Imagen	OpenAI / Stability AI / MJ / Google
圖生文	Image-to-Text / Image Captioning	影像 → 文字	BLIP、BLIP-2、Show and Tell、GPT-4V	Salesforce / Salesforce / Google / OpenAI
文生語音	Text-to-Speech (TTS)	文字 → 音訊	Tacotron 2、VALL-E、ElevenLabs	Google / Microsoft / ElevenLabs
語音轉文字	Speech-to-Text (STT/ASR)	音訊 → 文字	Whisper、Wav2Vec 2.0、Conformer	OpenAI / Meta / Google
文生影片	Text-to-Video (T2V)	文字 → 影片	Sora、Runway Gen-3、Pika、Veo	OpenAI / Runway / Pika / Google
圖生影片	Image-to-Video (I2V)	影像 → 影片	Runway、Pika、Stable Video Diffusion	Runway / Pika / Stability AI
影片轉文字	Video-to-Text	影片 → 描述	Video-LLaMA、VideoChat	開源學術

任務類別	英文	輸入 → 輸出	代表模型	開發者 / 年份
音訊轉影像	Audio-to-Image	聲音 → 圖像	AudioToken、Sound2Sight	學術研究
跨語言語音	Speech-to-Speech Translation	語音 → 不同語言語音	SeamlessM4T	Meta

【陷阱 4】：Text-to-Image 並非單一技術，主流有兩派：Diffusion Models (DALL·E 2/3、SD、Midjourney 主流) 與 Autoregressive (DALL·E 1、Parti)。GAN (如 StackGAN) 已基本退場。

四、代表多模態模型詳解

4.1 對比學習雙塔派 — CLIP 系列

CLIP (Contrastive Language-Image Pre-training, 對比式語言—影像預訓練) — OpenAI 2021

組件	內容
架構	雙塔架構：影像編碼器 (ViT 或 ResNet) + 文字編碼器 (Transformer)
訓練資料	4 億對網路爬取的圖文對 (WebImageText, WIT)
訓練目標	對比損失 (Contrastive Loss / InfoNCE)，讓匹配對距離近、不匹配對距離遠
主要功能	零樣本影像分類、圖文檢索、文字引導生成 (DALL·E 2 用 CLIP 做 guidance)
突破點	零樣本 (Zero-shot) 能力：未見過的類別也能用「a photo of a [class]」prompt 分類
限制	對細節、空間關係、計數能力弱；不會生成 (只比對)

【陷阱 5】：CLIP 不是生成模型，它只能「判斷圖文是否匹配」，不能直接生圖。生圖需 DALL·E、SD 等擴散模型，CLIP 在這些系統中扮演「文字條件提供者 (text encoder)」或「生成結果評分器 (CLIP guidance)」。

4.2 擴散生成派 — DALL·E / Stable Diffusion / Midjourney

模型	全名	開發者	發布	開源	核心特色
DALL·E 2	—	OpenAI	2022	否	unCLIP 架構：CLIP latent → 擴散解碼
DALL·E 3	—	OpenAI	2023	否	整合 ChatGPT，prompt 自動改寫提升細節
Stable Diffusion 1.5/2	—	Stability AI	2022	是	Latent Diffusion，可在消費級 GPU 跑
SDXL	Stable Diffusion XL	Stability AI	2023	是	雙 text encoder，畫質大幅提升
SD3	Stable Diffusion 3	Stability AI	2024	是	MMDiT (Multimodal Diffusion Transformer)
Midjourney v6	—	Midjourney	2024	否	商業 SOTA 美術風格
Imagen 3	—	Google	2024	否	文字理解力強、寫實派
Flux.1	—	Black Forest Labs	2024	部分	開源新霸主、prompt 跟隨度高

4.3 LLM + Vision Encoder 派 — 多模態 LLM (MLLM)

模型	開發者	發布	開源	視覺架構	特色
GPT-4V (Vision)	OpenAI	2023	否	GPT-4 + Vision Encoder (後接)	第一代主流商用 MLLM
GPT-4o (Omni)	OpenAI	2024	否	原生多模態 (文+圖+音同模型)	端到端低延遲、可即時對話
Claude 3.5 Sonnet / Claude Sonnet 4	Anthropic	2024-2025	否	LLM + Vision	圖表、文件理解強
Gemini 1.5 Pro	Google	2024	否	原生多模態	1M-2M token 長上下文
Gemini 2.0 Flash	Google	2024	否	原生多模態 + 工具呼叫	即時串流、低延遲
LLaVA / LLaVA-Next	UW-Madison 等	2023-2024	是	Vicuna + CLIP ViT	開源 MLLM 代表

模型	開發者	發布	開源	視覺架構	特色
BLIP-2	Salesforce	2023	是	Q-Former + 凍結 LLM	高效訓練（凍結大部分參數）
Flamingo	DeepMind	2022	否	Perceiver Resampler + Chinchilla	Few-shot 多模態鼻祖
Qwen-VL / Qwen2-VL	Alibaba	2023-2024	是	Qwen + ViT	中文多模態強
InternVL / InternVL2	Shanghai AI Lab	2024	是	大規模開源 VLM	部分超越 GPT-4V

4.4 影片生成派

模型	開發者	發布	特色
Sora	OpenAI	2024	60 秒高品質、世界模擬器概念、DiT 架構
Runway Gen-3	Runway	2024	商業影片生成主流
Pika 1.5	Pika Labs	2024	鏡頭運動控制
Veo / Veo 2	Google	2024	高解析、長秒數
Stable Video Diffusion	Stability AI	2024	開源影片生成

4.5 統一多模態派

模型	開發者	模態	特色
ImageBind	Meta	影像 + 文 + 音 + 深度 + 紅外 + IMU	六模態統一向量空間
Meta-Transformer	學術	12 種模態	通用骨幹網路
Unified-IO 2	AI2	文 + 圖 + 音 + 影	一個模型多任務

4.6 模型對照總表（精華）

模型	派系	開源	典型應用	發布
CLIP	對比雙塔	是	零樣本分類、檢索	2021
DALL·E 3	擴散	否	文生圖	2023
Stable Diffusion 3	擴散	是	文生圖、可微調	2024
Midjourney v6	擴散	否	美術級文生圖	2024
GPT-4o	LLM+多模態原生	否	即時對話、看圖、聽說	2024
Gemini 2.0	LLM+多模態原生	否	長上下文、工具呼叫	2024
Claude Sonnet 4	LLM+Vision	否	文件、圖表理解	2025
LLaVA-Next	LLM+CLIP	是	開源 VQA / 多模態對話	2024
BLIP-2	Q-Former	是	圖文問答、Captioning	2023
Flamingo	Perceiver	否	Few-shot 多模態	2022
Sora	擴散影片	否	文生影片	2024
ImageBind	統一表徵	是	六模態檢索	2023

【陷阱 6】：GPT-4V 與 GPT-4o 不同。GPT-4V 是 GPT-4 後接 Vision Encoder，音訊需透過 Whisper + TTS 串接（延遲高）；GPT-4o（Omni）是原生端到端多模態，音訊與影像直接進同一個 Transformer，延遲降至 ~320 ms，可做即時對話。

五、VLM（Vision-Language Model）架構演進

階段	代表	年份	架構特徵	訓練方式
Stage 1：雙塔對比學習	CLIP、ALIGN	2021	影像 / 文字各自編碼器，對比學習對齊	InfoNCE Contrastive Loss
Stage 2：Encoder-Decoder	BLIP、OFA	2022	編碼器處理多模態輸入、解碼器生成文字	Captioning + ITM + ITC 多任務
Stage 3：LLM + Vision Encoder	LLaVA、MiniGPT-4、GPT-4V	2023	凍結 LLM + 小型 Adapter / Projector 接視覺特徵	Visual Instruction Tuning

階段	代表	年份	架構特徵	訓練方式
Stage 4：原生多模態	GPT-4o、 Gemini Native、Chameleon	2024	文、圖、音 token 化進同一 Transformer	端到端多模態預訓練
Stage 5 (萌芽) :統一任意模態	ImageBind、Unified-IO 2、Meta-Transformer	2023-2024	任意模態進、任意模態出	大規模對齊預訓練

【判別表 3】 雙塔架構 vs LLM+Encoder 架構：

條件	雙塔（CLIP 派）	LLM+Encoder（LLaVA 派）
主要任務	跨模態檢索、零樣本分類	多模態對話、VQA、推理
計算成本	推理快（內積）	推理慢（自回歸生成）
可解釋性	高（向量距離）	中（注意力可視化）
互動深度	低（淺融合）	高（LLM 深層推理）
訓練資料	圖文配對即可	需指令微調資料

【判別表 4】 對比學習 vs 生成式預訓練（CLIP vs BLIP）：

維度	CLIP（對比學習）	BLIP（生成式）
訓練目標	對比損失 InfoNCE	Captioning + Matching + Contrastive
是否能生成	否	是（可生成 caption）
零樣本能力	極強	中等
VQA 能力	弱	強
訓練成本	中	高

六、多模態評估指標

多模態任務需用**任務特定指標**，下表為高頻考點：

指標	英文全名	評估什麼	計算方式	適用任務	優缺點
CLIPScore	—	文字與生成影像的語意對齊度	CLIP embedding 餘弦相似度	文生圖品質	與 CLIP 相同偏見、不評細節
FID	Fréchet Inception Distance	生成影像分布與真實影像分布距離	Inception-v3 特徵層 Fréchet 距離	生成影像品質	越低越好；對少樣本不穩定
IS	Inception Score	生成影像清晰度與多樣性	Inception 分類熵	生成影像品質	已被 FID 取代
LPIPS	Learned Perceptual Image Patch Similarity	影像感知相似度（接近人眼）	深度網路特徵差異	影像重建、生成	比 PSNR/SSIM 更貼近人眼
CIDEr	Consensus-based Image Description Evaluation	Captioning 與多參考的共識度	TF-IDF 加權 n-gram	圖像描述	Captioning 主流指標
SPICE	Semantic Propositional Image Caption Evaluation	語意命題級評估（物件、屬性、關係）	場景圖比對	圖像描述	比 BLEU 更貼語意
METEOR	Metric for Evaluation of Translation with Explicit ORdering	翻譯與 caption 評估	同義詞、詞幹比對	翻譯、Captioning	比 BLEU 更貼人類

指標	英文全名	評估什麼	計算方式	適用任務	優缺點
BLEU	Bilingual Evaluation Understudy	n-gram 重疊度	n-gram precision	翻譯、Captioning	不評語意、僅字面
ROUGE	Recall-Oriented Understudy for Gisting Evaluation	摘要 / Captioning 召回	n-gram recall	摘要、Captioning	著重召回
VQA Accuracy	Visual Question Answering Accuracy	視覺問答正確率	預測答案 vs 標準答案	VQA	多參考容錯
R@K	Recall at K	前 K 個檢索結果中命中率	命中數 / 總查詢	跨模態檢索	K 常取 1/5/10
WER	Word Error Rate	語音辨識錯誤率	編輯距離 / 總詞數	ASR	越低越好

【考點】FID 越低越好（與真實分布越近）；CIDEr、BLEU、CLIPScore 越高越好。考題常給出數值問哪個模型最佳。

七、跨模態檢索與多模態 RAG

7.1 跨模態檢索 (Cross-modal Retrieval)

子任務	英文	應用
文搜圖	Text-to-Image Retrieval	「找一張日落海邊的照片」
圖搜文	Image-to-Text Retrieval	商品圖 → 找對應描述
圖搜圖	Image-to-Image Retrieval	以圖搜物（電商）
跨模態檢索評估	Cross-modal Retrieval Eval	R@1、R@5、R@10

7.2 向量資料庫整合

向量資料庫	開發者	部署	特色
Pinecone	Pinecone	SaaS	商業託管、易上手
Weaviate	SeMI Tech	開源 + 雲端	內建模組化 vectorizer
Milvus	Zilliz	開源	大規模、高效能
Chroma	Chroma	開源	輕量、適合原型
Qdrant	Qdrant	開源 + 雲端	Rust 寫、效能高
pgvector	PostgreSQL 擴展	自架	整合既有 PG

7.3 多模態 RAG (Retrieval-Augmented Generation)

標準流程：

1. 文件 / 影像 / 影片切片 → 用 CLIP / ImageBind 編碼 → 存向量資料庫
2. 使用者查詢（文 / 圖）→ 同編碼器轉向量
3. 向量資料庫 ANN 檢索 Top-K 相關片段（可跨模態）
4. 把檢索到的多模態內容 + 查詢 → 餵給 MLLM (GPT-4o / Gemini) 生成

多模態 RAG 典型應用：醫療影像 + 病歷文字檢索、企業內 PDF（含圖表）問答、影片內容檢索。

→ 與生成式 AI / RAG 完整討論見 L21103 生成式 AI 技術與應用

八、多模態 AI 實際應用情境

領域	應用	整合模態	代表系統	評估指標	關鍵挑戰
醫學影像問答	Radiology Report Generation 放射科報告生成	CT/MRI 影像 + 既有報告 + EMR	RadFM、Med-Flamingo、ChatCAD	ROUGE、CIDEr、臨床準確率	醫療幻覺、隱私（HIPAA）

領域	應用	整合模態	代表系統	評估指標	關鍵挑戰
自動駕駛多感測融合	環境感知與決策	Camera + Lidar + Radar + GPS + IMU	Tesla FSD、Waymo Driver	mAP、IoU、安全里程	即時性、極端天氣、感測器失效
機器人視覺語言操控	自然語言指揮機器人	影像 + 文字指令 + 動作	RT-2、PaLM-E、Open-VLA	任務成功率、泛化測試	動作空間映射、安全性
電商以圖搜物	圖像式商品搜尋	商品圖 + 商品描述 + 評論	Amazon Lens、Google Lens	Recall@K、CTR、轉換率	商品庫即時更新、長尾類別
無障礙輔助	圖像描述給視障者	影像 → 語音描述	Be My AI、Seeing AI	BLEU、CIDEr、使用者滿意度	描述準確性、即時性
內容審核	多模態仇恨偵測、Deepfake	圖+文+音	Meta Hateful Memes	F1、AUROC	諷刺、文化背景、新興攻擊
元宇宙與虛擬人	Avatar 語音 + 手勢控制	語音 + 文字 + 表情 + 姿勢 + 3D	Apple Vision Pro Persona	Latency、WER、姿勢準確率	即時性、自然度
零售動線分析	店面布局優化	攝影機 + POS + 評論 + 社群	RetailNext、Trax	Precision、IoU、F1	多源整合、隱私
教育多模態學習	互動式 AI 家教	文 + 圖 + 語音 + 手寫	Khanmigo、Speak	學習成果、互動次數	因材施教、年齡適配

8.1 機器人多模態：RT-2 與 PaLM-E (DeepMind / Google)

- RT-2 (Robotic Transformer 2)：將動作 (action) 也 token 化，與文字、影像一同進 Transformer，實現「看到+聽到→直接輸出動作」。
- PaLM-E (Embodied Multimodal Language Model)：將機器人感測器資料、影像、文字統一接入 PaLM 大語言模型，做具身化推理。

九、多模態風險與治理

9.1 主要風險

風險類別	挑戰	解決策略
資料對齊與標註	時間戳對齊、語意一致、標註成本高	動態時間規整 (DTW, Dynamic Time Warping)、弱監督、自動標註、Pseudo-labeling
運算與部署	多模態模型參數巨大、邊緣設備資源有限	模型壓縮 (剪枝 Pruning、量化 Quantization、知識蒸餾 Knowledge Distillation)、LoRA、TensorRT/OpenVINO/CoreML 加速、混合雲端部署
隱私與法規	敏感資料 (臉部、聲紋、生理訊號) 易被竊取或誤用	匿名化、端到端加密 (End-to-End Encryption, E2EE)、聯邦學習 (Federated Learning)、差分隱私 (Differential Privacy)、GDPR/PDPA 合規
Deepfake 與深度偽造	多模態合成攻擊 (換臉、變聲、偽造影片)	Deepfake 偵測器、C2PA (Coalition for Content Provenance and Authenticity, 內容來源與真實性聯盟) 內容憑證、數位浮水印 (Watermarking)
多模態幻覺	圖文不一致、模型「看圖編故事」	RAG 接地、Chain-of-Thought + Verification、Visual Grounding 評估
跨模態偏見	訓練資料中性別、種族、文化偏見傳遞至圖文	資料去偏 (Debiasing)、公平性指標審計、多元化訓練集
著作權	訓練資料含未授權圖像 / 文字	授權資料集、選擇性訓練、Opt-out 機制

9.2 多模態幻覺 (Multimodal Hallucination)

【考點】多模態幻覺指 MLLM 對影像描述出不存在的物件、屬性或關係。

幻覺類別	範例
Object Hallucination	描述圖中沒有的物件（如圖中沒貓卻說有貓）
Attribute Hallucination	物件存在但屬性錯誤（紅車說成藍車）
Relation Hallucination	物件關係錯誤（人坐在椅子說成站著）

偵測基準：POPE、CHAIR、MMHal-Bench、AMBER 等。

9.3 跨模態偏見與公平性

→ 演算法偏見完整討論見 L23402 演算法偏見與公平性（見第三冊）

偏見類型	多模態具體表現
表徵偏見	CLIP 將「醫生」更常對應到男性影像
文化偏見	文生圖「婚禮」預設西式白紗，忽略印度 / 華人習俗
種族偏見	人臉辨識在深膚色族群準確率較低
性別偏見	Image Captioning 自動標註職業時性別刻板

9.4 著作權問題

→ AI 風險完整討論見 L21203 AI 風險管理

- 訓練資料（如 LAION-5B）含未授權圖像 → 美國、日本、歐盟訴訟不斷
- 生成圖風格模仿活躍藝術家 → 法律與倫理爭議
- 解方：選擇性訓練資料、藝術家 Opt-out（如 Stable Diffusion 3）、來源透明（C2PA）

十、多模態 AI 未來趨勢

趨勢	內涵	代表案例
統一架構（Any-to-Any）	朝通用多模態模型發展，支援任意模態輸入與輸出	GPT-4o、Gemini Native、Unified-IO 2
原生多模態	不再用「拼接」方式，從預訓練就多模態	GPT-4o、Gemini、Chameleon
邊緣部署	壓縮 + 最佳化、自適應推論	Phi-3-Vision、MobileVLM、CoreML 部署
自監督學習	大規模未標註資料預訓練	MAE、BEiT-3、Data2Vec
多模態代理人	主動感知、理解、回應	GPT-4o Voice、Gemini Live、機器人 VLA
World Model	多模態世界模擬	Sora（物理世界模擬）、Genie 2
跨模態工具呼叫	MLLM 直接呼叫圖像生成、影片生成工具	GPT-4o + DALL·E 3、Gemini + Imagen
法規與倫理框架	C2PA、EU AI Act 對生成式內容要求	C2PA、Adobe Content Credentials

【L21104 本章必考點 Cheat Sheet】

A. 必背三件套（首次出現要寫全）

- CLIP（Contrastive Language-Image Pre-training，對比式語言—影像預訓練）
- MLLM（Multimodal Large Language Model，多模態大語言模型）
- VLM（Vision-Language Model，視覺語言模型）
- VQA（Visual Question Answering，視覺問答）
- T2I / T2V（Text-to-Image / Text-to-Video，文生圖 / 文生影片）
- ASR（Automatic Speech Recognition，自動語音辨識）
- TTS（Text-to-Speech，語音合成）
- FID（Fréchet Inception Distance）
- CIDEr（Consensus-based Image Description Evaluation）
- DTW（Dynamic Time Warping，動態時間規整）

B. 必記三大挑戰口訣

「表對融」三字訣：

- 表徵（Representation）— 怎麼編碼
- 對齊（Alignment）— 怎麼對應

- 融合 (Fusion) — 怎麼整合

C. 融合策略五字口訣

「早晚混間注」：早期 / 晚期 / 混合 / 中間 / 跨模態注意力。

D. 必背模型派系四口訣

「對擴 LLM 統」：

- 對比雙塔 (CLIP)
- 擴散生成 (DALL·E、SD、Sora)
- LLM+Vision (LLaVA、GPT-4V)
- 統一原生 (GPT-4o、Gemini Native、ImageBind)

E. 高頻陷阱題彙整

1. 多模態 ≠ 多任務 (前者多輸入，後者多輸出)
2. 跨模態 ≠ 多模態 (前者轉換，後者並用)
3. CLIP 不會生成 (只做對比比對，生圖需擴散模型)
4. GPT-4V ≠ GPT-4o (後者原生多模態端到端、延遲極低)
5. Early Fusion 訊息保留多但維度爆炸，不一定比 Late 好
6. FID 越低越好，CIDEr / BLEU / CLIPScore 越高越好
7. 多模態模型對未見模態組合表現可能急遽下降 (OOD 問題)
8. Sora 是擴散模型 (DiT, Diffusion Transformer)，非 GAN
9. Whisper 是 ASR 模型 (語音→文字)，不是 TTS
10. ImageBind 統一六模態：影像、文、音、深度、紅外、IMU

F. 一頁式關鍵對照

對照組	主要差異
單模態 vs 多模態 vs 跨模態	一種 / 多種輸入 / 模態轉換
Joint vs Coordinated Embedding	共享空間 / 獨立空間
Hard vs Soft Alignment	一對一 / 注意力權重
Early vs Late Fusion	資料層融合 / 決策層融合
Cross-Attention vs Self-Attention	跨模態 / 同模態
CLIP vs BLIP	對比 vs 生成
GPT-4V vs GPT-4o	拼接 vs 原生多模態
Diffusion vs Autoregressive T2I	主流 (SD/DALL·E) vs 退場 (DALL·E 1)
FID (越低越好) vs CIDEr (越高越好)	影像分布距離 / Captioning 共識

→ 資料隱私與保護法規 見 L23401 數據隱私、安全與合規 (見第三冊)；模型部署 見 L21302 AI 技術系統集成與部署；演算法偏見 見 L23402 演算法偏見與公平性 (見第三冊)；AI 風險管理 見 L21203 AI 風險管理

延伸補充：多模態 AI 重點整理

以下為多模態 AI 章節的延伸整理，含融合策略、代表模型與落地挑戰。

考點

- 多模態 (Multimodal) AI 三大融合策略：
 - ▶ 早期融合 (Early Fusion)：在底層特徵階段就合併，模型一起學
 - ▶ 晚期融合 (Late Fusion)：各模態先各自訓練，最後再合併決策
 - ▶ 混合融合 (Hybrid Fusion)：在中間某幾層才融合
- 三大代表模型：
 - ▶ CLIP (Contrastive Language-Image Pre-training)：圖文對齊的基礎模型，OpenAI
 - ▶ BLIP (Bootstrapping Language-Image Pre-training)：可同時做圖文生成與理解

- Flamingo：DeepMind 的少樣本視覺語言模型
- 多模態落地的四大難關：
 1. 資料對齊：影像、聲音的時間軸要同步（毫秒級偏差就可能讓自駕車誤判）
 2. 標註成本高：用半監督學習 + 主動學習（Active Learning，挑出模型最不確定的片段交人工）來降低成本
 3. 部署資源：剪枝（Pruning）+ 量化（Quantization）
 4. 法務隱私：差分隱私（Differential Privacy）+ 聯邦學習（Federated Learning）
- 考點：題目提「即時性／隱私／節省頻寬」→ 答案幾乎都是**邊緣運算（Edge Computing）**
- 進階考點：「對硬體加速更友善」→ **結構化剪枝**（規律地整層整層修剪）

陷阱

- 陷阱：直覺以為「多模態資料越多越好」→ 真正核心是「對齊」（時間軸同步比資料量更關鍵）
- 陷阱：「降低標註成本」→ 選**半監督學習**（少量標籤 + 偽標籤），不是非監督式（完全不用標籤）
- 陷阱：「結構化剪枝 vs 非結構化剪枝」→ 要硬體友善就選結構化
- 陷阱：量化會帶來「精度損失」，這是換取效率的必要取捨

補充比較表

早期融合 vs 晚期融合

維度	早期融合	晚期融合
時機	底層特徵	模型輸出後
模態相關性	高（資料需嚴格對齊）	低（各模態獨立先學）
彈性	低	高
適用	影音同步任務	多源異質決策

雲端 vs 邊緣部署

維度	雲端	邊緣
算力	充裕	有限
延遲	高	極低
隱私	低（資料需上傳）	高（資料留在本地）
適用	非即時、訓練	工廠產線、隱私敏感

補充精華

- 智慧零售標註成本案例：與其硬標 100 小時影片，不如先標 10 小時訓練出初步模型 → 讓模型挑出「最不确定」的片段 → 只把這些關鍵畫面交人工標註（主動學習 Active Learning）
- 跨國詐騙視訊核身案例：金融業可用「活體檢測 + C2PA 來源驗證 + 對抗訓練」三層防 Deepfake
- AI Agent 趨勢：從「對話機器人」進化到「代理式 AI」，循環為 感知 → 規劃 → 行動；規劃師要為能自主行動的 AI 設計護欄
- 理想混合架構：邊緣端做半監督初步學習與資料篩選 + 聯邦學習只回傳模型更新參數到中央 → 同時降低標註成本並避開隱私法規風險

延伸補充：CLIP 與跨模態融合

考點

- 多模態 AI（Multimodal AI）：能同時處理兩種以上模態（文字 + 影像 + 聲音）的 AI。
- 直覺理解：就像人同時用視覺、聽覺等多種感官整合判斷，而非只靠單一感官。
- CLIP（Contrastive Language-Image Pre-training）關鍵能力：
 - 以文找圖：輸入「在雪地奔跑的哈士奇」→ 能精準匹配對應影像。
 - Zero-Shot Classification（零樣本分類）：無需重訓即可辨識新類別（如以「安全帽」一詞直接在工地影像中檢索未戴安全帽者）。
- CLIP 訓練法：用約 4 億組圖文配對做對比學習。

補充比較表 — 早期 / 晚期 / Transformer 跨模態融合

方法	融合位置	優點	缺點
早期融合 (Early Fusion)	輸入端就拼接特徵	保留低階相關性	抓不到深層互動 (如反諷)
晚期融合 (Late Fusion)	各模態決策後再整合	容錯高	模態間缺乏深度互動
Transformer 跨模態注意力	用注意力對齊各模態	達到真正語意對齊	需大量資料

補充精華 — 落地案例

- **無人商店多感測器融合**：以視覺辨識結合貨架感測 (如重量變化) 互相驗證顧客取放行為，降低單一感測器因遮擋造成的誤判——多模態互補的典型設計。
- **客服中心語音分析**：來電語音先轉文字 (ASR)、再自動生成摘要與分類標籤，縮短客服結案與品管抽聽時間——語音+文字兩種模態的串接應用。
- **內視鏡影像輔助偵測**：以內視鏡影像搭配病歷等臨床資訊作為多模態輸入，在檢查過程中即時提示可疑區域供醫師複核，補強人眼疲勞下的偵測敏感度。
- **醫療影像 × 文字病歷的跨模態診斷**：將醫學影像 (如 X 光) 與文字病歷整合輸入同一模型，讓系統同時參照「圖」與「文」兩類證據，輔助醫師形成更完整的判讀——影像+文字雙模態融合的代表場景。

延伸補充：多模態主軸提示

本章節以多模態融合與 CLIP 為主軸；概念延伸可參見深度學習相關章節。

【中級真題與解析 (114 年第二梯次)】

本節對應 3 題官方真題 (114 年第二梯次中級 AI 應用規劃師)，每題含 4 選項詳細解析、核心考點、易混淆對比。

第 21 題 (114-2-1-Q21)

題幹：在多模態 AI 模型訓練或推論過程中，遇到某一模態資料缺失 (例如僅有影像資料但缺少文本說明)，下列哪一種策略最有效維持模型效能？

選項：

- (A) 以零向量或固定向量填充缺失模態輸入
- (B) 訓練具備模態缺失感知能力的模型，使其適應缺失狀況
- (C) 利用生成模型 (如 GAN 或自迴歸模型) 預測並補全缺失模態資料
- (D) 直接捨棄缺少模態的樣本，避免干擾訓練或推論

正確答案：B

詳細解析：

- ✓ (B) 正確：訓練具備模態缺失感知能力 (Modality Missing-aware) 的模型是當前 SOTA 策略，使用 Modality Dropout、Cross-modal Attention 設計、Masked Modal Modeling 等技術讓模型在訓練階段就學會處理缺失情況，推論時自然能 robust 應對。
- × (A) 錯誤：零向量填充是最簡單但最差的方法，會引入「假特徵」，模型可能誤學「零模式」，效能下降明顯。
- × (C) 錯誤：生成模型補全雖可行，但會引入合成資料的偏誤與噪訊，且需要額外訓練生成模型，計算成本高，不是「最有效維持效能」的策略。
- × (D) 錯誤：直接捨棄樣本會大幅減少訓練資料，反而傷害模型效能；且推論時若遇缺失模態完全無法處理。

核心考點：多模態缺失處理策略的優劣比較。

易混淆對比：Modality Dropout (訓練時隨機 mask 模態，最佳) vs 零填充 (簡單但差) vs 生成補全 (成本高) vs 捨棄 (浪費資料)。

對應章節：L21104 多模態人工智慧應用

第 35 題 (114-2-1-Q35)

題幹：某媒體公司計畫導入 CLIP (Contrastive Language-Image Pre-training) 模型，以協助大量影像自動標註與搜尋，並希望在無需新增標訓資料的情況下，僅透過文字提示 (Text Prompt) 即可識別影像內容。請問此應用情境中，CLIP 能夠達成的關鍵技術特性為何？

選項：

- (A) 透過圖文對比式學習 (Contrastive Learning) 將影像與文字映射至共同嵌入空間 (Shared Embedding Space)，可直接以語意相似度進行零樣本分類
- (B) 透過影像增強與特徵擴散降低標訓資料需求
- (C) 以監督式學習結合多層感知器 (Multilayer Perceptron, MLP) 進行影像特徵分類
- (D) 以自迴歸生成模型 (Autoregressive Model) 逐步生成文字標籤描述影像內容

正確答案：A

詳細解析：

- ✓ (A) **正確：**CLIP (OpenAI, 2021) 核心是對比式學習 (Contrastive Learning)，用 4 億張圖文對訓練 Image Encoder + Text Encoder，將兩個模態映射至共同嵌入空間 (Shared Embedding Space)，使配對的圖文向量距離近、不配對的距離遠。**零樣本分類 (Zero-shot Classification)** 正是用「文字 prompt 的嵌入向量」與「影像嵌入向量」計算語意相似度，**無需重新訓練**即可分類新類別。
- × (B) **錯誤：**CLIP 不靠「影像增強 + 特徵擴散」，而是依賴**對比學習目標函數 (InfoNCE loss)**。
- × (C) **錯誤：**CLIP **不是監督式 MLP 分類**，而是**自監督對比學習** (用圖文對天然配對訊號)。
- × (D) **錯誤：**CLIP 不是自迴歸生成模型，**它不生成文字描述** (這是 BLIP、GIT 等的功能)。CLIP 只做圖文匹配 / 嵌入。

核心考點：CLIP 對比式學習 + 共同嵌入空間 → 零樣本分類能力。

易混淆對比：CLIP (對比學習，圖文匹配) vs DALL-E (自迴歸，文生圖) vs BLIP/GIT (生成式 caption) vs ALIGN (類 CLIP)。

對應章節：L21104 多模態人工智慧應用 (題幹『標訓』應為『標註』之誤植)

第 50 題 (114-2-1-Q50)

題幹：某設計師使用公司內部建置的生成式 AI 工具製作行銷素材，並輸入提示語 (Prompt)：「請生成一張模特兒手持品牌飲料、背景為海邊夕陽的照片」。系統能正確生成主要主題與場景，但輸出的圖像中，品牌標誌顏色常有誤差，或人物手部姿勢顯得不自然。若從多模態生成模型的技術機制分析，此現象最可能是下列哪一項原因所造成？

選項：

- (A) 擴散式生成模型的去雜訊過程出現隨機梯度漂移，導致影像像素錯誤
- (B) 提示語過長造成 Transformer 的位置編碼超出上下文限制，導致生成混亂
- (C) CLIP 模型中的文字編碼器與影像編碼器在語意嵌入空間未充分對齊，導致跨模態理解偏差
- (D) 模型未採用對比學習 (Contrastive Learning) 損失函數，無法建立多模態語意關聯

正確答案：C

詳細解析：

- ✓ (C) **正確：**文生圖模型 (如 Stable Diffusion) 使用 CLIP / OpenCLIP 作為**文字條件編碼器**，若 CLIP 的文字與影像編碼器嵌入空間對齊不夠精細 (語意對齊偏差)，會導致「主題理解大致正確但細節 (顏色、手指姿勢) 失準」。手指問題是 Diffusion 模型公認的「跨模態細節對齊缺陷」典型表現。
- × (A) **錯誤：**「隨機梯度漂移」非標準術語，且去噪過程在推論時不再有梯度更新，描述不合理。
- × (B) **錯誤：**題幹的 prompt 很短，**遠未達到 Transformer 上下文限制** (一般 77 或 128 token)，且 CLIP text encoder 的位置編碼問題影響有限。
- × (D) **錯誤：**CLIP 等多模態模型**早已採用對比學習**，這不是「未採用」的問題。

核心考點：CLIP 跨模態對齊不充分導致細節失準。

易混淆對比：對齊偏差 (語意層) vs 去噪不完整 (像素層) vs 位置編碼溢位 (架構層)。

對應章節：L21104 多模態人工智慧應用

延伸補充：多模態與 AI 四大支柱

以下為多模態理解與 AI 技術全貌的整合速記。

考點

- 【考點】多模態 AI (Multimodal AI) = 同時接收並理解多種類型資料（文字、圖像、聲音）的模型，目標是建立更全面、具情境感知的理解。
- 【考點】CLIP 是多模態理解的關鍵技術，全名 Contrastive Language-Image Pre-training（對比式語言影像預訓練）。

補充精華

- **多模態的直覺**：人類理解世界時常同時整合視覺、聽覺、文字等多種感官訊號，而非只靠單一感官；多模態 AI 的目標就是讓機器也能整合這些異質訊號、形成更完整的判斷。
- **CLIP 的學習方式**：以大量「圖片＋對應文字描述」的配對進行對比學習，將影像與文字映射到同一語意空間，使模型能判斷某張影像與某段文字描述是否相符（圖文對齊）。

延伸補充：AI 技術四大支柱

考點

- **AI 技術四大核心支柱**（企業需求媒合必考基本功）：
 1. **NLP**：理解與生成人類語言
 2. **CV (Computer Vision, 電腦視覺)**：讓機器看懂影像與影片
 3. **生成式 AI**：創造全新內容
 4. **多模態 AI**：跨模態綜合判斷
- **未來趨勢**：AI 正從單一小模型，走向能同時看、聽、讀的大型多模態系統，並由 MLOps (Machine Learning Operations) 負責整體營運。

【中級真題與解析（115 年第一次）】

本節對應 **4 題** 官方真題（115 年第一次中級 AI 應用規劃師），每題含 4 選項詳細解析、核心考點、易混淆對比。

第 17 題 (115-1-1-Q17)

題幹：某醫療新創公司正在開發一套「多模態患者風險評估系統」，需同時處理三種異質資料來源：胸腔 X 光影像（影像模態）、臨床診斷筆記（文字模態），以及心率與血氧的時序感測資料（數值時序模態）。工程師在進行各模態的特徵擷取模型選擇時，需為每種模態挑選最適合的模型架構。下列哪一組模型配置最符合三種模態各自的資料特性？

選項：

- (A) 影像模態用 LSTM、文字模態用 CNN、時序模態用 BERT
- (B) 影像模態用 TF-IDF、文字模態用 ResNet、時序模態用 Word2Vec
- (C) 三種模態統一使用 BERT，因為 Transformer 架構具備通用性，可處理任意形式的輸入資料
- (D) 影像模態用 CNN、文字模態用 Transformer、時序模態用 LSTM 或 Temporal CNN

正確答案：D

詳細解析：

- ✓ **(D) 正確**：模型架構應匹配資料的結構先驗 (Inductive Bias, 歸納偏置)：影像具二維空間局部性 → CNN (卷積神經網路) 的局部感受野與平移不變性最適合；臨床文字需要語意理解與長距依賴 → Transformer (如 BERT 類編碼器) 是當代 NLP 標準；心率／血氧是連續數值時序 → LSTM (長短期記憶網路) 或 Temporal CNN (時序卷積網路，如 TCN 的因果／膨脹卷積) 專為時間依賴建模。三者各得其所。
- × **(A) 錯誤**：配置整組錯位——LSTM 是序列模型不適合擷取影像空間特徵；CNN 雖可用於文字但非最佳；BERT 是文字預訓練模型，直接套數值時序訊號並不對口。
- × **(B) 錯誤**：完全張冠李戴——TF-IDF 是文字統計特徵法 (不能處理影像)、ResNet 是影像 CNN (不是文字模型)、Word2Vec 是詞嵌入 (不處理數值時序)。此選項考的是「認得每個模型原生的模態」。

- × (C) 錯誤：「統一用 BERT」忽略了模態先驗：BERT 的權重與斷詞器是為文字訓練的，直接餵影像像素或感測數值並不可行。注意陷阱的細膩處——Transformer「架構」確實可跨模態（如 ViT 處理影像），但那需要模態專屬的前處理（patch 化）與重新預訓練，「文字版 BERT 通吃任意輸入」的說法過度簡化。

核心考點：模態—架構配對表：影像→CNN（空間局部性）、文字→Transformer（語意與長距依賴）、時序→LSTM/TCN（時間依賴）；多模態系統的第一步是為各模態選對特徵擷取器。

易混淆對比：「Transformer 架構可通用」（真，需模態化改造如 ViT、時序 Transformer）vs 「文字 BERT 模型可直接吃任何模態」（偽）——「架構通用性」與「特定預訓練模型的適用範圍」是兩回事。

對應章節：L21104 多模態人工智慧應用

第 18 題 (115-1-1-Q18)

題幹：某醫院的 AI 研究團隊正在開發一套整合「CT 影像+電子病歷文本+基因序列」三種模態資料的癌症預測模型。請問在此場景中採用「跨模態對齊（Cross-Modal Alignment）」技術主要解決什麼問題？

選項：

- (A) 使模型僅聚焦於 CT 影像資料，避免文本與基因資料引入雜訊
- (B) 自動生成跨模態配對標註，以減少人工標記需求
- (C) 降低多模態資料的儲存與計算成本，以提升訓練效率
- (D) 將不同模態的資料表示對齊至共同語意空間，使模型能建立跨模態之間的語意關聯

正確答案：D

詳細解析：

- ✓ (D) 正確：不同模態各自編碼後的特徵向量位於「異質的表示空間」——CT 影像向量與病歷文字向量本來不可直接比較。跨模態對齊（Cross-Modal Alignment，跨模態對齊）的目標是把各模態映射到共同語意空間（Shared Semantic Space / Joint Embedding Space，共同嵌入空間），使「語意相關」的跨模態樣本（同一病人的影像、病歷、基因）在空間中彼此接近，模型才能建立跨模態語意關聯。代表性做法如 CLIP（Contrastive Language-Image Pre-training，對比式語言—影像預訓練）用對比學習拉近配對的圖文向量。
- × (A) 錯誤：只聚焦單一模態是「放棄」多模態融合，與對齊的目的（讓多模態互補）背道而馳。
- × (B) 錯誤：對齊訓練通常「消耗」配對資料（如圖—文對），其產出是共同表示空間，不是自動產生標註；把「需要配對資料」偷換成「生成配對標註」是文字陷阱。
- × (C) 錯誤：對齊是為了語意可比性，不是壓縮技術；它不以降低儲存或計算成本為目標（引入對比學習反而增加訓練成本）。

核心考點：跨模態對齊＝解決「異質模態表示空間不可比」問題，手段是投影到共同語意空間；判別關鍵字＝「共同語意空間」「跨模態語意關聯」。

易混淆對比：跨模態對齊（Alignment：把不同模態「拉到同一空間」，常用對比學習）vs 多模態融合（Fusion：把多模態特徵「合併」為聯合表示以做預測，分早期／晚期融合）——先對齊、後融合是常見管線順序，兩者角色不同。

對應章節：L21104 多模態人工智慧應用

第 35 題 (115-1-1-Q35)

題幹：某生物醫學研究機構正在建構一個整合「基因序列特徵」與「電子病歷文本特徵」的疾病風險預測模型。由於高維數值特徵和語意文本特徵的性質差異顯著，請問下列哪一種特徵處理與選擇策略最為合適？

選項：

- (A) 將所有特徵合併為單一特徵矩陣後，使用主成分分析（PCA）進行降維，作為模型輸入
- (B) 採分層策略，先對基因序列特徵進行特徵選擇，再對文本特徵進行語意表示，最後將兩類特徵融合（Feature Fusion）後輸入模型
- (C) 將所有特徵合併後，使用隨機森林（Random Forest）的特徵重要性進行一次性排序與篩選
- (D) 將文本特徵轉換為簡單統計特徵（如詞頻）後與基因特徵一併建模，以降低特徵處理複雜度

正確答案：B

詳細解析：

- ✓ (B) 正確：多模態資料處理的核心原則：「先各自用適合該模態的方法處理，再融合」。基因序列是高維稀疏數值特徵→適合以特徵選擇（如統計檢定、正則化）壓縮出有訊號的位點；病歷文本是語意資料→需經語言模型／詞嵌入（Embedding）取得語意表示（Semantic Representation），簡單數值方法無法捕捉語意。各模態處理成品質相當的表示後，再做特徵融合（Feature Fusion，屬中期／特徵層融合）輸入下游模型——既尊重模態異質性，又能學到跨模態交互。
- × (A) 錯誤：直接把異質特徵硬拼成一個矩陣做 PCA 有兩大問題：(1) PCA 是線性方法，對文本需要的語意結構無能為力；(2) 兩模態的尺度、維度、分佈差異巨大，PCA 的主成分會被高維基因特徵主宰，文本訊號被淹沒。
- × (C) 錯誤：與 (A) 同病：合併後一次性排序忽略模態異質性——隨機森林重要性對原始文本詞彙特徵（未經語意表示）的評估失真，且高維基因特徵會在數量上壓過文本特徵，導致篩選結果偏頗。
- × (D) 錯誤：把病歷文本降級為詞頻（Bag-of-Words 式統計）雖然「簡單」，卻拋棄語意資訊（同義詞、上下文、否定詞如「無發燒」vs「發燒」），在醫療文本這種語意敏感場景是嚴重的資訊損失；「降低複雜度」不能以犧牲關鍵訊號為代價。

核心考點：異質多模態特徵工程 SOP = 「模態內各自最適處理→特徵融合」。判別關鍵：看到「性質差異顯著的兩類特徵」，凡是「直接合併一起處理」的選項一律可疑，「分層／分模態處理後融合」才是正解。

易混淆對比：融合時機三型——早期融合（Early Fusion：輸入層直接拼接原始特徵）／中期·特徵層融合（Feature Fusion：各模態先編碼成表示再結合，本題做法）／晚期融合（Late Fusion：各模態獨立預測後再整合決策，見本科 Q50）；特徵選擇（挑子集，適合基因位點）vs 語意表示學習（Embedding，適合文本）。

對應章節：L21104 多模態人工智慧應用

第 50 題 (115-1-1-Q50)

題幹：某醫療團隊建立肺炎診斷系統，採用晚期融合（Late Fusion）策略，將胸腔 X 光影像與病患問診文字分別進行預測後再整合結果。測試發現，當問診紀錄品質不佳（如描述簡短或資訊缺漏）時，整體模型效能僅小幅下降。關於此現象，下列何者最不可能為其原因？

選項：

- (A) 各模態獨立進行預測，可降低單一模態品質不佳對整體結果的影響
- (B) 融合階段可調整不同模態的權重，使低品質模態影響降低
- (C) 各模態使用獨立模型，使錯誤不會在特徵層被放大
- (D) 晚期融合會在輸入階段整合多模態特徵，因此能避免低品質資料影響

正確答案：D

詳細解析：

- ✓ (D) 正確（最不可能——敘述本身錯誤）：這是「選出錯誤敘述」的反向題。晚期融合（Late Fusion，決策層融合）的定義是：各模態各自走完完整模型產生獨立預測（X 光→影像模型→預測；問診文字→文本模型→預測），最後才在決策層整合（加權平均、投票等）。「在輸入階段整合多模態特徵」描述的是早期融合（Early Fusion）——定義張冠李戴，且邏輯自相矛盾：若真在輸入階段就混合，低品質文本反而會污染整個聯合表示，怎麼可能因此「避免」影響？定義錯+因果錯，是最不可能的原因。
- × (A) 錯誤（是合理原因）：晚期融合的核心穩健性來源——文本品質差只會讓「文本分支的預測」變差，影像分支完全不受波及，最後整合時仍有高品質的影像預測撐住整體效能，故僅小幅下降。
- × (B) 錯誤（是合理原因）：決策層融合的天然優勢：整合時可依各模態的可靠度（如預測信心、學習到的權重）調整比重——文本品質差時降低文本分支權重、倚重影像分支，進一步壓低劣質模態的影響。
- × (C) 錯誤（是合理原因）：各模態模型完全獨立，文本的雜訊不會進入影像模型的特徵空間——對比早期融合中劣質特徵會在共享網路層與其他模態特徵交互、被逐層放大，晚期融合把錯誤隔離在單一支內。

核心考點：多模態融合時機光譜——早期融合（輸入/特徵層拼接：能學跨模態交互、但單模態劣化會污染全局）vs 晚期融合（決策層整合：模態間互相隔離、對單模態缺失/劣化穩健、可動態調權重，但學不到細粒度跨模態交互）。反向題（「最不可能」）技巧：先找「定義講反了」的選項。

易混淆對比：早期融合（Early Fusion，輸入階段整合——D 選項描述的其實是它）vs 中期／特徵層融合（各模態先編碼再於中間層融合，折衷方案，見 Q35）vs 晚期融合（Late Fusion，獨立預測後決策層整合，本題）；晚期融合的穩健性三來源＝模態隔離、錯誤不跨分支放大、決策層可調權重——正好對應 A、C、B 三個正確原因。

對應章節：L21104 多模態人工智慧應用

L212 AI 導入評估規劃

L21201 AI 導入評估

※ 考綱重點（L21201 AI 導入評估）：技術或工具效能評估、適用解決方案選擇、成本效益分析（ROI／TCO／PoC）等導入前可行性評估方法

導入評估目的與框架

AI 導入並非單純技術升級，而是橫跨業務策略、組織文化、資料體系與法規遵循的系統性工程。評估目標為判斷導入是否具實質價值與可行性，避免資源浪費。

評估四大面向：

面向	核心問題
業務需求面	AI 是否能解決企業實際痛點？
技術條件面	資料、IT、AI 模型適配度足夠嗎？
財務面（成本效益）	ROI、NPV、回收期是否合理？
風險面	法規、技術、組織三層風險是否可控？

【口訣】評估「需—技—錢—險」四問。

業務需求與痛點分析

三大切入問題：

問題	觀察點
哪些業務流程可作為 AI 導入目標	重複性高的工作、決策規則清晰的流程、數據驅動的決策
是否存在流程瓶頸或服務缺口	人力資源不足、效率問題
是否有需提升的 KPI（Key Performance Indicators，關鍵績效指標）	效率、準確率、回應速度

現況流程（As-Is）vs 理想流程（To-Be）落差分析是常用工具，透過跨部門訪談（Stakeholders 訪談）、流程觀察、資料分析勾勒落差。

◎ 技術可行性初探

評估面向	核心問題	因應策略
資料品質（Data Quality）	結構化、標註、代表性、完整性	建立資料治理、提升標註品質
IT 能力與系統整合性	伺服器、網路頻寬、雲端、資料倉儲	強化基礎設施、雲端擴充
AI 適配性	監督式/非監督式/強化式/生成式哪種最適？	從簡單統計模型試點再進階

若技術條件未成熟，可採「先資料治理、後 AI 試點」的階段性路徑。

◎ 成本與效益評估（三大財務模型）

模型	全名	公式	解讀
ROI	Return on Investment，投資報酬率	$ROI = \frac{\text{投資回報} - \text{投資成本}}{\text{投資成本}} \times 100\%$	ROI 越高 → 每元投入帶回越多回報
NPV	Net Present Value，淨現值	$NPV = \sum_{t=1}^n \frac{CF_t}{(1+r)^t} - \text{初期投資}$	NPV > 0 → 專案有經濟價值
Payback Period	回收期	$\text{回收期} = \frac{\text{初期投資成本}}{\text{每年淨現金流}}$	回收期越短 → 風險越低

【判別表】ROI vs NPV vs Payback：

指標	看的維度	考慮時間價值	適合
ROI	比率	否	單期或簡單比較
NPV	絕對價值	是	長期專案
Payback	速度	否	風險評估（須搭配 NPV）

【陷阱】Payback 公式分母是「每年淨現金流」不是「總成本」。Payback 簡單直觀但忽略折現，不可單獨作為決策依據。

組織成熟度盤點

維度	評估項目	關鍵指標
數位與資料成熟度	ERP、CRM、資料倉儲、資料治理（Data Governance）、API/ETL	系統建置完整度、資料正確性
團隊能力與跨部門協作	組織能力（Organizational Capability）、跨部門協作（Cross-functional Collaboration）、推動責任單位	AI 人才、培訓計畫、AI 專案辦公室
資源與預算支持	資源盤點、預算來源、導入條件	資金、人力、試辦環境

【考點】AI 導入需要的不只是「技術」，更是「資料治理」+「組織協作」。資料治理不完善時，先建治理再導模型。

風險與合規初探

風險類別	子項	因應
法規遵循與資料隱私	GDPR、PDPA、跨境傳輸、版權侵權	合法授權、匿名化、跨境協議
技術風險與模型穩定性	資料缺口、模型穩定性、黑箱風險、產出不確定性	持續監控、引入 XAI（Explainable AI，可解釋 AI）
組織文化與變革阻力	員工抗拒、決策文化、跨部門配合	變革管理、培訓、數據文化建立

XAI（Explainable AI，可解釋 AI）目標與應用：

目標	應用情境
增強使用者對 AI 決策的信任	醫療診斷：醫師需理解模型判斷依據
協助開發者與利害關係人理解模型行為與潛在偏誤	金融風控：須向主管機關說明風險評分組成
支援合規性、道德性與審核需求	人才招聘/教育：避免歷史偏見導致歧視性決策
法律可審查性	公部門/法務：AI 判斷需具法律可審查性

【考點】風險矩陣（Risk Matrix）將「發生機率（Likelihood）」與「影響程度（Impact）」交叉成 3×3 或 5×5 矩陣分類風險。

風險等級 = 發生機率 × 影響程度：

等級	英文	處理原則
低風險	Low Risk	可接受、監控
中風險	Medium Risk	需規劃因應對策
高風險	High Risk	優先處理，必要時迴避或延後導入

◎ POC（Proof of Concept，概念驗證）設計

POC 是在最小風險範圍內驗證導入假設、發掘問題、建立 AI 專案能力。

POC 條件設計四原則：

原則	說明
範圍清晰、風險可控	小範圍單位、部門或資料集
具代表性業務流程	能反映後續擴展挑戰
資料與技術資源具備初步條件	避免測試過程中斷
利益關係人支持度高	選擇有共識的業務單位

POC 評估雙軌：

評估類型	內容	工具
量化評估	效能指標（準確率、處理速度、錯誤率、成本節省）	與既有 KPI 比較
質性評估	使用者回饋（問卷、訪談、使用日誌）	觀察文化抗拒、流程磨合

初步導入可行性判斷四點：

判斷點	觀察
技術適配性	模型適合任務嗎
預期效益驗證	KPI 是否達成
組織接受度	使用者是否願意採用
問題與瓶頸辨識	POC 過程暴露的限制

延伸補充：導入評估的痛點分析、財務指標與 POC**考點 (B1)**

- 釐清業務痛點的四個提問層次：
 - 痛點定位 (Business Pain Point Identification)：鎖定流程中「拖慢、耗錢、惹怒客戶」的環節
 - 追因提問 (Core Questioning Method)：不停在「想要什麼功能」，往下追問「為何需要、要解決哪個根本問題」
 - 策略對齊 (Strategic Mindset Establishment)：確認 AI 專案能扣回公司長期方向與競爭定位
 - 價值排序 (Value-Driven Analysis)：依「省下多少成本／創造多少營收／提升多少滿意度」排優先序
- 導入評估三面向（資料與 IT 基建／模型適配／財務效益）（三者缺一就會翻車；注意與後文其他「三支柱」用語為不同概念）：
 - 資料與 IT 基礎設施是否到位（有沒有足量、乾淨的資料，跑得動的算力）
 - AI 模型是否對得上業務情境（選的方法能不能真的解決那個任務）
 - 財務效益是否划算（ROI 加上整體擁有成本 TCO）
- ROI (Return on Investment，投資報酬率) 公式： $(\text{收益} - \text{成本}) / \text{成本} \times 100\%$
- TCO (Total Cost of Ownership，總體擁有成本)：把生命週期內所有直接與間接花費都算進去（不只買進當下的價格，還含維護、升級、教育訓練、電力等隱性支出）
- 組織成熟度的三個檢視維度：
 - 數位治理 (Digital Governance)：管的是整個組織所有數位資產與策略層的規範
 - 資料治理 (Data Governance)：聚焦在資料本身的品質、安全與合規
 - 團隊能力與資源支持（人才、預算、推動單位）
- 成熟度模型 (Maturity Model) 三階段：初始 → 管理 → 優化
- 降低導入失敗風險的三個關鍵動作：
 - 風險識別 (Risk Identification)：提前盤點技術、法規、組織三類風險
 - 可解釋 AI (XAI, Explainable AI, 可解釋人工智慧)：讓決策依據能被檢視
 - POC (Proof of Concept, 概念驗證)：小成本先驗證再放大投資

陷阱 (B2)

- 陷阱**：把「競爭對手都導入 AI 了，我們不能落後」當成立案理由 → 錯！導入的起點應是自家確實存在、且值得用 AI 解的業務痛點，而非為了跟風而上馬（避免「為了用 AI 而用 AI」）
- 陷阱**：把「準確率最高」當成唯一選模標準 → 錯！須一併檢視混淆矩陣與不同錯誤的業務代價（漏判重症與誤刪一封廣告信，後果輕重天差地遠）
- 陷阱**：以為可解釋性可有可無 → 在信用評分、醫療診斷等高敏感場景，可解釋性是不可退讓的硬性需求
- 陷阱**：POC 一通過就直接全面上線 → 錯！POC 的目的是「先驗證成效，再據以決定是否擴大投資」，不是直接放大規模的綠燈

補充比較表（B2）

數位治理 vs 資料治理

維度	數位治理	資料治理
範圍	所有數位資產 + 整體策略	資料生命週期 + 品質
層級定位	組織層的全面規範	聚焦資料本身的子集規範
對象	軟體、平台、流程	資料的可用性、完整性、安全性、合規性

POC 三階段

階段	內容
POC Design	規劃範圍、目標、評估標準、資源、時程
POC Implementation	收集資料、開發模型、初步測試（快速迭代）
POC Performance Evaluation	對照預設標準，決定是否擴大投資

補充精華（B3）

- 「先釐清問題、再選技術」案例（日本老店食堂「あびや／Ebiya」來客預測，公開報導案例）：
 - ▶ 日本三重縣伊勢市的百年食堂 Ebiya，原本靠手寫帳本與經驗備料，長年苦於「備料過剩造成食材浪費、備料不足流失客人」
 - ▶ 經營者沒有直接導入坊間流行的 POS（Point of Sale，銷售時點情報系統）套裝方案，而是先量化現況：逐日記錄來客數、天氣、附近觀光人流，找出真正的痛點是「來客量預測不準」——備料與排班失當都只是它的下游症狀
 - ▶ 後續建置以天氣、季節、周邊活動等變數預測隔日來客數的模型（媒體報導預測準確率約九成），據以決定備料量與人力配置，數年間營收成長數倍、食材廢棄大幅下降
 - ▶ 教訓：表面需求（備料/排班混亂）≠ 真正痛點（預測不準）。先把上游的預測做準，下游的排程自然有依據；順序顛倒則是砸錢買症狀緩解
 - ▶ （案例出處：Ebiya 來客預測為日本媒體與微軟官方廣泛公開報導之數位轉型案例）
- 三面向評估實戰案例（日本富國生命保險導入 AI 理賠審核，2017 年公開報導案例）：
 - ▶ 日本富國生命（Fukoku Mutual Life Insurance）導入 IBM Watson 協助理賠審核：讀取醫療證明與住院紀錄、比對保單條款後產出理賠建議，最終給付仍由人類覆核（BBC、The Guardian 等公開報導）
 - ▶ 以「資料／IT／合規」三面向回看這類專案的前置功課：
 - 資料面：理賠單據多為紙本掃描、各醫院欄位格式不一 → 須先建立標註規範與文件數位化流程，才有可餵入模型的乾淨資料
 - IT 面：光學字元辨識（OCR，Optical Character Recognition）與大型模型批次處理需要相應運算基礎設施 → 先盤點缺口再排建置時程
 - 合規面：理賠資料屬高敏感個資 → 雲端服務的資料落地、稽核與「人類最終決策」的監督機制須先釐清
 - ▶ 分階段推進的通則：第一階段先處理格式標準的「標準件」並保留人工覆核；驗證穩定後，第二階段再擴展至複雜件——與 POC（Proof of Concept，概念驗證）「範圍清晰、先小後大」原則一致
- 高敏感場域的 POC 設計原則（一般化）：在金融、醫療、司法等決策後果重大的領域，POC 不只是驗證「做不做得出來」，更要驗證「能不能負責任地用」。可循以下原則設計：
 - ▶ 風險先行盤點：在動工前先列出資料偏見、決策黑箱、表現不穩定等可能風險，作為驗收項目而非事後補救。
 - ▶ 刻意縮小範圍：以較少且具代表性的資料、較簡化的模型、限定的適用情境先行試做，把不確定性壓在可控規模內，再決定是否擴大。
 - ▶ 驗收標準多軸並陳：除準確度外，把可解釋性、公平性、合規性等非功能需求一併列為通過門檻；在後果重大的場景，這些往往是不可退讓的硬性條件，而非加分項。
- 痛點導向三原則：先確認有真問題才去找工具、對需求反覆追問「為什麼」、把有限資源優先投在能創造最大價值的解法上

考點（B1）

- AI 專案的高失敗率：業界（如 Gartner）長期觀察到多數 AI 專案無法順利落地，凸顯導入前評估的重要性。
- 規則式系統（Rule-based）≠ AI：把交易條件寫死照規則執行只是自動化，要能「從資料學習並泛化到沒見過的情況」才算 AI。

- **落差分析 (Gap Analysis)**：As-Is (現況) → To-Be (理想) → 中間的缺口，正是 AI 可以發揮的地方。
- **POC (Proof of Concept, 概念驗證) 三項原則**：
 1. 範圍清晰 (先做小規模測試)
 2. 資料具代表性 (用真實資料而非實驗室理想資料)
 3. 事前訂好成功指標 (白紙黑字定義什麼叫達標)

補充比較表 — 問題類型對應模型 (B2)

商業問題	答案型態	對應模型
預測下月銷售量	連續數字	迴歸模型
客戶分群做精準行銷	群體類別	分群 (K-Means / DBSCAN)
判斷是否詐騙交易	是 / 否	分類模型

補充比較表 — 三大財務指標 (B2)

指標	意義	注意點
ROI (投資報酬率)	投 1 元能賺回幾元	最直觀，但忽略時間價值
NPV (淨現值)	把時間價值算進去的總價值	適合長期專案
回收期 (Payback Period)	多久能回本	AI 技術迭代快，拖到 5 年才回本風險偏高，「快速回本」有時比「高 ROI」更關鍵

陷阱 — 高準確率的假象 (B2)

- 信用卡詐騙偵測：正常交易佔絕大多數，模型「一律猜正常」就能拿到極高準確率，卻一筆詐騙都沒抓到，等於無用。
- 解法：改看 F1-Score / ROC / mAP 等對不平衡資料更敏感的指標，別只盯準確率。

補充精華 — 真實翻車教訓 (B3)

- **AI 客服亂承諾政策**：曾有航空公司的 AI 客服自行編造退費規則，最後企業被判須負責——AI 對外輸出也是企業的法律責任。
- **房產自動估價部門裁撤**：曾有大型房產平台的 AI 估價在回測時表現亮眼，真實市場一波動就嚴重失準，導致鉅額損失與部門收掉。教訓是「實驗室裡的冠軍未必撐得過真實世界」。
- **資料孤島 (Data Silo)**：行銷、業務、財務各管各的資料庫，缺乏統一治理，AI 的地基就站不穩。
- **MLOps (Machine Learning Operations, 機器學習維運)**：模型上線是維運的起點而非終點，否則會慢慢模型漂移 (Model Drift)。

規劃師的四種思維 (B1)

1. 財務思維：ROI / NPV / 回收期
2. 技術思維：分清自動化與 AI、警覺過擬合
3. 風險思維：GDPR、差分隱私、供應鏈攻擊
4. 指標思維：懂 F1 / mAP / IoU，知道「99% 準確率」不等於成功

考點 (B1)

判斷一個任務值不值得用 AI 的四個準則 (適合高 ROI 的場景)：

1. 任務高度重複且規模龐大
2. 有明確、可量化的優化目標
3. 規則複雜到連人類專家都難以一條條寫死
4. 潛在投資報酬率 (ROI) 夠高、夠划算

補充精華 (B3)

選型提醒：AI 並非萬用解。很多單純的預測問題，用傳統監督式學習反而更快更省。其中**強化學習**最容易被誤當萬靈丹，但它真正擅長的是「需要連續決策、又沒有現成標準答案」的場景。

【中級真題與解析（114 年第二梯次）】

本節對應 1 題官方真題（114 年第二梯次中級 AI 應用規劃師），每題含 4 選項詳細解析、核心考點、易混淆對比。

第 23 題（114-2-1-Q23）

題幹：某大型醫院即將部署一套輔助診斷的 AI 系統，為降低對臨床流程的衝擊，同時確保風險可控與回饋可收斂，應採取何種「漸進式部署（Phased Rollout）」策略最為合適？

選項：

- (A) 從單一專科（如放射科）或特定病房開始啟用，逐步擴展至全院
- (B) 先部署於病例量較高的急診單位，加速收集高頻使用回饋
- (C) 僅在夜班或離峰時段啟用，避免影響主要臨床工作負載
- (D) 在使用者界面啟用提示模式，讓全院同步體驗但不影響診斷流程

正確答案：A

詳細解析：

- ✓ (A) **正確：**漸進式部署（Phased Rollout）的核心是「先窄後寬、先小後大」。從單一專科（放射科 / 病理科常先試行）或特定病房開始 → 風險範圍可控、回饋可收斂、容易偵測模型漂移與失效模式、出問題時影響範圍小。逐步擴展模式對應「Canary Release / Pilot Deployment」工程實務。
- × (B) **錯誤：**先部署「病例量最高的急診」反而**最高風險場景優先**，違反漸進式部署原則。急診時間壓力大、容錯空間低，AI 錯誤後果嚴重。
- × (C) **錯誤：**「離峰時段啟用」並未限縮「使用範圍」而是限縮「使用時間」，回饋樣本量不足（離峰使用量低）且**離峰場景與正常負載差異大**，無法收斂可推廣到正常時段的證據。
- × (D) **錯誤：**「全院同步啟用提示模式」雖然不直接影響診斷，但**所有使用者都接觸 AI 介面**，仍有「介面誤導 / 資訊過載」風險；且全院規模收集回饋難以針對問題即時修正，違反「小規模試行」原則。

核心考點：漸進式部署（Phased Rollout / Canary Release / Pilot）的「小範圍 → 大範圍」原則。

易混淆對比：Phased Rollout（範圍漸進）vs Blue-Green Deployment（版本切換）vs Canary Release（小流量灰度）vs A/B Testing（並行比較）。

對應章節：L21201 AI 導入評估

延伸補充：評估三支柱、KPI 量化與財務指標辨析

考點（B1）

- 【考點】導入評估三要件：業務價值明確、技術與資料可行、財務效益成立——三者缺一即應暫緩。
- 【考點】業務需求分析的步驟：釐清待解的業務問題 → 訂出可量測的成效指標 → 盤點 as-is（現況）與 to-be（理想）流程的差距。
- 【考點】不合格與合格 KPI 對照：「讓流程更智慧化」太模糊（無法量化）；「客訴首次回覆時間由 48 小時縮短至 24 小時」「產線誤放行率控制在 0.5% 以下」才是可衡量目標。
- 【考點】技術可行性的三個要件：資料品質 + IT 基礎建設 + AI 適用性。
- 【考點】資料品質決定一切：原料不行，再強的演算法也救不回來（Garbage In, Garbage Out, GIGO，垃圾進垃圾出）。
- 【考點】POC（Proof of Concept，概念驗證）= 用最小成本先驗證想法可不可行。

補充判別表（B1）

財務指標	衡量重點	公式概念	適用情境
ROI（Return on Investment，投資報酬率）	賺錢效率	淨利潤 ÷ 總投資成本	比較多個專案誰的賺錢效率高
NPV（Net Present Value，淨現值）	折現後的未來總價值	未來現金流折成今值 - 初始投資	評估長期、大筆資金投入的專案
Payback Period（回收期間）	幾年回本（流動性風險）	投資成本完全回收所需時間	現金流吃緊、重視流動性

口訣：見附錄四自建版——「ROI 看比例、TCO 看總成本、NPV 看時間價值、Payback 看回本快慢」。

陷阱 (B2)

- 【陷阱】三個財務指標的區分是高頻考點，常被包裝成情境題：
 - 想比較哪個專案賺錢效率高 → ROI
 - 想評估長期大筆投資的整體價值 → NPV
 - 在意何時拿回本金、資金週轉與風險 → Payback Period
- 【陷阱】貨幣有時間價值（通膨＋機會成本），故 NPV 把未來各期現金流折算回現值後再與初始投資比較。

補充精華 (B3)

- 先確立業務問題定義，再對應技術方案：問題定義不清就直接套技術，往往做出沒人要用的系統。
- 適合與不適合用 AI 的任務：
 - 不適合：高度仰賴創意、人類同理心的工作
 - 適合：重複性高、規則明確可循的工作（例：自動擷取表單欄位，如報價單的品項與單價）

延伸補充：可行性三支柱與試點選擇

考點 (B1)

- 可行性評估三軸線（缺一不可）：
 1. 需求面：待解的業務問題是否明確且值得投資？
 2. 資料與技術面：資料是否可取得且品質堪用？IT 基礎設施是否就緒？
 3. 組織與文化面：流程負責人是否支持？使用者是否具備接納與操作的能力？
- AI 導入是持續性的能力建設：上線後仍需治理與迭代，而非一次性系統採購。

陷阱 (B2)

- 常見情境盲點：「導入智慧排程系統，模型與需求都到位，專案卻仍失敗」原因為何？
 - 答案：忽略了資料治理（Data Governance）與數位成熟度（Digital Maturity）。
 - 典型病灶：既有系統沒有 API、欄位缺乏資料字典、各部門各自維護不同版本的 Excel——模型再好也接不上真實資料流。

補充精華 (B3)

- 推進原則：以低風險場景先行試點，用可量化成效建立內部信任後再擴大範圍。
- 試點專案怎麼挑：優先選資料現成、技術門檻低、成效可在短週期內量測的場景，作為向管理層與其他部門展示價值的樣板。

延伸補充：資料管線、5V 與儲存架構

考點 (B1)

- 鐵律：「垃圾進、垃圾出（Garbage In, Garbage Out, GIGO）」
- ETL（Extract, Transform, Load，萃取-轉換-載入）vs ELT（先載入再轉換）：差別在「T 轉換」發生的時間點
- 大數據 5V：Volume（量）、Velocity（速度）、Variety（多樣性）、Veracity（真實性）、Value（價值）

補充比較表 (B2)：資料湖 vs 資料倉儲

維度	資料湖 (Data Lake)	資料倉儲 (Data Warehouse)
收料方式	原始資料照單全收、不先整理	先清洗整理過才入庫
資料型態	結構化／半結構化／非結構化都收	只收結構化、已處理資料
Schema	先存後定義（讀取時才定 schema）	寫入前就定 schema
適用	訓練多樣化的 AI 模型	產出商業報表

補充比較表 (B2)：Hadoop vs Spark

維度	Hadoop	Apache Spark
資料放哪	硬碟 (HDFS)	記憶體 (RAM)
運算方式	每步都讀寫磁碟	資料常駐記憶體中運算
速度	慢	快很多

維度	Hadoop	Apache Spark
適用	批次處理	即時分析 / 機器學習

- **PB (Petabyte, 拍位元組)**：1 PB 是極龐大的資料量，足以裝下數十萬小時的高畫質影片
- **HDFS (Hadoop Distributed File System, Hadoop 分散式檔案系統)** 運作概念：把大檔切成許多小區塊，分散存到多台機器上

【中級真題與解析 (115 年第一次)】

本節對應 3 題官方真題 (115 年第一次中級 AI 應用規劃師)，每題含 4 選項詳細解析、核心考點、易混淆對比。

第 8 題 (115-1-1-Q08)

題幹：某工程師訓練了一個皮膚病變二元分類模型（惡性/良性），在向臨床醫師報告模型效能時，使用 ROC 曲線 (Receiver Operating Characteristic Curve) 進行呈現。請問 ROC 曲線的橫軸 (X 軸) 與縱軸 (Y 軸) 分別代表哪些指標，且在醫療情境中代表哪一種意義？

選項：

- (A) X 軸為準確率 (Accuracy)，Y 軸為召回率 (Recall)，表示模型整體分類正確比例與偵測能力
- (B) X 軸為假陽率 (False Positive Rate, FPR)，Y 軸為真陽率 (True Positive Rate, TPR)，反映誤診健康個體的風險與正確識別病患的能力
- (C) X 軸為精確率 (Precision)，Y 軸為召回率 (Recall)，表示預測為陽性樣本的準確性與完整性
- (D) X 軸為 IoU 閾值，Y 軸為 mAP，反映物件偵測模型在不同重疊條件下的表現

正確答案：B

詳細解析：

- **✓ (B) 正確**：ROC 曲線 (Receiver Operating Characteristic Curve, 接收者操作特徵曲線) 的定義：X 軸為 FPR (False Positive Rate, 假陽率) = $FP/(FP+TN)$ ，即健康者被誤判為患病的比例 (誤診健康個體的風險)；Y 軸為 TPR (True Positive Rate, 真陽率) = $TP/(TP+FN)$ ，即實際患病者被正確識別的比例 (等同召回率/敏感度 Sensitivity)。曲線描繪分類閾值從嚴到寬掃描時兩者的取捨；越貼近左上角代表「高 TPR、低 FPR」，效能越好。
- **× (C) 錯誤**：Precision (X 或 Y 軸) 對 Recall 描繪的是 PR 曲線 (Precision-Recall Curve, 精確率—召回率曲線)，不是 ROC；PR 曲線在類別極不平衡時比 ROC 更能反映實際表現，是常見的搭配考點但軸定義不同。
- **× (A) 錯誤**：Accuracy 是單一整體指標，不是 ROC 的軸；ROC 的本質是「掃描閾值」下 FPR 與 TPR 的軌跡，與 Accuracy 無直接對應。
- **× (D) 錯誤**：IoU (Intersection over Union, 交並比) 閾值與 mAP (mean Average Precision, 平均精確率均值) 是物件偵測的評估框架，與二元分類的 ROC 完全不同領域。

核心考點：ROC 的軸定義——「X=FPR、Y=TPR」必背；醫療語境下 FPR=誤診健康人、TPR=抓到病人 (敏感度)。

易混淆對比：ROC 曲線 (FPR vs TPR, 對類別不平衡較不敏感) vs PR 曲線 (Recall vs Precision, 不平衡資料下更嚴格)；TPR=Recall=Sensitivity (敏感度)，FPR=1-Specificity (特異度)——同一量的多個名字是常見陷阱。

對應章節：L21201 AI 導入評估

第 9 題 (115-1-1-Q09)

題幹：某團隊在監控影像分類模型的線上效能時，透過儀表板呈現混淆矩陣 (Confusion Matrix)，以觀察模型預測結果與實際標籤的分佈情形。請問下列哪一項無法從混淆矩陣中直接計算？

選項：

- (A) 精確率 (Precision)
- (B) 準確率 (Accuracy)

- (C) 召回率 (Recall)
- (D) ROC 曲線下面積 (AUC)

正確答案：D

詳細解析：

- ✓ (D) 正確（無法直接計算）：單一混淆矩陣 (Confusion Matrix, 混淆矩陣) 是在「某一個固定分類閾值」下統計的 TP/FP/TN/FN 四格。AUC (Area Under the ROC Curve, ROC 曲線下面積) 則需要「掃描所有可能閾值」畫出整條 ROC 曲線再積分，等價於需要每筆樣本的預測機率分數 (或排序)，而非單一閾值下的計數——因此無法由一張混淆矩陣直接算出。
- × (A) 錯誤（可直接計算）：Precision (精確率) = $TP/(TP+FP)$ ，四格中兩格相除即得。
- × (B) 錯誤（可直接計算）：Accuracy (準確率) = $(TP+TN)/(TP+FP+TN+FN)$ ，即對角線和除以總數。
- × (C) 錯誤（可直接計算）：Recall (召回率) = $TP/(TP+FN)$ ，同樣直接由矩陣讀出。

核心考點：混淆矩陣 = 「單一閾值」的快照；AUC = 「全閾值掃描」的整合指標，需要機率分數——「一個點 vs 一條曲線」是判別關鍵。

易混淆對比：由混淆矩陣可直接得出的指標家族 (Accuracy/Precision/Recall/F1/FPR/Specificity) vs 需要預測分數與閾值掃描的指標 (ROC 曲線、AUC、PR 曲線、Log Loss——Log Loss 還需要機率值本身)。

對應章節：L21201 AI 導入評估

第 19 題 (115-1-1-Q19)

題幹：一家電商公司已將推薦系統 AI 模型上線三個月，業務主管要求專案團隊評估導入成效。團隊根據下圖數據得出結論：「因為 AUC 高達 0.91，模型表現優異，AI 導入成效良好。」請問此評估結論存在什麼根本問題？

【圖】導入成效數據表，欄位為「指標 / 導入前 / 導入後」：

指標	導入前	導入後
模型離線 AUC	—	0.91
點擊率 (CTR)	3.2%	3.1%
平均訂單金額	\$850	\$1,020
系統推論延遲	—	平均 85ms
模型推論費用	—	每月 \$12,000

選項：

- (A) 僅依賴離線指標 AUC 判斷模型成效，忽略線上業務指標 (如 CTR 與營收) 的變化，可能導致錯誤結論
- (B) AUC 已達 0.91，代表模型排序能力優異，即使 CTR 略為下降，仍可視為推薦品質提升
- (C) CTR 從 3.2% 降至 3.1%，顯示模型效果變差，應立即還原 (Rollback) 至舊模型
- (D) 平均訂單金額提升至 \$1,020，代表模型已成功優化營收，因此無需考慮其他指標

正確答案：A

詳細解析：

- ✓ (A) 正確：AUC 是「離線技術指標」——衡量模型在歷史資料上的排序能力，無法直接證明「上線後為業務帶來價值」。導入成效評估必須以「線上業務指標」為準：表中 CTR (Click-Through Rate, 點擊率) 不升反降 (3.2%→3.1%)、訂單金額上升、還有延遲與月費成本——這些多維訊號有好有壞，需綜合權衡 (且理想上經 A/B 測試確立因果)，僅憑單一離線指標下「成效良好」的結論在方法論上就站不住腳。離線指標好、線上表現平平的「離線—線上落差 (Offline-Online Gap)」是推薦系統的著名現象。
- × (B) 錯誤：犯了與題幹結論相同的錯——把離線 AUC 凌駕於線上實際行為之上；CTR 下降是真實使用者的負向訊號，不能用離線分數「蓋牌」。
- × (C) 錯誤：走向另一個極端——只看 CTR 單一指標就立即回滾，忽略訂單金額顯著上升 (\$850→\$1,020) 的正向訊號；點擊少但客單價高可能代表推薦更精準地觸達高價值意圖，需綜合評估而非速斷。

- × (D) 錯誤：同樣是單一指標謬誤的鏡像——只看訂單金額而無視 CTR 下滑與每月 \$12,000 的成本；成效評估需考慮投資報酬率（ROI，Return on Investment，投資報酬率）與整體指標組合。

核心考點：離線指標（AUC/NDCG，模型能力）≠ 線上業務成效（CTR、轉換、營收、成本）；導入成效評估必須以線上多維業務指標綜合判斷。情境線索：結論只引用了表中唯一的離線指標，對其餘四個線上指標視而不見。

易混淆對比：離線評估（歷史資料、技術指標、便宜快速、無因果保證）vs 線上評估（A/B 測試、業務指標、真實因果、有風險成本）；B、C、D 三個干擾項本質上都是「單一指標決策」，只是各抱一個不同的指標。

對應章節：L21201 AI 導入評估

L21202 AI 導入規劃

※ 考綱重點（L21202 AI 導入規劃）：需求分析、技術應用方案設計、目標設置（KPI／OKR）、資源分配（人力／預算／時程／基礎設施）等導入規劃要素

導入規劃的核心原則

原則	說明
情境/目的導向	依產業特性與業務需求定義目標（零售業聚焦銷售預測、醫療業強調診斷輔助）
資源盤點	評估資料、技術、預算，確保專案規模與資源匹配
彈性調整	動態回應需求改變、技術瓶頸（不照表操課）

◎ 資源盤點與配置

人力資源角色分工表：

角色	主要職責	能力要求
專案負責人（Project Manager）	整體協調、進度管理、跨部門衝突排解	PMP（Project Management Professional，國際專案管理師）認證、溝通能力
資料工程師	資料收集、清理、整合、ETL	資料庫管理、ETL 工具
AI 模型開發者	模型設計、訓練、優化	Python、TensorFlow、PyTorch
UI/UX 設計師	使用者介面與體驗設計	介面設計、可用性測試
業務顧問	連結技術與業務、定義 KPI	產業洞察
系統架構師	設計技術架構與部署方案	雲端服務、系統整合
測試工程師	驗證效能與穩定性（壓力測試）	測試框架、QA

硬體資源配置：

類型	範例	適用
GPU 伺服器	NVIDIA A100、H100	深度學習訓練、影像辨識、NLP
雲端平台	AWS、Google Cloud、Azure	彈性擴展、即時處理
本地運算設備	高效能工作站	小型試辦、資料敏感場景（醫療）

開發工具與框架：Python、TensorFlow、PyTorch、Spark、Hadoop、Git（版本控制）。

◎ 任務分解與時程設計（四大方法）

1. 甘特圖（Gantt Chart）

橫軸時間、縱軸任務的視覺化工具。AI 專案常見階段：

階段	估時
問題定義與需求訪談	1-2 週
資料準備與標註	數週至數月
模型設計與訓練	視模型複雜度
驗證測試與反饋調整	視結果而定
部署與落地	視系統整合

關鍵路徑（Critical Path）標示專案最長依賴鏈。

2. WBS（Work Breakdown Structure，工作分解結構）

由上而下拆解任務。例：「資料準備」拆為：

子任務	內容
資料源盤點	找出所有資料來源
資料清理	缺失、異常、重複處理
欄位標準化	統一格式
欄位對齊與標註流程	跨來源欄位映射

每子任務需定義：責任角色、預期成果、所需資源、預估時長。

3. Scrum 敏捷開發框架

敏捷開發（Agile Development）的代表框架，適合需求變動快、不確定性高的 AI 專案。

Scrum 3-5-3 架構：

類型	內容
三角色	Product Owner（產品負責人）、Scrum Master（敏捷教練）、Development Team（開發團隊）
五活動	Sprint Planning、Daily Scrum（每日站會 15 分鐘）、Sprint、Sprint Review、Sprint Retrospective
三產出	Product Backlog、Sprint Backlog、Increment（可交付成果）

Sprint（短衝）核心：

項目	內容
週期	1-4 週（常見 2 週）
Sprint Review	展示成果、收集回饋
Sprint Retrospective	回顧檢討、提出改進
下一輪 Sprint Planning	更新 Sprint Backlog

【口訣】Scrum「3-5-3」（三角色、五活動、三產出）。

4. 任務追蹤工具對比

工具	特色	適用
Trello	看板（Kanban）、輕量	小型團隊、初期原型
Asana	任務分層、時間軸	跨部門協作
JIRA	工作流自訂、敏捷支援、問題追蹤	技術團隊主導
ClickUp	結構化 + 看板 + 里程碑	中型專案

跨部門協作機制

機制	說明
協作流程設計	明確各部門責任（資料/IT/業務/法務）
例行同步節奏	每週例會追蹤進度
共用工具平台	Jira/Trello（任務）、Notion/Confluence（文件）、Slack/Teams（即時通訊）

◎ AI 導入模式選擇

模式	優勢	挑戰	適用
選用現有商業服務（Low-code、No-code 平台）	快速部署、技術門檻低、靈活	自定義有限、長期訂閱成本高、雲端資料隱私風險	技術能力有限、時間緊迫
內部技術團隊開發	掌控力強、適應性高、技術自主	招聘/設備/流程建立成本高、初期慢	長期 AI 發展計畫、敏感資料
委外開發	專業性與執行效率	合約管理、資料安全風險	缺技術人力但有預算

【判別表】三模式抉擇：

條件	推薦
預算少、需求簡單、時間緊	Low/No-code 平台
預算多、長期戰略、資料敏感	內部團隊
預算中、缺技術人力、有專業需求	委外 + SLA 合約

規劃成果整合（五大輸出文件）

文件	英文	內容
導入規劃文件	Implementation Plan Document	背景、目標、策略、範疇、任務、時程、團隊、預算、資源
專案成果彙整報告	Planning Summary	給高階主管的摘要
甘特圖與時程規劃	Gantt Chart and Timeline	里程碑、責任、資源
資源估算與成本預算表	—	人力、硬體、軟體、外包
利害關係人審查紀錄	Stakeholder Review	技術/業務/法務/高層審查決議

延伸補充：WBS、甘特圖、敏捷與導入模式

考點（B1）

- **AI 專案管理的三項核心工具：**
 - ▶ WBS（Work Breakdown Structure，工作分解結構）：把龐大專案逐層拆成可執行的小任務
 - ▶ 甘特圖（Gantt Chart）：以時間軸視覺化各任務的起迄與進度
 - ▶ 關鍵路徑（Critical Path）：決定專案總工期、絕對不能延誤的那條任務鏈
- **WBS 層級：**專案 → 主要交付物 → 工作包 → 活動（一層層往下拆到不可再分）
- **Deliverable（交付物）：**每個節點具體且可驗收的產出（如「乾淨資料集」「訓練好的模型」「測試報告」）
- **WBS Dictionary（WBS 字典）：**記錄每個工作包的範圍、負責人、資源與時程的說明文件
- **甘特圖三個關鍵組件：**任務 / 依賴關係 / 里程碑
- **AI 專案生命週期：**定義問題 → 收集資料 → 開發模型 → 部署 → 監控維護（循環往復）
- **可行性研究（Feasibility Study）四個維度：**技術 / 經濟 / 營運 / 法律
- **利害關係人分析（Stakeholder Analysis）：**盤點專案中的支持者與可能的阻力來源
- **敏捷（Agile）vs 瀑布（Waterfall）：**
 - ▶ 瀑布：階段依序走完、後期變更代價很高
 - ▶ 敏捷：小步快跑、隨時依回饋調整方向
- **Scrum 框架核心：**
 - ▶ Sprint（短衝）：固定 1-4 週的時間盒
 - ▶ Product Backlog（產品待辦清單）：所有要做的事，依優先序排列
 - ▶ Sprint Backlog（短衝待辦）：本次衝刺承諾要完成的任務
 - ▶ 三大角色：Product Owner（產品負責人）/ Scrum Master（敏捷教練）/ Development Team（開發團隊）
 - ▶ 三大活動：Daily Scrum（15 分鐘每日站會）/ Sprint Review（對外展示成果）/ Sprint Retrospective（團隊內部檢討）（此為省略 Sprint Planning 等項的簡化列法，完整為五活動，見 Scrum 3-5-3）
- **AI 團隊的四個核心角色：**AI 專案經理 / 資料科學家 / 機器學習工程師 / 領域專家
- **常用開發工具：**Jupyter Notebook（資料科學的互動式實驗環境）、VS Code（通用程式編輯器）、雲端 AI 平台（AWS/GCP/Azure）
- **任務管理工具取舍：**Trello（輕量、上手快）vs Jira（功能完整、流程嚴謹）
- **AI 導入三種模式：**
 - ▶ 採用現成商業服務（快、標準化，但能力難留在公司內）
 - ▶ 內部團隊自行開發（高度客製、資料安全，但成本高）
 - ▶ 委外開發（快速借助外部專家，但成本與機密外洩風險較高）

陷阱（B2）

- **陷阱：**想趕工就把人力全砸在非關鍵任務上 → 錯！只有壓縮**關鍵路徑**才能真正縮短總工期
- **陷阱：**把 WBS 等同甘特圖 → 錯！WBS 回答「要做哪些任務（What）」，甘特圖回答「何時做（When）」

- **陷阱**：AI 專案套用瀑布式 → 錯！AI 不確定性高，較適合敏捷
- **陷阱**：混淆 Sprint Backlog 與 Product Backlog（前者是本次衝刺的承諾，後者是全部待辦的願望清單）
- **陷阱**：明明缺人才又預算有限，卻硬要走內部開發 → 應該先用現成商業服務搭配 POC 驗證
- **燃盡圖（Burndown Chart）**：用實際數據（而非主觀感覺）追蹤剩餘工作量與進度落差

補充比較表（B2）

瀑布式 vs 敏捷式（AI 專案）

維度	瀑布式	敏捷式
推進方式	階段依序一次走完	短衝反覆迭代
流程	一條龍從頭到尾	多輪短衝
變更成本	極高	低
回饋頻率	末端才有	持續
適用	需求明確、規範嚴	AI、高度不確定

WBS vs 甘特圖

維度	WBS	甘特圖
回答	What（有什麼任務）	When（何時做）
結構	層級樹狀	時間軸條形
核心	範疇完整	進度依賴與里程碑

Trello vs Jira

維度	Trello	Jira
定位	輕量、上手快	功能完整、流程嚴謹
適用	小型團隊輕量協作	嚴謹工程團隊
學習曲線	低	高
流程	看板簡單	Scrum / Kanban 完整支援

三種導入模式

模式	優點	缺點
採用現成服務	快、便宜	客製化低、能力難內化
內部開發	客製化高、資料安全、能累積能力	研發成本高、要養人才
委外開發	借力外部專家、速度快	溝通成本高、機密外洩風險

補充精華（B3）

- **食品工廠轉型案例（日本 Kewpie 美乃滋工廠 AI 原料檢測，Google Cloud 官方公開案例）**：
 - ▶ 背景：日本食品大廠 Kewpie（キューピー）的嬰兒食品產線，過去靠人眼逐顆挑出瑕疵馬鈴薯丁，檢測人力吃緊且品質高度仰賴老手經驗
 - ▶ 決策點 1（可行性與利害關係人）：導入前先與產線品管人員（領域專家）合作定義「什麼算瑕疵」，確認以影像辨識取代人眼初篩在技術與品質要求上可行
 - ▶ 決策點 2（人才組合）：內部熟悉產線的品管老手擔任領域專家提供標註判準，機器學習實作與 Google 團隊合作——「領域專家＋外部技術專家」互補，而非全部自建
 - ▶ 決策點 3（硬體與工具）：採用開源框架 TensorFlow 與雲端運算訓練模型，避免一開始就自購昂貴設備；上線後 AI 先挑出可疑品、人員複檢，檢測負擔大幅下降
 - ▶ （案例出處：Kewpie 馬鈴薯丁瑕疵檢測為 Google Cloud 官方部落格與多家媒體公開報導之案例）
- **WBS 實戰拆解（AI 銷售預測系統）**：
 - ▶ 五大交付物：專案啟動 / 資料準備 / 模型開發 / 系統部署 / 監控維護
 - ▶ WBS Dictionary 範例：工作包 2.2「資料清洗」 / 描述：處理原始銷售資料的缺失值 / 負責人：資料科學團隊主管 / 產出：乾淨資料集
 - ▶ 里程碑：第 6 週「完成第一個模型」
 - ▶ 關鍵路徑：資料清洗 → 特徵工程

- **進度延誤的救援步驟**（資料清理卡關、6 週死線）：
 1. 打開甘特圖，確認延誤是否落在關鍵路徑上
 2. 評估能否從 UI 設計端調人力支援
 3. 更新甘特圖、模擬調整後的新時程
 4. 在任務管理工具中建立新任務並指派
 5. 拿更新後的甘特圖與老闆或客戶溝通
- **客戶分類需求變動演練（教學示範情境）**：
 - ▶ 情境設定：需求方原本說「要分類客戶」→ 三個月後改口「要預測流失率」
 - ▶ 教訓：AI 專案需求高度不確定，必須走敏捷——這正是敏捷宣言（Agile Manifesto，2001，公開文件）「回應變化重於遵循計畫」的典型場景
 - ▶ Scrum 解法：先做最小可行產品（MVP，Minimum Viable Product）「預測高價值客戶下月是否購買單一主力產品」，每兩週一短衝
- **零售商庫存優化演練（教學示範情境，對應通用 Build-vs-Buy 決策框架）**：
 - ▶ 決策一：選現成商業服務（缺人缺錢，而市面 SaaS [Software as a Service，軟體即服務] 已成熟）
 - ▶ 決策二：POC 試用一個月，看預測準度與是否真能減少缺貨／囤貨
 - ▶ 決策三：產出 AI 導入計畫書（Implementation Plan），作為專案的依循基準
- **核心心法**：WBS 為混亂的工作帶來結構，甘特圖為時間安排帶來清晰。

延伸補充：規劃師定位、召回率與導入策略

考點（B1）

- **AI 規劃師與資料科學家的分工**：規劃師偏向整體把關（前期評估、方案設計、風險控管、上線後維護），資料科學家偏向技術實作。
- **召回率（Recall）的使用時機**：寧可多誤判一些正常案例，也不能漏掉真正的異常（醫療診斷、金融反詐、癌症篩檢都屬此類）。
- **資料成熟度的三項檢視**：
 1. 可取得性（是否合法、能取得？）
 2. 品質（有無缺失值、標註是否正確？）
 3. 資料量（量是否足以支撐深度學習？）

補充比較表 — WBS vs 甘特圖（高頻考點）（B2）

工具	回答	焦點	結構
WBS（Work Breakdown Structure，工作分解結構）	What（做什麼）	範疇完整	階層式
甘特圖（Gantt Chart）	When（何時做）	時程安排	線性時間軸

補充比較表 — Sprint Review vs Retrospective（B2）

會議	焦點	對外 / 對內	目的
Sprint Review（短衝檢視）	產品	對外（給利害關係人）	展示成果、取得商業回饋
Sprint Retrospective（短衝回顧）	流程	對內（團隊）	持續改進工作流程

補充比較表 — 自建 / 購買 / 委外（B2）

策略	適用情境	優點	缺點
自建（Build）	不可取代的核心能力	差異化最強	成本高 / 較慢
購買（Buy / SaaS）	通用需求	快 / 省	受廠商鎖定
委外（Outsource）	需客製又缺人才	彈性	知識難內化

考點 — 資料漂移（Data Drift）（B1）

- 真實世界資料分佈改變 → 模型準確度衰退。
- 解法：MLOps 持續監控 + 自動再訓練。
- **GDPR 被遺忘權** 與 **XAI（Explainable AI，可解釋人工智慧）**：在金融、醫療等高風險領域是必備配套。

延伸補充：CRISP-DM 資料專案生命週期

考點 (B1)

- CRISP-DM (Cross-Industry Standard Process for Data Mining, 跨產業資料探勘標準流程) 六階段：
 1. 商業理解 (Business Understanding) — 把模糊的商業問題轉成具體的資料科學問題，並定義成功標準
 2. 資料理解 (Data Understanding) — 觀察與評估資料品質、做 EDA (Exploratory Data Analysis, 探索式資料分析)，此階段只看不改
 3. 資料準備 (Data Preparation) — 清洗、補值、特徵工程
 4. 模型建置 (Modeling) — 選演算法、訓練模型
 5. 模型評估 (Evaluation) — 重點是回頭檢查有沒有達成階段一的商業目標，不只看準確率
 6. 部署 (Deployment) — 整合進實際業務流程
- 時間分配重點：資料準備往往佔整個專案約 70-80% 的時間
- CRISP-DM 不是單向流程：發現問題時「往回走」是正常且必要的，可避免在錯誤基礎上繼續往下做

陷阱 (B2)

- 陷阱：誤以為 CRISP-DM 是線性流程 → 評估結果不理想時，要敢於回到「商業理解」重新定義問題
- 陷阱：把「資料理解」當成「資料準備」在做 → 資料理解階段「只能觀察、不能動手改資料」
- 陷阱：商業目標訂得太空泛（如「希望客戶別流失」）→ 必須翻成可衡量目標（如「6 個月內把首購後 90 天內的流失率降低 15%」）

補充精華 (B3)

- CRISP-DM 的定位：它是一套貫穿資料專案全程的標準流程，引導團隊一步步走向目標、降低走偏的風險。
- 資料理解與資料準備的差別：
 - 資料理解階段：收集線索、評估資料品質，不更動資料
 - 資料準備階段：清洗、補空值、做特徵工程，把原始資料整理成可訓練的素材
- CRISP-DM 的三項價值：
 1. 共同語言 — 讓工程師與業務端能在同一套術語下溝通
 2. 風險管理 — 從一開始就降低走錯方向的機率
 3. 方向指引 — 確保團隊全程朝同一個有價值的目標前進

【中級真題與解析 (114 年第二梯次)】

本節對應 1 題官方真題 (114 年第二梯次中級 AI 應用規劃師)，每題含 4 選項詳細解析、核心考點、易混淆對比。

第 29 題 (114-2-1-Q29)

題幹：某 AI 開發團隊為提升模型開發效率及品質控制，計畫實施持續整合 (Continuous Integration, CI) 流程。下列哪一項做法最符合 CI 的核心實踐，且能有效減少整合風險？

選項：

- (A) 在主分支 (Main Branch) 每日固定時間手動合併並執行完整測試流程
- (B) 每次程式碼提交 (Commit) 後自動觸發建置、單元測試及靜態程式碼分析
- (C) 於模型訓練完成後，定期安排開發團隊回顧並合併程式碼
- (D) 透過自動化部署腳本，將模型在特定時間點批次釋出到測試環境

正確答案：B

詳細解析：

- ✓ (B) 正確：CI (Continuous Integration, 持續整合) 核心實踐 = 「每次 commit 自動觸發 build + test + static analysis」。早期、頻繁、自動化整合是 CI 核心精神 — Fail Fast、提早暴露衝突、降低整合風險。CI 三件套：Build (建置) + Test (單元測試 + 整合測試) + Static Analysis (靜態分析如 lint / SonarQube)。
- × (A) 錯誤：「每日固定時間 + 手動合併」是傳統 Daily Build (夜間構建) 模式，整合間隔過長 + 人工流程違反 CI 「commit 即觸發」原則。
- × (C) 錯誤：「定期回顧 + 合併」描述的是 Code Review 流程，不是 CI 自動觸發機制。

- × (D) 錯誤：「特定時間點批次釋出到測試環境」是 CD (Continuous Delivery, 持續交付) 的部署環節，不是 CI 整合環節。CI ≠ CD。

核心考點：CI 定義 = 「commit 即觸發 + 自動化 build + test + static analysis」；CI vs CD vs CT 三者邊界。注意：Continuous Delivery (持續交付，人工核准後部署) 與 Continuous Deployment (持續部署，全自動) 是兩個不同概念，本書後文 CD 指後者。

易混淆對比：CI (commit → build/test, 整合) vs CD (delivery, 自動部署到 staging/prod) vs CT (Continuous Training, 自動再訓練 ML 模型) vs Daily Build (傳統夜間構建)。

對應章節：L21202 AI 導入規劃

延伸補充：開發方法論、規劃師職能與統計陷阱

考點 (B1)

- 【考點】WBS (Work Breakdown Structure, 工作分解結構) = 把專案拆成可執行的小任務。
- 【考點】瀑布式 (Waterfall) = 階段依序進行、順序不可亂，適合目標明確、不太變動的專案。
- 【考點】敏捷式 (Agile) / Scrum = 持續迭代、隨時修正，**對 AI 專案更合適** (因為充滿未知與變動)。
- 【考點】甘特圖 (Gantt Chart) = 瀑布式的經典工具，用時間軸呈現任務的起迄與依賴關係。

補充判別表 (B1) Scrum 四大核心活動

(此為省略 Sprint 本體的簡化列法，完整為五活動——見前文 Scrum 3-5-3 架構)

活動	目的	時機
Sprint Planning (衝刺規劃會議)	決定本次 Sprint 要達成哪個小目標	Sprint 開始
Daily Stand-up (每日站立會議)	15 分鐘快速同步進度、排除阻礙	每天
Sprint Review (衝刺審查會議)	向利害關係人展示本次 Sprint 成果	Sprint 結束
Sprint Retrospective (衝刺回顧會議)	團隊檢討如何讓下次 Sprint 做得更好	Sprint 結束

補充精華 (B3)

- **Sprint (衝刺) 核心精神：**是一段固定 2-4 週的短而集中的時間盒，團隊在這段期間專注交付一個具體成果。
- **甘特圖的侷限：**AI 專案常需大量實驗探索，一開始很難精準估出「這個模型要訓練多久才能達到目標準確率」，過於僵化的甘特圖反而綁手綁腳。

延伸補充：規劃師核心職能與跨部門需求

考點 (B1)

- **AI 應用規劃師的核心職能：**
 1. 針對業務需求評選技術方案與工具組合
 2. 協調跨部門利害關係人、推動導入落地
 3. 界定成功指標與驗收標準 (KPI、驗收條件、監控門檻)
 4. **角色定位在規劃與治理，而非親手實作程式** (常見陷阱：誤以為規劃師要會手寫 code)
- **各部門關注點不同 (衝突來源)：**
 - IT 部門：系統可用性、維運負擔與整合複雜度
 - 業務／行銷部門：成效落地速度與投資效益 (ROI, Return on Investment, 投資報酬率)
 - 法務部門：個資與法遵風險是否可控
 - 財務部門：TCO (Total Cost of Ownership, 總持有成本) 與回收期
 - 資安部門：攻擊面擴大與存取控制設計
 - AI 規劃師：在上述訴求之間排定優先序並取得平衡

補充精華 (B3)

- **規劃師要兼顧三件事：**技術、商業策略，以及乾淨的資料。
- **「資料品質決定模型效能」：**考試中看到「模型不準、專案卡關」，多半根因都在資料品質或前處理 (Garbage In, Garbage Out, 垃圾進垃圾出)。

延伸補充：假設檢定與描述統計考點

考點 (B1)

- **P 值判讀 (必背)**：P 值越小，代表在虛無假設成立下觀察到此結果的機率越低，越能拒絕虛無假設 H_0 ； $P < 0.05$ 通常視為結果顯著
- **箱型圖 (Box Plot) 的送分題**：圖上鬚線之外那些孤立的小點，就是「離群值／異常值」
- **Z 分數 (Z-Score) 警戒線**：絕對值 ≥ 3 通常就視為異常值
- **常態分佈下**： $Z > 3$ 多半就是異常值
- **峰度 (Kurtosis) 偏高**：代表分佈「厚尾」，極端事件（黑天鵝）發生機率比常態分佈所預估的高

補充比較表 (B2)：型一／型二錯誤 (必考)

錯誤類型	白話說明	統計意義	醫療例
Type I (型一)	把沒問題的當成有問題	偽陽性 (False Positive)	健康人被判有病
Type II (型二)	把有問題的放過了	偽陰性 (False Negative)	漏掉真正的病人

補充比較表 (B2)：平均數 vs 中位數

指標	是否抗極端值	計算方式	適用情境
平均數	不抗 (易被極端值拉走)	全部加總除以個數	資料分佈對稱時
中位數	抗 (不受極端值影響)	由小到大排序取正中間	房價、薪資 (厚尾分佈)

考點 (B1) — 進階統計陷阱

- **P 值 vs 效果量 (Effect Size) 陷阱**：大數據下任何微小差異都會讓 P 值極小，**必須同時看效果量**才知道是否有實際商業意義
- **多重檢定問題**：同時測上千個無用指標，純機率就會有一批「看似顯著」→ 需用 **Bonferroni 校正** 或 **FDR (False Discovery Rate, 偽發現率) 控制**
- **A/B 測試要看三件事**：P 值 (效果是否真實存在)、效果量 (差異有多大)、實務顯著性 (在業務上是否值得在意)

【中級真題與解析 (115 年第一次)】

本節對應 3 題官方真題 (115 年第一次中級 AI 應用規劃師)，每題含 4 選項詳細解析、核心考點、易混淆對比。

第 20 題 (115-1-1-Q20)

題幹：某電商公司計畫導入即時推薦系統，希望使用者進入網站後能在 100 毫秒內取得推薦結果，且推薦結果需依據最新使用者行為進行調整。系統需支援每日約 50 萬活躍使用者，尖峰時段每秒約 3,000 筆請求 (QPS)。目前公司已累積歷史購買紀錄與瀏覽行為資料，並持續接收即時點擊流 (Streaming Data)。IT 基礎架構採用雲端環境，團隊配置為 2 名資料工程師與 1 名機器學習工程師。某工程師提出以下導入規劃：

- (1) 使用批次訓練 (Batch Training) 建立協同過濾模型
- (2) 將模型部署為 REST API 提供即時推論服務
- (3) 使用 Kafka 串流處理即時使用者行為特徵
- (4) 將所有即時資料先寫入資料倉儲 (Data Warehouse) 再進行特徵計算
- (5) 使用 Redis 或 Feature Store 快取即時特徵

請問以下哪一項最合理的技術導入規劃組合與調整建議？

選項：

- (A) 保留 (1)(2)(3)，移除 (4)，並加入 (5) 以降低延遲
- (B) 保留 (1)(4)，移除 (3)，以確保資料一致性與系統穩定
- (C) 保留 (2)(4)(5)，移除 (1)，改用即時線上學習 (Online Learning)
- (D) 全部保留 (1)~(5)，可同時兼顧即時性與資料完整性

正確答案：A

詳細解析：

- ✓ (A) 正確：關鍵矛盾在 (4)——資料倉儲 (Data Warehouse，資料倉儲) 是為離線分析查詢設計的批次系統，把即時點擊流「先落倉再算特徵」會引入秒級以上延遲，直接違反 100ms 的即時需求，必須移除。合理架構是典型的「批次訓練+即時服務」組合：(1) 離線批次訓練協同過濾模型（歷史資料本來就適合批次）+ (3) Kafka 串流即時處理行為特徵 + (5) Redis/Feature Store（特徵庫）以記憶體級延遲（毫秒級）提供最新特徵 + (2) REST API 即時推論。這實質上是 Lambda 架構精神：批次層管模型、串流層管新鮮特徵。
- × (B) 錯誤：移除 Kafka 串流等於放棄「依據最新使用者行為調整」的核心需求；只靠倉儲批次管線，特徵新鮮度以小時計，不符題目情境。
- × (C) 錯誤：線上學習 (Online Learning，線上學習：模型隨每筆新資料即時更新) 工程複雜度高（更新穩定性、回滾、監控），對 2+1 人的小團隊過重；且保留 (4) 的倉儲繞路仍然卡延遲——移錯了對象。
- × (D) 錯誤：(4) 與 100ms 延遲需求直接衝突，「全部保留」迴避了取舍；規劃題中「全都要」幾乎都是干擾項。

核心考點：即時推薦的標準架構分層——離線批次訓練模型／串流管線算即時特徵／記憶體快取供特徵／API 供推論；判別關鍵是「Data Warehouse 在即時路徑上＝延遲瓶頸」。情境線索：100ms 延遲上限＋持續點擊流＋小團隊。

易混淆對比：批次處理（吞吐量優先、延遲分鐘～小時級，適合訓練）vs 串流處理（延遲秒級以下，適合即時特徵）；Data Warehouse（結構化、離線分析）vs Feature Store/Redis（低延遲線上特徵服務）——同是「存資料」，服務的延遲等級完全不同。

對應章節：L21202 AI 導入規劃

第 21 題 (115-1-1-Q21)

題幹：一位機器學習工程師正在優化公司內部的 RAG 法律文件問答系統。近期因營運成本壓力，公司要求在不更換模型且不影響回答品質的前提下，將整體 token 成本降低至目前的 60%，且目前成本主要集中於輸入 tokens。工程師在檢查系統後，盤點出目前的使用情況如下：

- ◆ 使用模型：GPT-4o（輸入 \$5/1M tokens、輸出 \$15/1M tokens）
- ◆ 每次查詢：將前 10 筆檢索文件區塊全部加入 Prompt（每塊約 600 tokens）
- ◆ System Prompt：每次請求均包含約 500 tokens 的公司背景說明
- ◆ 對話機制：保留完整對話歷史，平均累積約 8,000 tokens
- ◆ 每日查詢量：約 5,000 次
- ◆ 平均輸出：約 300 tokens/次

在上述限制與系統現況下，請問下列哪一項優化組合，最能在維持回答品質的前提下有效降低 token 成本？

選項：

- (A) 將輸出 max_tokens 從 1,000 壓縮至 200，強制模型給出更短的回答，以降低輸出費用
- (B) 將 System Prompt 改為 Prompt Caching 或靜態前綴重用，並對對話歷史實作摘要壓縮，以保留語意而非完整對話
- (C) 將所有查詢改為 Batch API 模式送出，透過非同步處理降低單次費用
- (D) 在 Prompt 中明確要求模型「回答時盡量簡短」，透過指令引導模型自行縮減輸出長度

正確答案：B

詳細解析：

- ✓ (B) 正確：先算成本結構：每次輸入 $\approx$ 檢索區塊 6,000 (10×600) + System Prompt 500 + 對話歷史 8,000 $\approx$ 14,500 tokens，輸出僅 300 tokens——題幹也明示「成本集中於輸入」。因此優化必須打輸入端的兩大塊：①每次重複傳送的固定 System Prompt → 用 Prompt Caching（提示快取：供應商對重複前綴收取大幅折扣費率）或靜態前綴重用；②不斷膨脹的 8,000 tokens 對話歷史 → 摘要壓縮 (Summarization Compression)，以摘要保留語意脈絡取代全文重送，直接砍掉輸入最大宗且不犧牲回答所需資訊。兩招都作用在輸入端、且不損品質，正中要害。
- × (A) 錯誤：打錯戰場——輸出僅 300 tokens/次，佔比極小 (300×\$15 對 14,500×\$5，輸出費用約為輸入的 6%)，壓輸出省不了多少；且硬砍 max_tokens 到 200 會截斷回答，直接違反「不影響回答品質」的前提。
- × (C) 錯誤：Batch API（批次 API：非同步、以延遲換折扣，常見 50% 折扣）雖能降費率，但這是「即時問答系統」——使用者在線等回答，改成非同步批次處理犧牲互動性，場景不適用。

- × (D) 錯誤：與 (A) 同樣打輸出端的小頭；且「盡量簡短」的指令對成本影響有限又可能讓回答遺漏法律細節，風險大於收益。

核心考點：LLM 成本優化第一步是「找出 token 花在哪」——本題輸入佔絕對大宗，正解必然是輸入端手段（快取重複前綴+壓縮對話歷史）；情境線索是題幹直接說「成本主要集中於輸入 tokens」。

易混淆對比：Prompt Caching（不減少 token 數，靠快取「降低重複前綴的單價」）vs 摘要壓縮（真正「減少輸入 token 數」）vs Batch API（降單價但變非同步，僅適合離線批量任務）——三種降本機制的作用點與適用場景各不同。

對應章節：L21202 AI 導入規劃

第 23 題 (115-1-1-Q23)

題幹：某製造業公司計劃將 AI 導入生產線瑕疵檢測流程，目前瑕疵樣本約 800 張（含各類瑕疵類型）、正常樣本約 15,000 張，現有 IT 基礎設施為地端伺服器且無 GPU，且生產線環境需於地端即時完成推論，檢測需求為每片零件須在 100 毫秒內完成檢測，且預算為中等、無法於短期內大規模採購硬體。工程師正在規劃第一階段的 AI 導入方案，請問下列哪一種規劃最為合適？

選項：

- (A) 從零訓練一個大型 CNN 模型，並採購高階 GPU 伺服器以滿足推論速度需求
- (B) 採用預訓練模型進行 Transfer Learning，針對瑕疵樣本進行 Fine-tuning，並使用模型量化（Quantization）或蒸餾（Distillation）技術壓縮模型以符合延遲需求，部署於地端
- (C) 因樣本數不足，建議先暫緩 AI 導入，待蒐集至少 10 萬筆瑕疵樣本後再啟動專案
- (D) 將所有影像上傳至雲端，使用第三方 AutoML 平台自動訓練並部署，以節省開發時間

正確答案：B

詳細解析：

- ✓ (B) 正確：逐一對應題幹約束：①瑕疵樣本僅 800 張 → 遷移學習（Transfer Learning，遷移學習）用大型資料集預訓練的特徵擷取能力，小樣本微調（Fine-tuning）即可達可用精度；②無 GPU+100ms 地端推論 → 量化（Quantization，量化：如 FP32→INT8，縮小模型、加速 CPU 推論）或蒸餾（Distillation，蒸餾：訓練小模型模仿大模型）壓縮模型以在 CPU 上滿足延遲；③預算中等 → 不需採購硬體。四項限制全部被此方案化解，是典型「約束驅動」的務實規劃。
- × (A) 錯誤：從零訓練大型 CNN 需要大量標註資料（800 張遠遠不夠）且違反「無法短期採購硬體」的預算限制——同時撞上資料與預算兩堵牆。
- × (C) 錯誤：過度保守。遷移學習的存在正是為了小樣本場景；「等 10 萬筆瑕疵樣本」在良率高的產線上可能要等數年，等於實質放棄導入。第一階段先以現有資料建立基線（Baseline）、上線後持續累積資料迭代，才是正確的導入節奏。
- × (D) 錯誤：違反「地端即時推論」的場景約束——雲端推論的網路往返延遲與連線穩定性難以保證 100ms；且製造業影像外傳雲端常有資料保密疑慮。

核心考點：AI 導入規劃＝在「資料量／硬體／延遲／預算」多重約束下選可行方案；小樣本→遷移學習、CPU 低延遲→量化/蒸餾、地端需求→不走雲端，三個映射是判別關鍵。

易混淆對比：遷移學習（解「資料少」）vs 量化／蒸餾（解「推論慢、硬體弱」）——一個作用在訓練階段、一個作用在部署階段，本題正解是兩者的組合拳；另「暫緩等資料」vs「小步先行」：導入規劃題中，善用現有資源起步幾乎總是優於無限期等待理想條件。

對應章節：L21202 AI 導入規劃

L21203 AI 風險管理

※ 考綱重點（L21203 AI 風險管理）：風險識別（資料／模型／部署／系統面）、安全與合規性（GDPR／個資法／台灣 AI 基本法）、AI 倫理、負責任 AI（RAI／TAI／FATE 原則）

風險管理為全生命週期治理

AI 風險管理應為 前瞻性與持續性機制，從規劃階段納入並貫穿模型開發、測試、部署、運維各階段，形成完整的全生命週期風險治理體系。AI 治理（AI Governance）為制度化框架，持續調整以因應技術與環境變動。

◎ 三層風險分類

A. 技術層風險

風險	子問題	影響案例
資料品質風險（Data Quality Risk）	資料遺漏（Missing Data）、資料偏頗（Data Bias）、不正確標註（Incorrect Labeling）、資料漂移（Data Drift）	信用評分系統因歷史偏差歧視特定族群
模型穩定性風險（Model Stability Risk）	模型漂移（Model Drift）、過擬合（Overfitting）、概念漂移（Concept Drift）	製造業瑕疵辨識系統因產線微調精準度下降

【易混淆對比】三種「漂移」：

類型	英文	定義	例子
資料漂移	Data Drift	輸入資料的統計分佈改變	顧客年齡分佈隨時間改變
概念漂移	Concept Drift	輸入與輸出間的潛在關係改變	詐欺手法變化，原有特徵失效
模型漂移	Model Drift	模型預測準確度隨時間下降	通常是 Data Drift 或 Concept Drift 的結果

【陷阱】三者常被互換使用，但精確定義不同。Data Drift 是「輸入變了」、Concept Drift 是「規則變了」、Model Drift 是「結果變差」。

B. 組織人力層風險

風險	英文	範例
跨部門溝通風險	Cross-functional Communication Risk	金融機構風控與 IT 部門溝通不足，模型與業務脫節
技能短缺風險	Skill Gap Risk	智慧城市專案內部缺資料分析人才，系統無法運作
變革抵制風險	Change Resistance Risk	醫療人員擔憂被取代，AI 輔助診斷使用率低

C. 法規層風險

風險	範例
個資與隱私保護風險	科技公司因未揭露資料用途遭 GDPR 高額罰款
產業特定監管風險	銀行 AI 客戶辨識未符法規導致營運暫停
侵權風險（Infringement Risk）	未授權使用第三方訓練資料被判侵權

◎ 重要法規逐項說明

A. GDPR（General Data Protection Regulation，歐盟通用資料保護規則）

適用於處理歐盟居民個資的所有企業（無論註冊地）。核心權利與原則：

編號	權利/原則	條文	內容
1	刪除權／遺忘權（Right to Erasure / Right to be Forgotten）	第 17 條	資料主體可要求刪除個資
2	修正權（Right to Rectification）	第 16 條	資料錯誤時要求修正
3	資料可攜權（Data Portability）	第 20 條	以結構化、可機讀格式取得並轉移資料
4	反對自動化決策權（Right to Object to Automated Decision Making）	第 22 條	反對純自動化的重大決策（如信用評分、招聘）
5	查閱權（Right of Access）	第 15 條	了解資料處理目的、類型、保存期限，一個月（約 30 日）內回覆
6	處理限制權（Right to Restriction of Processing）	第 18 條	暫停處理請求
7	同意原則（Consent）	第 6 條	處理需明確、自由給予的同意，可隨時撤回
8	資料最小化原則（Data Minimization）	第 5 條	僅收集達成目的所必須資料

編號	權利/原則	條文	內容
9	問責制 (Accountability)	第 5/24 條	必須證明合規措施並留紀錄
10	資料保護影響評估 (DPIA, Data Protection Impact Assessment)	第 35 條	高風險處理前須進行影響評估

【口訣】 GDPR 核心權利「刪修攜反查限同最問評」（刪除/修正/可攜/反對/查閱/限制/同意/最小化/問責/DPIA）。

B. PDPA (Personal Data Protection Act, 個人資料保護法, 台灣)

PDPA 之目的為規範個人資料之蒐集、處理及利用，以避免人格權受侵害，並促進個人資料之合理利用。

蒐集個人資料前應向當事人明確告知下列事項（事前告知義務）：

編號	告知事項
1	蒐集機關名稱（含公務機關及非公務機關）
2	蒐集目的與使用範圍
3	個人資料之類別
4	個人資料利用情形（包含利用期間、地區、對象及方式）
5	當事人權利及行使方式（依第三條規定，如查詢、閱覽、更正、刪除等權利）
6	不提供資料之影響（當事人得自由選擇是否提供，並應告知不提供時對其權益之影響）

【考點】 PDPA 事前告知義務的核心，在於確保當事人對個人資料之蒐集與利用具備充分知情權與自主決定權。詳細完整法規說明請參考《個人資料保護法》。

【陷阱】 PDPA 告知事項與 GDPR 權利不可互換：PDPA 強調「告知」+「同意」前提；GDPR 更強調主體權利清單與企業問責制。

C. CDPA (Consumer Data Protection Act, 美國消費者資料保護法)

美國地方性法規（如維吉尼亞州），重點：

重點	內容
權利	查閱、修正、刪除、資料可攜權
揭露	透明簡明的隱私政策
敏感資料	健康資訊等更嚴格保護

D. 產業專用合規規範

規範	全名	適用領域	重點
HIPAA	Health Insurance Portability and Accountability Act, 美國健康保險可攜性與責任法案	醫療	技術性保護（加密、身分驗證、安全傳輸）+ 實體性保護（設備、災難復原）+ 行政性保護（政策、培訓、風險評估）
PCI-DSS	Payment Card Industry Data Security Standard, 支付卡產業資料安全標準	支付卡產業	防火牆、TLS/AES 加密、多因素認證、弱點掃描、滲透測試
台灣金融科技創新實驗條例	FinTech Sandbox	金融創新	服務創新審核、個資安全、試行合規
台灣醫療器材管理法	—	醫療 AI	上市許可、品質與安全 (TFDA 主管)
台灣電信管理法	—	電信/AI 通訊	網路安全、消費者權益 (NCC 主管)
台灣智慧財產權法	—	著作權/專利	AI 模型與資料集版權 (TIPO 主管)

◎ 偏見與倫理

模型偏見產生來源：

偏見類型	英文	來源
資料分布不均	Imbalanced Data	群體樣本不足
歷史偏見	Historical Bias	歷史資料反映社會制度偏見
標註偏見	Labeling Bias	標註者主觀觀點
演算法偏見	Algorithmic Bias	設計優化整體效能犧牲少數群體

【考點】 偏見會造成弱勢群體歧視（貸款、招聘、醫療資源分配）+ 企業品牌與信譽損害。

國際 AI 倫理四原則：

原則	英文	核心	應用
透明度	Transparency	公開 AI 模型運作邏輯與決策依據	高風險領域必要
可解釋性	Explainability	解釋為何做出某決策	金融、人資
公平性	Fairness	避免不同群體歧視	訓練資料審查
問責性	Accountability	明確責任歸屬	出錯時可追溯與修正

【口訣】 AI 倫理四原則「透解公責」（透明、解釋、公平、問責）。

國際參考標準：

組織/文件	年份	主軸
歐盟《人工智慧倫理指導原則》(Ethics Guidelines for Trustworthy AI, AI HLEG)	2019	可信賴 AI
OECD《人工智慧高級準則》(OECD Principles on Artificial Intelligence)	2019	國家政策準則
聯合國 / UNESCO	—	推動人權與隱私
全球人工智慧聯盟 (GPAI, Global Partnership on Artificial Intelligence, 全球人工智慧夥伴關係)	—	跨國協作
國際標準化組織 (ISO/IEC)	—	技術標準

企業內部倫理治理框架：

機制	功能
倫理委員會 (Ethics Committee)	跨領域審查 AI 專案倫理影響
AI 審查流程 (Ethical Review Process)	部署前風險評估與預防建議
內部教育訓練 (Internal Training)	提升員工倫理意識
透明度與對外溝通 (Public Communication)	公開使用原則、接受外部監督

風險控管四策略

策略	英文	適用情境	範例
迴避	Avoidance	風險嚴重且難控	醫療 AI 資料不足，暫緩專案
轉移	Transfer	透過保險或合約轉嫁	購買 AI 系統故障保險、與供應商簽 SLA (Service Level Agreement, 服務水準協議)
緩解	Mitigation	最常見、主動降低風險	資料清洗、模型驗證、加密、合規培訓
接受	Acceptance	影響低、控管成本不划算	1% 推薦準確率波動、設監控閾值

【口訣】 四策略可用英文字首「ATMA」串記：Avoidance（迴避）、Transfer（轉移）、Mitigation（緩解）、Acceptance（接受）；判讀心法是「控不住就躲、扛不起就分、能壓就壓、影響小就收」。

風險管理計畫 (Risk Management Plan) 內容：

項目	內容
風險識別與評估結果	清單 + 影響評分
風險對應措施	行動 + 時程
責任人與分工	角色與權責
監控與回報機制	觸發條件、通報路徑

MLOps 風險監控

MLOps (Machine Learning Operations, 機器學習運維) 整合 ML 開發與營運，自動化模型全生命週期。常見風險監控情境：

監控類型	英文	觸發條件	自動行為
模型漂移監控	Model Drift Monitoring	模型準確率下降	自動觸發重新訓練
資料漂移監控	Data Drift Monitoring	輸入資料分佈變化	警告 + 調整模型

監控類型	英文	觸發條件	自動行為
資料品質監控	Data Quality Monitoring	缺失率升高、schema 變更	阻擋異常批次 + 通知資料負責人
效能異常警示	Performance Anomaly Alerting	關鍵指標劣化超過預設容忍區間	即時通知團隊
自動重新訓練	Auto-retraining	偵測漂移	自動訓練更新模型

→ MLOps 部署細節 見 L21302 AI 技術系統集成與部署；資料隱私 見 L23401 數據隱私、安全與合規（見第三冊）；演算法偏見 見 L23402 演算法偏見與公平性（見第三冊）

延伸補充：風險矩陣、應對策略與誤報漏報

考點（B1）

- **風險矩陣（Risk Matrix）公式：**風險等級 = 發生機率 × 影響程度
- **熱力圖（Heat Map）：**Y 軸為發生機率、X 軸為影響程度，左下角偏綠（安全）、右上角偏紅（極高危）
- **兩種分類錯誤（與混淆矩陣相關）：**
 - ▶ False Positive（誤報）= 沒問題卻被系統判為有問題
 - ▶ False Negative（漏報）= 有問題卻沒被系統偵測到
- **風險應對的四種策略：**
 1. 迴避（Avoid）：從源頭移除風險來源，例如**直接停用或下架高風險功能**
 2. 減輕（Mitigate）：設法壓低發生機率或縮小衝擊，例如**插入人工審核關卡、加密、增加驗證步驟**
 3. 轉移（Transfer）：把責任與損失分攤給第三方，例如**委外承作或投保責任險、簽 SLA**
 4. 接受（Accept）：評估後判定可承受，於是**留著風險但持續監控**，待其超標再處理
- **蝴蝶結分析（Bow-Tie Analysis）：**左側列致因與預防屏障、中央為風險事件、右側列後果與減緩屏障的視覺化工具。
 - ▶ 左半部：每條致因路徑上標註「預防型控制（Preventive Controls）」，用於降低事件被觸發的機率。
 - ▶ 右半部：每條後果路徑上標註「緩解型控制（Mitigative Controls）」，用於縮小事件發生後的衝擊。
 - ▶ **【考點】命名由來**＝圖形左右展開似蝴蝶結；作答時記住「左防發生、右防擴大」即可對應多數選項。
- **風險登錄表（Risk Register）：**以表格形式集中追蹤所有已識別風險的工作底稿。核心欄位可精簡為三大群組——「識別」（編號、描述、綜合等級）、「應對」（所選策略與具體行動）、「追蹤」（負責人、期限與目前狀態）；實務上可依專案需要增減欄位。
- **AI 的法律與合規風險點：**
 - ▶ 個資（PII，Personally Identifiable Information，可識別個人資料）外洩責任
 - ▶ 演算法歧視（年齡／性別／種族）
 - ▶ 智慧財產權（訓練資料來源是否合法）
 - ▶ 模型決策的可解釋責任
- **AI 偏見的法律責任與免責：**使用者協議要明確標示 AI 決策的限制與責任歸屬

陷阱（B2）

- **陷阱：**模型準確率高就等於安全？→ 錯！真正要問的是「犯錯時的代價有多大」
- **陷阱：**看到高風險就反射性選「減輕」→ 錯！像個資外洩、違法這類「無法控制」的風險，正解是**迴避**
- **陷阱：**只看發生機率排優先序 → 錯！要看「機率 × 影響」的綜合分數（風險等級）
- **陷阱：**癌症篩檢 AI 漏報（False Negative）代價極高（攸關人命）；垃圾郵件過濾 AI 誤報（False Positive）代價也可能極高（誤刪重要合約信）——代價方向因情境而異

補充比較表（B2）

False Positive vs False Negative

維度	False Positive（誤報）	False Negative（漏報）
定義	沒問題卻判為有問題	有問題卻沒被偵測到
癌症篩檢	多一場虛驚（尚可接受）	錯過治療黃金期（災難）
垃圾郵件	誤刪重要信（災難）	多看一兩封垃圾（尚可接受）
策略選擇	視情境寧嚴或寧鬆	由業務代價決定

風險應對四選一

策略	適用場景	AI 專案範例
迴避	風險無法控制（法律／個資）	砍掉敏感功能
減輕	可降低影響	加人工審核、加密
轉移	自身無法獨力承擔	外包、買保險
接受	風險低且穩定	接受並持續監控

補充精華（B3）

- 兩種錯誤的風險對比（以醫學篩檢為例——統計教科書經典場景）：
 - 風險 1：把真有疾病的患者判為陰性而放走（偽陰性，False Negative；機率中等、一旦發生影響為災難級——延誤治療）→ 綜合評為**極高風險**
 - 風險 2：把健康的人誤判為陽性（偽陽性，False Positive；機率偏高、但影響僅為複檢成本與短暫虛驚）→ 綜合評為**中風險**
 - 結論：排優先序要看「機率 × 影響」，影響可能釀成重大後果的低機率事件，往往該排在影響有限的高機率事件之前。同一邏輯搬到工業品檢就是「瑕疵品流出（漏檢）vs 良品誤殺（過殺）」的取捨
- AI 信貸審核系統的風險演練（示範如何套用 PMBOK 四策略；背景可對照公開的 Apple Card 事件——2019 年其信用額度演算法被投訴對女性額度偏低、引發紐約州金融署調查）：以一套自動核貸模型為例，常見的數個風險不必各自只對應單一策略，實務上往往是「多策略並用」——
 - 模型把有還款能力的優質客戶誤拒：屬於可量化、影響中等的營運風險，可先**接受**並持續監控核拒比例，待偏差累積到門檻再回頭調參。
 - 模型把高違約風險者誤准放款：影響等級高，採**減輕**為主——拉高決策門檻、加掛人工覆核關卡，同時對放款金額設上限以縮小單筆衝擊。
 - 訓練資料含敏感個資、潛在外洩與合規責任：採**減輕**加**轉移**雙管齊下——資料全程去識別化與加密（減輕），並以投保與委外合規稽核分攤殘餘責任（轉移）。
 - 若某項風險屬於「法令明文禁止、無法用控制手段壓低」（例如以受保護特徵直接做差別待遇——Apple Card 爭議的核心疑慮即在此類），則唯一正解是**迴避**——從設計上直接移除該欄位與相關邏輯。
 - 重點**：同一系統內不同風險可分別落在四種策略，甚至單一風險同時用兩種策略；策略選擇取決於「機率 × 影響」與「是否可控」，而非機械式地一對一套用。
- 自動系統誤傷正常民眾案例（澳洲 Robodebt 醜聞，公開的皇家調查委員會案例）：澳洲政府 2016–2019 年間以自動化所得比對系統向數十萬名領取福利者發出追債通知，其中大量債務其實是演算法平均化計算錯誤產生的「幽靈債務」；2023 年皇家調查委員會（Royal Commission）認定該計畫違法。教訓：根因不在程式有 bug，而在事前的風險識別、法律確認與人工覆核機制不足——自動化決策的錯誤會以行政規模放大

延伸補充：擬合、漂移與風險解法對照

考點（B1）

- 「準確率很高卻害公司虧錢」的典型情形：模型在不知不覺中對特定性別求職者產生歧視（曾有大型科技公司的 AI 履歷篩選工具發生此問題）。
- 過擬合（Overfitting）：訓練表現極好、測試表現很差，類似只會背題庫卻不會變化題的學生。
- 欠擬合（Underfitting）：訓練與測試都差，類似根本沒準備好的學生。

補充比較表 — 兩種漂移（B2）

類型	定義	白話
資料漂移 Data Drift	輸入 X 的分佈改變，但 $X \rightarrow Y$ 的關係不變	進來的資料樣貌變了
概念漂移 Concept Drift	$X \rightarrow Y$ 的關係本身改變（規則變了）	連判斷規則都變了

陷阱（B2）

- 代理變數導致的隱性歧視：曾有再犯風險評估演算法被指對特定族群被告系統性高估風險，關鍵在於即使刻意拿掉「種族」欄位，模型仍可能透過郵遞區號、學歷等「代理變數（Proxy Variable）」間接推斷出敏感屬性，繼續產生歧視。
- AI 幻覺（Hallucination）：並非惡意，而是生成式模型運作機制下的先天限制。

- **Deepfake（深偽）詐騙**：曾有跨國企業的財務人員在一場視訊會議中，除自己以外與會者全是 AI 合成影像，因而被詐騙鉅額款項。

補充風險→解決方案對照表（B2）

風險	解法
過度擬合	交叉驗證 / 正規化 / Dropout
資料偏見	重抽樣 / 平衡資料
隱私洩漏	差分隱私 / 聯邦學習
AI 幻覺	RAG（Retrieval-Augmented Generation，檢索增強生成）
供應鏈攻擊	模型來源驗證 / SBOM（Software Bill of Materials，軟體物料清單）

AI 治理三道防線（B3）

- **模型登錄中心**（為每個模型建立可追溯的身分與版本紀錄）
- **即時監控**（24/7 持續偵測模型健康狀態）
- **可解釋性**（讓黑盒模型的決策依據可被檢視）

延伸補充：演算法偏見來源與倫理界線

考點（B1）

- **演算法偏見不是程式 bug**，而是系統性問題，根源往往在於訓練資料本身就帶有偏差
- **偏見的兩大來源**：
 1. **歷史偏見（Historical Bias）**：資料如實反映了過去社會的不平等（例如過去某職業以男性居多 → 模型學到「男性是加分項」 → 履歷篩選對女性不利）
 2. **採樣偏見（Sampling Bias）**：收集到的樣本無法代表真實世界全貌（例如早期人臉辨識資料以特定族群為主 → 對其他族群的錯誤率偏高）
- **XAI（Explainable AI，可解釋人工智慧）** 是檢視黑盒決策的關鍵工具
- **核心原則**：「合法不等於合乎倫理」—— 法律只是道德的最低標準，不是上限

補充比較表（B2）

問題類型	法律層面	倫理層面
在問什麼	我們 能不能 做？	我們 應不應該 做？
性質	最低門檻（底線）	更深一層的考量（上限）
例子	法規禁止使用某些敏感個資	即使合法，透過代理變數間接歧視仍不應為

補充精華（B3）

- **偏見會被放大**：AI 等於把社會的樣貌反映出來，更需警惕的是它可能在統計與規模化下進一步放大既有的不公。
- **模型學什麼像什麼**：模型從我們餵入的資料中學習，若資料帶有偏見，模型就會習得偏見。
- **負責任規劃師的兩重自問**：
 - 法律面：「這件事我們可不可以做？」
 - 倫理面：「就算可以做，我們應不應該做？」

【中級真題與解析（114 年第二梯次）】

本節對應 **2 題**官方真題（114 年第二梯次中級 AI 應用規劃師），每題含 4 選項詳細解析、核心考點、易混淆對比。

第 24 題（114-2-1-Q24）

題幹：某金融機構的 AI 風控系統遭受對抗性攻擊（Adversarial Attack），駭客透過對輸入特徵進行微小但惡意的擾動，成功欺騙了模型。為了從根本上解決模型自身對這類攻擊的脆弱性，下列何者並非針對此種攻擊型態的技術手段？

選項：

- (A) 強化資料前處理，用以過濾掉格式不符或數值極端異常的輸入

- (B) 在模型訓練階段導入對抗樣本訓練 (Adversarial Training)，以提升模型對惡意特徵擾動的辨識與防禦能力
- (C) 於推論後階段使用規則引擎，以確保模型的預測結果不違反既有的業務硬性規定
- (D) 在模型部署環境中強化網路防火牆，以阻擋來自未授權來源的網路連線

正確答案：D

詳細解析：

- ✓ (D) 不正確 (即「並非」之答案)：網路防火牆是「網路層資安」措施，防的是未授權連線、DDoS、SQL Injection 等網路攻擊。但對抗性攻擊 (Adversarial Attack) 的攻擊者本身就是合法使用者，透過合法 API 提交「看似正常但含微小擾動」的輸入欺騙模型 — 防火牆完全無法阻擋這種「特徵層 / 輸入層攻擊」。
- × (A) 是有效手段：資料前處理可過濾「異常值 / 格式不符 / 數值極端」輸入，能擋掉部分粗糙的擾動樣本 (如肉眼可見的扭曲)。
- × (B) 是有效手段：對抗樣本訓練 (Adversarial Training) 是對抗攻擊的核心防禦。將擾動樣本納入訓練資料，提升模型對 FGSM / PGD 等攻擊的魯棒性 (Robustness)。
- × (C) 是有效手段：推論後規則引擎 (Post-inference Rule Engine) 作為最後一道防線，例如「金額超過 100 萬必須人工複核」「同 IP 短時間多次申請拒絕」等業務硬性規則可攔截模型被騙後的異常輸出。

核心考點：對抗性攻擊屬於「特徵層攻擊」，網路層防護無效；防禦手段須針對模型本身 (Adversarial Training / 輸入過濾 / 業務規則)。

易混淆對比：對抗性攻擊 (Adversarial Attack，特徵層) vs 資料投毒攻擊 (Data Poisoning，訓練資料層) vs 模型竊取 (Model Stealing) vs 成員推斷攻擊 (Membership Inference)。

對應章節：L21203 AI 風險管理

第 49 題 (114-2-1-Q49)

題幹：某電商平台導入 AI 情感分析模型，用以自動偵測顧客評論中的負面情緒並觸發客服機制。然而，上線後發現模型在面對不同語言或族群書寫風格的評論時表現不一致，例如部分語氣強烈的正面評論被誤判為負面，而禮貌但含批評意圖的評論卻被判為中性。若從技術與資料治理的角度分析，下列哪一項描述不正確？

選項：

- (A) 模型未啟用詞嵌入正規化 (Embedding Normalization) 可能造成語意距離不穩定，導致預測誤差
- (B) 訓練語料若偏向特定文化或語氣特徵，可能使模型產生內隱偏誤 (Implicit Bias)
- (C) 模型若訓練資料來源不平衡，容易導致對不同語言或族群風格的情緒判斷不準確
- (D) Transformer 架構能捕捉上下文語意，但若訓練資料偏差仍存在，模型仍可能學習到偏誤判斷

正確答案：A

詳細解析：

- ✓ (A) 不正確 (即「描述不正確」之答案)：詞嵌入正規化 (Embedding Normalization) 只是輔助穩定數值範圍 (如 L2 normalization 讓向量都在單位球上)，不是造成不同文化族群誤判的關鍵原因。本題核心問題是「訓練語料的文化 / 族群偏差」，這是資料層問題，與 Embedding Normalization 無關。題幹描述的現象 (正面被判負面、禮貌批評判為中性) 本質是文化語氣特徵的代理變數偏差。
- × (B) 描述正確：訓練語料偏向特定文化 (如英語為主、北美語境) → 模型學到該文化的情感表達模式 → 對其他文化失準 → 內隱偏誤 (Implicit Bias，隱性偏差)。
- × (C) 描述正確：訓練資料來源不平衡是抽樣偏誤 (Sampling Bias) 的典型場景，導致模型對少數族群表現差。
- × (D) 描述正確：Transformer 雖能捕捉長距離語境，但「Garbage In, Garbage Out」原則仍適用 — 模型只能反映訓練資料的偏差，架構強大也救不了資料偏差。

核心考點：偏差 (Bias) 根源辨識 — 技術層 (架構 / 正規化) vs 資料層 (語料偏差 / 抽樣偏誤)；情感分析的跨文化偏誤治理。

易混淆對比：Embedding Normalization (數值穩定，不解決偏差) vs Adversarial Debiasing (去偏訓練) vs Data Augmentation (補足少數族群樣本) vs Fairness Constraints (公平性約束)。

對應章節：L21203 AI 風險管理

延伸補充：四大風險、漂移辨析與隱私技術

考點 (B1)

- 【考點】AI 風險的四大類別：
 1. 技術風險：模型不準、資料出問題
 2. 法律與合規：違反個資法規（如 GDPR）
 3. 倫理與偏見：模型對特定族群產生歧視
 4. 組織風險：員工抗拒採用新系統
- 【考點】技術風險的四個關鍵名詞（必懂）：
 - ▶ 資料漂移（Data Drift）：餵給模型的真實世界輸入資料分佈隨時間改變
 - ▶ 概念漂移（Concept Drift）：X→Y 的關係本身改變
 - ▶ 模型漂移（Model Drift）：模型預測效能持續下降的結果現象，通常由資料漂移或概念漂移引起（例：以 2023 年消費行為訓練的需求預測模型，在市場結構改變後準確率逐月下滑）
 - ▶ 過擬合（Overfitting）：模型記住訓練樣本的雜訊細節，對未見資料泛化能力差
- 【考點】GDPR (General Data Protection Regulation，歐盟一般資料保護規則) = 歐盟相當嚴格的個資法規。
- 【考點】XAI (Explainable AI，可解釋人工智慧) = 讓模型決策過程透明化。
- 【考點】MLOps (Machine Learning Operations，機器學習維運) = 確保 AI 系統長期穩定運作。

補充判別表 (B1) 四大風險應對策略

策略	中文	做法	適用情境
Avoidance	規避	停止該活動、從根本繞開風險	潛在損失超出組織風險胃納
Transfer	轉移	分擔／轉嫁給第三方	可透過契約或保險移轉（如 SLA 罰則、保單）
Mitigation	減緩	採取措施降低發生機率或衝擊	多數技術風險的預設處理方式
Acceptance	接受	接受並持續監控	發生機率與影響皆低、緩解不符成本效益

補充精華 (B3)

- 資料漂移 vs 概念漂移 案例（以「依天氣預測門市冷飲銷量」的模型為例）：
 - ▶ 資料漂移（Data Drift）：門市客群結構改變（如周邊新增大量上班族），輸入特徵的分佈跟著變，但「氣溫越高、冷飲賣越多」這條規則本身沒變
 - ▶ 概念漂移（Concept Drift）：消費習慣改變後，同樣的高溫不再帶來同樣的銷量（例如熱飲、機能飲料分食市場），是輸入與輸出之間的對應關係本身變了
- 風險矩陣（Risk Matrix）：橫軸為發生可能性（Likelihood），縱軸為衝擊力（Impact）。落在「高機率 × 高衝擊」象限者優先處理。
- 模型反演攻擊（Model Inversion Attack，模型逆向攻擊）：透過模型輸出反推訓練資料，屬於治理與隱私風險考點。

延伸補充：治理四支柱與漂移觀察點

考點 (B1)

- AI 治理、隱私與倫理的四大支柱：
 1. 資料匿名化：移除可識別資訊以降低風險
 2. 差分隱私（Differential Privacy）：在查詢結果或訓練過程加入經校準的雜訊，使單筆資料的存在與否對輸出影響有數學上界（詳見 L22404 大數據隱私保護、安全與合規（見第二冊）的 ϵ -差分隱私）
 3. 演算法公平性：主動辨識並減輕資料偏見
 4. 法規遵循：符合 GDPR（General Data Protection Regulation，歐盟一般資料保護規則）等地區性法律框架

補充比較表 (B2)

危機類型	定義	觀察重點
標籤偏差 (Label Bias)	人類貼標籤時帶入主觀偏見	訓練資料的源頭

危機類型	定義	觀察重點
資料漂移 (Data Drift)	監控 X 的分佈變化 (如 PSI 超標)	輸入端 (特徵分佈)
模型漂移 (Model Drift)	監控預測品質指標的持續退化，屬結果面現象	輸出端 (預測品質指標)
概念漂移 (Concept Drift)	資料背後的潛在關係發生根本性改變	變數之間的關係

陷阱 (B2)

- 資料漂移 ≠ 模型漂移 (必考易混淆對比)：
 - 資料漂移：監控輸入特徵的分佈是否偏離訓練期 (可用 PSI 等統計量偵測)
 - 模型漂移：監控線上預測品質指標是否持續退化 (屬結果面、通常較晚被發現)

補充精華 (B3)

- 訓練資料多樣性的重要：一個只在單一、理想環境下訓練過的模型，面對差異很大的真實情境往往會失靈——訓練資料若缺乏多樣性，部署後容易踩雷。

延伸補充：分散式系統的 CAP 取捨**考點 (B1)**

- CAP 定理 (不可能三角)：分散式系統中 Consistency (一致性)、Availability (可用性)、Partition tolerance (分區容錯性) 三者最多同時滿足兩項
- 真實世界中網路分區 P 無法避免 → 實際取捨落在 C 與 A 之間
- 近似分位數 (Approximate Quantile)：面對數十億筆資料無法全部排序時，犧牲極小精度換取即時答案

補充比較表 (B2)：CAP 取捨

選擇	做法	後果
一致性 (C)	不一致時寧可暫停服務	資料同步、但可能停機
可用性 (A)	永遠回應請求	服務不中斷、但資料可能不是最新

【中級真題與解析 (115 年第一次)】

本節對應 5 題官方真題 (115 年第一次中級 AI 應用規劃師)，每題含 4 選項詳細解析、核心考點、易混淆對比。

第 25 題 (115-1-1-Q25)

題幹：某企業欲將其 AI 輔助決策系統提交給外部稽核單位審查，並宣稱符合 NIST《AI 風險管理框架》(NIST AI RMF) 中可驗證性 (Verifiability) 的要求。為讓第三方稽核人員能獨立重現模型評估結果，下列哪一項技術實踐最直接符合此要求？

選項：

- (A) 將模型測試準確率優化至 99% 以上，以達到業界公認的高可靠標準
- (B) 建立可追溯的測試資料與評估流程，並記錄模型訓練與評估過程中的關鍵設定，以確保結果可被重現
- (C) 加快模型迭代速度，縮短版本發布週期以盡快累積外部驗證數據
- (D) 擴充訓練資料量至數百萬筆，以統計方式確保模型的泛化能力達標

正確答案：B

詳細解析：

- ✓ (B) 正確：可驗證性 (Verifiability，可驗證性) 的操作型定義是「第三方能『獨立重現』宣稱的結果」。要達成重現，必須把產生結果的全部要素固定並留痕：測試資料集版本 (可追溯)、評估流程與指標定義、訓練與評估的關鍵設定 (超參數、隨機種子、環境版本等)。NIST AI RMF (National Institute of Standards and Technology AI Risk Management Framework，美國國家標準暨技術研究院 AI 風險管理框架) 強調可信賴 AI (Trustworthy AI) 特性需「可量測、可驗證」，其 Govern/Measure 功能都要求文件化與可追溯的評估證據——本選項正是重現性工程的直接實踐。(註：RMF 七項可信賴特性的正式名稱為 Valid & Reliable、Safe、Secure & Resilient、Accountable & Transparent、Explainable & Interpretable、Privacy-Enhanced、Fair 等；題幹的「可驗證性 (Verifiability)」是對其 Measure 功能「可量測、可驗證」要求的概括用語，非特性清單的正式名稱。)

- × (A) 錯誤：偷換概念——準確率高低是「效能」問題，可驗證性問的是「這個數字能否被獨立重現與查證」；一個無法重現的 99% 比可重現的 92% 更不符合稽核要求。
- × (C) 錯誤：加快迭代與縮短發布週期是開發效率議題；版本變動更頻繁反而增加追溯與重現的難度，與稽核目標背道而馳。
- × (D) 錯誤：擴充資料量針對的是泛化能力（效能面向），與「評估結果可否被第三方重現」無邏輯關聯。

核心考點：NIST AI RMF 的可驗證性＝可重現性工程：資料版本化＋流程文件化＋設定留痕，讓第三方能獨立重跑得到相同結果；情境線索是「讓稽核人員『獨立重現』評估結果」。

易混淆對比：可驗證性／可重現性（結果能被第三方重現查證）vs 可解釋性（Explainability：說明模型為何做出某預測）vs 透明性（Transparency：揭露系統的設計、資料與限制資訊）——三者都是可信賴 AI 特性，但分別回答「能否重現」「為何如此」「揭露了什麼」三個不同問題。

對應章節：L21203 AI 風險管理

第 26 題 (115-1-1-Q26)

題幹：某銀行導入一套 AI 授信審核系統，針對貸款申請人進行自動化決策。監理單位要求系統必須符合負責任 AI (Responsible AI) 原則，特別是對被拒絕的申請人提供每筆決策的具體理由說明。從技術與合規的角度，此要求的核心能力需求為何？

選項：

- (A) 系統必須在收到申請後 10 秒內自動刪除申請人個資
- (B) 系統應隨機調整部分決策以確保多元性
- (C) 系統必須保證所有決策準確率達到 100%
- (D) 系統必須具備可解釋性 (Explainability) 能力，能提供特徵貢獻說明

正確答案：D

詳細解析：

- √ (D) 正確：題幹關鍵線索是「對被拒絕的申請人提供每筆決策的具體理由說明」——這正是 XAI (Explainable AI，可解釋人工智慧) 中「局部解釋 (Local Explanation)」的定義：針對單一預測個案，說明各輸入特徵（如收入、負債比、信用紀錄）對該筆決策的貢獻方向與大小。金融授信是高風險應用場景，各國監理（如歐盟 GDPR (General Data Protection Regulation，一般資料保護規則) 第 22 條自動化決策條款、EU AI Act (歐盟人工智慧法案) 高風險系統透明度義務）普遍要求「拒絕貸款須能說明理由」，技術上對應 SHAP (SHapley Additive exPlanations，夏普利加法解釋)、LIME (Local Interpretable Model-agnostic Explanations，局部可解釋模型無關解釋) 等特徵貢獻方法。
- × (A) 錯誤：刪除個資屬於隱私保護與資料保存期限 (Data Retention) 議題，與「說明決策理由」無關；且授信決策依法反而需要保留審核紀錄以供稽核，收件後 10 秒刪除個資會使決策無法追溯，違反課責性 (Accountability) 要求。
- × (B) 錯誤：隨機調整決策破壞模型的一致性 (Consistency) 與公平性 (Fairness) ——相同條件的申請人可能得到不同結果，這在授信場景本身就是歧視爭議來源。「多元性」不是靠隨機化決策達成的，公平性應透過偏差檢測與緩解 (Bias Mitigation) 處理。
- × (C) 錯誤：100% 準確率在統計學習上不可能達成（資料本身含不可約誤差 Irreducible Error），且監理要求的是「透明、可課責」，從未要求完美準確；此選項是「把合規要求偷換成效能要求」的典型陷阱。

核心考點：負責任 AI 原則中「透明性／可解釋性」的落地——「對單筆決策提供理由」＝局部可解釋性＝特徵貢獻說明能力。看到「監理要求說明拒絕理由」直接對應 Explainability。

易混淆對比：可解釋性 (Explainability，說明為什麼做此決策) vs 透明性 (Transparency，揭露系統存在與運作方式) vs 課責性 (Accountability，出錯時可歸責與救濟) ——三者是負責任 AI 的不同支柱；本題考的是第一個。另注意「全域解釋」（模型整體如何運作）與「局部解釋」（單筆預測理由）之別，監理的「每筆決策理由」是局部解釋。

對應章節：L21203 AI 風險管理

第 27 題 (115-1-1-Q27)

題幹：某醫院計劃導入一套 AI 醫療影像診斷輔助系統，用於輔助放射科醫師判讀 CT 影像。院方技術委員會討論在人命攸關且需確保最終臨床決策責任由人類承擔的情境下，從系統設計架構層面，最關鍵的安全機制為何？

選項：

- (A) 採用人機協作 (Human-in-the-Loop, HITL) 架構，由醫師最終審核決策
- (B) 模型信心低於閾值 (Threshold) 即自動關機
- (C) 隨機切換模型並以多數決決策
- (D) 對輸入影像加入隨機擾動

正確答案：A

詳細解析：

- ✓ (A) **正確：**題幹兩個關鍵線索：「人命攸關」+「最終臨床決策責任由人類承擔」。HITL (Human-in-the-Loop，人在迴路) 架構讓 AI 只做「輔助判讀／初篩／標示可疑區域」，最終診斷由醫師審核簽核，確保 (1) 人類保有最終決策權 (Human Oversight，人類監督)；(2) 責任歸屬明確 (醫師為法律上的決策主體)；(3) AI 錯誤有人工把關防線。這正是 EU AI Act 對高風險 AI 系統要求的「有效人類監督」設計，也符合醫療器材軟體 (SaMD，Software as a Medical Device) 「輔助診斷」而非「取代醫師」的定位。
- × (B) **錯誤：**「信心低就自動關機」是過度粗暴的失效處理——關機導致服務完全中斷，且高信心的錯誤預測 (模型過度自信) 反而不會被攔截；正確做法是低信心案例「轉交人工複核」(即 HITL 的分流機制)，而非停機。
- × (C) **錯誤：**隨機切換模型多數決是對「模型集成 (Ensemble)」的錯誤模仿——集成是同時聚合多模型輸出，不是隨機切換；且集成只能提升準確率，無法解決「人類承擔最終責任」的架構需求。
- × (D) **錯誤：**對輸入加入隨機擾動是「對抗性訓練 (Adversarial Training) 資料擴增」或測試穩健性 (Robustness) 的手段，在推論階段對真實病患影像加擾動反而降低判讀品質，與人類監督責任完全無關。

核心考點：高風險 (人命攸關) AI 場景的架構級安全機制 = HITL 人類監督。判別關鍵字：「最終決策責任由人類承擔」→ 架構上必須保留人類審核節點。

易混淆對比：HITL (Human-in-the-Loop，人在迴路：每筆決策人類參與審核) vs HOTL (Human-on-the-Loop，人在迴路上：人類監控整體運作、必要時介入) vs Human-in-Command (人類全權掌控) ——監督強度遞減／遞增之別；醫療診斷這種單筆高風險決策要求最強的 in-the-loop。另勿與「Active Learning (主動學習) 的人工標註迴圈」混淆——那是訓練階段的人機協作，本題是推論／決策階段。

對應章節：L21203 AI 風險管理

第 28 題 (115-1-1-Q28)

題幹：一位資料科學家使用 XGBoost 建立信用風險評分模型，並使用 SHAP 解釋模型對某申請人的預測結果。SHAP summary plot 顯示該樣本中「月收入」的 SHAP 值為 -2.3，「負債比率」為 +1.8，其中 SHAP 值代表各特徵對模型輸出值的影響程度與方向。關於對 SHAP 值的解讀，下列敘述何者正確？

選項：

- (A) 「月收入」的 SHAP 值 -2.3 代表該特徵使此申請人的違約預測機率降低了 2.3%
- (B) 「月收入」的 SHAP 值 -2.3 代表相對於基準值 (base value)，此特徵將模型輸出值往負方向推移了 2.3 個單位，表示月收入對該申請人有降低違約風險的貢獻
- (C) SHAP 值為負代表該特徵對模型整體來說是不重要的特徵，應考慮從模型中移除
- (D) 「負債比率」SHAP 值 +1.8 代表負債比率是整個訓練集中對違約影響最大的特徵

正確答案：B

詳細解析：

- ✓ (B) **正確：**SHAP (SHapley Additive exPlanations，夏普利加法解釋) 源自合作賽局理論的 Shapley 值：把「預測值 - 基準值 (base value，通常為訓練集預測平均)」公平分攤給各特徵。其加法性質為：模型輸出 = base value + $\sum$ 各特徵 SHAP 值。因此 -2.3 的正確讀法是「此特徵把模型輸出值 (對 XGBoost 二元分類而言通常是 log-odds / margin 尺度，非機率) 相對基準值往負方向推 2.3 個單位」；輸出值變小 = 違約風險方向的貢獻為負 = 月收入降低了該申請人的違約風險評估。

- × (A) 錯誤：把 SHAP 值直接讀成「機率降低 2.3%」是最經典的陷阱——樹模型的 SHAP 值預設在 log-odds (對數勝算) 尺度上，不是機率百分點；log-odds 與機率是非線性 (sigmoid) 關係，-2.3 個 log-odds 單位對應的機率變化取決於基準點位置，不會恰好等於 2.3%。
- × (C) 錯誤：混淆「方向」與「重要性」。SHAP 值的正負是影響方向 (推高或壓低輸出)，重要性看的是絕對值大小 ($|-2.3|$ 其實比 $|+1.8|$ 貢獻更大)；負值特徵往往是重要的保護性因子，移除反而傷害模型。
- × (D) 錯誤：混淆「局部解釋」與「全域解釋」。 $+1.8$ 只是該單一樣本的局部貢獻；要判斷「整個訓練集最重要的特徵」須看全域重要性 (如所有樣本 $|SHAP|$ 的平均)，單一樣本的值無法推論全域排序。

核心考點：SHAP 值三要素：(1) 相對於 base value 的偏移量；(2) 尺度是模型輸出單位 (樹模型常為 log-odds) 而非機率百分比；(3) 正負 = 方向、絕對值 = 該樣本的貢獻大小。

易混淆對比：局部解釋 (單一樣本的 SHAP 值) vs 全域解釋 (全資料集 mean $|SHAP|$ 特徵排序)；SHAP 值尺度 (log-odds/margin) vs 機率尺度 (需經 sigmoid 轉換)；SHAP (有理論保證的公平分攤、計算較重) vs LIME (局部線性近似、較快但不穩定)；TreeExplainer (樹模型專用、精確且快) vs KernelExplainer (模型無關、需大量採樣)。

對應章節：L21203 AI 風險管理

第 29 題 (115-1-1-Q29)

題幹：某工程師為一套卷積神經網路 (CNN) 的醫療影像輔助診斷系統設計模型可解釋性機制。該系統需滿足下列需求：

1. 能向醫師說明影像被判定為異常的原因
2. 支援近即時推論，每次解釋須於 200 毫秒內完成，且不可進行大量重複採樣計算
3. 解釋結果須以影像中具代表性的視覺化像素區域呈現

在此情境下，下列何種方法最為適合？

選項：

- (A) 使用 LIME，透過超像素擾動取樣分析影像區塊對預測的影響
- (B) 使用 SHAP KernelExplainer，計算各像素的 Shapley 值並疊加於原始影像
- (C) 使用 Grad-CAM (Class Activation Map)，透過梯度反向傳播生成類別關注區域
- (D) 使用 SHAP TreeExplainer，計算特徵貢獻並以熱力圖呈現

正確答案：C

詳細解析：

- ✓ (C) 正確：三個需求逐一比對：(1) 視覺化說明異常原因 ✓——Grad-CAM (Gradient-weighted Class Activation Mapping，梯度加權類別活化映射) 產生熱力圖標示模型關注的影像區域；(2) 200ms 內、不可大量重複採樣 ✓——Grad-CAM 只需一次前向傳播 + 一次反向傳播取得目標類別對最後卷積層特徵圖的梯度，計算成本約等於一次推論，是四個選項中唯一免採樣的方法；(3) 像素區域視覺化 ✓——輸出即為疊加在原圖上的類別關注區域熱圖。Grad-CAM 是 CNN 專用 (需要卷積特徵圖)，本題模型正是 CNN，完全吻合。
- × (A) 錯誤：LIME 對影像的做法是把圖切成超像素 (Superpixel)，反覆擾動 (遮蔽) 數百至數千次、每次都要重新推論，再擬合局部線性模型——這正是需求 2 明文禁止的「大量重複採樣計算」，延遲遠超 200ms。
- × (B) 錯誤：SHAP KernelExplainer 是模型無關 (model-agnostic) 方法，同樣依賴大量擾動採樣估計 Shapley 值；對高解析度影像逐像素計算，成本比 LIME 更高，即時性完全不可行。
- × (D) 錯誤：SHAP TreeExplainer 雖快，但它只適用於樹模型 (XGBoost、隨機森林、LightGBM 等)，對 CNN 神經網路根本無法使用——這是「方法—模型類型不匹配」的陷阱選項。

核心考點：XAI 方法選型三軸：模型類型相容性 (Grad-CAM 限 CNN、TreeExplainer 限樹模型、LIME/KernelSHAP 模型無關) × 計算成本 (梯度法一次反傳 vs 擾動法需大量採樣) × 輸出形式 (區域熱圖 vs 特徵貢獻值)。「近即時 + 不可採樣 + CNN + 視覺化」四線索唯一指向 Grad-CAM。

易混淆對比：梯度式解釋 (Grad-CAM、Saliency Map、Integrated Gradients：快、需可微分模型白箱存取) vs 擾動式解釋 (LIME、KernelSHAP：模型無關黑箱可用、但需大量重複推論)；Grad-CAM (粗粒度區域、類別區辨性強) vs Saliency Map (逐像素梯度、雜訊多)。

對應章節：L21203 AI 風險管理

L213 AI 技術應用與系統部署

L21301 數據準備與模型選擇

※ 考綱重點（L21301 數據準備與模型選擇）：數據收集（來源／合法性）、數據清洗與預處理（缺失值／異常值／重複值）、特徵工程（特徵選擇／轉換／衍生）、不同模型的優缺點（傳統 ML vs DL vs GenAI）

「垃圾進，垃圾出」與資料準備

GIGO (Garbage In, Garbage Out)：資料品質直接決定 AI 模型可靠性與準確度。在完成導入規劃後，必須聚焦於資料準備與模型選擇。

◎ 資料收集與來源

內部資料來源：

來源	全名	用途
ERP	Enterprise Resource Planning，企業資源規劃	銷售、庫存、採購、財務、營運基礎資料
CRM	Customer Relationship Management，顧客關係管理	顧客互動、服務歷程、回饋、客戶分群、行為預測
機台資料	Machine Data	運轉狀態、操作參數、故障紀錄、智慧製造
使用者行為	POS、Web/App、IoT	操作路徑、點擊熱區、停留時間、產品優化
內部報表與流程紀錄	—	作業流程、稽核、法遵、風險管理

外部資料來源：

來源	範例	注意事項
開放資料	政府開放平台、社群媒體 API、氣象機構	注意更新頻率
Web Scraping（網頁爬蟲）	價格、評論、新聞	須符合網站條款與資料合規
商業資料庫	Refinitiv、Statista、Experian	授權購買、用於金融/徵信/產業趨勢

◎ 資料清理與品質檢核

常見處理情境：

情境	英文	處理方法
缺失值	Missing Values	平均/中位數填補 (Mean/Median Imputation)、前後值填補 (Forward/Backward Fill)、插值法 (Interpolation)、模型推估；過高缺失比例則刪除
重複值	Duplicate Values	對主鍵欄位用 .drop_duplicates() (pandas、Spark DataFrame)
異常值	Outliers	統計法 (Z-score、IQR)、模型法 (Isolation Forest、LOF, Local Outlier Factor)

資料品質 (Data Quality) 五大評估指標：

指標	英文	內容
完整性	Completeness	是否缺少關鍵欄位
一致性	Consistency	邏輯是否一致 (如年齡不為負)
準確性	Accuracy	反映真實世界狀況
即時性	Timeliness	是否最新
唯一性	Uniqueness	是否有重複或衝突 (主鍵)

【口訣】資料品質「完一準即唯」五要件。

→ 資料收集與清理 見 L22201 數據收集與清理（見第二冊）；資料儲存與管理 見 L22202 數據儲存與管理（見第二冊）

◎ 資料標註與特徵工程

特徵處理流程：

類型	英文/技術	說明
數值正規化	Normalization (Min-Max)	縮至 0-1 區間
數值標準化	Standardization (Z-score)	平均 0、標準差 1
類別獨熱編碼	One-hot Encoding	無序分類變數
類別標籤編碼	Label Encoding	有序類別（高中、學士、碩士）
時間特徵擴增	—	從時間戳擷取週期性特徵（星期、上午/下午）
文字處理	TF-IDF、Word Embeddings	文字轉數值

【易混淆對比】正規化（Normalization）vs 標準化（Standardization）：

維度	正規化 (Min-Max)	標準化 (Z-score)
輸出範圍	固定區間（如 0-1）	平均 0、標準差 1
對極端值敏感度	高	較穩健
適用模型	神經網路輸入層	線性迴歸、SVM 等用梯度的模型

特徵選擇方法：

方法	英文	說明
資訊增益	Information Gain	衡量特徵帶來的資訊量
皮爾森相關係數	Pearson Correlation Coefficient	數值特徵之間的線性相關
L1 正則化	Lasso	懲罰複雜度，自動篩選特徵

降維方法：

方法	全名	監督類型	用途
PCA	Principal Component Analysis，主成分分析	非監督式	找出方差最大方向、保留資訊、減少計算
t-SNE	t-Distributed Stochastic Neighbor Embedding	非監督式	高維資料視覺化
UMAP	Uniform Manifold Approximation and Projection	非監督式	高維資料視覺化、保留全局結構
LDA	Linear Discriminant Analysis，線性判別分析	監督式	降維 + 分類（用類別標籤）

【陷阱】PCA 為非監督式降維（不用標籤）；LDA 為監督式降維（用類別標籤）。考題易混。

AutoML 與自動特徵工程

AutoML（Automated Machine Learning，自動化機器學習）核心功能：

功能	內容
自動特徵創建	拆解日期、組合特徵、多項式特徵
自動篩選有用特徵	隨機森林、Lasso
特徵組合與互動作用檢測（Interaction）	自動找出交互效應
適應不同資料集	自動選擇 One-hot 或 Target encoding
基於模型反饋的特徵選擇	反覆優化

代表平台：Google AutoML、H2O.ai、AutoKeras、TPOT。

【考點】AutoML 降低技術門檻、加速資料科學流程，但無法完全取代領域知識與業務理解。

→ 特徵工程細節 見 L23301 數據準備與特徵工程（見第三冊）

模型選擇策略（六大任務類別）

模型選擇影響預測準確率、可維護性、擴展性與運營成本。應根據業務情境、問題類型、資料特性選擇。

1. 監督式學習 — 迴歸（Regression）：預測連續數值

演算法	英文	特點
線性迴歸	Linear Regression	簡單、線性關係資料

演算法	英文	特點
決策樹迴歸	Decision Tree Regression	處理非線性、可解釋
隨機森林迴歸	Random Forest Regression	多棵樹平均，降低過擬合
梯度提升樹	Gradient Boosting Regression	集成學習，複雜資料表現佳

應用：銷售量預測、房價預測。

2. 監督式學習 — 分類 (Classification)：分到離散類別

演算法	英文	特點
邏輯迴歸	Logistic Regression	二元/多元分類、Sigmoid 函數轉機率
決策樹分類	Decision Tree Classification	條件分支、可解釋、易過擬合
隨機森林分類	Random Forest Classification	投票機制，降低過擬合
SVM	Support Vector Machine，支持向量機	最佳超平面、可用核函數處理非線性
KNN	K-Nearest Neighbors，K 最近鄰	鄰近投票，對資料量與維度敏感
梯度提升樹分類	Gradient Boosting Classification	逐步修正錯誤，多數分類問題表現穩定

應用：垃圾郵件辨識、疾病診斷、客戶流失預測、金融風險評估。

3. 非監督式學習 (Unsupervised Learning)：無標註資料下找內在結構

演算法	全名	特點
K-means	K-means Clustering	分到 K 個群集中心，需預設 K，對初始點與異常值敏感
DBSCAN	Density-Based Spatial Clustering of Applications with Noise	基於密度、自動標離群點為雜訊、不需預設群集數
階層式分群	Hierarchical Clustering	樹狀層級 (Dendrogram)、無需指定群集數
PCA	Principal Component Analysis，主成分分析	降維、視覺化

【判別表】 K-means vs DBSCAN：

維度	K-means	DBSCAN
需指定群集數 K	是	否
處理任意形狀群集	否 (偏球形)	是
對雜訊處理	敏感	自動標雜訊
適用	群集結構明確	密度變化、含雜訊

應用：顧客分群、異常偵測、特徵壓縮與資料視覺化。

4. 深度學習 (Deep Learning)

演算法	全名	適用
CNN	Convolutional Neural Network，卷積神經網路	影像辨識、空間特徵
RNN / LSTM / GRU	—	時間序列、語音、文字
Transformer	BERT、GPT	NLP、跨模態

應用：醫療影像診斷 (CNN)、智慧客服 (Transformer)、自動駕駛 (多模態)、金融風險時序 (LSTM)。

5. 強化式學習 (Reinforcement Learning, RL)

智能體 (Agent) 在環境中嘗試行動 (Action) → 觀察狀態 (State) → 獲得獎勵 (Reward) → 調整策略。

演算法	全名	特點
Q-learning	—	值函數法、離散動作空間
DQN	Deep Q Network	結合深度學習處理高維輸入 (如圖像)
Policy Gradient	策略梯度 (REINFORCE、Actor-Critic)	直接學策略機率分佈
PPO	Proximal Policy Optimization，近端策略優化	OpenAI 提出，平衡更新幅度與學習效率

應用：自駕車控制、智慧倉儲機器人、雲端資源調度、遊戲 AI (AlphaGo、AlphaStar)。

6. 生成式模型（Generative Models）

演算法	全名	特點
GAN	Generative Adversarial Networks，生成對抗網路	生成器+判別器對抗；圖像生成、風格轉換；訓練不穩定（Mode Collapse）
VAE	Variational Autoencoder，變分自編碼器	潛在空間結構好；異常偵測、語音重建；生成樣本較平滑但細節弱
Diffusion Models	擴散模型	逐步加噪去噪；DALL·E 2、Stable Diffusion；品質高、速度慢

應用：影像與藝術生成、語音與文本合成、資料補全與模擬。

【考點】四大學習類型對比表：

類型	中文	是否需標籤	代表演算法	典型應用
Supervised Learning	監督式學習	是	線性迴歸、SVM、決策樹、CNN（分類）、LDA	分類、迴歸
Unsupervised Learning	非監督式學習	否	K-means、DBSCAN、PCA、t-SNE	分群、降維
Reinforcement Learning	強化式學習	透過獎勵訊號	Q-learning、DQN、PPO	控制、博弈
Generative Models	生成式模型	視情況	GAN、VAE、Diffusion、GPT	內容生成

【陷阱】LDA（Linear Discriminant Analysis，線性判別分析）為**監督式**降維（用類別標籤）；PCA 是**非監督式**降維。考題易混。

→ 機器學習演算法細節 見 L23202 常見機器學習演算法（見第三冊）；深度學習原理 見 L23203 深度學習原理與框架（見第三冊）

延伸補充：學習典範、任務類型與模型選擇

考點（B1）

- 模型選擇的三個考量：專案目標 / 資料特性 / 資源限制
- 兩大基礎典範：
 - 監督式學習（Supervised Learning）：用有標籤資料，目標明確（做預測）
 - 非監督式學習（Unsupervised Learning）：用無標籤資料，自行探索潛在模式
- 監督式學習的兩大任務：
 - 迴歸（Regression）：預測**連續**數值（房價、氣溫、銷售額）→ 線性迴歸、多項式迴歸
 - 分類（Classification）：預測**離散**類別（垃圾信、貓狗）→ 邏輯迴歸、決策樹、SVM（Support Vector Machine，支持向量機）
- 非監督式學習的任務：
 - 分群（Clustering）：把相似資料聚成一群，如 K-Means → 客戶分群
 - 異常偵測（Anomaly Detection）：找出與多數不同的少數樣本（詐騙、設備故障預警）
- 三種進階引擎（傳統 ML 之外的延伸）：
 - 深度學習（Deep Learning）：多層神經網路；CNN（影像）、RNN（時序）、Transformer（語言）
 - 強化學習（Reinforcement Learning）：智能體（Agent）與環境互動、從試誤中學習，追求累積獎勵
 - 生成式模型（Generative Models）：學習資料的機率分佈，再從中採樣產生新內容
- 遷移學習（Transfer Learning）+ 微調（Fine-tuning）：沿用既有預訓練模型，不必從零訓練
- 強化學習關鍵字：Agent / Environment / State / Action / Reward / Policy（策略）
- 資料清理：處理缺失值、異常值、重複值、格式不一致
- 特徵工程（Feature Engineering）：從原始資料產生模型可用的特徵
- 降維（Dimensionality Reduction）：PCA（Principal Component Analysis，主成分分析，**非監督式**）、t-SNE
- 小模型與部署層級：雲端（算力充足）/ 邊緣（低延遲、隱私佳）/ 裝置端（省電、資源受限）
- 知識蒸餾（Knowledge Distillation）：用大模型（Teacher）指導小模型（Student），讓小模型逼近大模型的表現

陷阱（B2）

- 陷阱：「不知道客戶該怎麼分群，想先探索看看」→ 屬非監督式（K-Means），不是分類
- 陷阱：邏輯迴歸（Logistic Regression）名字帶「迴歸」，實際上是**分類**演算法
- 陷阱：要動態調整、追求長期累積效益 → 用強化學習，不是監督式
- 陷阱：生成式模型不是在做分類或預測，而是在**生成新內容**（學分佈後採樣）

補充比較表（B2）

監督式 vs 非監督式

維度	監督式	非監督式
資料	有標籤	無標籤
目標	預測（迴歸／分類）	探索（分群／異常）
學習方式	有正確答案可對照	自行從資料找規律
代表演算法	線性迴歸、決策樹、SVM	K-Means、PCA

三種進階引擎

維度	深度學習	強化學習	生成式
核心	多層神經網路	試誤學習	學分佈後生成
適用	影像／語言／語音	遊戲／機器人／動態決策	內容生成／設計
代表	CNN、RNN、Transformer	DQN、PPO、A3C	GAN、VAE、Diffusion、LLM

模型評估指標（分類）

指標	適用
Accuracy	類別平衡時
Precision	抓詐騙、怕誤報
Recall	醫療、怕漏報
F1 Score	兼顧 Precision／Recall
ROC-AUC	整體分類器的排序鑑別力

補充精華（B3）

- 同一份業務資料、三種任務型態的對應練習（以線上訂閱平台的用戶資料為例）：
 - ▶ 任務一：「估計每位用戶下個月的累積使用分鐘數」→ 答案是**連續數值** → 屬**迴歸**（線性迴歸、梯度提升迴歸）
 - ▶ 任務二：「判斷哪些用戶下個月可能取消訂閱」→ 答案是**是／否兩類** → 屬**分類**（邏輯迴歸、隨機森林），此情境寧可錯抓也不能漏抓，故以 Recall（召回率）為主要把關指標
 - ▶ 任務三：「在沒有事先定義標籤的情況下，把用戶依行為自然分成數種型態」→ 沒有標準答案 → 屬**分群**（K-Means、DBSCAN）
 - ▶ 判讀訣竅：先看「答案長什麼樣子」——連續數字選迴歸、固定幾類選分類、連分幾類都未知就選分群。
- 多種 AI 技術整合於單一產品的範例（語言學習 App「Duolingo」，官方公開技術部落格案例）：
 - ▶ **語音辨識與發音評估**：以語音模型比對使用者發音與標準發音的差異，即時給出糾正回饋（深度學習於語音訊號的判別式應用）
 - ▶ **個人化出題「Birdbrain」模型**：Duolingo 官方公開的難度預測系統，依據每位學習者的歷史作答資料預測「答對機率」，動態挑選難度適中的題目——結構上就是「模型＝出題引擎、學習者作答狀態＝環境回饋、答對率與留存＝優化目標」的適應性學習迴圈
 - ▶ **生成式 AI 功能（Duolingo Max）**：以 LLM（Large Language Model，大型語言模型）驅動「解釋我的答案」與角色扮演對話，自動生成個人化的解說與鼓勵語句（生成式應用）
 - ▶ 重點：單一產品常同時動用**判別式（語音評估）、適應性學習（出題）、生成式（對話解說）**多種典範，規劃師要能依「每個子功能要的答案型態」對應正確技術。
 - ▶ （案例出處：Birdbrain 與 Duolingo Max 均為 Duolingo 官方部落格公開說明的功能）
- **資料前處理到訓練的標準流程**：原始資料 → 清理（缺失／異常／重複）→ 特徵工程 → 降維（PCA）→ 模型訓練

- **知識蒸餾的爭議點**：以他人預訓練模型的輸出當作訓練自家小模型的素材，是否屬於合法的資料與模型再利用？此舉牽涉智慧財產權與商業競爭，目前在法律上仍屬界線未定的灰色地帶。

延伸補充：缺失值、標準化與漂移指標

考點 (B1)

- **實驗室到上線的落差**：模型在實驗室分數亮眼，部署到真實世界卻可能立刻失效，需特別留意這道落差。
- **缺失值處理三招**：①刪除法（快但流失資訊）②統計填補（用中位數可抗極端值）③模型插補（精準但成本高）。
- **標準化 (Standardization, Z-Score) vs 正規化 (Normalization, Min-Max)**：
 - 標準化：平均 0、標準差 1，**保留異常值的相對資訊**，距離型演算法的首選。
 - 正規化：壓到 [0, 1] 區間，**對異常值極敏感**（一個超大值會把其餘數值都壓得很小）。

補充比較表 — 三大深度學習模型 (B2)

模型	強項	核心機制
CNN (Convolutional Neural Network, 卷積神經網路)	影像	卷積 + 池化
LSTM (Long Short-Term Memory, 長短期記憶網路)	時間序列 / 句子	閘門機制：遺忘 / 輸入 / 輸出
Transformer	語言 / 多模態	自注意力機制 (Self-Attention)

補充精華 — Docker + Kubernetes (B3)

- **Docker**：把應用程式連同其相依環境打包成一致的容器，解決「在我電腦上跑得起來，到別處就壞」的問題。
- **Kubernetes (K8s) = 容器調度的指揮者**，三大能力：
 1. 自動擴展（負載升高 → 自動增加運算資源）
 2. 自我修復（節點故障 → 自動替換）
 3. 負載平衡（流量平均分配）

考點 — PSI (Population Stability Index, 群體穩定性指標) (B1)

PSI 值	狀態	處置
< 0.1	穩定	無須動作
0.1 ~ 0.25	輕微漂移	持續觀察
> 0.25	顯著漂移	評估重訓

考點 — 資料漂移 vs 概念漂移 (再次重申)

- **資料漂移 (Data Drift)**：X 的分佈改變（如客群結構從年輕轉年長）
- **概念漂移 (Concept Drift)**：X→Y 的對應規則改變（如垃圾信的判定特徵變了）

延伸補充：規劃師思維框架與產業案例

考點 (B1)

案例拆解四問（任何案例都可套）：

1. 要解什麼商業問題？
2. 資料從哪來？
3. 用什麼技術？
4. **成敗關鍵指標是什麼？**（最重要：是策略取捨，而非單純統計）

金融／保險業兩大案例對比：

案例	商業問題	資料	技術	關鍵焦點
信用卡盜刷偵測	即時攔截詐騙交易	交易記錄	分類 / 異常偵測	業務代價不對稱：FN 損失遠大於 FP 客擾成本 → 以 Recall 為主要指標
保險核保輔助	輔助核保決策與費率評估	投保資料 / 理賠歷史	分類 / 迴歸	可解釋性 + 公平性 （核保結論須可向監理機關與保戶說明，且不得對特定族群系統性不利）

製造業兩大案例：

案例	技術	關鍵焦點
光學瑕疵檢測 (AOI)	CNN	Precision 為先 ：FP（良品被誤殺）直接墊高報廢與複檢成本
預測性維護	時間序列分析	預警提前量 vs 誤報率的取捨：警報太頻繁會被現場忽略、太保守則來不及排程停機

服務業（客服營運）：

- 客服工單自動分類：核心技術為 NLP 文本分類——依工單內容自動判別意圖並派送對應處理隊列
- 關鍵焦點：意圖類別的設計（類別粒度、互斥性、涵蓋率）決定成敗；類別切不好，模型再準也派錯單

補充比較表（B2）

產業	資料特性	處理難度
金融業	結構化、相對乾淨	中
製造業	時間序列、雜訊大	高
客服／服務業	非結構化口語文字、變異大	高

補充精華（B3）

核心觀念：真正的關鍵不是先精通技術，而是先把問題本身搞清楚。

各案例的策略重點：

- 盜刷偵測：業務代價不對稱——漏抓一筆詐騙（FN）的損失遠大於多攔一筆正常交易（FP）的客擾成本，故以 Recall 為主要指標
- 保險核保輔助：每個核保結論都要能歸因與說明，並持續檢核對不同族群的通過率差異（重可解釋性與公平性）
- CNN 光學檢測：以卷積層由低階到高階逐層抽取邊緣、形狀、紋理特徵，將肉眼難辨的微小瑕疵轉為可分類訊號
- 客服工單分類：先盤點歷史工單定義意圖類別，再以標註資料訓練分類器；上線後持續監控「其他／未分類」比例作為類別設計健康度指標

【中級真題與解析（114 年第二梯次）】

本節對應 15 題官方真題（114 年第二梯次中級 AI 應用規劃師），每題含 4 選項詳細解析、核心考點、易混淆對比。

第 10 題（114-2-1-Q10）

題幹：如果希望同時兼顧「精確率（Precision）」和「召回率（Recall）」，下列哪一個指標可以作為綜合評估的標準？

選項：

- (A) 準確率（Accuracy）
- (B) 均方根誤差（RMSE）
- (C) 均方誤差（MSE）
- (D) F1 分數（F1 Score）

正確答案：D

詳細解析：

- ✓ (D) 正確：F1 Score（F1 分數）= $\frac{2 \times \text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$ ，是 Precision 與 Recall 的調和平均（Harmonic Mean），特別適合類別不平衡資料的綜合評估。當 Precision 或 Recall 任一極低時 F1 也會低，能有效防止單邊極端。
- × (A) 錯誤：Accuracy = $\frac{TP+TN}{TP+TN+FP+FN}$ ，在類別不平衡情境會誤導（如 95% 多數類別，全預測多數也有 95% Accuracy），且未直接考慮 Precision/Recall 平衡。
- × (B) 錯誤：RMSE（Root Mean Squared Error）是迴歸任務的評估指標，用於連續值預測，與分類的 Precision/Recall 完全不同。
- × (C) 錯誤：MSE（Mean Squared Error）同為迴歸指標，不適用於分類任務的 Precision/Recall 兼顧。

核心考點：F1 Score 是 Precision 與 Recall 的調和平均。

易混淆對比：F1 (兼顧 P/R) vs Accuracy (整體正確率) vs RMSE/MSE (迴歸) vs ROC-AUC (閾值不變的判別力)。

對應章節：L21301 數據準備與模型選擇

第 11 題 (114-2-1-Q11)

題幹：企業資料分析團隊使用 DBSCAN (Density-Based Spatial Clustering of Applications with Noise) 演算法進行顧客行為分群,並希望模型能自動區分主要群集與雜訊資料。在此演算法中,決定聚類結果的兩個主要超參數為下列何者?

選項：

- (A) 特徵數與學習率
- (B) K 值與距離閾值
- (C) 鄰域半徑 (Epsilon ϵ) 與最小點數 (MinPts)
- (D) 交叉熵 (Cross Entropy) 與權重初始化

正確答案：C

詳細解析：

- ✓ (C) **正確：**DBSCAN 兩大超參數：**Epsilon (ϵ , 鄰域半徑)** 定義「鄰居」範圍；**MinPts (最小點數)** 定義「核心點」需要的鄰居數量。一個點若 ϵ 範圍內有 $\geq$ MinPts 個鄰居,即為 Core Point,可作為群集種子；不滿足且無核心點鄰居者為 Noise。
- × (A) **錯誤：**「特徵數」與「學習率」是深度學習 / 神經網路超參數,不是 DBSCAN 的。
- × (B) **錯誤：**「K 值」是 **K-Means / KNN** 的超參數 (指定群數),**DBSCAN 不需指定 K 值** (這正是 DBSCAN 的優勢)。「距離閾值」是部分接近 ϵ 的概念但不準確。
- × (D) **錯誤：**交叉熵是分類損失函數、權重初始化是神經網路概念,與 DBSCAN 無關。

核心考點：DBSCAN 的兩大超參數 ϵ 與 MinPts。

易混淆對比：K-Means (需指定 K) vs DBSCAN (ϵ + MinPts,自動決定群數) vs Hierarchical Clustering (無需指定 K,dendrogram 切)。

對應章節：L21301 數據準備與模型選擇

第 12 題 (114-2-1-Q12)

題幹：某金融科技公司建立房價預測模型,使用多項特徵 (如建坪、房齡、樓層、總價等) 進行線性迴歸分析 (Linear Regression Analysis)。資料分析師發現多個特徵之間存在高度相關性,導致模型係數不穩定、預測誤差上升。為解決此問題,下列哪一種方法最適合?

選項：

- (A) 繼續保留所有特徵,不進行任何處理
- (B) 使用主成分分析 (PCA) 將相關特徵轉換為彼此獨立的主成分
- (C) 新增更多原始變數以提升模型表現
- (D) 改用分類模型進行預測

正確答案：B

詳細解析：

- ✓ (B) **正確：****多重共線性 (Multicollinearity)** 問題的標準解法是 **PCA (Principal Component Analysis, 主成分分析)**,將相關特徵投影到正交主成分,得到**彼此線性獨立的新特徵**,從根本上消除共線性。其他解法如 Ridge 迴歸 (L2 正則化)、VIF 篩選變數也常用。
- × (A) **錯誤：**不處理共線性會持續導致係數不穩定、p-value 失真,違反問題情境。
- × (C) **錯誤：**新增更多原始變數可能引入更多相關性,**加劇共線性問題**,與目標相反。
- × (D) **錯誤：**題目是「房價預測」(連續值),需用迴歸模型;改用分類模型違反任務性質,且不解決共線性問題。

核心考點：PCA 解決多重共線性的標準應用。

易混淆對比：PCA (無監督降維) vs LDA (監督式降維, 需標籤) vs Ridge (L2 正則化, 保留所有特徵但縮小係數) vs LASSO (L1, 自動特徵選擇)。

對應章節：L21301 數據準備與模型選擇

第 14 題 (114-2-1-Q14)

題幹：在調整模型超參數 (Hyperparameters) 時, 若希望避免因過度調整參數而導致過擬合, 下列哪一種做法最有效提升模型的泛化能力?

選項：

- (A) 採用交叉驗證 (Cross-Validation) 於多組參數組合間反覆評估, 選擇在驗證資料上表現最穩定的設定
- (B) 使用早期停止機制 (Early Stopping) 監控訓練誤差並在收斂前停止訓練, 以防模型學習過度
- (C) 對輸入特徵進行標準化以減少特徵值差異帶來的過擬合風險
- (D) 提高模型複雜度並使用更多超參數搜尋範圍, 以確保模型能充分學習資料特徵

正確答案：A

詳細解析：

- ✓ (A) **正確**：**K-Fold 交叉驗證 (Cross-Validation)** 將資料分 K 折, 每組超參數在 K 個 fold 上反覆訓練驗證, **取平均表現**選擇最穩定的設定。這是「**超參數選擇**」階段防止過擬合的標準方法 (避免單一驗證集 overfitting)。
- × (B) **錯誤**：**Early Stopping** 應監控「**驗證誤差 (Validation Loss)**」, 不是「**訓練誤差 (Training Loss)**」 (題目寫錯)。訓練誤差會持續下降, 無法判斷過擬合。
- × (C) **錯誤**：特徵標準化主要解決「**數值尺度差異**」 (如梯度下降收斂), **不是直接防止超參數過擬合的方法**。
- × (D) **錯誤**：提高複雜度 + 擴大搜尋空間會**加劇過擬合**, 與目標完全相反。

核心考點：交叉驗證在超參數選擇中的防過擬合作用。

易混淆對比：CV (超參數選擇) vs Early Stopping (訓練收斂控制) vs 正則化 (模型容量約束) vs Standardization (特徵尺度)。

對應章節：L21301 數據準備與模型選擇

第 16 題 (114-2-1-Q16)

題幹：下列哪一種情境中最適合使用「序列到序列 (Seq2Seq)」模型?

選項：

- (A) 預測銷售趨勢曲線, 輸出未來數值序列
- (B) 辨識文本中出現的人名、地名與組織名稱等實體資訊
- (C) 對輸入文本中的關鍵字進行頻率統計與可視化
- (D) 將輸入文字轉換成語意等價的另一段文字, 如自動翻譯或摘要生成

正確答案：D

詳細解析：

- ✓ (D) **正確**：**Seq2Seq (Sequence-to-Sequence)** 架構由 Encoder + Decoder 組成, **將一個序列映射到另一個序列**, 最典型應用是**機器翻譯 (NMT)** 與**自動摘要 (Summarization)**。Sutskever 2014 提出 Seq2Seq, Vaswani 2017 用 Transformer 取代 RNN。
- × (A) **錯誤**：銷售趨勢預測是**時間序列預測 (Time Series Forecasting)**, 雖也輸出序列, 但典型用 ARIMA、Prophet、LSTM regression, 非 Seq2Seq 的標準應用。
- × (B) **錯誤**：人名 / 地名 / 組織辨識是**命名實體識別 (Named Entity Recognition, NER)**, 屬於**序列標註 (Sequence Labeling)** 任務 (用 BiLSTM-CRF / BERT-CRF), 不是序列到序列。
- × (C) **錯誤**：關鍵字頻率統計屬於**簡單統計分析** (如 word frequency / TF-IDF), 不需要 Seq2Seq。

核心考點：Seq2Seq 的典型應用 (翻譯、摘要)。

易混淆對比：Seq2Seq (NMT/摘要, N→M tokens) vs Sequence Labeling (NER, 每 token 對應 1 標籤) vs Time Series (數值序列預測) vs Classification (多→1)。

對應章節：L21301 數據準備與模型選擇

第 26 題 (114-2-1-Q26)

題幹：在房價預測任務中,若發現特徵如「房間數」與「坪數」存在高度多重共線性 (Multicollinearity),為降低共線性對模型參數估計的負面影響,應優先選擇下列哪種模型?

選項：

- (A) 不受多重共線性影響的決策樹模型
- (B) 傳統線性迴歸模型,不含正則化項
- (C) 支持向量機搭配線性核函數
- (D) 含 L1 正則化的 LASSO 迴歸模型

正確答案：D

詳細解析：

- ✓ (D) 正確：LASSO 迴歸 (L1 正則化) 會將不重要的特徵係數壓到 0,達到自動特徵選擇效果,在共線性高的情況下可挑出代表性特徵、丟棄冗餘特徵,是處理共線性的標準工具之一。Ridge (L2) 也有效但不會置 0。
- △ (A) 部分正確但非優先：決策樹確實對共線性不敏感 (每次分裂只選一特徵),但題目情境是線性迴歸框架延續,「優先」選 LASSO 較符合題意 (保留線性可解釋性)。題目用「優先選擇」暗示在迴歸路線內找最佳解。
- × (B) 錯誤：傳統線性迴歸 (無正則化) 完全不解決共線性,係數會極不穩定 (VIF 高),是問題本身的源頭。
- × (C) 錯誤：SVM 線性核也是線性模型,對特徵相關性敏感,且 SVM 用於分類為主、迴歸不常用。

核心考點：LASSO (L1) 的特徵選擇能力處理共線性。

易混淆對比：LASSO (L1,置 0 選特徵) vs Ridge (L2,縮小不置 0) vs Elastic Net (L1+L2) vs Decision Tree (非線性,免疫共線性但失可解釋性)。

對應章節：L21301 數據準備與模型選擇

第 27 題 (114-2-1-Q27)

題幹：某企業需分析半結構化的系統日誌 (JSON 格式),以提取關鍵的時序特徵供故障預測模型使用。考量日誌結構複雜且包含巢狀欄位 (Nested Fields),下列哪一種策略最有效且實務可行?

選項：

- (A) 先將 JSON 資料扁平化轉成 CSV,再對欄位計算統計量 (如均值、次數) 作為特徵
- (B) 使用遞歸神經網路 (RNN) 直接輸入原始 JSON 字串進行時序特徵抽取
- (C) 設計遞迴函式展開巢狀欄位,並基於時間窗口 (Time Window) 進行聚合與特徵萃取
- (D) 只保留時間戳記欄位,忽略其他巢狀內容以簡化特徵工程

正確答案：C

詳細解析：

- ✓ (C) 正確：遞迴展開巢狀欄位 + 時間窗口聚合是工業界處理 JSON log 的標準做法。展開保留結構資訊,時間窗口聚合 (如 5 分鐘內的錯誤次數、平均響應時間) 提取時序特徵,直接餵給 LightGBM / XGBoost 等模型。
- × (A) 錯誤：簡單扁平化會丟失巢狀結構資訊 (如 array 內的關聯),且僅算統計量太粗糙,無法捕捉時序動態。
- × (B) 錯誤：RNN 直接吃 JSON 字串是反模式：JSON 是結構化資料,直接當文本處理會浪費結構資訊且 RNN 對長 JSON 收斂困難。應該先解析結構。
- × (D) 錯誤：「只保留時間戳記」過度簡化,捨棄了所有信號 (錯誤訊息、響應時間、用戶 ID 等),模型無法學到有用模式。

核心考點：JSON log 的結構化解析 + 時間窗口聚合特徵工程。

易混淆對比：扁平化 (簡單但失結構) vs 遞迴展開 (保結構) vs 文本化 (失語義) vs 時間窗口聚合 (捕捉時序)。

對應章節：L21301 數據準備與模型選擇

第 28 題 (114-2-1-Q28)

題幹：在一個同時包含連續型特徵與類別型特徵的資料集中,若希望透過適當的特徵工程流程來提升模型整體表現,下列哪一種作法最為合適?

選項：

- (A) 將類別型特徵使用標籤編碼 (Label Encoding) 轉換後,與連續特徵直接合併進行模型訓練
- (B) 將連續特徵進行離散化 (Discretization) 或分桶 (Binning) 轉為類別型特徵,統一以類別方式處理
- (C) 對連續特徵做標準化 (Standardization),類別特徵採用目標編碼 (Target Encoding),並生成交互特徵提升模型表現
- (D) 只保留連續特徵,忽略類別型變量以簡化模型

正確答案：C

詳細解析：

- ✓ (C) 正確：標準特徵工程組合：
 - ▶ 連續特徵 → **Standardization** (z-score, 零均值單位方差), 避免尺度差異
 - ▶ 類別特徵 → **Target Encoding** (用目標變數均值編碼), 高基數類別友好
 - ▶ 交互特徵 (**Interaction Features**)：捕捉特徵間非線性關係 (如建坪 × 樓層)
 - ▶ 這套組合是 Kaggle 比賽常見最佳實踐
- × (A) 錯誤：**Label Encoding** 會給類別賦予「人為順序」(如 A=0, B=1, C=2), 對線性模型誤導嚴重；對非樹模型不適合。
- × (B) 錯誤：將連續轉類別會丟失資訊 (如「年齡 25」與「年齡 30」變同桶), 且失去數值關係。除非有理由分桶, 否則不建議。
- × (D) 錯誤：捨棄類別特徵浪費資訊, 與「提升整體表現」目標背道而馳。

核心考點：混合型資料的標準特徵工程組合。

易混淆對比：Label Encoding (有序, 誤導線性) vs One-Hot (高基數爆炸) vs Target Encoding (用標籤統計) vs 嵌入 (深度模型)。

對應章節：L21301 數據準備與模型選擇

第 36 題 (114-2-1-Q36)

題幹：某資料科學團隊在開發預測模型時,針對多種模型設定 (如學習率、樹深度、正則化係數等) 進行系統化測試,希望找出在驗證資料上表現最穩定的組合。此過程最可能採用下列哪一種方法?

選項：

- (A) 使用交叉驗證 (Cross Validation) 反覆評估模型以降低過擬合風險
- (B) 透過網格搜尋 (Grid Search) 在多組超參數設定中進行系統化搜尋與評估
- (C) 以隨機搜尋 (Random Search) 快速探索部分參數空間以提升搜尋效率
- (D) 採用貝葉斯優化 (Bayesian Optimization) 根據歷次結果動態調整搜尋方向

正確答案：B

詳細解析：

- ✓ (B) 正確：題幹關鍵字「**系統化測試 (systematic search)**」精準對應 **Grid Search (網格搜尋)**：定義各超參數的離散候選值, 遍歷所有組合進行評估, 是最「系統化」的窮舉式搜尋。
- △ (A) 部分相關：交叉驗證是評估方法, **搭配 Grid Search 使用** (每組超參數做 CV), 但 CV 本身不是「搜尋超參數」的方法, 是「評估」方法。
- △ (C) 部分相關：Random Search 高效但**不系統化** (隨機抽樣), 題幹明確說「系統化測試」→ 排除。
- △ (D) 部分相關：Bayesian Optimization 高效 (用 surrogate model 引導搜尋), 但本質是**自適應 (adaptive)** 而非系統化窮舉。

核心考點：超參數搜尋方法的特性比較。

易混淆對比：Grid Search (窮舉, 系統化但慢) vs Random Search (隨機, 高效但無系統) vs Bayesian Opt (自適應, 最高效) vs CV (評估方法, 搭配上上述)。

對應章節：L21301 數據準備與模型選擇

第 39 題 (114-2-1-Q39)

題幹：某企業的資料科學團隊利用 ARIMA 模型 (AutoRegressive Integrated Moving Average Model) 預測每週產品銷售量。模型建立完成後,分析人員發現預測誤差隨時間呈現週期性波動,且自相關函數 (ACF) 顯示殘差在多個時滯 (Lag) 上仍顯著不為零。根據上述現象,最合理的模型診斷結論為何?

選項：

- (A) 模型殘差符合白噪音 (White Noise) 假設,預測表現穩定
- (B) 模型殘差雖有輕微異常,但可視為隨機誤差忽略不計
- (C) 模型存在配適不足 (Underfitting) 問題,需重新調整 p 或 q 參數以捕捉時間依賴性
- (D) 殘差特性不影響預測結果,無須進一步修正

正確答案：C

詳細解析：

- ✓ (C) 正確：ARIMA 模型診斷標準：理想殘差應為白噪音 (White Noise), ACF 在所有 lag 應接近 0。題幹「殘差在多個 Lag 上顯著不為零」表示仍有時間依賴未被捕捉,正是配適不足 (Underfitting) 的典型症狀,應調整 p (AR 階) / q (MA 階) / d (差分階) 或加入季節性項 (SARIMA)。
- × (A) 錯誤：題幹明確說「ACF 顯著不為零」、「週期性波動」,完全不符合白噪音假設。白噪音 ACF 應接近 0。
- × (B) 錯誤：殘差有系統性結構 (不是隨機) 就不能忽略,否則預測會持續偏差。
- × (D) 錯誤：殘差特性是模型診斷核心,直接影響預測可靠性。週期性殘差表示模型遺漏了週期成分 (如季節性),必須修正。

核心考點：ARIMA 殘差白噪音假設與配適不足診斷。

易混淆對比：白噪音 (理想殘差, ACF ≈ 0) vs 自相關殘差 (配適不足) vs 季節性 (需用 SARIMA) vs 異方差 (需 GARCH)。

對應章節：L21301 數據準備與模型選擇

第 41 題 (114-2-1-Q41)

題幹：在進行超參數調校 (Hyperparameter Tuning) 時,若直接在 K-Fold 交叉驗證 (Cross-Validation) 的資料上同時調整模型參數並評估效能,最可能導致下列哪一種問題?

選項：

- (A) 模型的交叉驗證結果出現過度樂觀偏差 (Over-optimistic Bias), 因測試摺資料間接參與參數選擇,造成資料洩漏 (Data Leakage)
- (B) 模型會在每一摺 (Fold) 內反覆調整參數,導致訓練不穩與過度正則化
- (C) 因交叉驗證資料被重複使用,造成效能方差增大,無法獲得穩定估計
- (D) K-Fold 交叉驗證的假設與超參數搜尋相衝突,導致驗證過程失效

正確答案：A

詳細解析：

- ✓ (A) 正確：在同一份 CV 資料上同時做「調參」+「評估」會造成資料洩漏 (Data Leakage)：因為每一個 fold 都間接參與了超參數選擇 (你選的是「在這份 CV 上表現最好的超參數」), 導致 CV 分數過度樂觀。標準解法是 Nested Cross-Validation (外層 CV 評估, 內層 CV 調參)。
- × (B) 錯誤：「每 fold 內反覆調參」是錯誤的 CV 用法,但這不是主要問題,題目焦點是「同時調參+評估」的資料洩漏。
- × (C) 錯誤：CV 資料「重複使用」不直接導致方差增大,反而 CV 主要是為了讓有限資料能同時用於訓練與評估、降低 bias 並提升資料利用率而設計的; 資料重複使用本身不直接造成方差增大。
- × (D) 錯誤：CV 與超參數搜尋並無架構衝突,問題在使用方式錯誤,不是兩者「衝突」。

核心考點：CV 同時調參評估導致資料洩漏。

易混淆對比：單層 CV (評估) vs Nested CV (外層評估 + 內層調參, 避免 leakage) vs Hold-out Validation。

對應章節：L21301 數據準備與模型選擇

第 42 題 (114-2-1-Q42)

題幹：若部署一個深度學習模型至金融風控系統，該模型採用鑑別式架構（如 Transformer Classifier）。然而上線後，模型對新樣本的分類錯誤率顯著上升，經檢查發現，輸入資料分佈已與原訓練集明顯不同。針對此情形，下列哪一種應對策略最為適合？

選項：

- (A) 改用生成對抗網路 (GAN) 生成新樣本並混入訓練集
- (B) 改用邏輯迴歸模型 (Logistic Regression) 以提升穩定性
- (C) 增加模型容量 (Model Capacity)，以學習更多樣本差異
- (D) 使用變分自編碼器 (VAE) 監控潛在空間分佈，偵測輸入資料偏移

正確答案：D

詳細解析：

- ✓ (D) 正確：VAE 潛在空間分佈監控是先進的資料漂移偵測 (Data Drift Detection) 手段：VAE 編碼後的 latent distribution 可作為訓練資料分佈的代理，新樣本投影到該空間後若分佈偏離 (可用 KL Divergence、Wasserstein 距離量化)，即為漂移警訊。能及早觸發重訓或人工介入。
- × (A) 錯誤：GAN 生成「合成樣本」並不能解決真實分佈已偏移的問題 (生成的還是基於舊分佈)；且 GAN 生成的樣本可能與新真實分佈不符。
- × (B) 錯誤：邏輯迴歸是更簡單的模型，對分佈偏移更脆弱 (線性無法適應複雜新模式)，不解決根本問題。
- × (C) 錯誤：增加模型容量會加劇過擬合，對「分佈漂移」反而更敏感 (背離訓練分佈時錯得更離譜)。

核心考點：資料漂移的進階偵測技術 (VAE 潛在空間監控)。

易混淆對比：VAE 潛在空間 (連續偏移偵測) vs KL Divergence/PSI (統計指標) vs 模型容量 (不解決漂移) vs 重訓練 (被動應對)。

對應章節：L21301 數據準備與模型選擇

第 43 題 (114-2-1-Q43)

題幹：某金融科技公司欲導入 AI 模型協助客服郵件自動分類 (投訴、詢問、表揚)。團隊同時考慮兩種模型設計：

- 方案 A (生成式路徑)：採用 VAE 建構潛在語意空間，再結合下游分類器進行標籤預測
- 方案 B (鑑別式路徑)：採用 BERT Classifier 直接根據輸入文本進行監督式分類

現有標註資料約 2,000 筆，資料分佈均勻但擴充成本高。若團隊希望公平比較兩種模型的資料利用效率與泛化能力，下列哪一種實驗設計最能突顯兩者的本質差異？

選項：

- (A) 在完整資料集上分別訓練兩者，並比較其分類準確率 (Accuracy) 與推論時間
- (B) 在低資源情境 (Low-resource Setting) 下，逐步減少標註比例 (100%、50%、10%)，比較其 F1-score
- (C) 使用 GAN 自動生成文本樣本補足資料，觀察兩模型在資料增強後的精確率 (Precision) 差異
- (D) 在相同訓練資料上固定輸入維度，僅調整模型參數量，比較其對過擬合的敏感度

正確答案：B

詳細解析：

- ✓ (B) 正確：生成式 vs 鑑別式的本質差異在於「資料利用效率」：生成式模型 (VAE) 建模 $P(X)$ 與 $P(X|Y)$ ，理論上低資料時更有優勢 (捕捉資料結構)；鑑別式模型 (BERT Classifier) 建模 $P(Y|X)$ ，高資料時表現更好。逐步減少標註比例 (100%→50%→10%) 測試低資源表現，正是經典「Data Efficiency Curve」實驗，能突顯兩者本質差異。
- × (A) 錯誤：「完整資料集 + 推論時間」只比較最終表現，無法突顯資料效率的本質差異。
- × (C) 錯誤：用 GAN 補足資料會引入混淆變量 (confounder)，無法分清「模型本質」與「資料增強效果」。
- × (D) 錯誤：調整參數量只測模型容量影響，不直接測「生成 vs 鑑別」差異。

核心考點：生成式 vs 鑑別式模型的資料效率比較設計。

易混淆對比：生成式 (建模聯合分佈, 低資料友好) vs 鑑別式 (建模條件分佈, 高資料強) vs Data Efficiency Curve (不同標註比例比較)。

對應章節：L21301 數據準備與模型選擇

第 45 題 (114-2-1-Q45)

題幹：進行影像分類任務時, 研究團隊嘗試利用主成分分析 (Principal Component Analysis, PCA) 將輸入特徵從 1024 維降至 100 維, 並將降維後的資料輸入支持向量機 (Support Vector Machine, SVM) 模型進行訓練。關於此作法, 下列哪一項描述最為合理?

選項：

- (A) PCA 保留的主成分必然能提升 SVM 的分類準確率
- (B) 使用原始高維資料通常更能保留資訊, 因此 PCA 沒有實際意義
- (C) PCA 可讓 SVM 自動適用於非線性 (Nonlinear) 資料集
- (D) 降維後可降低訓練時間並減少過擬合 (Overfitting) 風險

正確答案：D

詳細解析：

- ✓ (D) 正確：PCA 降維的標準效益：(1) 降低訓練時間 (特徵數從 1024→100, 計算成本大幅下降)；(2) 減少過擬合風險 (特徵減少 → 模型自由度減少 → 泛化能力提升), 這是 PCA + SVM 經典 pipeline 的主要動機。
- × (A) 錯誤：「必然提升準確率」過度絕對。PCA 是無監督降維, 可能丟失分類相關的「判別性資訊」, 準確率可能下降 (取決於丟掉的是雜訊還是訊號)。
- × (B) 錯誤：高維資料有「維度災難」問題 (樣本稀疏、距離失效、過擬合風險高), PCA 在多數情況下有明確意義 (去冗餘、抗噪、加速)。
- × (C) 錯誤：PCA 是線性降維 (線性投影), 不會將線性 SVM 變成非線性。非線性需要 Kernel SVM (RBF、Poly Kernel)。

核心考點：PCA 降維對訓練效率與過擬合的雙重效益。

易混淆對比：PCA (線性無監督) vs LDA (線性監督) vs t-SNE/UMAP (非線性可視化) vs Kernel SVM (非線性分類)。

對應章節：L21301 數據準備與模型選擇

第 48 題 (114-2-1-Q48)

題幹：某數據工程師使用 DBSCAN 演算法對一份數百萬筆的高維顧客資料進行聚類分析, 但發現程式執行速度極慢, 甚至出現記憶體不足的情況。若要在不改變演算法核心邏輯的前提下, 最有效提升其運算效率的作法為何?

選項：

- (A) 改用以平均連結 (Average Linkage) 為基礎的階層式群集法 (Hierarchical Clustering)
- (B) 採用高效率的距離索引結構 (Distance Index Structure), 例如 KD-Tree 或 Ball Tree
- (C) 將 ϵ (Epsilon) 參數調得極小, 以減少鄰近點的數量
- (D) 在資料前處理時增加標準化後的特徵維度數

正確答案：B

詳細解析：

- ✓ (B) 正確：DBSCAN 主要瓶頸是「鄰居查詢 (Range Query)」, naive 實作需 $O(n^2)$ 。KD-Tree / Ball Tree 等空間索引結構可將查詢加速至 $O(n \log n)$, 在百萬筆資料上效能提升數十倍, 且不改變演算法核心邏輯 (DBSCAN 流程不變, 只換查詢結構)。sklearn DBSCAN 預設可選 `algorithm= 'kd_tree' / 'ball_tree'`。
- × (A) 錯誤：階層式群集 $O(n^2)$ 或 $O(n^3)$, 比 DBSCAN 更慢, 且這「改變演算法」, 違反題目「不改變核心邏輯」。
- × (C) 錯誤： ϵ 調極小會讓多數點變雜訊, 破壞聚類結果 (不是改善效能而是破壞結果), 且這是改變超參數不是提升效能。

- × (D) 錯誤：增加特徵維度會加劇「維度災難」，使距離計算更慢、KD-Tree 失效（高維下索引退化），與目標完全相反。

核心考點：DBSCAN 的空間索引加速。

易混淆對比：KD-Tree（低維高效）vs Ball Tree（中高維友好）vs HNSW/FAISS（近似最近鄰，大規模）vs Brute-force（最慢）。

對應章節：L21301 數據準備與模型選擇

延伸補充：資料品質、縮放與分類模型辨析

考點 (B1)

- 【考點】資料品質的四個評估面向：準確性、完整性、一致性、即時性。（另一常見版本加上唯一性成五大指標，見前文『完一準即唯』）
- 【考點】資料品質差會導致：預測不準 + 模型不穩 + 結果帶偏誤 + 使用者信任崩潰。
- 【考點】標準化（Standardization）的目的 = 把不同單位、不同大小的特徵拉到同一尺度上比較。
- 【考點】監督式 = 有正確答案（標籤）可學；非監督式 = 把資料丟給模型自己找規律。
- 【考點】分類常見的五個模型：邏輯迴歸、決策樹、隨機森林、SVM、KNN。
- 【判別】輸出為有限離散選項（是/否、類別 A/B/C）→ 分類；輸出為連續數值 → 迴歸。

陷阱 (B2)

- 【陷阱】正規化（Normalization）vs 標準化（Standardization）是熱門易混考點：
 - ▶ 正規化 = 用公式把數值壓縮到 0-1 區間（最大值變 1、最小值變 0）
 - ▶ 標準化 = 換算成「距離平均幾個標準差」→ 結果平均為 0、標準差為 1
- 【判別】特徵縮放類選項的關鍵詞是「量綱」「尺度一致」——與距離型模型（KNN、K-Means、SVM）連動出題。
- 【陷阱】歷史資料偏差會被模型放大：Amazon 2018 年的招聘 AI 因訓練資料以男性履歷為主，學會懲罰含「women's」字樣的履歷，最終遭棄用——公開報導的經典偏見案例。

補充判別表 (B1)

任務	答案類型	範例	適合演算法
迴歸 (Regression)	連續數值	房價、明天氣溫	線性迴歸、LASSO、Ridge
分類 (Classification)	離散類別	是/否、貓/狗、垃圾信/正常信	決策樹、隨機森林、SVM、KNN

補充精華 (B3)

- 決策樹 vs 隨機森林：
 - ▶ 決策樹：規則路徑可完整追溯，適合需要向非技術關係人交代決策依據的場景
 - ▶ 隨機森林：以集成投票換取更高準確率與穩定性，但單一預測難以歸因
 - ▶ 選型軸 = 可解釋性需求 vs 效能需求。
- 資料尺度問題範例：身高（150–190 cm）與月消費金額（0–30 萬元）同時作為特徵時，未縮放前距離幾乎由消費金額決定，身高的影響力近乎消失。

延伸補充：GIGO、ETL 與演算法兩大陣營

考點 (B1)

- 資料科學鐵律：「垃圾進、垃圾出（Garbage In, Garbage Out, GIGO）」
- 七成法則：資料科學家約有 70% 時間花在資料準備，這直接影響 AI 專案的 ROI。
- AI 效能仰賴三要素：完整性、一致性、代表性。

補充比較表 (B2) — ETL 管線

階段	英文	動作
萃取	Extract	從各來源取得原始資料
轉換	Transform	清理、格式化、做特徵工程
載入	Load	載入目標儲存系統供 AI 使用

補充比較表（B2）— 演算法的兩大思路

陣營	邏輯	代表演算法	思考方式
幾何式	把資料視為空間中的座標，計算距離與分界	SVM、神經網路	在特徵空間中畫出分界線
規則式	透過一連串「是／否」條件逐層判斷	決策樹、XGBoost	一層層條件篩選

補充精華（B3）

- 依資料型態選模型：結構化資料（表格）→ 隨機森林、XGBoost；非結構化資料（文字、聲音）→ NLP 或貝氏分類器。
- 三步流程：清理資料 → 特徵工程 → 選擇模型。

延伸補充：Pandas 清洗、編碼與縮放方法

考點（B1）— 資料清洗 Pandas 關鍵字

Pandas 指令	任務	備註
pd.read_csv(...)	載入資料	基本必會
.isnull().sum()	檢查缺失值	資料健檢第一步
.fillna(...)	填補缺失	數值用平均／中位，類別用眾數
.head() / .describe()	概覽資料	describe() 中 50% 那列即中位數
df.groupby("X")["Y"].sum()	分組加總	需懂得拆解串接指令

陷阱（B2）— Pandas 必考陷阱

- 整數欄位含 NaN 會自動轉浮點：原本是整數 1, 2, 4 的欄位，只要中間出現空值，Pandas 讀進來就會把整欄變成 float64 (1.0, 2.0, NaN)
- stratify=y 的作用：train_test_split 時加上它，可確保切分後各類別比例與原資料一致（不平衡資料務必加）
- sm.add_constant(X) 陷阱：做線性迴歸時忘了加常數項，會強迫迴歸線通過原點 (0,0)，使整個模型出錯

考點（B1）— 異常值與編碼

- Z-Score > 3 視為警戒：常用的判定門檻是 3
- 獨熱編碼（One-Hot Encoding）vs 標籤編碼（Label Encoding）：
 - ▶ One-Hot：用於無順序類別（城市：台北／台中／高雄）
 - ▶ Label：用於有順序類別（衣服尺寸：S=1, M=2, L=3）
 - ▶ 陷阱：若對信用卡等級用 Label（普卡=1／白金=2／黑卡=3），模型會誤以為黑卡的「數值權重」是普卡的 3 倍 → 應改用 One-Hot

補充比較表（B2）：三種縮放方法

方法	公式	對極端值敏感度	適用
Z-Score 標準化	$(x - \mu) / \sigma$ ，平均 0、標準差 1	高	一般情況
Min-Max	縮到 0~1	高	影像、有界資料
Robust Scaling（穩健縮放）	中位數 + 四分位距（IQR）	低（最耐極端值）	含極端值的資料

- 鐵則：執行 PCA 前務必先標準化（否則大尺度特徵會主導主成分）

【中級真題與解析（115 年第一次）】

本節對應 9 題官方真題（115 年第一次中級 AI 應用規劃師），每題含 4 選項詳細解析、核心考點、易混淆對比。

第 12 題（115-1-1-Q12）

題幹：某工程師在設計一個二元分類器（Binary Classifier）時，考慮在輸出層使用 Sigmoid 函數。請問 Sigmoid 函數的主要特性與限制為何？

選項：

- (A) 可將輸入轉換為任意實數範圍，適合用於迴歸任務
- (B) 可將輸入壓縮至 (0, 1) 區間，可解釋為機率值，但在輸入值過大或過小時可能產生梯度消失問題
- (C) 可將輸入轉換為多類別機率分布，常用於多分類任務

- (D) 可在整個輸入範圍內梯度保持穩定，適合用於深層神經網路

正確答案：B

詳細解析：

- ✓ (B) 正確：Sigmoid 函數 $\sigma(x)=1/(1+e^{-x})$ 將任意實數壓縮至 (0, 1) 開區間，輸出可直接解釋為「屬於正類的機率」，因此是二元分類輸出層的標準選擇（搭配二元交叉熵損失）。其限制：導數 $\sigma'(x)=\sigma(x)(1-\sigma(x))$ 最大值僅 0.25，且當 $|x|$ 很大時曲線進入飽和區、導數趨近 0——反向傳播時梯度逐層相乘而迅速衰減，即梯度消失（Vanishing Gradient，梯度消失）問題，這是深層網路隱藏層改用 ReLU（Rectified Linear Unit，線性整流單元）的主因。
- × (C) 錯誤：「多類別機率分布」（各類機率總和為 1）是 Softmax 函數的功能，用於多元分類輸出層；Sigmoid 單一輸出只給一個機率值。
- × (A) 錯誤：Sigmoid 輸出被限制在 (0, 1)，不是任意實數範圍；迴歸任務的輸出層通常用線性（恆等）激活。
- × (D) 錯誤：與事實相反——Sigmoid 正因飽和區梯度趨零而「不適合」深層網路的隱藏層；「梯度整段穩定」較接近 ReLU 在正區間的性質。

核心考點：激活函數的「輸出範圍＋機率解釋＋梯度行為」三件事——Sigmoid :(0,1)、可當機率、會飽和梯度消失。

易混淆對比：Sigmoid（單輸出 (0,1)、二元分類）vs Softmax（多輸出總和=1、多元分類）vs Tanh ((-1,1)、零中心但同樣飽和) vs ReLU（max(0,x)、正區間梯度恆 1、緩解梯度消失但有神經元死亡問題）。

對應章節：L21301 數據準備與模型選擇

第 30 題 (115-1-1-Q30)

題幹：某資料科學家正在處理一份包含 200 個感測器特徵的工廠設備監測資料集，為了降低模型複雜度並保留主要變異資訊，他先對資料進行標準化（Standardization），再使用主成分分析（PCA）進行降維。在 PCA 過程中，為了找出能最大化資料變異量的主成分方向，演算法主要依賴哪一項數學操作？

選項：

- (A) 透過對目標函數進行梯度下降（Gradient Descent）最佳化，迭代求得主成分方向
- (B) 根據特徵與目標變數之間的相關性（Correlation）進行排序，選擇重要特徵
- (C) 對資料的協方差矩陣（Covariance Matrix）進行特徵值分解（Eigen Decomposition），取得對應主要變異方向的特徵向量
- (D) 對資料矩陣進行卷積運算（Convolution），擷取特徵之間的局部關係

正確答案：C

詳細解析：

- ✓ (C) 正確：PCA（Principal Component Analysis，主成分分析）的數學核心：先計算資料的協方差矩陣（描述各特徵兩兩之間的共變異結構），再對它做特徵值分解——特徵向量（Eigenvector）給出互相正交的主成分方向，對應的特徵值（Eigenvalue）等於資料投影到該方向後的變異量大小；取特徵值最大的前 k 個特徵向量即為「保留最多變異」的 k 維子空間。（實務上也常用 SVD（Singular Value Decomposition，奇異值分解）直接分解資料矩陣，數學上等價。）標準化的目的是避免量綱大的感測器特徵主宰協方差矩陣。
- × (A) 錯誤：PCA 有封閉解（Closed-form Solution），直接由線性代數分解一步求得，不需迭代最佳化；梯度下降是神經網路等無封閉解模型的訓練方式。（自編碼器 Autoencoder 降維才用梯度下降，那是另一種技術。）
- × (B) 錯誤：這描述的是監督式特徵選擇（Feature Selection）的過濾法（Filter Method）——需要目標變數 y。PCA 是非監督式特徵萃取（Feature Extraction），完全不看目標變數，且產生的是原特徵的線性組合（新特徵）而非挑選原特徵子集。
- × (D) 錯誤：卷積運算是 CNN 擷取影像局部空間模式的動作，與 PCA 的全域線性投影無關；此選項純粹是名詞干擾。

核心考點：PCA 演算法核心＝協方差矩陣的特徵值分解；特徵值＝該主成分方向的變異量、特徵向量＝投影方向。記住「PCA＝非監督＋線性＋封閉解」三性質即可排除所有錯項。

易混淆對比：特徵萃取（Feature Extraction，PCA：造出新特徵＝原特徵線性組合）vs 特徵選擇（Feature Selection：挑原特徵子集、保留可解釋性）；PCA（非監督、最大化總變異）vs LDA（Linear Discriminant Analysis，線性判別分析：監督式、最大化類別間分離度）；PCA（線性）vs t-SNE／UMAP（非線性流形降維、主用於視覺化）。

對應章節：L21301 數據準備與模型選擇

第 31 題 (115-1-1-Q31)

題幹：某資料工程師嘗試對包含 300 個特徵的使用者行為資料集使用 DBSCAN 進行群集分析，但發現幾乎所有資料點都被判定為雜訊點（Noise Points），難以形成有意義的群集，即使不斷調整 ϵ （Epsilon）與 MinPts 參數也無濟於事。請問下列何者為此問題最可能的根本原因？

選項：

- (A) 在高維空間中，維度詛咒（Curse of Dimensionality）使得資料點之間的距離趨於相近，導致 DBSCAN 的密度估計失效
- (B) DBSCAN 演算法僅適用於低維資料，無法處理高維資料
- (C) 300 個特徵的資料必然不具備群集結構，因此無法進行有效的分群
- (D) 高維空間中核心點的數量會受到數學限制，導致無法形成群集

正確答案：A

詳細解析：

- ✓ (A) **正確：**DBSCAN（Density-Based Spatial Clustering of Applications with Noise，基於密度且能處理雜訊的空間分群）依賴「 ϵ 半徑內至少有 MinPts 個鄰居」的**密度**定義。維度詛咒的核心現象是：維度升高時，空間體積指數膨脹、資料極度稀疏，且任兩點的距離**集中化（Distance Concentration）**——最近鄰與最遠鄰的距離比值趨近 1，「近」與「遠」失去區辨力。結果是： ϵ 設小→所有點半徑內都湊不滿 MinPts→全部變雜訊點； ϵ 設大→整個資料集連成一團。所以「怎麼調參都無濟於事」正是密度估計在 300 維空間根本性失效的訊號，這是**問題的本質**而非參數問題。
- × (B) **錯誤：**說法過度絕對。DBSCAN 演算法本身沒有維度上限，「僅適用低維、無法處理高維」是把「高維下效果退化」誇大成「演算法不支援」；正確理解是距離度量在高維退化，而非演算法禁止高維輸入。
- × (C) **錯誤：**「必然不具備群集結構」邏輯錯誤——高維資料常存在低維流形上的真實群集（實務解法正是先用 PCA／UMAP 降維再分群），分不出來是方法失效，不代表結構不存在。
- × (D) **錯誤：**「核心點數量受數學限制」是虛構的偽定理；核心點少是距離集中化的**結果**，不是某條獨立的數學限制，此選項是聽起來專業的煙霧彈。

核心考點：維度詛咒對距離型／密度型演算法的殺傷力：高維→距離集中化→密度概念失效→DBSCAN／KNN／K-means 全部退化。題幹線索「300 特徵＋調參無效」＝根本原因在維度、不在參數。實務解法：先降維（PCA／自編碼器／UMAP）再分群。

易混淆對比：維度詛咒的三種面向——資料稀疏（樣本需求指數成長）、距離集中（近鄰失義）、過擬合風險升高；DBSCAN（密度式、不需指定群數、能標雜訊、對高維敏感）vs K-means（切割式、需指定 K、假設球形群、同樣受高維所苦但退化方式不同）。

對應章節：L21301 數據準備與模型選擇

第 33 題 (115-1-1-Q33)

題幹：某自駕車公司的 AI 訓練團隊面臨標註成本高的問題，無法取得足夠的真實惡劣天氣（大雨、濃霧）駕駛場景資料，工程師提議使用合成資料（Synthetic Data）來補充訓練集。請問下列何者最能正確敘述合成資料在 AI 訓練中的角色？

選項：

- (A) 合成資料主要用於文字任務的資料擴增，影像任務仍需依賴真實資料
- (B) 合成資料可完全取代真實資料，直接用於模型訓練
- (C) 合成資料主要用於降低模型推論時的計算成本
- (D) 合成資料可在控制條件下產生多樣化場景，用於擴充訓練資料並提升模型的泛化能力

正確答案：D

詳細解析：

- ✓ (D) 正確：合成資料 (Synthetic Data) 的核心價值有三：(1) 可控生成——在模擬器 (如自駕常用的 CARLA) 中精確控制天氣、光照、車流等參數，量產真實世界稀缺或危險而難以蒐集的場景 (大雨、濃霧、事故邊緣案例 Corner Cases)；(2) 自帶標註——模擬器生成時即知每個像素的真值 (Ground Truth)，省去人工標註成本，直接對應題幹「標註成本高」痛點；(3) 擴充分佈覆蓋——補齊訓練分佈的長尾，提升模型對罕見情境的泛化能力 (Generalization)。「補充」而非「取代」正是其正確定位。
- × (A) 錯誤：方向恰好顛倒——影像／3D 場景反而是合成資料最成熟的領域 (遊戲引擎渲染、模擬器)，自駕、機器人視覺大量使用；並非「僅限文字任務」。
- × (B) 錯誤：「完全取代」過度絕對。合成資料存在領域差距 (Domain Gap / Sim-to-Real Gap)：渲染影像與真實感測器資料在紋理、噪聲、物理細節上仍有系統性差異，只用合成資料訓練的模型在真實環境會效能下降，故實務上是「合成＋真實」混合訓練並輔以領域適應 (Domain Adaptation)。
- × (C) 錯誤：合成資料作用於訓練資料端，與推論階段的計算成本毫無關係；降低推論成本靠的是模型量化、剪枝、蒸餾等模型壓縮技術——典型的「張冠李戴」干擾項。

核心考點：合成資料定位＝「可控條件下量產多樣化／稀缺場景，擴充 (非取代) 訓練集、提升泛化」。判別關鍵：選項出現「完全取代」「必然」等絕對化字眼多為錯；正確選項通常是「補充＋泛化」的中性陳述。

易混淆對比：合成資料 (模擬器／生成模型從零造出新樣本，可造出訓練集沒有的場景) vs 資料擴增 (Data Augmentation：對既有真實樣本做旋轉、裁切、加噪等變換，多樣性受原始資料限制)；Sim-to-Real Gap (合成→真實的分佈落差) 是使用合成資料的首要風險。

對應章節：L21301 數據準備與模型選擇

第 34 題 (115-1-1-Q34)

題幹：某廣告技術公司的點擊率 (CTR) 預測系統每天新增數百個用戶行為特徵 (如新廣告位、新設備類型)，特徵空間持續動態擴展。若採用傳統靜態模型每週批次重訓一次，會導致嚴重的模型過期問題。為在特徵空間頻繁變化的情況下維持模型即時準確度，最適合的模型架構方向為何？

選項：

- (A) 採用傳統靜態羅吉斯迴歸 (Logistic Regression)，縮短批次重訓週期從每週改為每日
- (B) 採用支援增量學習 (Incremental Learning) 的模型，使模型能隨新資料即時更新並適應新增特徵，而不需重新訓練整個模型
- (C) 採用固定架構的深度神經網路 (DNN)，每次有新特徵時重新定義輸入層後全量重訓
- (D) 改用預訓練圖神經網路 (GNN)，透過圖結構建立特徵間的關聯，自動應對新增特徵

正確答案：B

詳細解析：

- ✓ (B) 正確：題幹兩個關鍵需求：(1) 「每天新增數百個特徵、特徵空間動態擴展」；(2) 「維持即時準確度」。增量學習 (Incremental Learning，又稱線上學習 Online Learning) 讓模型以串流方式逐批 (甚至逐筆) 更新參數，不必每次都對全量歷史資料重訓；搭配特徵雜湊 (Feature Hashing) 等技巧可把無限成長的特徵映射到固定維度空間，天然吸納新特徵。廣告 CTR (Click-Through Rate，點擊率) 預測正是線上學習的經典戰場 (如 Google 的 FTRL-Proximal 線上羅吉斯迴歸)。
- × (A) 錯誤：縮短重訓週期只是「把過期問題從 7 天壓到 1 天」，本質仍是靜態批次典範——特徵每天新增數百個，每日重訓後幾小時內又過期；且全量重訓成本隨資料累積線性上升，治標不治本。
- × (C) 錯誤：「新特徵→改輸入層→全量重訓」是最昂貴的路線：每天數百個新特徵意味著幾乎每天全量重訓 DNN (Deep Neural Network，深度神經網路)，計算成本與更新延遲都無法滿足「即時」需求。
- × (D) 錯誤：GNN (Graph Neural Network，圖神經網路) 處理的是「樣本／實體間的圖結構關係」 (如社交網路、知識圖譜)，「自動應對新增特徵」是對 GNN 能力的錯誤宣稱——預訓練 GNN 同樣面臨新節點／新特徵的冷啟動與重訓問題，並非動態特徵空間的對症解法。

核心考點：批次學習 (Batch Learning，全量資料離線重訓) vs 增量／線上學習 (隨資料流即時更新) 的選型：資料分佈或特徵空間高頻變動＋要求即時性→增量學習。題幹線索「每天新增特徵＋模型過期」直接對應。

易混淆對比：增量學習（隨新資料持續更新、可能遭遇災難性遺忘 Catastrophic Forgetting）vs 定期重訓（穩定可控但有過期窗口）vs 遷移學習（一次性把預訓練知識搬到新任務，不解決持續變動）；線上學習的代價：需監控漂移、防止被異常資料流帶偏（須配合監控與回滾機制）。

對應章節：L21301 數據準備與模型選擇

第 36 題 (115-1-1-Q36)

題幹：某公司希望開發一個工業零件瑕疵辨識分類模型，共有 10 個類別，但每類僅約 50 張人工標註影像（總計約 500 張）。由於標註成本高昂，短期內無法擴充資料集。在此情境下，工程師需要在有限標註資料下建構高效能模型。請問下列哪一種策略最為適合？

選項：

- (A) 使用在大型資料集預訓練完成的卷積神經網路（CNN），並進行遷移學習微調
- (B) 從頭訓練大型 Vision Transformer（ViT），完全使用現有 500 張影像
- (C) 使用 K-means 對影像進行分群，並直接將群集結果作為分類模型輸出
- (D) 複製既有的資料以增加標註影像數量，並從頭訓練深度 CNN 模型

正確答案：A

詳細解析：

- ✓ (A) **正確：**小樣本影像分類的標準解法＝遷移學習（Transfer Learning）：取在 ImageNet 等大型資料集預訓練的 CNN，其底層卷積已學會通用視覺特徵（邊緣、紋理、形狀），只需以 500 張瑕疵影像**微調（Fine-tuning）**上層或重訓分類頭。因為要從資料中學的參數量大幅減少，小資料也能達到高效能——「預訓練提供先驗知識、微調做領域適配」正是「標註稀缺」情境的教科書答案。
- × (B) **錯誤：**ViT（Vision Transformer，視覺 Transformer）缺乏 CNN 的歸納偏置（Inductive Bias，如局部性、平移等變性），**極度依賴大規模資料**（原論文用 1,400 萬～3 億張）才能超越 CNN；用 500 張從頭訓練大型 ViT 必然嚴重過擬合，是所有選項中資料需求與資料現況落差最大的。
- × (C) **錯誤：**K-means 是非監督分群——群集編號與「10 類瑕疵標籤」之間沒有對應保證，且原始像素空間的距離無法反映瑕疵語意；手上明明有標註（監督訊號）卻棄之不用改走非監督，方法選型根本錯誤。
- × (D) **錯誤：**複製資料不產生任何新資訊——模型看到的仍是同 500 張圖，只是每張多看幾遍，等同增加 epoch 數，過擬合風險不減反增。（注意與資料擴增區分：擴增是施加旋轉、翻轉、色彩擾動等**變換**產生變體，能提供有效的新變異；純複製不能。）

核心考點：「每類 50 張／總計 500 張＋標註成本高」＝小樣本情境→首選「預訓練＋遷移學習微調」。判別關鍵：小資料絕不「從頭訓練」大模型；有標註就不要退回非監督。

易混淆對比：遷移學習（借預訓練權重、小資料微調）vs 從頭訓練（Training from Scratch，需大資料）；資料複製（無新資訊、助長過擬合）vs 資料擴增（變換出有效變異）vs 合成資料（模擬器／生成模型造新樣本，見 Q33）；小樣本學習家族：遷移學習／少樣本學習（Few-shot Learning）／資料擴增，三者可疊加使用。

對應章節：L21301 數據準備與模型選擇

第 37 題 (115-1-1-Q37)

題幹：某製造廠開發產線瑕疵檢測模型時，資料集存在嚴重類別不平衡問題，其中良品約占 99%，瑕疵品僅占 1%。若直接使用原始資料進行訓練，模型容易偏向預測多數類別（良品），導致對少數類別（瑕疵品）辨識能力不足。在不調整模型架構與學習演算法的前提下，僅透過資料前處理方式改善此問題，下列何者最適當？

選項：

- (A) 使用 SMOTE 等過採樣方法進行少數類別擴增
- (B) 加入 L1／L2 正則化（Regularization）以防止過擬合
- (C) 大幅增加深度神經網路的層數，以強化特徵萃取能力
- (D) 複製更多良品數據，以進一步提升模型的準確率（Accuracy）

正確答案：A

詳細解析：

- ✓ (A) 正確：題幹限制條件是解題關鍵——「不調整模型架構與學習演算法、僅透過資料前處理」，直接把解法限定在重採樣 (Resampling) 家族。SMOTE (Synthetic Minority Over-sampling Technique，合成少數類過採樣技術) 在少數類樣本與其 k 近鄰之間做線性內插合成新樣本，比單純複製少數類更能增加樣本多樣性、降低過擬合風險，是類別不平衡資料前處理的代表性方法。過採樣後兩類比例趨衡，模型不再靠「全猜良品」蒙混。
- × (B) 錯誤：L1/L2 正則化是學習演算法層的手段 (修改損失函數懲罰項)，違反題幹「僅資料前處理」的限制；且正則化解決的是過擬合，不是類別不平衡——欠代表的少數類不會因為權重被懲罰而變得可辨識。
- × (C) 錯誤：加深網路是模型架構層調整，同樣違反限制；且更深的網路在極度不平衡資料上只會更高效地學會「永遠預測良品」這條捷徑，問題根源 (訊號比例失衡) 未除。
- × (D) 錯誤：方向完全顛倒——複製多數類 (良品) 使不平衡更惡化；「提升準確率」是誘餌：99:1 資料下全猜良品就有 99% Accuracy，準確率在不平衡場景本來就是失真指標 (應改看 Recall、F1、PR-AUC)。

核心考點：類別不平衡三層解法分類——資料層 (過採樣 SMOTE/欠採樣 Undersampling)、演算法層 (類別權重 Class Weight、代價敏感學習)、模型/閾值層 (調決策閾值)；題幹鎖定「資料前處理」→ 只能選重採樣。加碼考點：不平衡資料勿用 Accuracy 評估。

易混淆對比：SMOTE (內插合成新少數類樣本、多樣性佳) vs 隨機過採樣 (單純複製少數類、易過擬合) vs 欠採樣 (丟棄多數類樣本、可能損失資訊)；SMOTE 注意事項：只能對訓練集做 (測試集重採樣會造成評估失真)、且須在資料切分之後做以防資料洩漏 (Data Leakage)。

對應章節：L21301 數據準備與模型選擇

第 38 題 (115-1-1-Q38)

題幹：某 IoT 平台接收工廠溫度感測器資料，發現在常態分佈 (均值 25°C，標準差 2°C) 的數萬筆紀錄中，出現數筆「999°C」的極端值，研判為感測器通訊錯誤 (網路封包延遲導致數值溢位) 所致，且該異常數值在實際情況下不可能發生。在進行模型訓練前的資料清洗階段，針對這類離群值，最適當的處理策略為何？

選項：

- (A) 保留所有原始數值，並使用平均數 (Mean) 作為特徵輸入模型
- (B) 對數據進行 Z-score 標準化，使數值落於約 $[-3, 3]$ 範圍
- (C) 將 999°C 以獨熱編碼 (One-Hot Encoding) 轉為獨立類別特徵
- (D) 刪除異常的 999°C 記錄，或以中位數 (Median) 進行填補

正確答案：D

詳細解析：

- ✓ (D) 正確：判斷離群值處理方式的第一步是分辨其性質：題幹已明說 999°C 是「感測器通訊錯誤 (數值溢位)、實際不可能發生」——這是技術性錯誤值 (Erroneous Value)，不是攜帶資訊的真實極端事件，因此正確策略就是移除或修補：直接刪除該筆紀錄，或以中位數 (Median) 填補。選中位數而非平均數是因為中位數是穩健統計量 (Robust Statistic)，不受殘留極端值拉扯 (若用平均數填補，而平均數本身已被 999 污染，會引入偏差)。
- × (A) 錯誤：保留 999°C 且用平均數當特徵是雙重錯誤——數萬筆中僅數筆 999 也足以把平均值明顯拉高 (平均數對離群值極不穩健)，等於讓已知的錯誤資料直接污染特徵。
- × (B) 錯誤：常見誤解陷阱——Z-score 標準化只是線性變換 (減均值除以標準差)，離群值變換後依然是離群值 (999°C 的 Z 值約 $(999-25)/2 \approx 487$ ，遠超 $[-3, 3]$)；標準化不會「使數值落於 $[-3, 3]$ 」，那是對「常態資料 99.7% 落在 $\pm 3\sigma$ 」的誤用，且錯誤值該被清除而非改尺度保留。
- × (C) 錯誤：獨熱編碼是類別型特徵的編碼方法；把連續溫度的錯誤值編成一個類別，等於把「已知的通訊錯誤」當成有意義的狀態餵給模型，概念層級完全錯置。

核心考點：離群值處理決策樹——先判性質：技術錯誤值 (不可能發生) → 刪除或以穩健統計量 (中位數) 填補；真實極端值 (罕見但可能) → 保留並考慮穩健模型或截尾 (Winsorization)。本題線索「研判為通訊錯誤 + 實際不可能」直接走刪除/填補分支。

易混淆對比：平均數（對離群值敏感）vs 中位數（穩健，填補首選）；標準化（改尺度、不除離群）vs 清洗（除錯誤值）——順序上應「先清洗、後標準化」；錯誤值（Error，該刪）vs 異常值（Anomaly，可能是要偵測的目標事件，如設備真過熱，不可亂刪）。

對應章節：L21301 數據準備與模型選擇

第 39 題 (115-1-1-Q39)

題幹：某 AI 平台工程師正在為多模態模型訓練系統規劃資料儲存架構，需要同時處理原始影像、非結構化文本，以及經過整理的結構化特徵資料。在此情境下，應如何選擇資料湖（Data Lake）與資料倉儲（Data Warehouse）的使用方式？

選項：

- (A) 將原始影像與文本資料儲存在 Data Lake，將整理後的結構化特徵資料儲存在 Data Warehouse
- (B) 將所有資料統一儲存在 Data Warehouse，以提升查詢效率
- (C) 將所有資料統一儲存在 Data Lake，但犧牲結構化資料的查詢效率
- (D) 僅將原始影像資料儲存在 Data Lake，其餘資料統一存入 Data Warehouse

正確答案：A

詳細解析：

- ✓ (A) **正確：**兩種儲存架構的分工原則：Data Lake（資料湖）採 **Schema-on-Read**（讀取時才套結構），以低成本物件儲存容納**任意格式的原始資料**——影像、音訊、日誌、自由文本都能原樣入湖，適合 AI 訓練保留全量原始素材；Data Warehouse（資料倉儲）採 **Schema-on-Write**（寫入時即定義結構），存放**清洗整理後的結構化資料**，靠欄式儲存與索引提供高效 SQL 查詢與分析。「原始影像＋非結構化文本→Lake；整理後結構化特徵→Warehouse」正是各取所長的標準架構。
- × (B) **錯誤：**Data Warehouse 要求寫入前定義 Schema，原始影像／自由文本這類非結構化資料**不適合也**不經濟地塞進倉儲（通常僅能以 BLOB 硬存，喪失倉儲的查詢優勢且成本高昂）。
- × (C) **錯誤：**全部入湖雖然「存得下」，但選項自己承認「犧牲結構化資料的查詢效率」——明知有更好的分工方案（結構化資料放倉儲）卻選擇次佳解，在「應如何**選擇**使用方式」的題意下不是最適答案。
- × (D) **錯誤：**把「非結構化文本」放進 Data Warehouse 犯了與 (B) 相同的錯——自由文本沒有固定 Schema，屬於湖的守備範圍；此選項只對了影像一半。

核心考點：Data Lake vs Data Warehouse 分流原則：「原始／非結構化→湖；整理後／結構化→倉儲」。判別口訣：湖裝生水（Raw、Schema-on-Read、便宜大容量）、倉放熟貨（Curated、Schema-on-Write、快查詢）。

易混淆對比：Data Lake（全格式、Schema-on-Read、成本低、風險是變成無治理的資料沼澤 Data Swamp）vs Data Warehouse（結構化、Schema-on-Write、查詢快、成本高）vs Data Lakehouse（湖倉一體：在資料湖上加交易與 Schema 管理層，如 Delta Lake / Iceberg，兼取兩者）——若選項出現 Lakehouse 則是「魚與熊掌兼得」的新典範，本題只考前兩者的經典分工。

對應章節：L21301 數據準備與模型選擇

L21302 AI 技術系統集成與部署

※ **考綱重點（L21302 AI 技術系統集成與部署）：**AI 技術系統架構設計、模型部署技術（容器化／API／邊緣）、模型效能監控和更新管理（資料漂移／模型漂移）、系統測試與驗證、系統穩定性和可用性（SLA／SLO）、雲端環境建置（AWS／GCP／Azure）

AI 部署的特殊性

AI 系統部署複雜性高於傳統 IT 系統的三大來源：

特性	內涵
動態性	模型效能會隨輸入資料變化而衰退（漂移）
資料敏感性	合規與透明度要求高

特性	內涵
持續更新	頻繁重訓 + 版本控管

AI 模型「部署」≠「模型上線」，而是涵蓋開發、測試、部署、監控、回訓與優化的完整技術流程。

系統集成五大面向

A. 資料來源與資料管線（Data Pipeline）整合

來源	範例
資料倉儲（Data Warehouse）	結構化企業內部資料
資料湖（Data Lake）	大規模非結構資料
IoT 即時感測資料	工廠/車輛/裝置
第三方 API	外部服務介接

資料管線涵蓋：擷取 → 格式轉換 → 清理 → 入庫。

B. 企業內部系統整合

模型輸出需整合回 ERP、CRM、POS、MES（Manufacturing Execution System，製造執行系統）等核心系統。範例：CRM 自動依推薦寄促銷信、ERP 依預測動態採購。

C. API 與平台接軌

介面型態	特性	適用
RESTful API	最常見、HTTP/JSON	一般 Web 服務
gRPC	高效能雙向通訊	服務間通信
Webhooks	事件觸發	即時通知

設計需含容錯、快取、負載管理。

D. 安全與權限控管

機制	全名	用途
OAuth2 / JWT	JSON Web Token	用戶身份驗證與授權
RBAC	Role-Based Access Control，角色存取控制	不同角色不同權限（誰可調參、誰可重訓）
API Gateway	—	存取日誌、流量控管

E. 跨雲與異質系統整合

訓練在本地、推論在邊緣、儲存在雲端 → 設計中介整合層或服務中樞（Service Mesh），統一管理同步、調用、狀態追蹤。

◎ 系統架構設計

A. 微服務架構（Microservices Architecture）

優點	挑戰
錯誤隔離（單一模組失效不影響全系統）	模組間需設計標準 API
跨團隊並行開發	分散式管理複雜度高
彈性調整資源	服務追蹤難度高

B. 容器化與編排（Containerization and Orchestration）

工具	角色
Docker	容器映像建構與執行
Kubernetes (K8s)	容器編排、資源調度、故障恢復

常見實作原則：

原則	英文	內涵
滾動更新	Rolling Update	不中斷服務地更新

原則	英文	內涵
自動擴縮	Autoscaling	依流量調整容器數
負載平衡	Load Balancing	請求分擔

C. 模型服務化與 API 封裝

工具：Flask、FastAPI、TensorFlow Serving。需設計：

設計重點	內容
多版本管理 (Model Versioning)	不同版本並存與切換
API 安全機制	驗證、速率限制
推論結果記錄與監控	Log & Metrics

D. 可擴充與高可用性設計

機制	中文	用途
Redundancy	冗餘部署	多節點避免單點故障
Failover	容錯切換	故障時自動切備援

E. 分散式容錯設計模式 (Resilience Patterns)

當 AI 平台整合多個外部微服務（語音辨識 API、NLP 分析 API、知識圖譜查詢等），單一外部服務的延遲或逾時，會在請求鏈路上層層卡住，最終拖垮整個平台——這就是連鎖故障（Cascading Failure，連鎖／瀑布式故障）。架構層面的對策是一套「韌性設計模式」：

模式	全名／中譯	機制	解決什麼
斷路器	Circuit Breaker	偵測某下游服務連續失敗達門檻 → 「跳閘」短路後續呼叫、直接快速失敗 (Fail Fast) 並回傳替代回應，待半開 (Half-Open) 試探恢復才合閘	預防連鎖故障：不讓壞掉的服務持續占用呼叫端資源
逾時	Timeout	為每次外部呼叫設上限，逾時即放棄	避免請求無限等待卡住執行緒
重試	Retry	失敗後自動重試（常配指數退避 Exponential Backoff）	救短暫瞬斷 (transient fault)
艙壁隔離	Bulkhead（艙壁／隔艙）	仿船艙分隔，為不同下游服務切分獨立資源池（執行緒池／連線池）	一個服務爆掉不會吃光全部資源、不波及其他服務
降級	Fallback（後備回應）	主服務失效時回傳預設值／快取／簡化結果	維持部分可用而非整體掛掉
限流	Rate Limiting（速率限制）	限制單位時間請求數，超量即拒絕	防過載與濫用（保護「自己」不被打爆）

【易混淆對比】Circuit Breaker vs Retry vs Timeout vs Bulkhead vs Rate Limiting：

維度	Circuit Breaker（斷路器）	Retry（重試）	Timeout（逾時）	Bulkhead（艙壁隔離）	Rate Limiting（限流）
觸發時機	下游連續失敗達門檻	單次失敗後	單次呼叫超時	資源分配（設計時）	請求量超閾值
核心目的	阻斷連鎖故障	救瞬斷	防無限等待	隔離爆炸半徑	防過載
對連鎖故障	✓ 主力解	⚠ 用錯反而加重（壞服務被重複猛打）	輔助（避免單點卡死）	✓ 限制波及範圍	輔助（保護自身）
比喻	電箱跳電保護	再按一次門鈴	等太久就掛電話	船艙隔水閘門	餐廳限制帶位數
風險／陷阱	門檻設不好誤跳	無上限重試 → 雪上加霜	設太短誤殺正常請求	切太細浪費資源	太嚴傷正常用戶

【口訣】「斷路器擋連鎖、艙壁限範圍、逾時防卡死、重試救瞬斷、降級保體驗、限流防過載」。其中只有斷路器（+ 艙壁）是「架構層面預防連鎖故障」的主力。

【115-1 科一 Q45 真題對應】正解 (B)：為外部服務導入斷路器模式 (Circuit Breaker)，異常時暫停呼叫並提供替代回應 (Fallback) ——這正是從架構層阻斷 Cascading Failure 的標準解。各干擾選項為何錯：

- × (A) 改同步串行 + **取消逾時限制**：完全反向——取消 Timeout 會讓請求**無限等待**、串行更易塞爆鏈路，是教科書級錯誤設計。
- × (C) 擴充執行緒池上限：只是「加大水管」拖延崩潰時間，外部服務若持續慢，**更多執行緒一起卡死**，反而擴大故障面（與 Bulkhead「切分隔離」相反）。
- × (D) 停用健康檢查：等於**拔掉故障偵測眼睛**，無法提早發現異常、更難自動切備援，降低可用性。

◎ AI 部署四模式

模式	優勢	挑戰	適用
公有雲 (Public Cloud)	彈性擴充、按量付費、全球節點	合規、資料主權、供應商鎖定	新創、中大型專案、GPU 密集型訓練
私有雲 (Private Cloud)	資安可控、資料不外流、定制化	建置維運成本高、彈性受限	政府、金融、醫療
邊緣運算 (Edge Computing)	即時反應、低延遲、隱私保護	運算資源有限、同步設計複雜	工業監控、智慧城市、車聯網
混合部署 (Hybrid Deployment)	兼顧計算、速度、保護	系統整合難度高	多元情境（雲訓練+邊緣推論）

【判別表】 部署模式抉擇：

條件	推薦
敏感資料、嚴格法規	私有雲
大規模訓練、彈性需求	公有雲
低延遲推論、IoT 場景	邊緣運算
多重需求（訓練 + 推論）	混合部署

【考點】 公有雲三巨頭：

廠商	全名
AWS	Amazon Web Services
Microsoft Azure	—
GCP	Google Cloud Platform

◎ MLOps 與持續維運

MLOps (Machine Learning Operations，機器學習運維)：DevOps 在 AI 領域的延伸，自動化模型生命週期。

A. CI/CD (持續整合 / 持續部署)

階段	全名	內容
CI	Continuous Integration	原始碼/資料變動觸發訓練測試；單元測試 + 模型準確率驗證
CD	Continuous Deployment	通過測試的模型自動部署；支援 A/B 測試、藍綠部署 (Blue-Green Deployment)

模型版本控管工具：

工具	全名	用途
MLflow	—	實驗記錄、模型訓練、部署、版本控制（開源）
DVC	Data Version Control，資料版本控制	機器學習專案的資料集與模型版本追蹤

B. 模型監控與回饋 (Monitoring & Feedback)

監控項目	說明
模型漂移 (Model Drift)	預測分佈與訓練時期不同
資料漂移 (Data Drift)	輸入統計特徵改變
效能指標	錯誤率、延遲、吞吐量

回饋與自動修正流程：

步驟	動作
設定觸發門檻	如準確率下降 5%
啟動再訓練流程	Retraining Pipeline
部署方式	熱更新（Hot Swap）或滾動更新

可視化與預警工具：Prometheus + Grafana。

成效追蹤與優化

三層級 KPI 設計：

層級	範例指標
系統層級	推論延遲（Inference Latency）、吞吐量（Throughput）、可用率（Uptime）、GPU 記憶體
應用層級	CTR（點擊率）、Accuracy、F1-Score、異常偵測精確度
業務層級	轉換率、成本節省、客戶留存率、ROI

資料與績效回收週期（Feedback Loop）：

週期	動作
每日	監控推論效能與使用情況
每週	收集錯誤樣本與業務回饋
每月	模型重新評估或重訓需求確認

【口訣】 AI KPI 「系應業」 三層級必須兼顧（技術 + 業務雙軌制）。

模型更新與持續優化策略：

策略	英文	說明
滾動更新	Rolling Update	漸進釋出新版本
藍綠部署	Blue-Green Deployment	新舊版本並存、可快速切換
金絲雀部署	Canary Deployment	小比例流量先試新版本
再訓練與資料再標註	Retraining	漂移超門檻自動觸發
人在迴圈	Human-in-the-Loop	自動標記錯誤樣本進行學習
AutoML / Online Learning	—	持續模型微調

【易混淆對比】 三種更新策略：

策略	流量分配	風險	適用
Rolling Update	逐步替換節點	低	一般更新
Blue-Green	100% 切換	中（但可快速回退）	大版本變更
Canary	1-10% → 50% → 100%	最低	高風險新功能

跨部門整合

AI 專案成功落地不僅是技術部署，更是組織內部各部門協作的基礎。

部門角色：

部門	主要責任
業務與行銷	提供需求情境與績效指標、根據模型輸出進行策略應用
客服與營運	回收實際互動案例與異常反應、持續優化模型
法務與風險	資料隱私、模型公平性、風險揭露審查
資訊部門	部署、權限管理、API 整合、維運支援

常態溝通與決策機制：

機制	內容
定期 AI 專案工作小組	跨部門同步進度

機制	內容
共用績效指標	AI 影響 KPI
快速協調通道	模型調整、資料異常、需求更動

AI 納入組織治理流程：

機制	功能
AI 治理委員會 (AI Governance Committee)	統籌資源、風險審查、戰略發展
內部 AI 產品經理或協調人員	技術與部門間橋梁
跨部門培訓與教育	強化非技術人員對 AI 模型意義與限制的理解

→ 風險治理體系 見 L21203 AI 風險管理；模型訓練評估 見 L23303 模型訓練、評估與驗證（見第三冊）；演算法偏見治理 見 L23402 演算法偏見與公平性（見第三冊）

延伸補充：漂移成因、自動再訓練與部署策略

考點 (B1)

- 模型衰退的兩種漂移：
 - 資料漂移 (Data Drift)：輸入資料的分佈變了（如消費行為隨時間改變）
 - 概念漂移 (Concept Drift)：輸入與輸出之間的關聯變了（如詐騙手法不斷翻新）
- 自動再訓練 (Automated Retraining) 的失控陷阱：
 - 反饋迴路偏見 (Feedback Loop Bias, 回饋迴路偏誤)：模型的輸出會引導使用者的下一步行為，而這些被引導出來的行為又被當成新的訓練樣本回收，導致模型一輪輪「自我增強」既有傾向，原本的小偏差會被逐次放大成系統性偏差
 - 基準對照資料集 (golden set) 防線：另行維護一份人工嚴格標註、且**不參與**任何自動再訓練的固定評測集；每次自動重訓後在其上回測，指標退步即攔截該版本、轉由人工介入排查
- MLOps 三支柱：CI/CD（持續整合與部署）+ 模型版本控管 + 持續監控
- 部署層級：
 - 雲端：可縮放至零 (scale-to-zero)、算力充足
 - 邊緣 (Edge AI)：低延遲、隱私佳、省頻寬
 - 裝置端 (On-Device)：手機/IoT 上的即時推論

陷阱 (B2)

- 陷阱：「模型部署完就結束了」→ 錯！必須持續監控漂移，否則準確度會悄悄下滑
- 陷阱：再訓練管線若缺乏獨立評測把關，回饋迴路偏誤會持續累積且難以察覺——自動化程度越高，越需要基準對照資料集 (golden set) 這道防線
- 陷阱：題目強調「即時／隱私／省頻寬」→ 多半指向邊緣運算

補充比較表 (B2)

模型漂移類型

類型	原因	範例
資料漂移	輸入分佈改變	消費習慣隨環境改變
概念漂移	輸入-輸出關係改變	詐騙手法升級
標籤漂移	標籤定義或分佈改變	法規調整改變了詐騙的認定

補充精華 (B3)

- 自動再訓練失控案例：內容推薦系統一旦持續強化使用者既有偏好，接觸面會愈收愈窄、形成同溫層（過濾氣泡）；定期以基準對照資料集 (golden set) 回測，是判斷模型是否已偏離健康狀態的關鍵把關點。
- 模型漂移應對流程（標準五步）：監控指標退化 → 判斷屬於哪一類漂移 → 補充新資料或重新訓練 → 在基準對照資料集 (golden set) 上驗證新版本是否達標 → 通過後才部署上線。

延伸補充：MLOps、即時與批次部署

考點 (B1)

- **MLOps** (Machine Learning Operations, 機器學習維運) = 建立自動化、可重複、可監控的流程, 管理整個 ML 生命週期
- **兩種部署型態**:
 1. **即時預測 (Real-time)** — 請求一來就立刻回應, 如電商即時推薦
 2. **批次預測 (Batch)** — 累積到一定時間一次處理 (如銀行於離峰時段一次計算所有客戶的信用風險)
- **比傳統軟體更複雜的三個變動源**:
 1. 程式碼
 2. 模型
 3. 資料 (最關鍵的變動源)
- **模型衰退 (Model Decay / Drift) 的兩大成因**:
 1. **概念漂移 (Concept Drift)**: 預測目標的「定義」本身改變 (如詐騙手法演進、垃圾郵件樣態改變)
 2. **資料漂移 (Data Drift)**: 目標沒變, 但「使用者行為」改變 (如環境變遷使購物行為大幅改變)
- **三步維運計畫**:
 1. **持續監控** — 即時追蹤模型健康指標
 2. **觸發機制** — 指標越過警戒線 → 自動啟動再訓練
 3. **版本控制** — 每個模型版本都有可追溯的紀錄, 必要時可快速回滾

補充比較表 (B2: 概念漂移 vs 資料漂移)

漂移類型	變動主體	案例
概念漂移 (Concept Drift)	預測目標的定義變了	詐騙集團發明新手法、垃圾郵件型態演進
資料漂移 (Data Drift)	使用者行為變了	環境變遷使購物的時間、地點、品類全面改變

補充精華 (B3)

- **沒有部署就沒有價值**: 再強的模型若始終停留在實驗階段、無法上線服務, 對業務的實際貢獻就是零。
- **MLOps 的定位**: 把從資料進來到模型上線的整套流程標準化、自動化。
- **模型衰退實例**: 某模型上線首月準確率約 95%, 數月後一路下滑, 原因在於「模型內建的舊世界認知, 跟不上持續變化的真實世界」。

【中級真題與解析 (114 年第二梯次)】

本節對應 **9 題** 官方真題 (114 年第二梯次中級 AI 應用規劃師), 每題含 4 選項詳細解析、核心考點、易混淆對比。

第 13 題 (114-2-1-Q13)

題幹: 下列何者為 Kubernetes 在 AI 模型部署與運行中的核心功能?

選項:

- (A) 自動化管理模型的訓練流程與參數調校
- (B) 管理與協調模型服務的部署、擴展與運行環境
- (C) 提供 AI 模型的資料儲存與版本控管功能
- (D) 負責深度學習推論的 GPU 加速運算

正確答案: B

詳細解析:

- **✓ (B) 正確**: Kubernetes (K8s) 是容器編排平台 (Container Orchestration), 核心功能是管理容器化服務的部署、擴展、運行環境: 自動部署 Pod、滾動更新、彈性伸縮 (HPA、VPA)、服務發現 (Service)、負載平衡、自我修復。AI 模型服務 (如 TensorFlow Serving、KServe) 部署在 K8s 上享受這些能力。
- **× (A) 錯誤**: 模型訓練流程管理是 MLflow、Kubeflow Pipelines、Airflow 等 MLOps 工具職責, K8s 是底層執行平台, 不直接管理訓練流程或自動調參。

- × (C) 錯誤：資料儲存與版本控管是 DVC、MLflow Model Registry、S3/Artifactory 等專屬工具的職責,K8s 不負責此功能。
- × (D) 錯誤：GPU 加速運算是 CUDA / cuDNN / TensorRT 等底層運算庫的職責,K8s 透過 Device Plugin 提供 GPU resource 但本身不執行運算。

核心考點：Kubernetes 在 AI 部署中的容器編排角色。

易混淆對比：K8s (部署 / 編排) vs Kubeflow (K8s 上的 MLOps) vs MLflow (實驗追蹤 / Model Registry) vs Docker (容器執行) vs CUDA (GPU 運算)。

對應章節：L21302 AI 技術系統集成與部署

第 15 題 (114-2-1-Q15)

題幹：在企業導入的 MLOps (Machine Learning Operations) 流程中,Model Registry 最常用於哪一個階段?

選項：

- (A) 用於設定運算資源與執行環境以確保訓練穩定
- (B) 用於建立可重複使用的資料與特徵版本
- (C) 用於集中管理模型版本、訓練紀錄與部署狀態
- (D) 用於追蹤模型上線後的表現與漂移情況

正確答案：C

詳細解析：

- ✓ (C) 正確：**Model Registry (模型登錄中心)** 是 MLOps 核心組件,集中管理模型版本 (**Versioning**)、訓練紀錄 (**Lineage**)、部署狀態 (**Staging / Production / Archived**)。MLflow Model Registry、AWS SageMaker Model Registry、Vertex AI Model Registry 都是典型實作。讓團隊知道「哪個版本上線、誰負責、效能如何」。
- × (A) 錯誤：「運算資源與執行環境設定」是 **Kubernetes / Docker / Terraform** 等基礎設施工具的職責,非 Model Registry。
- × (B) 錯誤：「資料與特徵版本」是 **Feature Store (如 Feast、Tecton) + DVC** 的職責,管的是「資料 / 特徵」而非「模型」。
- × (D) 錯誤：「模型上線後表現與漂移追蹤」是 **Monitoring 工具 (如 Evidently、Arize、WhyLabs)** 的職責,不是 Model Registry 的核心功能 (雖有部分整合)。

核心考點：Model Registry 在 MLOps 中的版本與部署狀態管理角色。

易混淆對比：Model Registry (模型版本) vs Feature Store (特徵版本) vs Experiment Tracking (實驗紀錄) vs Monitoring (線上監控)。

對應章節：L21302 AI 技術系統集成與部署

第 22 題 (114-2-1-Q22)

題幹：某電商平台開發的顧客流失預測模型在上線數月後,預測準確率明顯下降。專案團隊懷疑顧客行為模式改變,導致模型輸入特徵的分佈與原始訓練資料不同,出現典型的資料漂移 (Data Drift) 問題。為了偵測並確認資料分佈是否發生變化,下列哪一種作法最合適?

選項：

- (A) 定期重新訓練模型以應对外部變化
- (B) 提升模型複雜度以捕捉更多資料變異性
- (C) 增加測試資料量以提高評估準確度
- (D) 計算輸入特徵分佈間的 KL 散度 (KL Divergence)

正確答案：D

詳細解析：

- ✓ (D) 正確：KL 散度 (Kullback-Leibler Divergence) $= D_{KL}(P \parallel Q) = \sum P(x) \log \frac{P(x)}{Q(x)}$, 衡量兩個分佈差異, 是偵測資料漂移的標準統計指標。比較「原訓練分佈 P」與「新資料分佈 Q」的 KL 散度, 值越大表示漂移越嚴重。其他類似指標：PSI (Population Stability Index)、JS Divergence、Wasserstein 距離。
- × (A) 錯誤：「定期重訓練」是應對策略 (mitigation), 不是「偵測」方法。題目問「偵測並確認分佈變化」→ 必須先量化分佈差異。
- × (B) 錯誤：提升模型複雜度只會加劇過擬合, 無法偵測也無法解決資料漂移。
- × (C) 錯誤：增加測試資料量只能讓評估更穩定, 不能偵測分佈是否變化。

核心考點：KL 散度作為資料漂移偵測的標準指標。

易混淆對比：KL Divergence (不對稱) vs JS Divergence (對稱) vs PSI (業界常用) vs Wasserstein (最佳傳輸距離) vs KS Test (單變數)。

對應章節：L21302 AI 技術系統集成與部署

第 30 題 (114-2-1-Q30)

題幹：某銀行計劃將 AI 詐欺偵測模組整合至核心交易系統, 主管機關要求全流程必須符合金融監管對「不可否認性 (Non-repudiation)」的資訊安全規範, 以確保日後能進行法務追蹤與稽核。下列哪一項措施最能確保此要求的落實?

選項：

- (A) 為每筆 AI 模型推論記錄其輸入與輸出結果的加密雜湊值 (Hash), 並簽署數位簽章以確保不可竄改性
- (B) 優化模型效能以降低平均推論延遲至 100ms 以下, 提升使用者體驗
- (C) 增加主機備援數量, 以確保系統在故障時持續可用
- (D) 將模型推論請求導入負載平衡器, 避免單點壅塞導致服務延遲

正確答案：A

詳細解析：

- ✓ (A) 正確：不可否認性 (Non-repudiation) 屬 CIA 三要素及其延伸特性 (Non-repudiation 不可否認性、Authenticity 真實性) 之一, 核心是「事後無法否認自己做過」。實作上靠 Hash (雜湊驗證資料完整性) + Digital Signature (數位簽章驗證來源), 確保每筆 AI 推論的輸入輸出可被驗證、不可竄改、可法務追溯。
- × (B) 錯誤：推論延遲屬於 效能/體驗指標, 與資安「不可否認性」無關。
- × (C) 錯誤：主機備援是 可用性 (Availability) 指標, 與「不可否認性」無關。
- × (D) 錯誤：負載平衡器解決壅塞, 屬於 效能/可用性 議題, 不解決「不可否認性」。

核心考點：不可否認性與 Hash + 數位簽章的對應。

易混淆對比：資安五要素 (下方以助記寫法「CIA-NAA」標示, 非業界標準縮寫)：機密性 (Confidentiality, 加密) / 完整性 (Integrity, Hash) / 可用性 (Availability, 備援) / 不可否認性 (Non-repudiation, 數位簽章) / 認證性 (Authenticity, 憑證)。

對應章節：L21302 AI 技術系統集成與部署

第 31 題 (114-2-1-Q31)

題幹：某 AI 服務系統每次推論請求需約 1 秒完成, 且必須支撐高達 10,000 次請求每秒 (RPS) 的流量。為確保系統具備高可用性且能穩定應付流量峰值, 下列哪一種架構方案最為合適?

選項：

- (A) 依賴單台超高效能伺服器進行垂直擴展, 提升硬體規格
- (B) 採用容器化部署並水平擴展服務實例, 結合自動彈性伸縮機制 (Auto Scaling)
- (C) 限制最大併發連線數, 以避免系統過載
- (D) 增加批次處理大小, 一次同時處理上千筆請求

正確答案：B

詳細解析：

- ✓ (B) 正確：10,000 RPS × 1 秒 = 10,000 個併發，必須以水平擴展 (Horizontal Scaling) 處理。容器化 (Docker) + Kubernetes Auto Scaling (HPA) 是業界標準解：服務實例可依負載自動增減，流量峰值時擴展更多 Pod，流量低時節省成本。同時提供高可用性 (單一 Pod 失敗自動補上)。
- × (A) 錯誤：垂直擴展 (Vertical Scaling) 有物理上限 (單機 CPU/RAM 不可能無限提升)，且單點故障風險高，無法達到「高可用性」目標。10,000 RPS 單機很難處理。
- × (C) 錯誤：限制併發連線只是**保護措施**，不能應付流量峰值 (超過限制的請求會被拒絕，UX 差)。
- × (D) 錯誤：批次處理增加延遲 (要等湊滿一批)，違反「即時推論 1 秒完成」的需求，且不解決總吞吐量問題。

核心考點：高 RPS 場景的水平擴展 + Auto Scaling 架構。

易混淆對比：水平擴展 (Horizontal, 加機器, 可無限) vs 垂直擴展 (Vertical, 加規格, 有上限)；HPA (Pod 數) vs VPA (Pod 規格) vs Cluster Autoscaler (Node 數)。

對應章節：L21302 AI 技術系統集成與部署

第 32 題 (114-2-1-Q32)

題幹：某企業已將 AI 模型部署於生產環境，為確保系統持續穩定運作，並能提前偵測模型效能可能衰退，技術團隊希望透過監控指標進行預警。下列哪一項監控指標最具預測效力，能提早發現模型效能下滑風險？

選項：

- (A) 系統 CPU 與記憶體使用率波動幅度
- (B) 模型推論結果的置信度 (Confidence) 分佈變化趨勢
- (C) API 平均回應時間與延遲百分位數變化
- (D) 輸入特徵與訓練資料分布差異的 PSI (Population Stability Index) 指數

正確答案：D

詳細解析：

- ✓ (D) 正確：PSI (Population Stability Index) 是金融與工業界最廣泛使用的資料漂移偵測指標： $PSI = \sum (P_i - Q_i) \times \ln(P_i / Q_i)$ 。經驗閾值：PSI < 0.1 穩定 / 0.1~0.25 輕微漂移 / >0.25 嚴重漂移。最具預測效力，因為「輸入特徵漂移」是「模型效能下降」的領先指標 (Leading Indicator)，可在效能下滑前就觸發警報。
- △ (B) 部分正確：置信度分佈變化也能反映模型異常，但屬於「輸出端」指標，通常落後於 PSI (先有輸入漂移、再有輸出異常)。
- × (A) 錯誤：CPU / RAM 是**基礎設施指標**，反映「系統健康」，不反映「模型效能」。
- × (C) 錯誤：API 回應時間反映「服務延遲」，與「模型預測準確度」無直接關聯。

核心考點：PSI 作為資料漂移的領先指標。

易混淆對比：領先指標 (PSI/KL Divergence, 輸入漂移) vs 落後指標 (Confidence、Accuracy, 輸出異常) vs 基礎設施指標 (CPU/RAM, 系統健康) vs SLA 指標 (延遲、可用性)。

對應章節：L21302 AI 技術系統集成與部署

第 37 題 (114-2-1-Q37)

題幹：某公司正在訓練一個大型語音合成模型，開發團隊使用多台 GPU 進行訓練，但經常出現 GPU 記憶體不足問題。由於模型架構已固定且無法更換硬體，團隊希望在維持模型效能與收斂品質的前提下，下列哪一種方法最有效降低單張 GPU 的記憶體壓力？

選項：

- (A) 減少訓練資料量以降低記憶體使用
- (B) 採用較小的批次大小 (Batch Size) 並搭配資料分片 (Data Sharding) 分散訓練負載
- (C) 增加學習率 (Learning Rate) 以加快收斂速度
- (D) 改用測試資料集 (Test Set) 進行部分訓練以節省空間

正確答案：B

詳細解析：

- ✓ (B) 正確：降低 GPU 記憶體壓力的標準方法：(1) 減小 Batch Size (線性減少記憶體佔用)；(2) Data Sharding (資料分片), 跨多 GPU 分散資料負載 (如 Distributed Data Parallel, DDP)。其他補強：Gradient Accumulation (小 batch + 累積梯度模擬大 batch) \Mixed Precision (FP16) \Gradient Checkpointing。
- × (A) 錯誤：減少訓練資料量會犧牲模型效能 (題目要求「維持模型效能」), 且不是針對 GPU 記憶體壓力的本質解法。
- × (C) 錯誤：增加學習率與記憶體無關, 且過大學習率會破壞收斂品質 (題目要求「維持收斂品質」)。
- × (D) 錯誤：用測試集做訓練是嚴重的資料洩漏 (Data Leakage), 違反 ML 基本原則。

核心考點：GPU 記憶體不足的標準應對：小 batch + 分片。

易混淆對比：Batch Size 減小 (記憶體線性減) vs Gradient Accumulation (模擬大 batch) vs Data Parallel (資料分片) vs Model Parallel (模型分片) vs Mixed Precision (FP16, 半精度)。

對應章節：L21302 AI 技術系統集成與部署

第 46 題 (114-2-1-Q46)

題幹：某企業的 AI 模型已部署於線上服務環境中, 用於即時預測顧客流失機率。近期團隊注意到模型預測準確率逐漸下降, 但系統運作正常且未出現錯誤訊息。經分析發現, 近期輸入資料的分布與模型訓練資料相比出現顯著偏移。若要在 MLOps 流程中主動偵測並預警此類問題, 最應採用下列哪項措施?

選項：

- (A) 建立即時的資料漂移 (Data Drift) 與概念漂移 (Concept Drift) 監測機制
- (B) 將模型轉換為量化版本以降低延遲
- (C) 增加模型超參數調整次數以強化適應性
- (D) 使用固定隨機種子 (Random Seed) 確保訓練穩定

正確答案：A

詳細解析：

- ✓ (A) 正確：MLOps 監控核心是「資料漂移 + 概念漂移」雙重偵測：
 - 資料漂移 (Data Drift)： $P(X)$ 改變 (輸入分佈變化)
 - 概念漂移 (Concept Drift)： $P(Y|X)$ 改變 (輸入到輸出的對應關係變化)
 - 建立即時監控 (如 Evidently AI、Arize、WhyLabs) 可在指標越線時自動告警。
- × (B) 錯誤：量化 (Quantization) 降低延遲與記憶體使用, 不解決資料漂移, 反而可能因精度下降使預測更差。
- × (C) 錯誤：超參數調整是「離線訓練」階段的事, 不解決「線上漂移」。
- × (D) 錯誤：固定隨機種子確保訓練可重現, 與「線上漂移偵測」完全無關。

核心考點：MLOps 中的雙重漂移監控 (Data Drift + Concept Drift)。

易混淆對比：Data Drift ($P(X)$ 變, 輸入分佈) vs Concept Drift ($P(Y|X)$ 變, 標籤關係) vs Label Drift ($P(Y)$ 變, 類別比例) vs Covariate Shift (同 Data Drift)。

對應章節：L21302 AI 技術系統集成與部署

第 47 題 (114-2-1-Q47)

題幹：某金融科技公司導入多任務學習架構, 讓單一 Transformer 模型同時執行 OCR (Optical Character Recognition) 後的文檔分類以及命名實體辨識 (Named Entity Recognition, NER) 任務, 以協助自動歸檔與抽取關鍵金融資訊。在部署初期, 團隊發現當模型的 NER 準確率 (Accuracy) 提升時, 文檔分類準確率反而下降。若模型架構正確且資料品質良好, 下列哪一項最可能是造成此現象的原因?

選項：

- (A) 模型架構無法同時支援文字分類與序列標註任務 (Sequence Labeling)
- (B) 文檔分類任務不需要語意化表徵 (Contextualized Representation)
- (C) 損失函數 (Loss Function) 未進行權重平衡, 導致任務間競爭
- (D) 所使用的 BERT 模型無法支援多任務輸出頭 (Multi-Head Outputs)

正確答案：C

詳細解析：

- ✓ (C) 正確：多任務學習 (Multi-task Learning, MTL) 的經典挑戰是「任務間競爭 (Task Interference / Negative Transfer)」：總損失 $\mathcal{L} = \lambda_1 \mathcal{L}_{NER} + \lambda_2 \mathcal{L}_{Cls}$ ，若 λ 未平衡，模型會「偏向」損失梯度大的任務，另一任務表現下降。解法：動態權重平衡 (GradNorm、Uncertainty Weighting) 或 Pareto MTL。
- × (A) 錯誤：Transformer 天然支援多任務輸出 (分類用 [CLS] token, 序列標註用 token-level output)，架構不是問題。
- × (B) 錯誤：文檔分類確實需要語意化表徵 (context vector)，這是 BERT 的核心優勢，描述錯誤。
- × (D) 錯誤：BERT 可以輕鬆加多輸出頭 (一個分類頭 + 一個 token classification 頭)，架構完全支援。

核心考點：多任務學習的損失權重平衡 (Task Interference)。

易混淆對比：MTL Loss Balancing (GradNorm / Uncertainty Weighting / Pareto MTL) vs Multi-Head Output (架構) vs Negative Transfer (任務干擾)。

對應章節：L21302 AI 技術系統集成與部署

延伸補充：微服務、容器化與 CI/CD**考點 (B1)**

- 【考點】微服務架構 (Microservices) = 把應用程式拆成一組鬆散耦合的服務，各服務可獨立部署。
- 【考點】單體式架構 vs 微服務：單體把所有功能綁在一起；微服務則將功能切成各自獨立、分工明確的服務。
- 【考點】Docker 容器技術的主要優點 = 讓部署平台與執行環境保持一致 (解決「在我電腦上跑得起來」的問題)。
- 【考點】Kubernetes (K8s) = 大規模容器調度平台，可管理成千上萬個容器 (高頻考點)。
- 【考點】MLOps 流程：資料準備 → 模型訓練 → 部署上線 → 持續監控 (隨環境變化重新學習更新)。
- 【考點】CI/CD (Continuous Integration / Continuous Deployment，持續整合 / 持續部署)：
 - CI = 每當有新程式碼／模型提交，自動跑完整品質檢查
 - CD = CI 通過後自動打包並送上正式環境
- 【考點】Model Registry (模型登錄中心) = MLOps 的高頻必考重點。

陷阱 (B2)

- 【判別】Docker 考點核心 = 環境一致性與可攜性；K8s 考點核心 = 調度與擴縮。
- 【陷阱】別把資料漂移與模型漂移搞混 (冷飲銷量預測漂移案例見 L21203)。

補充精華 (B3)

- 容器化的核心價值：將模型與其相依環境 (函式庫、設定、執行環境) 封裝為單一映像，跨機器部署行為可重現。
- Docker 與 Kubernetes 的分工：Docker 負責把應用打包成容器，Kubernetes 負責大規模調度與管理這些容器。
- 環境變遷致模型失效的例子：COVID-19 疫情使消費與出行模式驟變，大量需求預測模型在 2020 年集體失準 (公開報導甚多) —— 屬概念漂移的典型，凸顯 MLOps 監控與重訓練的必要性。
- 正規化定義：以線性映射將數值特徵壓縮至 $[0, 1]$ 區間。
- 特徵選擇定義：依重要性評估準則，從全體特徵中保留與目標最相關的子集。

延伸補充：MLOps 自動化維運循環**考點 (B1)**

- MLOps 自動化維護循環四步驟：
 1. 效能異常警示：錯誤率超過閾值即發出警告
 2. 持續監控：追蹤輸入特徵以偵測資料漂移
 3. 自動重新訓練：效能下滑時自動更新模型
 4. 容器化部署：確保跨平台與環境一致
- 容器化技術 (如 Docker) 是高頻考點：確保模型在開發與上線環境中行為一致。
- 部署上線只是模型生命週期的中點：維運監控才是長期成本所在 —— 持續追蹤漂移，系統才能長期穩定運作。

補充精華 (B3)

- MLOps 的角色：相當於一套 24 小時全自動的維運機制，隨時監控模型狀態並在需要時自動修補。

- 部署後的隱形殺手 = 漂移：MLOps 正是對付漂移的自動化防護機制。

延伸補充：不平衡資料的指標與重抽樣

考點 (B1)

- 遇到資料不平衡的標準反應：想到用 SMOTE 處理，評估時看 F1 Score 或 Recall (絕不能只看 Accuracy)
- 「準確率陷阱」：若詐騙僅佔 1%，模型一律猜「正常」也能拿到 99% 準確率，但實際抓到 0 筆詐騙，等於無效
- 醫療例：97% 準確率可能只是假象 (若 97% 的人本來就健康，全猜沒病也有 97%)

補充精華 (B3)

- SMOTE (Synthetic Minority Over-sampling Technique, 合成少數類過採樣技術)：分析少數類別的特徵，產生逼真但不重複的合成樣本，補足少數類資料量
- 分層 K 折交叉驗證 (Stratified K-Fold)：對不平衡資料而言是「必要」而非「可選」

【中級真題與解析 (115 年第一次)】

本節對應 12 題官方真題 (115 年第一次中級 AI 應用規劃師)，每題含 4 選項詳細解析、核心考點、易混淆對比。

第 22 題 (115-1-1-Q22)

題幹：某金融科技公司計劃建立完整的 AI 開發到維運流程，希望實現「模型訓練→測試→部署→監控→再訓練」的自動化流程串接，並確保線上模型的版本可追溯。技術主管建議引入 MLOps 框架。MLOps 在此 AI 開發生命週期中的核心角色為何？

選項：

- (A) 專注於訓練資料的標註與品質控管，以提升模型訓練效果
- (B) 透過自動化模型搜尋與參數調整，降低模型開發門檻
- (C) 建立機器學習流程的自動化與版本管理機制，支援模型部署、監控與持續更新
- (D) 確保模型在部署後維持穩定效能，減少後續維運與更新需求

正確答案：C

詳細解析：

- ✓ (C) 正確：MLOps (Machine Learning Operations, 機器學習維運) 是把 DevOps 的自動化與版本控制精神延伸到 ML 生命週期：以 CI/CD/CT (Continuous Integration/Delivery/Training, 持續整合/交付/訓練) 串接「訓練→測試→部署→監控→再訓練」的自動化管線，並對「程式碼+資料+模型」三者做版本管理 (如模型註冊表 Model Registry)，確保線上模型可追溯、可重現、可回滾——與題幹「自動化流程串接+版本可追溯」兩個需求一一對應。
- × (A) 錯誤：資料標註與品質控管只是 ML 生命週期中「資料準備」的一環，是 MLOps 涵蓋的眾多環節之一，說「專注於」則以偏概全。
- × (B) 錯誤：「自動化模型搜尋與參數調整」是 AutoML (Automated Machine Learning, 自動化機器學習) 的定義——解決的是「建模自動化」；MLOps 解決的是「流程與維運自動化」，兩者是常考的對照組。
- × (D) 錯誤：陷阱在後半句——MLOps 的核心假設恰是模型上線後「會」隨資料漂移而衰退，所以才要監控與持續再訓練；「減少後續維運與更新需求」與 MLOps 「擁抱持續更新」的哲學相反。

核心考點：MLOps = ML 生命週期的自動化 + 版本管理 (程式碼/資料/模型三軌) + 持續監控與再訓練閉環；判別關鍵字 = 「流程串接」「版本可追溯」。

易混淆對比：MLOps (管流程與維運) vs AutoML (管建模自動化：特徵、模型搜尋、超參數) vs DevOps (管一般軟體交付；MLOps 額外要處理資料與模型的版本與漂移，這是 ML 特有的複雜度)。

對應章節：L21302 AI 技術系統集成與部署

第 24 題 (115-1-1-Q24)

題幹：某即時詐欺偵測系統對模型回應時間有嚴格限制，若推論延遲過高將影響交易核准流程。維運工程師在模型上線前進行延遲測試 (Latency Testing) 時，主要評估的目標為何？

選項：

- (A) 評估模型推論過程中的記憶體使用量，以確認部署資源是否足夠
- (B) 驗證模型對異常或攻擊輸入的穩定性與安全性
- (C) 評估模型在不同使用者族群上的預測結果是否一致
- (D) 評估模型從接收輸入到產生預測結果所需的回應時間是否符合系統要求

正確答案：D

詳細解析：

- ✓ (D) 正確：延遲測試（Latency Testing，延遲測試）的定義即量測「從接收輸入到產生預測輸出」的端到端回應時間，並驗證其是否符合系統的 SLA（Service Level Agreement，服務水準協議）要求。實務上除了平均值，更會關注尾端延遲百分位數（如 P95/P99），因為即時交易場景中少數慢請求就足以阻塞核准流程——題幹「回應時間有嚴格限制」直接對應此定義。
- × (A) 錯誤：記憶體使用量屬於資源使用測試／容量規劃（Capacity Planning）的範疇，與「時間」維度的延遲測試不同軸。
- × (B) 錯誤：對異常或對抗性輸入的穩定性屬於強韌性測試（Robustness Testing）與安全測試（如對抗樣本攻擊評估）的目標。
- × (C) 錯誤：不同族群上預測結果的一致性是公平性測試（Fairness Testing）的目標，屬於負責任 AI 的評估面向。

核心考點：模型上線前各類非功能性測試的分工——延遲測試量「回應時間」；判別方式是把測試名稱直接對應到它量測的維度（時間／資源／強韌／公平）。

易混淆對比：延遲測試（單一請求的回應時間）vs 負載測試（Load Testing：高併發流量下的吞吐量與延遲變化）vs 壓力測試（Stress Testing：找出系統崩潰極限）——三者常混考；延遲是「一次多快」，負載是「同時多少人時還多快」，壓力是「加到多少會垮」。

對應章節：L21302 AI 技術系統集成與部署

第 40 題 (115-1-1-Q40)

題幹：某智慧製造公司在產線上部署工業相機進行即時外觀瑕疵檢測，原先將影像傳至雲端進行 AI 推論，但因網路延遲與連線不穩導致系統無法滿足即時需求（需低於 200ms）。工程師因此改為將模型部署於產線端的邊緣裝置後，但仍未達系統需求。在不更換硬體設備的前提下，下列哪一組技術最能有效降低推論延遲，同時維持合理準確率？

選項：

- (A) 減少訓練資料的使用數量，並重新訓練模型以提升推論效率
- (B) 使用批次推論（Batch Inference）處理多張影像以提升計算效率
- (C) 採用模型集成（Model Ensemble），透過多模型投票提升準確率
- (D) 將模型由 FP32 量化為 INT8，並進行推論加速優化

正確答案：D

詳細解析：

- ✓ (D) 正確：量化（Quantization）把模型權重與運算從 FP32（32 位元浮點數）降為 INT8（8 位元整數）：記憶體佔用減為 1/4、整數運算吞吐大增（多數邊緣晶片對 INT8 有專用加速單元），再配合推論引擎優化（如 TensorRT、ONNX Runtime 的運算子融合），可在**不換硬體**下把延遲大幅壓低，而量化後準確率通常僅小幅下降（訓練後量化 PTQ 或量化感知訓練 QAT 可將損失控制在 1% 內）——完全命中「降延遲＋維持合理準確率＋不換硬體」三個條件。
- × (A) 錯誤：訓練資料量影響的是**訓練時間與模型品質，與推論延遲無關**——推論速度取決於模型結構與運算精度，不取決於當初用多少資料訓練；減資料只會傷準確率，一無所得。
- × (B) 錯誤：批次推論以「湊滿一批再一起算」換取吞吐量（Throughput），但**單筆延遲（Latency）反而增加**（要等批次湊齊）；產線即時檢測是逐件、低延遲場景，批次化方向相反。這是「吞吐 vs 延遲」的經典陷阱。
- × (C) 錯誤：模型集成要跑**多個模型**再投票，推論計算量成倍增加、延遲惡化——它是用算力換準確率的技術，與「降低延遲」的目標背道而馳。

核心考點：邊緣推論加速工具箱＝模型壓縮三劍客：量化 (Quantization, 降精度) / 剪枝 (Pruning, 刪冗餘連結) / 知識蒸餾 (Knowledge Distillation, 大模型教小模型) + 推論引擎優化。「不換硬體 + 壓延遲 + 準確率可接受」→首選 INT8 量化。

易混淆對比：延遲 (Latency, 單筆請求耗時, 即時系統的硬指標) vs 吞吐量 (Throughput, 單位時間處理量, 批次場景指標)——批次推論提升後者、犧牲前者; PTQ (Post-Training Quantization, 訓練後量化: 快速方便、精度損失稍大) vs QAT (Quantization-Aware Training, 量化感知訓練: 訓練中模擬量化、精度保持最佳但需重訓)。

對應章節：L21302 AI 技術系統集成與部署

第 41 題 (115-1-1-Q41)

題幹：某 AI 影像辨識平台以單一 GPU 伺服器提供多租戶推論服務，系統長期觀察到 GPU 使用率約維持在 60% 左右，且在執行過程中可觀察到 GPU kernel 之間存在明顯閒置間隔，單次推論多以小批次方式執行。然而，在尖峰時段時，請求延遲會出現明顯波動甚至突增。同時，CPU 與記憶體資源使用率均未達瓶頸，且系統團隊已排除硬體、網路與請求併發控制異常。在此情境下，請判斷最可能造成問題的原因為何？

選項：

- (A) GPU 排程策略與批次大小設定不當，導致 GPU 運算單元未被有效利用
- (B) 請求併發控制機制不佳，導致多個請求同時搶占 GPU Context 資源造成延遲
- (C) GPU 硬體效能不足，無法支撐推論負載
- (D) 模型未進行量化優化，導致推論計算成本過高

正確答案：A

詳細解析：

- ✓ (A) **正確：**這是一題「讀懂監控證據」的診斷題，題幹每條線索都指向排程／批次問題：(1)「GPU 使用率僅 60%+kernel 之間明顯閒置間隔」＝GPU 有算力沒被餵飽，工作提交存在空窗；(2)「單次推論多以小批次執行」＝每次 kernel 啟動的固定開銷 (Launch Overhead) 攤提不掉、平行度低，運算單元大量閒置；(3) 尖峰時請求排隊，但 GPU 明明還有 40% 餘裕→問題不在容量而在**排程效率**。對症解法是動態批次處理 (Dynamic Batching, 如 Triton Inference Server 把短時間內的多個請求自動併批) 與更佳的 GPU 排程策略，把閒置間隔填滿。
- × (B) **錯誤：**題幹最後一句明文「已排除……請求併發控制異常」——此選項直接與給定條件矛盾；且 Context 搶占的典型症狀是 GPU 使用率飆高伴隨切換開銷，與「60%+閒置間隔」的觀察不符。
- × (C) **錯誤：**硬體不足的症狀應是 GPU 長期滿載 (接近 100%) 仍供不應求；現況 60% 使用率+kernel 閒置說明算力**過剩未用滿**，且題幹已排除硬體異常。
- × (D) **錯誤：**未量化會使**每次推論的計算時間變長** (GPU 忙碌時間拉長、使用率偏高)，但無法解釋「kernel 之間的閒置間隔」——空隙是排程餵料問題，不是單次計算太重的問題。

核心考點：GPU 推論服務效能診斷：低使用率+kernel 閒置+小批次＝排程與批次策略問題 (解法：動態批次、併流 CUDA Streams、MPS/MIG 分割)；高使用率滿載＝容量問題 (解法：擴容、量化)。先看使用率型態再定位瓶頸層。

易混淆對比：「GPU 使用率低而延遲高」(排程/餵料瓶頸，本題) vs 「GPU 使用率高而延遲高」(容量/模型計算瓶頸，才輪到量化與擴容)；靜態批次 (等固定批量) vs 動態批次 (時間窗內自動併批，兼顧延遲與利用率)。情境題技巧：題幹「已排除 X」的選項直接刪。

對應章節：L21302 AI 技術系統集成與部署

第 42 題 (115-1-1-Q42)

題幹：某保險公司將理賠金額預測模型正式部署上線，MLOps 團隊設計監控機制。三個月後模型整體均方根誤差 (RMSE) 無明顯變化，但業務單位反映高額理賠案件的預測誤差明顯增加。經分析，高額理賠案件僅佔約 5% 的樣本比例，且未被監控機制及時發現。請問最可能的設計缺陷為何？

選項：

- (A) 監控頻率不足，應由每日批次監控改為即時串流監控

- (B) 高額理賠案件屬於長尾分布，難以透過監控指標偵測，因此無法透過監控機制發現問題
- (C) RMSE 無法有效反映高額誤差，應改以平均絕對誤差 (MAE) 作為主要監控指標
- (D) 僅監控整體 RMSE，未針對不同理賠金額區間進行分群監控

正確答案：D

詳細解析：

- ✓ (D) 正確：問題的結構是：高額案件僅佔 5%，其誤差惡化被 95% 表現正常的一般案件平均稀釋——整體 RMSE (Root Mean Square Error, 均方根誤差) 因此「無明顯變化」，監控看不到警訊。這是「聚合指標掩蓋子群體劣化」的經典缺陷，解法是分群監控 (Sliced / Segmented Monitoring)：依理賠金額區間 (或地區、通路等業務維度) 分別追蹤各區段的誤差指標，任何子群體劣化都能獨立觸發告警。這也是 MLOps 監控設計的核心原則：重要子群體要有自己的指標切片。
- × (A) 錯誤：監控頻率 (每日 vs 即時) 解決的是「多快發現」；本題的問題是「指標根本照不出來」——就算改成即時串流，看的仍是被稀釋的整體 RMSE，三個月後依然無感。維度診斷錯誤。
- × (B) 錯誤：「無法透過監控機制發現」是投降式的錯誤結論——長尾／少數子群體完全可以監控，方法正是 (D) 的分群切片；此選項把「目前設計沒照到」偷換成「本質上照不到」。
- × (C) 錯誤：方向恰好相反——RMSE 因平方項反而更放大誤差的權重，對高額誤差比 MAE (Mean Absolute Error, 平均絕對誤差) 更敏感；換成 MAE 只會更遲鈍。且不論 RMSE 或 MAE，只要是「整體」聚合指標，5% 子群的劣化都會被稀釋，換指標不解決結構問題。

核心考點：模型監控設計原則：整體聚合指標會掩蓋少數重要子群體的劣化→須依業務關鍵維度做分群 (切片) 監控。判別線索：「整體指標沒動 + 某子群體變差 + 該子群佔比小」= 聚合稀釋問題。

易混淆對比：RMSE (平方懲罰、對大誤差更敏感、受離群值影響大) vs MAE (線性懲罰、穩健但對大誤差鈍感)——本題陷阱是讓你以為換指標就好；監控頻率 (時間軸：多快發現) vs 監控粒度 (群體軸：照不照得到)——兩個獨立設計維度，本題缺陷在粒度。

對應章節：L21302 AI 技術系統集成與部署

第 43 題 (115-1-1-Q43)

題幹：某電商平台的演算法工程師開發了一個新版商品推薦模型，在離線 A/B 測試中，新模型的各項評估指標 (AUC、NDCG@10) 均顯著優於現行線上模型。然而，離線測試無法完全反映真實使用者的互動行為 (點擊、購買、停留時間)。在正式全面上線前，若希望在可控制風險下量化真實業務指標，應採用下列何種線上驗證策略？

選項：

- (A) 影子模式 (Shadow Mode)：新舊模型同時產生預測，但僅顯示舊模型結果，於後端比較輸出差異
- (B) 回測 (Backtesting)：使用歷史日誌模擬模型表現作為上線依據
- (C) 金絲雀發布 (Canary Release)：將 1-5% 使用者流量導向新模型，量測 CTR、CVR 等指標並逐步擴量
- (D) 負載測試 (Load Testing)：於測試環境進行高流量壓力測試後直接全面上線

正確答案：C

詳細解析：

- ✓ (C) 正確：題幹的雙重要求是解題鑰匙：(1)「量化真實業務指標」(點擊、購買等真實互動) = 新模型的結果必須實際呈現給部分使用者，才會產生真實的 CTR (Click-Through Rate, 點擊率)、CVR (Conversion Rate, 轉換率)；(2)「可控制風險」= 先只導 1-5% 流量，若指標異常僅影響小部分使用者、可立即回滾，驗證通過再逐步擴量。金絲雀發布 (Canary Release, 名稱源自礦坑金絲雀預警) 同時滿足兩者，是推薦系統上線驗證的標準策略。
- × (A) 錯誤：影子模式雖零風險 (使用者只看到舊模型結果)，但正因新模型的推薦從未呈現給使用者，無法產生任何真實互動——量不到 CTR/CVR 等業務指標，只能比較輸出差異與系統穩定性。它是金絲雀之前的驗證階段，不滿足題幹「量化真實業務指標」的要求。
- × (B) 錯誤：回測用歷史日誌離線模擬，本質仍是離線評估——歷史資料是舊模型策略下收集的 (存在曝光偏差 Exposure Bias)，無法反映使用者對「新推薦」的真實反應；題幹已明說離線測試不足，回測沒有跨出這個限制。

- × (D) 錯誤：負載測試驗證的是**系統效能**（能扛多少 QPS），與推薦品質、業務指標無關；「壓測後直接全面上線」更是跳過風險控制、與題意背道而馳。

核心考點：線上驗證策略選型：要「真實業務指標」→必須真流量曝光；要「風險可控」→小比例漸進。兩者交集＝金絲雀發布。典型演進鏈：離線評估→影子模式（驗穩定性）→金絲雀（驗業務指標）→全量。

易混淆對比：影子模式（真流量、假曝光——不影響使用者也量不到互動指標）vs 金絲雀發布（真流量、真曝光、小比例）vs A/B 測試（真曝光、統計嚴謹的對照實驗，流量比例通常更大、跑更久以取得顯著性）vs 藍綠部署（Blue-Green：全量瞬切、雙環境待命，主打快速回滾而非漸進驗證）。

對應章節：L21302 AI 技術系統集成與部署

第 44 題 (115-1-1-Q44)

題幹：某 MLOps 工程師正在設計 AI 模型的推論服務 API，需要處理使用者上傳的高解析度影像（平均 5MB）進行即時分類。在 RESTful API 設計時，選擇 HTTP 請求方法與資料傳輸格式的最佳實踐為何？

選項：

- (A) 使用 HTTP GET 方法，將影像資料 Base64 編碼後附加於 URL Query String 中
- (B) 採用 HTTP POST 請求，將影像資料以 multipart/form-data 或 application/octet-stream 傳輸於 Request Body
- (C) 使用 HTTP PUT 方法，透過 Content-Type: application/xml 傳遞影像資料
- (D) 要求客戶端下載模型於本地推論，僅回傳分類結果

正確答案：B

詳細解析：

- ✓ (B) 正確：兩個設計維度都對：(1) **HTTP 方法**——POST 語意為「提交資料給伺服器處理」，正符合「上傳影像請求推論」；且推論請求非冪等 (Idempotent) 資源建立，POST 是 REST 慣例下的正確動詞。(2) **傳輸格式**——大型二進位資料應放在 Request Body：multipart/form-data（表單式檔案上傳，可夾帶其他欄位）或 application/octet-stream（原始二進位串流）都是標準做法，5MB 影像可完整、高效傳輸，必要時還能搭配串流上傳。
- × (A) 錯誤：三重致命傷——(1) URL 長度實務上限僅約 2KB~8KB（伺服器／代理各有限制），5MB 影像 Base64 後約 6.7MB，遠遠超標；(2) Base64 編碼本身膨脹約 33% 資料量；(3) GET 語意是「讀取資源」且 URL 會進入伺服器日誌、代理快取，把大量資料塞 Query String 違反 REST 語意也有安全疑慮。
- × (C) 錯誤：PUT 語意是「建立或完整替換指定 URI 的資源」（冪等操作），與「提交推論請求」語意不符；且 application/xml 是文字格式，塞二進位影像需 Base64 包裝、既膨脹又低效，XML 更非影像傳輸慣例。
- × (D) 錯誤：「客戶端下載模型本地推論」直接推翻了「設計推論服務 API」的前提——模型下發到客戶端有智財外洩風險、版本管理災難、且客戶端未必有算力；答非所問。

核心考點：推論 API 設計兩原則：大型二進位上傳＝POST + Request Body (multipart/form-data 或 octet-stream)；GET + Query String 只適合小型、可快取的讀取參數。

易混淆對比：GET（讀取、參數在 URL、可快取、有長度限制）vs POST（提交處理、資料在 Body、無實務大小限制）vs PUT（冪等地建立/替換指定資源）；multipart/form-data（多欄位混合上傳，瀏覽器表單原生）vs application/octet-stream（純二進位串流，程式間傳輸簡潔）vs Base64-in-JSON（方便但膨脹 33%，僅適合小圖）。

對應章節：L21302 AI 技術系統集成與部署

第 45 題 (115-1-1-Q45)

題幹：某 AI 平台整合多個外部 AI 微服務（語音辨識 API、NLP 分析 API、知識圖譜查詢服務），在高峰期間某外部服務偶發延遲或逾時 (Timeout)，導致請求鏈路壅塞，最終造成平台級服務中斷 (Cascading Failure)。為從架構層面預防此類連鎖故障，最有效的設計模式為何？

選項：

- (A) 將所有外部 API 呼叫改為同步串行處理，並取消逾時限制，確保每個請求皆完成後再繼續
- (B) 為外部服務導入斷路器模式 (Circuit Breaker)，在異常時暫停呼叫並提供替代回應

- (C) 擴充各微服務的執行緒池 (Thread Pool) 上限，以提升併發處理能力
- (D) 停用服務健康檢查，減少不必要的額外負載

正確答案：B

詳細解析：

- ✓ (B) 正確：連鎖故障 (Cascading Failure) 的機轉：某外部服務變慢→呼叫端的執行緒／連線被逾時等待佔住→資源耗盡→呼叫端自己也癱瘓→故障沿呼叫鏈向上蔓延。斷路器模式 (Circuit Breaker，仿電路保險絲) 正是對症解藥：監測對某服務的失敗率，超過閾值即「跳開」(Open 狀態)——後續請求**快速失敗 (Fail Fast)** 不再等待，改走替代回應 (Fallback，如快取結果、降級功能)，避免資源被拖垮；經過冷卻期進入半開 (Half-Open) 狀態試探性放行少量請求，成功則恢復 (Closed)。三態機制讓故障被隔離在單一依賴，不再擴散成平台級中斷。
- × (A) 錯誤：反教材等級的錯誤——**取消逾時限制**讓執行緒可以被慢服務無限期佔住，資源耗盡更快；同步串行更使任何一環卡住就全鏈停擺，是「加速連鎖故障」的做法。
- × (C) 錯誤：擴大執行緒池只是把「被慢服務佔住的資源」上限調高——請求持續湧入慢服務時，更大的池只意味著**更多執行緒被卡住**、記憶體壓力更大，故障規模反而擴大；治標且反效果。
- × (D) 錯誤：健康檢查是及早發現異常實例並將其移出負載平衡的防線；停用它等於拆掉故障偵測雷達，異常服務會持續收到流量，連鎖故障更難阻斷。

核心考點：微服務韌性 (Resilience) 設計模式：斷路器 = 「快速失敗 + 降級回應 + 自動恢復試探」三合一，是防連鎖故障的架構級標準解。判別線索：「外部依賴逾時→鏈路壅塞→平台級中斷」固定對應 Circuit Breaker。

易混淆對比：斷路器 (失敗率超閾值即停止呼叫、給 Fallback) vs 重試 (Retry：暫時性錯誤時再試，但對已過載的服務盲目重試會火上加油，需搭配指數退避) vs 艙壁隔離 (Bulkhead：為不同依賴劃分獨立資源池，限制災損範圍) vs 限流 (Rate Limiting：控制進入流量)——四者常組合使用 (如 Resilience4j)，本題問「預防連鎖故障最有效」= 斷路器。

對應章節：L21302 AI 技術系統集成與部署

第 46 題 (115-1-1-Q46)

題幹：某醫院計劃建立混合雲 AI 平台：使用公有雲 GPU 叢集進行 CT 影像模型訓練，但基於 HIPAA (Health Insurance Portability and Accountability Act) 法規要求，患者影像原始資料不得離開醫院院內環境。下列何者最符合「利用公有雲算力訓練模型」與「不傳輸原始患者資料」雙重限制的技術方案？

選項：

- (A) 將患者影像資料以 AES-256 加密後上傳至公有雲，並於雲端解密後進行模型訓練
- (B) 在院內部署同態加密 (Homomorphic Encryption) 模組，對推論請求進行加密處理
- (C) 採用聯邦學習 (Federated Learning) 於院內訓練模型，僅傳送模型更新至雲端聚合，原始資料不外流
- (D) 建立專線 VPN 連接醫院與雲端，以網路層安全保護資料傳輸

正確答案：C

詳細解析：

- ✓ (C) 正確：聯邦學習 (Federated Learning, FL) 的核心思想是「**資料不動、模型動**」：訓練在資料所在地 (院內) 就地進行，只把模型更新 (梯度或權重差分) 上傳到中央伺服器 (雲端) 做聚合 (如 FedAvg 演算法)，再把聚合後的全域模型發回。原始患者影像自始至終不離開院內，同時借用雲端做聚合協調——是唯一同時滿足「原始資料不外流」與「利用雲端」雙重限制的選項。(嚴格說本題架構中主要算力在院端、雲端擔任聚合，這是命題上「利用公有雲」的寬鬆解讀，但其餘三項都直接違反資料不外流限制，C 為最佳解。)
- × (A) 錯誤：加密上傳後「**於雲端解密**」= 原始資料以明文形式存在於院外環境——資料實質上已離開醫院管控，直接違反「原始資料不得離開院內」的法規限制；傳輸加密不等於資料不外流。
- × (B) 錯誤：答非所問——題目要解決的是**訓練階段**的資料問題，此選項卻處理「**推論請求**」的加密；且同態加密 (在密文上直接運算) 目前用於深度模型訓練的計算開銷極大 (數千倍以上)，實務上不可行，選項也未說明訓練資料如何處理。

- × (D) 錯誤：VPN 專線只保護「傳輸過程」不被竊聽（網路層安全），資料仍然被傳到了雲端——「安全地傳出去」依舊是傳出去，違反資料駐留（Data Residency）要求；混淆了「傳輸安全」與「資料不外流」兩個不同層次的概念。

核心考點：隱私保護機器學習（Privacy-Preserving ML）選型：法規要求「原始資料不得離開場域」→聯邦學習（資料不動、只傳模型更新）。判別關鍵：任何形式的「資料上傳」（加密與否、VPN 與否）都違反資料駐留限制。

易混淆對比：聯邦學習（資料留原地、傳模型更新；殘餘風險是梯度反推攻擊，可加差分隱私 Differential Privacy 或安全聚合 Secure Aggregation 強化）vs 同態加密（密文上運算、理論最強但算力代價極高）vs 傳輸加密／VPN（只防竊聽、資料仍外流）vs 資料去識別化（De-identification：移除可識別欄位後可外傳，但影像去識別化困難且有再識別風險）。

對應章節：L21302 AI 技術系統集成與部署

第 47 題 (115-1-1-Q47)

題幹：某電商平台將新的推薦模型部署至線上系統，為降低風險，團隊採用漸進式部署策略（Phased Rollout），先將新模型流量從 5% 逐步提升至 100%。在部署初期，團隊發現轉換率（Conversion Rate）略有提升，但在流量提升至 30% 時，系統延遲（Latency）明顯上升，且部分使用者體驗變差。請問在此情境下，最適當的下一步策略為何？

選項：

- (A) 立即將新模型全面部署至 100%，以觀察整體效果並評估系統表現變化
- (B) 還原（Rollback）至舊模型並停止新模型測試流程，以確保系統穩定與使用者體驗品質
- (C) 維持目前 30% 流量並持續觀察，即使延遲問題存在也暫不進行調整
- (D) 暫停流量提升，針對延遲問題進行效能分析與優化後再繼續部署

正確答案：D

詳細解析：

- ✓ (D) 正確：情境的兩面訊號要並重：**業務指標為正**（轉換率提升＝模型本身有價值）、**系統指標為負**（30% 流量時延遲上升＝效能瓶頸浮現，可能是新模型計算較重、資源配置不足或快取失效）。漸進式部署的設計初衷正是「在小規模就發現問題、就地處置」：暫停擴量（凍結在風險可控的現狀）→ 效能分析定位瓶頸（Profiling）→ 優化（擴資源、量化、快取）→ 驗證後再續推。既不放棄有效益的新模型，也不讓延遲問題擴大，是風險與收益的最佳平衡。
- × (A) 錯誤：延遲問題在 30% 流量就已顯現，推到 100% 只會讓瓶頸被 3 倍以上的流量徹底擊穿——「上線觀察整體效果」是把生產環境全體使用者當試驗品，違反漸進部署的根本精神。
- × (B) 錯誤：過度反應。Rollback 是**業務指標劣化或系統瀕臨故障**時的手段；本題轉換率是提升的、延遲問題屬於可分析可優化的工程問題，直接放棄整個測試流程等於丟掉已驗證的業務收益。（若延遲已造成嚴重事故，先回滾再優化才合理——題幹描述是「明顯上升、部分體驗變差」，尚在可暫停處理的範圍。）
- × (C) 錯誤：「明知有問題卻暫不調整」是放任 30% 使用者持續受延遲之害，問題不會自己消失；漸進式部署的每一階段都要求「發現異常即處置」，消極觀察不是策略。

核心考點：漸進式部署的決策規則：業務指標正向＋系統指標異常→**暫停擴量、修復後再續**；業務指標劣化或系統嚴重故障→回滾。兩訊號分開評估，不因單一負訊號全盤放棄、也不帶病擴量。

易混淆對比：暫停修復（問題可工程解決、業務效益仍在）vs 回滾 Rollback（模型本身有害或系統事故等級）vs 繼續擴量（各項指標全綠才允許）——三個動作對應三種訊號組合；Phased Rollout／Canary（漸進驗證）vs 藍綠部署（全量瞬切、靠雙環境快速回滾）。

對應章節：L21302 AI 技術系統集成與部署

第 48 題 (115-1-1-Q48)

題幹：某銀行的信用卡風控模型已穩定上線一年，主要用於偵測盜刷交易提醒。近期在未對模型或特徵工程進行調整的情況下，系統觀察到深夜電商交易的核准率明顯上升，盜刷攔截率下降，但模型 AUC 幾乎維持不變，且交易金額、地區與裝置等特徵分布未出現明顯變化。進一步分析發現，疫情後使用者行為改變，使原本被視為高風險的交易型態逐漸轉為一般消費。下列何者最能敘述此現象的原因？

選項：

- (A) 資料漂移 (Data Drift)，因輸入特徵分布發生變化
- (B) 訓練與服務偏差 (Training-Serving Skew)，因線上與離線特徵處理不一致
- (C) 概念漂移 (Concept Drift)，因特徵與目標標籤之間的關聯性改變
- (D) 決策閾值偏移 (Threshold Shift)，因分類門檻設定不當導致預測偏差

正確答案：C

詳細解析：

- ✓ (C) 正確：題幹給了教科書級的判別線索組合：(1)「交易金額、地區與裝置等特徵分布未出現明顯變化」→ 輸入分佈 $P(X)$ 沒變，排除資料漂移；(2)「疫情後使用者行為改變，原本高風險的交易型態轉為一般消費」→ 同樣的特徵組合 (深夜電商交易)，其對應的標籤意義變了——即條件分佈 $P(Y|X)$ 改變，這正是概念漂移 (Concept Drift) 的定義：「 X 與 Y 之間的關聯 (概念) 隨時間改變」。模型學的是疫情前的舊概念，對新世界的判讀自然失準。
- × (A) 錯誤：資料漂移 (Data Drift / Covariate Shift) 指輸入特徵分佈 $P(X)$ 改變而 $X \rightarrow Y$ 關係不變；題幹明文「特徵分布未出現明顯變化」，直接排除——這是命題者刻意放的對照線索。
- × (B) 錯誤：Training-Serving Skew 是「離線訓練與線上服務的特徵處理管線不一致」造成的工程缺陷 (例如訓練用批次統計、上線用即時計算導致特徵值不同)——它從部署第一天就會存在，不會「穩定上線一年後」才因使用者行為改變而出現；且題幹說未調整特徵工程。
- × (D) 錯誤：決策閾值一年來沒人動過 (未對模型調整)，閾值本身沒有「偏移」；表面上看起來像閾值不再合適，但那是 $P(Y|X)$ 變化的結果而非原因——根因是概念變了，調閾值只是治標。

核心考點：漂移判別公式—— $P(X)$ 變、 $P(Y|X)$ 不變 = 資料漂移； $P(X)$ 不變、 $P(Y|X)$ 變 = 概念漂移；兩者皆變 = 混合漂移。題幹「特徵分布沒變 + 行為意義變了」= 純概念漂移。附帶：概念漂移常無法從輸入端監控發現 (PSI 照不出來)，需靠標籤回收後的實際成效指標 (如攔截率) 偵測——這正是題中「AUC 沒變但攔截率下降」延遲顯現的原因。

易混淆對比：資料漂移 (輸入分佈變，PSI / KS 檢定可偵測) vs 概念漂移 ($X \rightarrow Y$ 關聯變，需標籤回收才能確認，偵測延遲) vs Training-Serving Skew (工程管線不一致，上線即存在) vs 標籤漂移 (Label Drift, $P(Y)$ 邊際分佈變)。

對應章節：L21302 AI 技術系統集成與部署

第 49 題 (115-1-1-Q49)

題幹：某零售電商平台已建立模型監控儀表板，用於追蹤線上推薦模型的運作狀態與效能表現。維運工程師需判斷哪些指標屬於「線上持續監控 (Continuous Monitoring)」的範疇。下列指標中，哪一項最不適合在即時監控系統中追蹤，而應改由離線實驗追蹤系統管理？

選項：

- (A) 訓練實驗中每個 Epoch 的學習率 (Learning Rate) 變化曲線與超參數 (Hyperparameter) 設定軌跡
- (B) 線上推論 API 的 P50/P95/P99 回應延遲與每日請求量 (RPS) 趨勢
- (C) 輸入特徵分佈的族群穩定性指數 (Population Stability Index, PSI)，偵測資料漂移
- (D) 模型預測結果分佈 (如 CTR) 與定期回收的人工標註結果之對比

正確答案：A

詳細解析：

- ✓ (A) 正確 (最不适合線上監控)：學習率曲線與超參數軌跡是訓練階段的實驗產物——它們在模型訓練完成的那一刻就固定了，上線後不會再變化，對「線上運作狀態」沒有任何持續監控價值。這類資訊屬於實驗追蹤 (Experiment Tracking) 系統的守備範圍 (如 MLflow、Weights & Biases)，用途是實驗重現、模型比較與血緣追溯 (Lineage)，本質是離線管理，不該佔用即時監控儀表板。
- × (B) 錯誤 (適合線上監控)：P50/P95/P99 延遲 (中位數 / 95 / 99 百分位延遲，尾端延遲反映最差使用者體驗) 與 RPS 是服務健康度核心指標，隨每一筆線上請求即時變動，是持續監控的最典型項目。

- × (C) 錯誤（適合線上監控）：PSI（Population Stability Index，族群穩定性指數）比較線上輸入特徵分佈與訓練基準分佈的偏移程度（經驗閾值： <0.1 穩定、 $0.1-0.25$ 需留意、 >0.25 顯著漂移），是資料漂移的線上偵測標準工具，必須持續計算才能及時告警。
- × (D) 錯誤（適合線上監控）：預測分佈與定期回收標註的對比是模型實際成效的持續驗證（處理標籤延遲問題的標準做法），屬於線上監控中「模型品質」層的常規項目——雖然標註回收有週期，但仍是對線上模型的持續追蹤，不是離線實驗管理。

核心考點：MLOps 監控範疇切分：線上持續監控＝「會隨線上流量／時間持續變化的訊號」（服務延遲、流量、資料漂移、預測品質）；實驗追蹤＝「訓練期一次性產生、訓練完即凍結的紀錄」（超參數、學習曲線、實驗版本）。判別問句：「這個指標在模型上線後還會變嗎？」不會變→離線實驗系統。

易混淆對比：模型監控（Monitoring：線上、持續、告警導向——分服務層 Latency/RPS、資料層 PSI、模型層成效對比三層）vs 實驗追蹤（Experiment Tracking：離線、版本化、重現導向）；P95/P99 尾端延遲（照顧最差體驗）vs 平均延遲（會掩蓋長尾）——監控慣用百分位而非平均。

對應章節：L21302 AI 技術系統集成與部署

考綱編碼索引

依 iPAS 官方考綱編碼順序排列（本冊收錄 L211～L213）；頁碼為內文頁碼，可對照頁尾。

L211 AI 相關技術應用	7
L21101 自然語言處理技術與應用	7
L21102 電腦視覺技術與應用	26
L21103 生成式 AI 技術與應用	37
L21104 多模態人工智慧應用	53
L212 AI 導入評估規劃	69
L21201 AI 導入評估	69
L21202 AI 導入規劃	78
L21203 AI 風險管理	87
L213 AI 技術應用與系統部署	100
L21301 數據準備與模型選擇	100
L21302 AI 技術系統集成與部署	121



唐門企鵝 DonmenKir

iPAS AI 應用規劃師・中級・第一冊 | 科目一 人工智慧技術應用與規劃



<https://DonmenKir.com>

© 2026 唐門企鵝 · 自編內容依 CC BY-NC-SA 4.0 授權

DONMENKIR